

深度学习经典论文原理总览

本文档基于《论文总览.xlsx》整理，覆盖 15 个大类、190+ 篇深度学习经典论文（含 2023-2025 最新进展）。每篇论文按「核心思想 → 关键设计 → 影响与意义」的结构讲解其原理。

目录

- 一、计算机视觉 - CNN
- 二、计算机视觉 - Transformer
- 三、生成模型
- 四、计算机视觉 - 目标检测
- 五、计算机视觉 - 对比学习
- 六、计算机视觉 - 视频理解
- 七、多模态学习
- 八、自然语言处理 - Transformer
- 九、分布式训练系统
- 十、图神经网络
- 十一、优化算法与理论
- 十二、新领域应用
- 十三、CLIP 应用生态
- 十四、综述类
- 十五、大模型时代最新进展 (2023-2025)
 - 15.1 大语言模型架构与效率
 - 15.2 推理与测试时计算
 - 15.3 对齐与高效微调
 - 15.4 多模态大模型
 - 15.5 扩散与图像生成新进展
 - 15.6 视频生成


- 15.7 3D 生成与重建
 - 15.8 具身智能与世界模型
 - 15.9 Agent 与工具使用
-

一、计算机视觉 - CNN

1. AlexNet (2012) — 深度学习热潮的奠基作

核心理念

用 GPU 训练一个 8 层卷积神经网络，在 ImageNet 大规模图像分类任务上以巨大优势击败传统手工特征方法（SIFT + SVM），证明「深度 + 大数据 + 强算力」的可行性。



关键设计

- **ReLU 激活**：相比 Sigmoid/Tanh，ReLU 缓解梯度消失，训练速度提升数倍。
- **Dropout**：全连接层随机失活，抑制过拟合。
- **数据增强**：随机裁剪、水平翻转、PCA 颜色扰动。
- **重叠池化**：池化窗口步长小于窗口尺寸，略微提升精度。
- **双 GPU 并行**：将网络拆分到两块 GTX 580 上训练（受限于当时显存）。

影响与意义

- ImageNet Top-5 错误率从 26.2% 降至 15.3%，引爆深度学习浪潮。
- 确立了「卷积 + 池化 + 全连接」的 CNN 基本范式。


2. VGG (2014) — 使用 3×3 卷积构造更深的网络

核心理念

用

堆叠的小卷积核 (3×3)

替代大卷积核，在保持感受野的同时减少参数量、增加非线性，从而构建更深的网络（16/19 层）。



关键设计

- **感受野等价性**：两个 3×3 卷积堆叠的感受野等于一个 5×5 ；三个 3×3 等于一个 7×7 。
- **参数量对比**：假设通道数均为 C ，
- 3 个 3×3 卷积： $3 \times (3^2 C^2) = 27C^2$
- 1 个 7×7 卷积： $7^2 C^2 = 49C^2$
- 参数量减少约 45%，且引入 3 次非线性激活。
- **统一架构**：整个网络只用 3×3 卷积、 2×2 最大池化，结构极其规整。
- **训练技巧**：先训练浅层（11 层）再迁移初始化深层网络。

影响与意义

- 证明**深度**是提升性能的关键因素。
- 其规整结构成为后续网络设计的参考基准，VGG 特征至今仍用于风格迁移、感知损失等任务。


3. GoogLeNet / Inception (2014) — 使用并行架构构造更深的网络

核心思想

不纠结于「用多大卷积核」，而是

在同一层并行使用多种尺寸的卷积核

(1×1 、 3×3 、 5×5 、池化)，让网络自己选择最合适的尺度。



关键设计

- **Inception 模块**：并行分支 + 通道拼接 (concat)。
- **1×1 卷积降维**：在 3×3、5×5 卷积前先用 1×1 卷积压缩通道，控制计算量。这是「瓶颈结构」的雏形。
- **全局平均池化 (GAP)**：替代最后的全连接层，大幅减少参数量 (AlexNet 全连接层占 90% 参数量)。
- **辅助分类器**：在中间层加两个辅助 softmax 分支，缓解深层梯度消失。
- **22 层深度**，参数量仅 5M (AlexNet 的 1/12)。


影响与意义

- 提出「多尺度并行」与「瓶颈降维」两大设计思想。
 - 1×1 卷积成为后续所有高效网络的标准组件。
-

4. ResNet (2015) — 构建深层网络都要有的残差连接

核心理念

解决深层网络的**退化问题**（degradation）：56 层网络比 20 层网络训练误差更高，这不是过拟合而是优化困难。ResNet 引入**残差连接**，让网络学习「残差映射」而非「完整映射」。



关键设计

- **残差块**： $y = F(x) + x$ ，其中 $F(x)$ 是残差函数。
- **恒等映射的易学性**：如果某层不需要变换，网络只需将 $F(x)$ 学成 0，比直接学 $F(x) = x$ 容易得多。
- **梯度高速公路**：反向传播时梯度可通过恒等路径直接回传，缓解梯度消失。

$$\frac{\partial \mathcal{L}}{\partial x} = \frac{\partial \mathcal{L}}{\partial y} \left(1 + \frac{\partial F}{\partial x} \right)$$

其中「1」保证了梯度不会消失。

- **瓶颈块 (Bottleneck)**： $1 \times 1 \rightarrow 3 \times 3 \rightarrow 1 \times 1$ ，用于 ResNet-50/101/152。
- **Batch Normalization**：配合残差连接稳定训练。

影响与意义

- 成功训练 152 层甚至 1000+ 层网络，ImageNet Top-5 错误率降至 3.57%。
 - 残差连接成为**所有现代深度网络（含 Transformer）的标配**。
-


5. MobileNet (2017) — 适合终端设备的小 CNN

核心思想

用

深度可分离卷积 (Depthwise Separable Convolution)

替代标准卷积，大幅降低计算量和参数量，使 CNN 能部署在手机等移动设备上。



关键设计

- 深度可分离卷积 = 深度卷积 + 逐点卷积
- 深度卷积：每个通道独立做空间卷积（不混合通道）
- 逐点卷积： 1×1 卷积负责通道混合
- 计算量对比（输入 $D_F \times D_F \times M$ ，输出 $D_F \times D_F \times N$ ，卷积核 D_K ）：

- 标准卷积: $D_K^2 \cdot M \cdot N \cdot D_F^2$
- 深度可分离卷积: $D_K^2 \cdot M \cdot D_F^2 + M \cdot N \cdot D_F^2$
- 压缩比: $\frac{1}{N} + \frac{1}{D_K^2}$, 当 $D_K = 3$ 、 $N \gg 9$ 时约为 **1/8 ~ 1/9**
- **宽度乘子** α 与 **分辨率乘子** ρ : 可调超参, 在精度与速度间权衡。
- **ReLU6**: 限制激活值上限为 6, 适合低精度定点运算。


影响与意义

- 移动端视觉的基石, 后续 MobileNetV2 (倒残差 + 线性瓶颈)、V3 (NAS 搜索) 持续演进。
-

6. EfficientNet (2019) — 通过架构搜索得到的 CNN

核心思想

提出**复合缩放 (Compound Scaling)**: 网络的深度、宽度、分辨率三个维度应**按固定比例协同放大**, 而非单独放大某一维。



关键设计

- 复合缩放公式：

$$\begin{aligned} \text{depth : } d &= \alpha^\phi, \quad \text{width : } w = \beta^\phi, \quad \text{resolution : } r = \gamma^\phi \\ \text{s.t. } &\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2, \quad \alpha, \beta, \gamma \geq 1 \end{aligned}$$

其中 ϕ 是用户指定的缩放系数, α, β, γ 由小规模网格搜索确定。

- **约束来源**：卷积计算量正比于 $d \cdot w^2 \cdot r^2$, 故约束乘积为 2 使 FLOPs 约翻倍。
- **MBConv 基础块**：来自 MobileNetV2 的倒残差结构 + SE 注意力。
- **NAS 搜索**：用 MnasNet 式多目标搜索得到 EfficientNet-B0 基线。


影响与意义

- ImageNet 上以 1/5 的参数量达到当时 SOTA。
- 复合缩放思想被广泛借鉴（如 EfficientNetV2、ConvNeXt 的缩放策略）。

7. Non-deep Networks (2021) — 让不深的网络也能在 ImageNet 刷到 SOTA

核心思想

挑战「深度是性能关键」的共识：**并行子网络 (Parallel subnetworks)** 可以在不增加深度的情况下提升表示能力。提出 **ParNet**，仅 12 层深度即可达到 ResNet-152 级别的精度。



关键设计

- **并行分支结构**：多个浅层分支并行处理，最后融合，等效于增加「宽度 + 多尺度」。
- **RepVGG 式重参数化**：训练时多分支，推理时融合为单路，不增加推理成本。
- **深度-宽度权衡**：论文指出低深度网络在**延迟敏感场景**（如边缘设备、需要低延迟的实时系统）有独特优势。
- **SSE (Skip-Squeeze-Excitation)**：分支间的特征交互模块。

影响与意义

- 证明深度不是唯一路径，为低延迟部署提供新思路。
 - 对「深度 vs 宽度」的理论理解有补充价值。
-

二、计算机视觉 - Transformer

1. ViT (2020) — Transformer 杀入 CV 界

核心理念

将图像切成固定大小的**图像块 (patch)**，线性嵌入后当作「词序列」送入标准 Transformer 编码器。证明**纯 Transformer 无需卷积**也能在图像分类上达到 SOTA，但需要大规模数据预训练。



关键设计

- **Patch Embedding**: 图像 $H \times W \times C$ 切成 $N = HW/P^2$ 个 $P \times P$ 块，展平后线性投影到 D 维。
- **位置编码**: 可学习的一维位置嵌入（实验表明 2D-aware 编码无显著提升）。
- **Class Token**: 借鉴 BERT，在序列前加一个可学习的 `[CLS]` token，其输出用于分类。
- **归纳偏置的缺失**: ViT 缺少 CNN 的平移不变性和局部性先验，因此**必须在大数据集 (JFT-300M) 上预训练**才能超越 CNN；在中小数据集 (ImageNet) 上不如 ResNet。
- **混合架构**: 也可用 CNN 特征图替代原始 patch 作为输入。


影响与意义


- 开启 Vision Transformer 时代，后续 Swin、MAE、DINO 等均基于此。
- 揭示「大数据 + 大模型 + 少归纳偏置」的 Scaling Law 在视觉同样成立。

2. Swin Transformer (2021) — 多层次的 Vision Transformer

核心理念

ViT 的 patch 尺寸固定，导致**单尺度、高计算量**（自注意力是序列长度的平方）。Swin 引入**层次化结构**和**移动窗口注意力**，使 Transformer 适配密集预测任务（检测、分割）。





关键设计

- **层次化特征图**：像 CNN 一样分 4 个 stage，逐级下采样 2 倍，产生多尺度特征。
- **窗口注意力 (W-MSA)**：将注意力限制在 $M \times M$ 局部窗口内，复杂度从 $O(N^2)$ 降到 $O(N)$ 。
- **移动窗口 (SW-MSA)**：相邻层窗口偏移 $M/2$ ，实现跨窗口信息交互。
- **Shift 的高效实现**：用 `torch.roll` + 掩码，避免实际像素搬移。
- **相对位置偏置**：在注意力中加入相对位置编码，提升性能。

影响与意义

- 成为检测/分割的通用骨干网络 (Swin-T/S/B/L)。
- 2021 年 ICCV 最佳论文 (Marr Prize)。


3. MLP-Mixer (2021) — 使用 MLP 替换 self-attention

核心思想

既然 Transformer 的核心是「token 混合 + 通道混合」，那么

用纯 MLP 也能做到

。提出完全不含卷积和注意力的架构，仅用 MLP 在 patch 间和通道间交替混合。



关键设计

- 两种 MLP 交替：
- **Token-mixing MLP**：在 patch 维度（跨空间位置）做 MLP，权重共享。
- **Channel-mixing MLP**：在通道维度做 MLP。
- **结构**：Patch Embedding → [Token-MLP → Channel-MLP] × N → GAP → 分类头
- **计算复杂度**：token-mixing 是 $O(N^2)$ (N 为 patch 数)，与注意力相同，但无 softmax。
- **性能**：在大数据预训练下接近 ViT，但小数据下明显更差。

影响与意义

- 引发「注意力是否必要」的讨论，催生 gMLP、ConvMixer 等一批工作。
- 说明架构的归纳偏置与数据规模强相关。

4. MAE (2021) — BERT 的 CV 版

核心思想

将 BERT 的**掩码语言建模**迁移到视觉：随机遮挡 75% 的图像块，让模型**重建被遮挡的像素**。由于图像信息冗余度高，需要极高掩码率才能形成有意义的自监督任务。



关键设计

- **非对称编码器-解码器：**
- **编码器：**只处理**可见的 25% patch**（计算量降至 1/4），是标准 ViT。
- **解码器：**轻量级（8 层、512 维），接收编码器输出 + 掩码 token，重建全部 patch。
- **高掩码率（75%）：**相比 BERT 的 15%，因为图像空间冗余远高于语言。
- **重建目标：**归一化后的像素值（每 patch 内做 mean/std 归一化），MSE 损失。
- **损失只算在掩码 patch 上。**

影响与意义


- 训练效率对比学习（如 BEiT、SimMIM）高 3 倍以上。
- 学到的特征在检测、分割、迁移任务上表现优异，成为视觉自监督的重要范式。

三、生成模型

1. GAN (2014) — 生成对抗网络

核心思想

用**对抗博弈**训练生成器：生成器 G 试图骗过判别器 D ，判别器 D 试图区分真假样本。二者交替优化，最终 G 学得真实数据分布。



关键设计

- **极小极大博弈目标**： $\min_G \max_D \mathbb{E}_x [\log(1 - D(G(z)))] + \mathbb{E}_z [\log D(x)]$
- **理论保证**：当 D 达到最优时， G 的优化等价于最小化 p_{data} 与 p_g 的 **Jensen-Shannon 散度**。
- **全局最优**： $p_g = p_{data}$ 时 $D \equiv 1/2$ ，达到纳什均衡。
- **无需显式密度建模**：只需从 G 采样，避免了对复杂似然的计算。

影响与意义

- 开创生成模型新范式，催生 DCGAN、WGAN、StyleGAN、CycleGAN 等大量工作。
- 训练不稳定、模式崩溃 (mode collapse) 是其固有难题。


2. DCGAN (2015) — 把 CNN 引入 GAN

核心思想

为 GAN 的生成器和判别器设计

稳定的卷积架构

，使训练可控、可复现。



关键设计

- **架构约束：**
- 用**步长卷积**替代所有池化层（判别器用 strided conv，生成器用转置卷积）。
- 生成器和判别器都使用 **Batch Normalization**。
- 移除所有全连接层（除输入/输出）。
- 生成器输出层用 **Tanh**，其余层用 **ReLU**。
- 判别器所有层用 **LeakyReLU**（斜率 0.2）。
- **潜在空间算术**： z 向量具有线性语义（如「戴眼镜的男性」-「男性」+「女性」=「戴眼镜的女性」）。
- **潜在空间插值**：平滑过渡证明 G 学到了有意义的表示。

影响与意义

- 首个稳定可训练的卷积 GAN，成为后续 GAN 的标准骨架。


3. pix2pix (2016) — 条件 GAN 做图像到图像翻译

核心思想

用

条件 GAN

解决通用的 image-to-image 翻译：给定输入图像，生成对应的输出图像（如边缘→照片、黑白→彩色、语义图→街景）。



关键设计

- **条件 GAN 目标**: $\mathcal{L}_{cGAN} = \mathbb{E}[\log(1 - D(x, G(x, z)))] + \mathbb{E}_{x,z}[\log D(x, y)]$ 判别器同时看输入 x 和输出 y , 判断「是否匹配」。
- **U-Net 生成器**: 编码器-解码器 + 跳跃连接, 保留低级细节。
- **PatchGAN 判别器**: 不判断整图真假, 而是对 $N \times N$ patch 逐块判断, 输出一个矩阵。参数量小、聚焦高频细节。
- **L1 损失**: $\mathcal{L}_{L1} = |y - G(x, z)|_1$, 保证低频正确性, 与 GAN 损失互补。
- **总损失**: $\mathcal{L} = \mathcal{L}_{cGAN} + \lambda \mathcal{L}_{L1}$ ($\lambda = 100$)。


影响与意义

- 提出通用图像翻译框架, 无需针对任务设计损失函数。
- PatchGAN 与 U-Net 组合被后续大量工作沿用。

4. SRGAN (2016) — 图片超分辨率

核心思想

传统超分用 MSE 损失, 导致结果**过度平滑、缺乏纹理**。SRGAN 引入**感知损失 + 对抗损失**, 生成视觉上更真实的高分辨率图像。



关键设计

- **感知损失 (Perceptual Loss)**：用预训练 VGG 网络的特征图计算损失，而非像素级 MSE。

$$\mathcal{L}_{VGG} = \frac{1}{W} \sum_{i,j} \|\phi_{i,j}(I^{HR}) - \phi_{i,j}(I^{LR})\|_2^2$$
- **对抗损失**：判别器区分真实 HR 图与生成图，迫使生成器产生真实纹理。
- **内容损失**： $\mathcal{L}_{content} = \mathcal{L}_{MSE} + 10^{-3} \mathcal{L}_{VGG}$
- **SRResNet 生成器**：16 个残差块 + 亚像素卷积 (PixelShuffle) 上采样。
- **评价指标**：PSNR/SSIM 略降，但 **MOS (主观评分) 显著提升**。


影响与意义

- 揭示「像素级指标」与「感知质量」的矛盾，推动感知损失成为超分/增强的标准工具。

5. WGAN (2017) — 训练更加容易

核心思想

原始 GAN 用 JS 散度衡量分布差异，当两个分布**不重叠**时梯度消失。WGAN 改用 **Wasserstein 距离 (推土机距离)**，即使分布不重叠也能提供有意义的梯度。



关键设计

- **Wasserstein 距离:**

$$W(p_r, p_g) = \inf_{\gamma \sim \Pi(p_r, p_g)} \mathbb{E}_{(x, y) \sim \gamma} [|x - y|]$$

- **Kantorovich-Rubinstein 对偶:** $W(p_r, p_g) = \sup_{\{f | L \leq 1\}} \mathbb{E}[f(x)] - \mathbb{E}[f(y)]$ 要求 f 满足 $|f(x) - f(y)| \leq \|x - y\|$ **1-Lipschitz 连续。**
- **权重裁剪 (Weight Clipping):** 将判别器 (改称 Critic) 权重限制在 $[-c, c]$, 强制 Lipschitz 约束。
- **去掉判别器最后的 Sigmoid:** 输出实数而非概率。
- **损失函数:** $\mathcal{L}_D = \mathbb{E}[f(G(z))] - \mathbb{E}[f(x)]$, $\mathcal{L}_G = -\mathbb{E}[f(G(z))]$ 。
- **理论优势:** W 距离连续且几乎处处可导, 训练更稳定, 且损失值可反映生成质量。


影响与意义

- 解决 GAN 训练不稳定与模式崩溃问题。
- 后续 WGAN-GP 用梯度惩罚替代权重裁剪, 效果更好。

6. CycleGAN (2017) — 无配对图像翻译

核心思想

pix2pix 需要**成对**训练数据 (同一场景的输入输出)。CycleGAN 用**循环一致性损失**实现**无配对**翻译 (如 马 ↔ 斑马、夏天 ↔ 冬天)。



关键设计

- **两个生成器 + 两个判别器:** $G: X \rightarrow Y$, $F: Y \rightarrow X$ 。
- **循环一致性损失:** $\mathcal{L}_{cyc} = \mathbb{E}[|F(G(x)) - x|_1] + \mathbb{E}[|G(F(y)) - y|_1]$ 即「翻译过去再翻译回来应还原」。
- **对抗损失:** G 生成的 Y 域图像要骗过 D_Y , 反之亦然。
- **总损失:** $\mathcal{L} = \mathcal{L}_{GAN} + \lambda \mathcal{L}_{cyc}$ ($\lambda = 10$) 。
- **循环一致性为何有效:** 它约束了映射的**双射性**, 防止模式崩溃 (否则 G 可以把所有 x 映射到同一个 y) 。

影响与意义

- 大幅降低图像翻译的数据门槛, 成为无监督域适应的经典方法。


7. StyleGAN (2018) — 风格驱动的生成

核心思想

借鉴风格迁移的思想, 重新设计生成器:

将随机噪声注入到每一层

, 实现「粗粒度风格 (姿态、脸型)」与「细粒度风格 (发丝、雀斑)」的解耦控制。



关键设计

- **映射网络 (Mapping Network)** : 8 层 MLP 将 z 映射到中间潜空间 $\mathcal{W}$, 解耦潜空间。
- **AdaIN (自适应实例归一化)** :

$$\text{AdaIN}(x_i, y) = y_{s,i} \frac{x_i - \mu(x_i)}{\sigma(x_i)} + y_{b,i}$$

用风格向量 y 的缩放/偏置调制特征。

- **噪声注入**: 每层加入高斯噪声, 只影响随机细节 (如发丝位置), 不影响整体结构。
- **渐进式增长 (Progressive Growing)** : 从 4×4 逐步增长到 1024×1024 。
- **风格混合 (Style Mixing)** : 训练时用两个 z 的不同层风格, 防止层间相关性。
- **解耦度量**: 提出 PPL (Perceptual Path Length) 衡量潜空间平滑度。

影响与意义

- 首次实现高质量、可控的人脸生成, FFHQ 数据集成为标准。
- 引发 deepfake 等伦理讨论。


8. StyleGAN2 (2019) — 修复伪影

核心思想

分析并修复 StyleGAN 生成图像中的

水滴状伪影 (artifacts)

，并改进训练与评价指标。



关键设计

- **伪影根因**：AdaIN 的实例归一化会「抹掉」特征中的均值信息，导致生成器用「尖峰」方式编码信息。
- **权重解调 (Weight Demodulation)**：将 AdaIN 从激活层移到**权重层**，对卷积核做归一化：
$$w'_{ijk} = s_i \cdot w_{ijk} / \sqrt{\sum_{i,k} (s_i w_{ijk})^2 + \epsilon}$$
- **移除渐进式增长**：改用**残差架构 + 跳跃连接**，训练更稳定。
- **路径长度正则化**： $\mathcal{L}_{PPL}$ 惩罚潜空间方向上的过大变化。
- **无伪影生成器**：用双线性上采样 + 卷积替代转置卷积，消除棋盘格伪影。
- **新指标 PPL / P&R**：更全面地评价生成质量与多样性。


影响与意义

- 生成质量进一步提升，成为 GAN 图像生成的巅峰之作。

9. DDPM (2020) — 扩散模型

核心思想

用**两个马尔可夫链**建模生成过程： - **前向过程**：逐步向图像加高斯噪声，直到变成纯噪声（固定，无需学习）。 - **反向过程**：学习逐步去噪，从纯噪声恢复图像。



关键设计

- 前向加噪：

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t I)$$

可重参数化为一步到位：

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I)$$

其中 $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$ 。

- 反向去噪：

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

- 简化训练目标：预测噪声 ϵ 而非均值 $\mathbb{E}[\epsilon]$ ， $\mathbb{E}[\epsilon^2] = \epsilon_\theta^2 \bar{\alpha}_t x_0 + (1 - \bar{\alpha}_t)$
- U-Net 骨干：带时间步嵌入的 U-Net 预测噪声。
- 与去噪分数匹配的等价性：预测噪声等价于学习数据分布的分数函数 $\nabla_x \log p(x)$ 。


影响与意义

- 生成质量超越 GAN，训练更稳定，无模式崩溃。
- 开启扩散模型时代（Stable Diffusion、DALL·E 2、Sora 等）。

10. Improved DDPM (2021) — 改进的 DDPM

核心思想

系统性地改进 DDPM 的训练与采样，用更少的采样步数达到更好的效果。



关键设计

- **余弦噪声调度**: $\bar{\alpha}_t = \cos^2 \left(\frac{t/T+s}{1+s} \cdot \frac{\pi}{2} \right)$, 避免线性调度在低噪声端信息破坏过快。
- **学习方差 Σ_θ** : DDPM 固定方差为 β_t , 此处让网络预测方差插值系数 v :

$$\Sigma_\theta(x_t, t) = \exp(v \log \beta_t + (1 - v) \log \tilde{\beta}_t)$$

- **混合损失**: $\mathcal{L} = \mathcal{L}_{\text{simple}} + \lambda \mathcal{L}_{\text{vlb}}$ 是变分下界。}, 其中 $\mathcal{L}_{\text{vlb}}$
- **重要性采样**: 对 $\mathcal{L}_{\text{vlb}}$ 按损失大小采样时间步, 降低梯度噪声。
- **采样加速**: 用更少的步数 (如 100 步) 即可达到 DDPM 1000 步的质量。

影响与意义

- 成为后续扩散模型的标准配置 (余弦调度、学习方差)。


11. Guided Diffusion / Diffusion Models Beat GANs (2021) — 号称超越 GAN

核心思想

通过

架构改进 + 分类器引导 (Classifier Guidance)

，首次让扩散模型在 ImageNet 上全面超越 GAN 的 FID 指标。



关键设计

- **架构改进：**
- 增加深度与宽度、增加注意力头数
- 多分辨率注意力 (32×32 、 16×16 、 8×8)
- BigGAN 残差块 + 自适应组归一化 (AdaGN)
- **分类器引导：**用预训练分类器 $p_\phi(y|x_t)$ 的梯度修正采样：

$$\hat{\mu}_\theta(x_t|y) = \mu_\theta(x_t|y) + s \cdot \Sigma_\theta(x_t|y) \nabla_{x_t} \log p_\phi(y|x_t)$$

其中 s 是引导强度。 s 越大，样本越符合类别但多样性下降（FID vs IS 权衡）。

- **无分类器引导 (Classifier-Free Guidance)：**训练时随机丢弃类别标签，采样时混合条件与无条件预测：

$$\hat{\epsilon} = \epsilon_\theta(x_t, \emptyset) + s \cdot (\epsilon_\theta(x_t, y) - \epsilon_\theta(x_t, \emptyset))$$


影响与意义

- 证明扩散模型可以超越 GAN，成为生成模型主流。
- 引导采样成为条件生成的标准技术。

12. StyleGAN3 (2021) — 无混叠的生成器

核心理想

StyleGAN2 的生成图像存在**纹理粘连 (texture sticking)** 问题：细节随图像平移而「粘」在像素网格上，而非随物体移动。根因是**混叠 (aliasing)**。StyleGAN3 从信号处理角度设计**平移等变**的生成器。



关键设计

- **混叠的根源**：上采样、下采样、非线性激活都会引入高频混叠。
- **解决方案**：
- 所有上/下采样使用**理想低通滤波器**（窗化 Sinc 滤波器）
- 卷积前做低通滤波，避免非线性产生的高频混叠
- 移除噪声注入（噪声是逐像素的，破坏等变性）
- 用**傅里叶特征**替代可学习位置编码
- **等变性度量**：EQ-T（平移等变）、EQ-R（旋转等变）。
- **结果**：EQ-T 从 StyleGAN2 的 47.4 降至 0.4，视频插值中细节随物体自然移动。

影响与意义

- 将信号处理理论引入生成模型设计，提升生成器的物理合理性。
- 对视频生成、动画等时序一致性任务意义重大。


13. DALL·E 2 (2022) — CLIP + Diffusion, 文本生成图像新高度

核心思想

用

CLIP 的联合嵌入空间

作为桥梁，将文本条件注入扩散模型，实现高质量、可控的文本到图像生成。



关键设计

- **两阶段架构**：
- **Prior (先验)**：将 CLIP 文本嵌入映射为 CLIP 图像嵌入。两种实现：
 - **自回归先验**：Transformer 逐 token 生成
 - **扩散先验**：扩散模型生成（效果更好）
- **Decoder (解码器)**：以 CLIP 图像嵌入为条件，用扩散模型生成图像（unCLIP 模型）。
- **为什么用 CLIP 嵌入而非直接文本**：CLIP 空间已对齐图文语义，且能利用大规模图文对预训练。
- **无分类器引导**：提升样本质量与文本一致性。
- **图像编辑能力**：在 CLIP 潜空间做插值/编辑，可实现变体生成、属性修改。

影响与意义

- 展示「对比学习 + 扩散模型」组合的强大威力。
- 生成质量与语义一致性大幅提升，推动 AIGC 爆发。

14. Whisper (2022) — 大规模弱监督语音识别

核心思想

用 **68 万小时** 多语言、多任务的弱监督网络音频训练一个**编码器-解码器 Transformer**，实现鲁棒的语音识别与翻译，无需微调即可跨数据集泛化。



关键设计

- **数据规模**：680,000 小时（其中 117,000 小时多语言 + 125,000 小时翻译数据）。
- **弱监督**：数据来自互联网，标注质量参差不齐，但规模弥补了噪声。
- **多任务格式**：用特殊 token 统一表示任务 `<|startoftext|><|zh|><|transcribe|><|0.00|>`
文本内容 `<|endoftext|>` 支持：转录、翻译、语言识别、时间戳预测。
- **架构**：标准 Transformer 编码器-解码器（无特殊创新）。
- **鲁棒性**：在分布外数据上零样本性能接近有监督模型。


影响与意义

- 证明「大规模弱监督 + 通用架构」在语音领域同样有效。
- 开源模型成为语音识别的事实标准。

15. Action-GPT (2022) — 用语言模型生成动作

核心思想

利用**大语言模型 (LLM)** 的常识推理能力，将自然语言描述转化为**细粒度的人体动作序列**，用于文本驱动的动作生成。



关键设计

- **LLM 作为动作规划器**：将粗粒度文本（如「一个人慢慢地站起来」）分解为细粒度动作描述。
- **动作生成器**：将细粒度描述映射为人体动作序列（如 HumanML3D 格式）。
- **语言-动作对齐**：利用 CLIP 等模型保证生成动作与文本语义一致。
- **零样本泛化**：借助 LLM 的常识，可处理训练集中未出现的动作组合。


影响与意义

- 展示 LLM 作为「跨模态规划器」的潜力。
- 推动文本驱动动画、虚拟人、机器人动作生成等应用。

16. LLaMA (2023) — 开放高效的基础语言模型

核心思想

用**公开数据集**训练一系列高效的基础语言模型（7B~65B），证明在**更多数据上训练更小的模型**可以超越更大的模型。



关键设计

- **Chinchilla 缩放律**：给定计算预算，模型大小与训练 token 数应同比缩放。LLaMA-7B 用 1T token 训练（远超 GPT-3 的 300B）。
- **架构改进**（基于 Transformer 的现代化改造）：
- **Pre-normalization**：用 RMSNorm，归一化放在子层前
- **SwiGLU 激活函数**：替代 ReLU，提升性能
- **旋转位置编码 (RoPE)**：替代绝对位置编码，支持更长上下文
- **训练效率**：65B 模型用 2048 张 A100 训练 21 天。
- **性能**：LLaMA-13B 超越 GPT-3 (175B)，65B 接近 Chinchilla-70B。

影响与意义

- 开源模型生态的引爆点（Alpaca、Vicuna、Llama 2/3 等均基于此）。
- 证明数据质量与规模比单纯堆参数更重要。


17. PaLM-E (2023) — 具身多模态语言模型

核心思想

将

视觉、语言、机器人状态

统一到一个 LLM 中，实现「具身智能」：模型能看图、理解语言、并输出机器人动作。



关键设计

- **多模态 token 化：**
 - 文本 → 标准 token
 - 图像 → ViT 编码 + 投影到 LLM 嵌入空间
 - 机器人状态（关节角度等）→ 线性投影
- 动作 → 文本形式输出
- **统一序列建模：**所有模态拼成一个序列，用自回归方式训练。
- **规模：**562B 参数（基于 PaLM）。
- **正迁移：**多任务联合训练时，视觉-语言任务与机器人任务互相促进。
- **涌现能力：**可执行多步推理、零样本泛化到新任务。

影响与意义

- 展示 LLM 作为通用「具身智能体大脑」的可行性。
- 推动 VLA (Vision-Language-Action) 模型研究（如 RT-2）。


18. HuggingGPT (2023) — 用 LLM 调度 AI 模型

核心思想

将 LLM 作为

控制器

，调用 HuggingFace 上的各种专家模型完成复杂任务。LLM 负责「任务规划 → 模型选择 → 执行 → 结果整合」。



关键设计

- **四阶段流程：**
- **任务规划：** LLM 将用户请求分解为子任务
- **模型选择：** 根据任务描述从模型库中选模型（基于下载量等指标）
- **任务执行：** 调用选定模型（如用 ViT 分类、Stable Diffusion 生成）
- **响应生成：** LLM 整合所有结果，生成最终回答
- **依赖解析：** 子任务间可能有依赖（如先检测再分割），用有向图表示。
- **资源处理：** 处理模型调用失败、超时等异常。

影响与意义

- 提出「LLM 作为操作系统」的 Agent 范式。
 - 催生大量 Agent 框架（AutoGPT、LangChain 等）。
-

四、计算机视觉 - 目标检测


1. R-CNN (2014) — Two-stage 检测的开山之作

核心思想

将目标检测转化为「

区域提议 + CNN 分类

」两步：先用选择性搜索生成候选框，再用 CNN 对每个候选框分类。



关键设计

- **四步流程：**
- **区域提议：**选择性搜索（Selective Search）生成约 2000 个候选框
- **特征提取：**每个候选框缩放到 227×227，送入 AlexNet 提取 4096 维特征
- **分类：**每个类别训练一个 SVM 分类器
- **回归：**用线性回归微调候选框位置
- **监督预训练 + 微调：**先在 ImageNet 上预训练，再在检测数据上微调。
- **mAP 提升：**VOC 2007 上从 33.7%（DPM）提升到 58.5%。


影响与意义

- 首次证明 CNN 在检测任务上的巨大潜力。
- 缺点：训练慢（多阶段）、推理慢（2000 次 CNN 前向）、存储大。

2. Fast R-CNN (2015) — 端到端单阶段训练

核心理念

解决 R-CNN 的重复计算问题：**整张图只过一次 CNN**，然后用 **RoI Pooling** 从特征图上提取每个候选框的特征。



关键设计

- **RoI Pooling**: 将任意大小的 RoI 特征图池化为固定尺寸（如 7×7 ），使全连接层可处理。
- **多任务损失**: 分类 + 边界框回归联合训练 $\mathcal{L} = \mathcal{L}_{cls} + \lambda [u \geq 1] \mathcal{L}_{loc}$ 其中 $\mathcal{L}_{loc}$ 用 **Smooth L1** 损失。
- **单阶段训练**: 除区域提议外，其余全部端到端。
- **速度提升**: 训练快 9 倍，推理快 213 倍（相比 R-CNN）。
- **SVD 加速全连接层**: 进一步提速。


影响与意义

- 奠定 two-stage 检测的标准框架。
- 瓶颈转移到区域提议（选择性搜索仍需 2 秒/图）。

3. Faster R-CNN (2015) — 引入 RPN

核心理念

用**区域提议网络（RPN）**替代选择性搜索，实现**完全端到端**的检测，且 RPN 与检测网络**共享卷积特征**。



关键设计

- **RPN 机制：**
- 在特征图上每个位置放置 k 个**锚框 (anchor)** (3 种尺度 × 3 种长宽比 = 9 个)
- 每个锚框预测 2 个分数 (前景/背景) + 4 个偏移量
- 输出约 300 个高质量候选框
- **锚框 (Anchor)**：这是检测领域的核心概念，用预设的参考框将「无限制回归」转化为「相对偏移回归」。
- **交替训练**：RPN 与 Fast R-CNN 共享卷积层，4 步交替训练。
- **损失函数**：
$$L(\{p_i\}, \{t_i\}) = \frac{1}{N_{\text{cls}}} \sum L_{\text{cls}}(p_i, p_i^*) + \lambda \frac{1}{N_{\text{reg}}} \sum p_i^* L_{\text{reg}}(t_i, t_i^*)$$
- **速度**：5 FPS (GPU)，实现实时检测。

影响与意义


- 首个真正端到端的检测框架，成为 two-stage 检测的标杆。
- 锚框机制被 SSD、YOLOv2 等广泛采用。

4. SSD (2016) — Single stage 检测

核心思想

单阶段检测

：直接在多个尺度的特征图上预测类别和框偏移，无需区域提议，速度与精度兼顾。



关键设计

- **多尺度特征图**：在 VGG 基础上添加 6 个不同尺度的特征图（38×38 到 1×1），大特征图检测小目标，小特征图检测大目标。
- **默认框 (Default Boxes)**：类似锚框，每个特征图位置放置多个不同尺度的默认框。
- **直接预测**：每个默认框预测 $(c + 4)$ 个值（ c 类分数 + 4 个偏移）。
- **数据增强**：随机裁剪、颜色扰动等。
- **难例挖掘 (Hard Negative Mining)**：按损失排序，保持正负样本 1:3 比例。
- **速度**：59 FPS (VOC2007, mAP 74.3%)。


影响与意义

- 首个能与 two-stage 精度媲美的单阶段检测器。
- 多尺度预测成为单阶段检测的标准设计。

5. YOLO (2016) — You Only Look Once

核心理念

将检测**重构为回归问题**：把图像划分为 $S \times S$ 网格，每个网格直接预测边界框和类别概率，一次前向即可完成检测。



关键设计

- **网格划分**： 7×7 网格，每个网格预测 2 个框（每个框 5 个值： $x, y, w, h, confidence$ ）+ 20 类概率。
- **输出张量**： $7 \times 7 \times (2 \times 5 + 20) = 7 \times 7 \times 30$ 。
- **损失函数**：坐标误差 + 置信度误差 + 分类误差的加权和，坐标用宽高开方（缓解大小框权重不均）。
- **优势**：
 - 极快（45 FPS，Fast YOLO 达 155 FPS）
 - 全局视野，背景误检少
 - 泛化能力强（可迁移到艺术图像）
- **劣势**：定位精度不如 two-stage，小目标与密集目标效果差。

影响与意义

- 开创单阶段检测范式，YOLO 系列成为工业界最流行的检测器。


6. Mask R-CNN (2017) — 实例分割

核心理念

在 Faster R-CNN 基础上

并行添加一个分割分支

，实现像素级实例分割，且不损失检测性能。



关键设计

- **RoI Align**: 替代 RoI Pooling，用**双线性插值**解决量化误差（RoI Pooling 两次取整导致掩码与目标错位）。
- **三支输出**: 分类 + 框回归 + 掩码（ K 个 28×28 二值掩码，每类一个）。
- **解耦掩码与分类**: 掩码分支不预测类别，只输出二值掩码，避免类间竞争。
- **损失**: $\mathcal{L} = \mathcal{L}_{cls} + \mathcal{L}_{reg} + \mathcal{L}_{mask}$
- **性能**: COCO 上实例分割 mAP 37.1%，检测 mAP 39.8%，5 FPS。


影响与意义

- 统一了检测、分割、关键点检测（加一个分支即可）。
- RoI Align 成为后续分割网络的标准组件。

7. YOLOv2 (2017) — 更好、更快、更强

核心理想

在 YOLO 基础上引入一系列改进（Batch Norm、锚框、多尺度训练），大幅提升精度与召回率。



关键设计

- **Batch Normalization**: 每层卷积后加 BN, mAP 提升 2%。
- **高分辨率分类器**: 先在 448×448 上微调分类网络, 再用于检测。
- **锚框 (Anchor Boxes)**: 用 k-means 聚类数据集得到先验框尺寸 (而非手工设计), 召回率从 81% 提升到 88%。
- **维度聚类**: 距离度量用 $d(\text{box}, \text{centroid}) = 1 - \text{IOU}$ 。
- **直接位置预测**: 用 sigmoid 约束偏移量在网格内, 训练更稳定。
- **细粒度特征 (Passthrough)**: 将浅层特征与深层特征拼接, 提升小目标检测。
- **多尺度训练**: 每 10 个 batch 换一次输入尺寸 (320~608), 使模型适应不同分辨率。
- **Darknet-19 骨干**: 19 层卷积 + 5 层池化。

影响与意义

- YOLOv2 (YOLO9000) 可检测 9000+ 类, 展示检测与分类联合训练的潜力。


8. YOLOv3 (2018) — 多尺度预测

核心思想

引入

特征金字塔 (FPN) 式的多尺度预测

和更好的骨干网络 (Darknet-53), 显著提升小目标检测能力。



关键设计

- **Darknet-53**: 借鉴 ResNet 的残差连接, 53 层卷积, 比 ResNet-152 快 2 倍且精度相当。
- **多尺度预测**: 在 3 个尺度 (13×13 、 26×26 、 52×52) 上预测, 每个尺度 3 个锚框, 共 9 个锚框 (k-means 聚类)。
- **上采样 + 拼接**: 深层特征上采样后与浅层特征拼接, 融合语义与细节。
- **分类用 Logistic**: 替代 softmax, 支持多标签分类 (一个目标可属于多类)。
- **性能**: COCO mAP 33.0% (AP50 57.9%) , 速度 51ms/图 (Titan X)。


影响与意义

- 成为工业界最广泛使用的检测器之一, YOLOv3 是「实用主义」的典范。

9. CenterNet (2019) — Anchor Free

核心思想

无锚框检测: 将目标表示为其**中心点**, 用关键点估计的方式检测目标, 无需锚框和非极大值抑制 (NMS)。



关键设计

- **中心点热力图**: 预测 C 个类别的热力图, 峰值位置即目标中心。
- **中心点偏移**: 预测亚像素级偏移, 弥补下采样量化误差。
- **尺寸回归**: 直接回归目标的宽高 (w, h)。
- **损失函数**:
- 热力图用 **Focal Loss** 变体 (惩罚中心点附近的负样本)

- 偏移和尺寸用 L1 损失
- **无需 NMS**：因为每个目标只有一个中心点，后处理只需提取局部峰值。
- **速度**：142 FPS (COCO mAP 28.1%)，精度与速度俱佳。


影响与意义

- 开创 anchor-free 检测范式，后续 FCOS、CornerNet 等跟进。
- 同一框架可扩展到 3D 检测、姿态估计、人体关键点。

10. DETR (2020) — Transformer 做检测

核心理念

用 **Transformer 编码器-解码器** 将检测建模为**集合预测**问题，彻底移除锚框和 NMS，实现真正的端到端检测。



关键设计

- **CNN 骨干 + Transformer**：CNN 提取特征图，展平后加位置编码送入 Transformer。
- **可学习的目标查询 (Object Queries)**： N 个 (如 100 个) 可学习的嵌入，每个查询输出一个目标 (类别 + 框)。
- **二分图匹配损失**：用 **匈牙利算法** 在预测与真值间做最优匹配，再计算损失：
$$\hat{\sigma} = \arg\min_{\sigma \in \mathcal{S}} \sum_i \mathcal{L}(y_i, \hat{y}_{\sigma(i)})$$
- **集合预测损失**：分类用交叉熵，框用 L1 + GloU 损失。
- **无需 NMS**：匈牙利匹配保证一对一，天然避免重复预测。
- **性能**：COCO mAP 42.0% (与 Faster R-CNN 相当)，但训练收敛慢 (500 epoch)。

影响与意义

- 首个端到端 Transformer 检测器，开启检测新范式。
- 后续 Deformable DETR、DINO-DETR 等解决收敛慢问题。

五、计算机视觉 - 对比学习


对比学习核心思想

：通过「拉近正样本对、推远负样本对」学习表征。正样本通常是同一图像的不同增强视图。

1. InstDisc (2018) — 提出实例判别和 Memory Bank

核心思想

将每个实例视为一个独立类别（instance discrimination），用对比学习训练无监督特征。提出 **Memory Bank** 存储所有样本的特征。



关键设计

- **实例判别**： N 张图 = N 个类别，目标是让每张图被正确识别为自己。
- **Memory Bank**：存储所有样本的特征向量（如 12800×128 ），每次更新当前 batch 的特征。
- **NCE 损失 (Noise Contrastive Estimation)**：将多分类问题转化为二分类（真样本 vs 噪声样本）。
- **Proximal Regularization**：约束特征平滑变化，稳定训练。
- **问题**：Memory Bank 中的特征滞后（stale），一致性差。

影响与意义

- 开创基于实例判别的无监督学习范式，MoCo 的直接前身。


2. CPC (2018) — 对比预测编码

核心思想

通过

预测未来

学习表征：给定过去的信息，预测未来的潜在表示。可用于图像、语音、文本、强化学习。



关键设计

- InfoNCE 损失：

$$\mathcal{L} = -\mathbb{E} \left[\log \frac{\exp(z_{t+k}^T W_k c_t)}{\sum_{x_j \in X} \exp(z_j^T W_k c_t)} \right]$$

其中 c_t 是上下文表示, z_{t+k} 是未来表示, X 包含 1 个正样本 + $N - 1$ 个负样本。

- **自回归编码**：用 GRU 编码上下文，预测未来 k 步的表示。
- **与互信息的关系**：InfoNCE 是互信息的下界，最小化该损失即最大化 $I(c_t; z_{t+k})$ 。
- **多领域通用**：图像（预测下/右 patch）、语音、NLP、RL 均可。

影响与意义


- 提出 InfoNCE 损失，成为对比学习的标准工具。
 - 是 wav2vec、VQ-VAE 等工作的思想源头。
-

3. InvaSpread (2019) — 一个编码器的端到端对比学习

核心思想

端到端

训练单个编码器（无需 Memory Bank），用同一 batch 内的其他样本作为负样本。



关键设计

- **不变性 + 扩散性**：同一图像的两个增强视图应相似（invariance），不同图像应远离（spread）。
- **单编码器**：与 InstDisc 的 Memory Bank 不同，直接端到端反向传播。
- **损失函数**：

$$\mathcal{L} = - \sum_i \log \frac{\exp(z_i \cdot z_{i+} / \tau)}{\sum_{j \neq i} \exp(z_i \cdot z_j / \tau)}$$

- **局限**：负样本数量受 batch size 限制（如 256），效果不如 MoCo。


影响与意义

- 证明端到端对比学习可行，为 SimCLR 铺路。

4. CMC (2019) — 多视角下的对比学习

核心思想

利用**同一场景的多个视角**（如 Lab* 颜色通道、深度、表面法向量）作为正样本对，学习视角不变的表示。



关键设计

- **多视角正样本**：同一图像的 L、a、b 通道分别编码，互为正样本。
- **InfoNCE 损失**：扩展到多视角，任意两个视角的组合都是正样本对。
- **视角选择**：实验表明 Lab* 通道效果最好（比灰度、RGB 拆分好）。
- **与 InstDisc 结合**：用 Memory Bank 存储负样本。

影响与意义

- 提出「多视角」这一对比学习的重要维度，后续被 CLIP（图文视角）等发扬光大。


5. MoCo v1 (2019) — 无监督训练效果也很好

核心思想

用

动量编码器 + 队列

解决对比学习中「负样本数量」与「特征一致性」的矛盾。



关键设计

- **动量编码器 (Momentum Encoder)** : k 编码器参数用动量更新, 保持特征一致性:

$$\theta_k \leftarrow m\theta_k + (1 - m)\theta_q, \quad m = 0.999$$

- **队列 (Queue)** : 存储最近 K 个 (如 65536) batch 的特征作为负样本, 解耦 batch size 与负样本数。
- **InfoNCE 损失**: q 与 k_+ 相似, 与队列中 K 个 k_- 不相似。
- **优势**: 负样本多 (65536)、特征一致 (动量更新)、显存友好。


影响与意义

- 无监督预训练性能接近有监督, 成为自监督学习的里程碑。
- MoCo 系列 (v2、v3) 持续演进。

6. SimCLR v1 (2020) — 简单的对比学习

核心理念

极简框架: 数据增强 + 编码器 + MLP 投影头 + NT-Xent 损失, 用**超大 batch** (4096~8192) 提供负样本。



关键设计

- **数据增强组合**：随机裁剪 + 颜色抖动是**最关键**的组合（缺一不可）。
- **投影头 (Projection Head)**：编码器后接 2 层 MLP，对比损失算在投影空间，下游任务用编码器输出。防止表示空间被对比损失「破坏」。
- **NT-Xent 损失**（归一化温度缩放交叉熵）：

$$\ell_{i,j} = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k \neq i} \exp(\text{sim}(z_i, z_k)/\tau)}$$

- **大 batch + 长训练**：batch 4096，训练 1000 epoch。
- **性能**：ImageNet 线性评估 76.5%（超越有监督 AlexNet）。


影响与意义

- 证明「简单方法 + 大算力」的威力，推动自监督学习成为主流。

7. MoCo v2 (2020) — MoCo v1 + SimCLR 的改进

核心思想

将 SimCLR 的两个关键改进（**MLP 投影头 + 更强的数据增强**）移植到 MoCo，用更小的 batch 达到超越 SimCLR 的效果。



关键设计

- **MLP 投影头**：2 层 MLP（2048 维），替代 MoCo v1 的单层线性层。
- **更强增强**：加入模糊增强（Gaussian blur）、更强的颜色抖动。
- **余弦学习率调度**。
- **性能**：batch 256 达到 71.1%（SimCLR batch 4096 为 69.3%）。


影响与意义

- 证明 MoCo 框架的高效性，小 batch 也能取得好效果。

8. SimCLR v2 (2020) — 大的自监督预训练模型很适合做半监督学习

核心理念

将 SimCLR 扩展到**更大模型**（ResNet-152 + 3× 宽度），并用于**半监督学习**，用少量标签微调即可超越有监督训练。



关键设计

- **更大模型**：ResNet-50 → ResNet-152 (3×)，深度 + 宽度同时增加。
- **更深投影头**：2 层 → 3 层 MLP。
- **记忆机制**：用教师网络的预测作为伪标签（类似 Mean Teacher）。
- **半监督流程**：
 - 无监督预训练（大模型）
 - 用 1% 或 10% 标签微调
 - 蒸馏到小模型
- **性能**：1% 标签下 Top-5 达 85.8%（有监督仅 48.4%）。


影响与意义

- 证明自监督预训练 + 少量标签是高效的学习范式。

9. BYOL (2020) — 不需要负样本的对比学习

核心理念

完全不用负样本！只用正样本对（同一图像的两个视图），通过**在线网络预测目标网络的输出**来学习。



关键设计

- **双网络结构**：
 - **在线网络 (Online)**：编码器 + 投影头 + **预测器 (Predictor)**
 - **目标网络 (Target)**：编码器 + 投影头（参数用在线网络的 EMA 更新）
- **损失函数**：在线网络的预测与目标网络输出之间的 MSE（归一化后）：

$$\mathcal{L} = |q_{\theta}(z_{\theta}) - sg(z_{\xi})|_2^2$$

其中 sg 是 stop-gradient。

- **为何不崩溃**：预测器 + EMA 目标网络的**不对称性**是关键。若去掉预测器，会表示崩溃。
- **性能**：ImageNet 线性评估 74.3% (ResNet-50) 。


影响与意义

- 挑战「负样本必要」的共识，催生 SimSiam、DINO 等一批无负样本方法。

10. SWaV (2020) — 聚类对比学习

核心思想

用**聚类**替代实例判别：将样本分配到 K 个聚类原型，用**最优传输 (Sinkhorn-Knopp)** 保证聚类均衡，实现「聚类级」对比学习。



关键设计

- **聚类原型**： K 个可学习的原型向量（如 3000 个）。
- **双损失**：
- **SwAV 损失**：同一图像的两个视图，一个视图的聚类分配预测另一个视图的分配（交换预测）。
- **多裁剪 (Multi-crop)**：2 个大裁剪 + 6 个小裁剪，增加正样本对。
- **Sinkhorn-Knopp 算法**：强制每个 batch 内聚类分配均衡（避免所有样本聚到一类）。
- **无需负样本对**：聚类原型天然提供对比信号。
- **性能**：ImageNet 线性评估 75.3%，且训练更快（无需大 batch）。


影响与意义

- 提出「聚类 + 对比」的混合范式，多裁剪策略被广泛采用。

11. SimSiam (2020) — 化繁为简的孪生表征学习

核心思想

极简：不需要负样本、不需要大 batch、不需要动量编码器，只需孪生网络 + 预测器 + stop-gradient。



关键设计

- **结构**：同一编码器处理两个视图，一侧接预测器，另一侧 stop-gradient。
- **损失**： $\mathcal{L} = -\frac{1}{2} (\mathcal{D}(p_1, \text{sg}(z_2)) + \mathcal{D}(p_2, \text{sg}(z_1)))$, $\mathcal{D}$ 是余弦相似度。
- **崩溃的避免**：stop-gradient 是关键。论文用**期望最大化 (EM)** 视角解释：stop-gradient 相当于固定一侧优化另一侧。
- **消融实验**：去掉 stop-gradient 立即崩溃；去掉预测器也崩溃。
- **性能**：ImageNet 线性评估 68.1% (batch 256, 100 epoch)。


影响与意义

- 用最简结构揭示对比学习的本质，理论价值高。

12. MoCo v3 (2021) — 如何更稳定地自监督训练 ViT

核心思想

将 MoCo 框架用于 ViT，并解决 ViT 自监督训练不稳定的问题。



关键设计

- **不稳定现象**：训练中期损失突然上升，精度骤降。
- **根因分析**：ViT 的 **patch projection 层**（第一个卷积/线性层）梯度波动大。
- **解决方案**：**冻结 patch projection 层**（随机初始化后不更新），训练立即稳定。
- **对称损失**：两个视图都过在线网络（而非一正一副），提升效果。
- **性能**：ViT-B 线性评估 76.7%，ViT-L 77.6%。


影响与意义

- 为 ViT 自监督训练提供实用技巧，推动 ViT 在自监督领域应用。

13. DINO (2021) — Transformer 加自监督在视觉也很香

核心思想

自蒸馏 + 无标签：学生网络预测教师网络（EMA）的输出，用**中心化 + 锐化**避免崩溃。在 ViT 上效果极佳，且注意力图能自动分割物体。



关键设计

- **自蒸馏框架**：学生和教师结构相同，教师用 EMA 更新。
- **损失函数**：交叉熵（学生 softmax 预测教师 softmax 分布），温度不同：

$$\mathcal{L} = - \sum P_t(x) \log P_s(x)$$

教师温度 $\tau_t = 0.04$ （锐化），学生 $\tau_s = 0.1$ 。

- **中心化 (Centering)**：减去教师输出的均值，防止某一维主导。
- **锐化 (Sharpening)**：低温度使分布尖锐，防止均匀分布。
- **多裁剪策略**：2 全局 + 10 局部裁剪。
- **涌现能力**：ViT 的**自注意力图自动聚焦于语义物体**，无需分割监督即可做无监督分割。

影响与意义

- 无监督 ViT 特征质量达到新高度，催生 DINOv2。
- 揭示自监督 ViT 的注意力具有语义可解释性。


14. DINOv2 (2023) — 通用视觉特征

核心思想

用

精心策划的数据 + 改进的自监督方法

训练「通用视觉基础模型」，特征无需微调即可用于分类、分割、深度估计等任务。



关键设计

- **数据策划**：用自建 pipeline 从网络爬取 1.42 亿张高质量图像（LVD-142M），用聚类保证多样性。
- **方法改进**：
 - **DINO 损失 + iBOT 掩码图像建模损失联合训练**
 - **Sinkhorn-Knopp 中心化替代移动平均中心化**
 - **可学习的位置编码插值适应不同分辨率**
 - **短时高频训练 + 长时低频训练两阶段**
 - **模型规模**：ViT-S/B/L/g（最大 11 亿参数）。
 - **蒸馏**：将大模型蒸馏到小模型，保持性能。
 - **性能**：多数任务上超越 OpenCLIP，且无需微调。

影响与意义


- 提供「开箱即用」的视觉特征，成为视觉基础模型的重要代表。
-

六、计算机视觉 - 视频理解

1. DeepVideo (2014) — 提出 Sports-1M 数据集

核心思想

首次将深度学习系统应用于视频理解，并发布 **Sports-1M** 大规模视频数据集（100 万视频、487 类体育动作）。



关键设计

- **数据集:** 100 万 YouTube 视频，487 个体育类别，自动标注。
- **三种融合方式:**
- **单帧 (Single Frame):** 每帧独立分类，再平均
- **晚期融合 (Late Fusion):** 两个网络分别处理相隔 15 帧的图像，最后融合

- **早期融合 (Early Fusion)**：首层就拼接多帧
- **结论**：单帧 + 晚期融合效果最好，说明**运动信息未被有效利用**。
- **局限**：简单堆叠帧无法建模长时序依赖。


影响与意义

- 提供大规模视频数据集，推动视频理解研究。
- 揭示「如何建模时序」是核心难题。

2. Two-Stream (2014) — 引入光流做时序建模

核心思想

双流架构：一路处理 **RGB 单帧**（外观），一路处理**光流图**（运动），两路融合。这是神经网络首次在视频任务上超越手工特征。



关键设计

- **空间流 (Spatial Stream)**：单帧 RGB，捕捉场景与物体外观。
- **时间流 (Temporal Stream)**：堆叠的光流位移场 (L 帧光流)，捕捉运动信息。
- **光流计算**：用 TV-L1 算法预计算。
- **融合策略**：平均、SVM、堆叠等，**平均**最简单有效。
- **训练技巧**：多任务（分类 + 光流）、多尺度裁剪、dropout。
- **性能**：UCF-101 准确率 88.0%（超越手工特征 iDT 的 85.9%）。


影响与意义

- 双流架构成为视频理解的经典范式，后续 TSN、I3D 等均受启发。
- 光流成为视频理解的重要输入。

3. C3D (2014) — 比较深的 3D-CNN

核心思想

用 **3D 卷积** 同时建模空间和时间：卷积核是 $3 \times 3 \times 3$ （时间 $\times$ 高 $\times$ 宽），直接从视频片段学习时空特征。



关键设计

- **3D 卷积 vs 2D 卷积：**
- 2D 卷积： $k \times k$ ，只处理空间
- 3D 卷积： $d \times k \times k$ ，同时处理时间与空间
- **网络结构：**8 层卷积 + 5 层池化 + 2 层全连接，所有卷积核为 $3 \times 3 \times 3$ ，步长 1。
- **输入：**16 帧连续视频片段 ($16 \times 112 \times 112$)。
- **优势：**
- 3D 卷积保留时序信息
- 可同时学习外观与运动
- 特征通用性强（C3D 特征可用于动作识别、检索、场景识别）
- **性能：**UCF-101 准确率 85.2%。


影响与意义

- 证明 3D 卷积的有效性，开启 3D-CNN 时代。
- C3D 特征成为视频领域的「通用特征」。

4. Beyond Short Snippets (2015) — 尝试使用 LSTM

核心思想

C3D 只能处理短片段（16 帧），无法建模**长时序依赖**。该工作用 **LSTM** 聚合 CNN 特征，建模长视频。



关键设计

- **CNN + LSTM 架构**：CNN 提取每帧/片段特征，LSTM 建模时序演化。
- **多种 LSTM 变体**：
 - **LSTM**：标准长短期记忆
 - **ConvLSTM**：卷积 LSTM，保留空间结构
 - **ConvGRU**：卷积门控循环单元
- **池化策略**：LSTM 最后隐状态 vs 平均池化。
- **性能**：Sports-1M 上 73.1%（超越 DeepVideo 的 63.9%）。


影响与意义

- 首次系统探索 RNN 在视频理解中的应用。
- 后续被 3D 卷积和 Transformer 取代，但思想影响深远。

5. Convolutional Fusion (2016) — 做 Early Fusion 来加强时空建模

核心思想

系统研究**何时融合**时空信息：早期融合（首层）、中期融合、晚期融合，发现**早期融合**在 3D 卷积中效果最好。



关键设计

- **融合位置对比：**
- **早期融合：**首层就用 3D 卷积处理多帧
- **晚期融合：**各帧独立处理，最后融合
- **慢融合：**中间层逐步融合
- **结论：**早期融合（3D 卷积）效果最好，因为能在底层就捕捉运动。
- **网络设计：**VGG 式 3D 网络，输入 10 帧。
- **性能：**UCF-101 准确率 82.6%。


影响与意义

- 为 3D 卷积设计提供实证依据，推动 I3D 等工作。

6. TSN (2016) — 超级有效的视频分段建模

核心思想

稀疏采样 + 分段聚合：将视频分成 K 段，每段随机采样一帧，分别预测后聚合。用极低成本实现长时序建模。



关键设计

- **稀疏时间采样**：从整段视频均匀分 K 段（如 3、5、7 段），每段随机取一帧。
- **分段共识 (Segment Consensus)**： K 个片段的分类分数平均，作为视频预测。
- **双流扩展**：RGB + 光流双流，各自分段聚合。
- **数据增强 (Bag of Tricks)**：
 - 角裁剪、尺度抖动、比例抖动
 - 部分 BN、高学习率、多 GPU BN
- **性能**：UCF-101 94.2%，HMDB-51 69.4%（当时 SOTA）。


影响与意义

- 提出高效的长时序建模方案，成为视频理解的标配。
- 「Bag of Tricks」总结了视频训练的实用技巧。

7. I3D (2017) — 提出 Kinetics 数据集，膨胀 2D 网络到 3D

核心理想

膨胀 (Inflation)：将预训练的 2D 卷积核「膨胀」为 3D（时间维复制），从而利用 ImageNet 预训练权重初始化 3D 网络。同时发布 **Kinetics** 数据集。



关键设计

- **膨胀 2D 卷积：**
- 2D 卷积核 $N \times N \rightarrow$ 3D 卷积核 $N \times N \times N$ (时间维复制初始权重)
- 除以 N 保持激活值尺度不变
- **双流膨胀：** RGB 流 + 光流流都用 I3D。
- **Kinetics 数据集：** 400 类、30 万视频，规模远超 UCF-101。
- **性能：** Kinetics 上 71.1% (RGB) 、UCF-101 98.0% (双流) 。

影响与意义

- 解决 3D 网络难以预训练的问题，开启 3D-CNN 时代。
- Kinetics 成为视频理解的标准基准数据集。


8. R(2+1)D (2017) — 拆分 3D 卷积核

核心理想

将 3D 卷积

分解为 2D 空间卷积 + 1D 时间卷积

，在保持表达能力的同时减少参数、增加非线性、便于优化。



关键设计

- **分解**: $N \times N \times N$ 3D 卷积 $\rightarrow 1 \times N \times N$ (空间) + $N \times 1 \times 1$ (时间)
- **参数量对比** (输入输出通道 M 、 N_i) :
 - 3D: MN_iN^3
 - 分解: $MN_iN^2 + MN_iN$
- **优势**:
 - 中间多了一次 ReLU, 非线性更强
 - 优化更容易 (论文用实验证明)
 - 精度更高 (Sports-1M 上 3D 为 55.9%, R(2+1)D 为 56.8%)
 - **性能**: Kinetics 上 73.9% (RGB) 。


影响与意义

- 提出高效的 3D 卷积分解方案, 被后续工作广泛采用。

9. Non-local (2017) — 引入自注意力做视觉问题

核心理想

卷积是**局部操作**, 感受野有限。Non-local 引入**自注意力**, 让每个位置直接与所有位置交互, 建模**长距离依赖**。



关键设计

- **Non-local 块:**

$$y_i = \frac{1}{\mathcal{C}(x)} \sum_{\forall j} f(x_i, x_j) g(x_j)$$

其中 f 是相似度函数, g 是变换函数, $\mathcal{C}$ 是归一化。

- **四种 f 的实现:** 高斯、嵌入高斯、点积、拼接。**嵌入高斯**最常用:

$$f(x_i, x_j) = e^{\theta(x_i)^T \phi(x_j)}$$

- **即插即用:** 可插入任何 CNN 架构 (ResNet、C3D 等) 。
- **与自注意力的关系:** Non-local 块本质就是**自注意力**, 比 Transformer 早几个月。
- **性能:** 视频分类、检测、分割任务均有提升。


影响与意义

- 将自注意力引入视觉, 为 Vision Transformer 铺路。
- 是「卷积 + 注意力」混合架构的先驱。

10. SlowFast (2018) — 快慢两支提升效率

核心思想

借鉴生物视觉的**双路径**机制: **Slow 路径**低帧率、高通道数 (捕捉语义/外观), **Fast 路径**高帧率、低通道数 (捕捉快速运动)。



关键设计

- **Slow 路径:** 帧率 τ (如 4 帧/秒), 通道数 C (如 64), 处理空间语义。
- **Fast 路径:** 帧率 $\alpha\tau$ ($\alpha = 8$), 通道数 C/β ($\beta = 8$), 轻量但时间分辨率高。

- **侧向连接 (Lateral Connection)**：将 Fast 路径特征融合到 Slow 路径，用**时间步长卷积**对齐时间维度。
- **设计原则**：
 - Fast 路径通道少 (1/8)，因为运动信息维度低
 - Fast 路径计算量占比小 (约 20%)
- **性能**：Kinetics-400 79.0% (当时 SOTA)，AVA 动作检测 28.3 mAP。


影响与意义

- 提出高效的双路径视频建模方案，成为视频理解主流架构之一。

11. TimeSformer (2021) — 视频中第一个引入 Transformer

核心思想

将 ViT 扩展到视频：把视频切成时空 patch，用**时空注意力**建模。系统比较了多种注意力设计，发现**时空分离注意力**效果最好且效率最高。



关键设计

- **时空 patch 化**：视频 $T \times H \times W$ 切成 $T \times (H/P) \times (W/P)$ 个 patch。
- **五种注意力设计对比**：
- **Space-Time**：所有 patch 全连接 ($O(T^2 H^2 W^2)$)，太贵)

- **Time-Space**: 先时间后空间
- **Divided Space-Time**: **时空分离** (每层只做空间或时间注意力)
- **Sparse Local Global**: 局部 + 全局
- **Axial**: 轴向注意力
- **最佳方案: Divided Space-Time Attention**, 复杂度从 $O(T^2H^2W^2)$ 降到 $O(TH^2W^2 + T^2HW)$ 。
- **性能**: Kinetics-400 78.0% (仅用 RGB, 无光流) , 训练更快。

影响与意义


- 开启 Video Transformer 时代, 后续 VideoMAE、ViViT 等跟进。
 - 证明 Transformer 在视频领域同样有效。
-

七、多模态学习

1. CLIP (2021) — 图片和文本之间的对比学习

核心思想

用 4 亿图文对做对比学习：匹配的图文对在嵌入空间中靠近，不匹配的远离。训练后的模型可零样本迁移到任意分类任务。



关键设计

- **双塔架构**：图像编码器（ViT 或 ResNet）+ 文本编码器（Transformer）。
- **对比损失 (InfoNCE)**：batch 内 N 个图文对， N^2 个组合中只有 N 个正样本：
$$\frac{1}{2} \left(\mathcal{L}_{i \rightarrow t} + \mathcal{L}_{t \rightarrow i} \right)$$
- **零样本分类**：将类别名转为文本提示（如 "a photo of a {class}"），计算图像嵌入与所有文本嵌入的相似度，取最高。
- **提示工程 (Prompt Engineering)**："a photo of a {class}" 比直接用类名提升 1.3%；集成多个提示再提升。
- **数据规模**：400M 图文对（WIT 数据集）。
- **鲁棒性**：在 ImageNet 变体（ImageNet-R/A/Sketch）上零样本性能超越有监督 ResNet-50。


影响与意义

- 开创视觉-语言预训练范式，成为多模态领域的基石。
- 零样本能力颠覆了传统「预训练 + 微调」范式。

2. ViLT (2021) — 第一个摆脱目标检测的视觉文本模型

核心思想

此前的 VLP 模型（如 ViLBERT、LXMERT）都用 **Faster R-CNN 提取区域特征**，速度慢且依赖检测器。ViLT 直接用 **patch embedding**（像 ViT 一样），实现极简、极快的多模态模型。



关键设计

- **极简架构**：图像 patch 线性嵌入 + 文本 token 嵌入 → 拼接 → 单个 Transformer。
- **无卷积、无区域特征**：图像处理仅需线性投影，比区域特征快 60 倍。
- **模态交互**：在 Transformer 内部通过自注意力实现（而非双流交叉注意力）。
- **预训练任务**：
 - **ITM（图像文本匹配）**：判断图文是否匹配
 - **MLM（掩码语言建模）**：预测被掩码的词
 - **WPA（全词掩码）**：掩码整个词
- **性能**：VQA 上略低于区域特征模型，但速度快 10 倍以上。

影响与意义

- 证明「无检测器的 VLP」可行，推动多模态模型简化。
- 后续 ALBEF、BLIP 等均采用类似思路。


3. ViLD (2021) — CLIP 蒸馏帮助开集目标检测

核心思想

用

CLIP 蒸馏

训练开集（open-vocabulary）目标检测器：让检测器的区域嵌入对齐 CLIP 的文本嵌入，从而识别训练集中未出现的类别。



关键设计

- 两阶段蒸馏：
- 区域嵌入对齐：检测器提取的 RoI 特征，通过蒸馏对齐到 CLIP 图像嵌入空间
- 文本嵌入对齐：用 CLIP 文本编码器编码类别名，作为分类权重
- 损失函数：
- 图像级蒸馏： $\mathcal{L}_{img}$ 对齐区域嵌入与 CLIP 图像嵌入
- 文本级蒸馏： $\mathcal{L}_{txt}$ 对齐区域嵌入与 CLIP 文本嵌入
- 推理：用 CLIP 文本嵌入作为分类器，支持任意类别名。
- 性能：LVIS 数据集上 mask AP 提升 3.5%（稀有类别提升 5.5%）。

影响与意义

- 开创「CLIP 蒸馏做开集检测」范式，后续 GLIP、Grounding DINO 等跟进。


4. GLIP (2021) — 联合目标检测和文本定位

核心思想

将

目标检测统一为视觉-语言对齐任务

: 把检测框和短语都表示为 token，用对比学习对齐，实现「检测即定位（grounding）」。



关键设计

- **统一形式化：**
- 检测：输入图像，输出框 + 类别
- 定位：输入图像 + 文本，输出框
- **统一：**输入图像 + 文本（类别名拼接），输出框 + 短语对齐
- **深度融合：**图像编码器与文本编码器在**多个阶段**交互（而非仅最后对齐）。
- **损失函数：**
- **对齐损失：**图像区域与文本短语的对比损失
- **定位损失：**框回归
- **预训练数据：**用检测数据 + 定位数据联合训练，数据量扩大 10 倍。
- **零样本迁移：**COCO 零样本 49.8 AP（超越有监督的 44.0）。

影响与意义

- 统一检测与定位，实现强大的零样本检测能力。
- 后续 GLIPv2 进一步统一检测、定位、分割。


5. CLIP4Clip (2021) — 拿 CLIP 直接做视频文本检索

核心思想

将

CLIP 直接迁移到视频-文本检索

：用 CLIP 编码视频帧和文本，通过时序聚合建模视频表示。



关键设计

- **视频编码**：每帧用 CLIP 图像编码器提取特征，得到 T 个帧特征。
- **三种时序聚合方式**：
 - **无参数 (Mean Pooling)**：帧特征平均
 - **序列模型 (LSTM/Transformer)**：建模时序
- **紧密相似度 (Tight Trans.)**：帧级与词级细粒度对齐
- **相似度计算**：视频表示与文本表示的余弦相似度。
- **训练策略**：
 - **两阶段**：先冻结 CLIP 训练聚合层，再端到端微调
 - **参数空间残差**：微调时加残差连接，防止灾难性遗忘
- **性能**：MSR-VTT 上 R@1 达 44.5% (超越当时 SOTA)。

影响与意义

- 证明 CLIP 可有效迁移到视频领域，推动视频-文本检索研究。


6. ActionCLIP (2021) — 用多模态对比学习有监督地做视频动作分类

核心思想

将动作识别重构为

多模态对比学习

：用 CLIP 的图文对齐能力，把动作类别名作为文本，与视频特征对齐。



关键设计

- **三模态输入**：视频 + 文本（动作类别名）+ 标签。
- **语义预训练**：用 CLIP 的图文对齐能力初始化。
- **视频编码**：用 CLIP 图像编码器 + 时序融合（如 Transformer）。
- **损失函数**：
- **多模态对比损失**：视频特征与文本特征对齐
- **相似度损失**：视频与类别的相似度
- **零样本/少样本**：支持零样本动作识别（用类别名文本）。
- **性能**：Kinetics-400 上 83.8%（超越有监督方法）。


影响与意义

- 将动作识别纳入多模态框架，实现零样本能力。

7. PointCLIP (2021) — 3D 变 2D，巧妙利用 CLIP 做点云

核心理想

CLIP 只在 2D 图像上训练，无法直接处理 3D 点云。PointCLIP 将点云**投影为多视角深度图**，用 CLIP 编码，实现**零样本 3D 分类**。



关键设计

- **点云 → 深度图**：将 3D 点云从多个视角投影为深度图（2D）。

- **CLIP 编码**：深度图送入 CLIP 图像编码器（虽然 CLIP 没见过深度图，但仍有迁移能力）。
- **多视角聚合**：多个视角的预测结果加权聚合。
- **全局-局部对齐**：用图卷积网络（GCN）建模视角间关系，提升聚合效果。
- **零样本性能**：ModelNet40 上 20.2%（无需任何 3D 训练数据）。


影响与意义

- 首次将 CLIP 用于 3D 点云，开创 3D 多模态学习。
- 后续 ULIP、PointCLIP V2 等跟进。

8. LSeg (2022) — 有监督的开集分割

核心思想

用 CLIP 的文本嵌入作为**像素级分类器**，实现**语言驱动的语义分割**：给定任意文本描述，分割出对应区域。



关键设计

- **像素-文本对齐**：图像编码器输出像素级嵌入，与 CLIP 文本嵌入计算相似度。
- **训练**：用有标注的分割数据，让像素嵌入对齐对应类别的文本嵌入。
- **损失函数**：像素级交叉熵 + 类别内/间对比损失。
- **零样本能力**：可分割训练集中未出现的类别（如 "the wheel"）。
- **性能**：PASCAL-5i 上零样本 mIoU 提升显著。


影响与意义

- 开创语言驱动分割范式，后续 GroupViT、CLIPSeg 等跟进。

9. GroupViT (2022) — 只用图像文本对也能无监督做分割

核心思想

无需像素级标注，只用**图像-文本对**训练分割模型：通过**分组 token** 逐步聚合像素，形成语义区域，再与文本对齐。



关键设计

- **层次化分组**：
 - 阶段 1：64 个可学习 group token 与 patch 做注意力，聚合为 64 个区域
 - 阶段 2：8 个 group token 进一步聚合为 8 个区域
- **分组机制**：用 **Gumbel-Softmax** 做硬分配，每个 patch 只属于一个 group。
- **图文对齐**：最终 group token 与文本嵌入做对比学习。
- **零样本分割**：训练后可直接用文本查询分割区域。
- **性能**：PASCAL VOC 零样本 mIoU 52.2%。

影响与意义

- 证明无像素标注也能学分割，推动弱监督分割研究。


10. CLIPasso (2022) — 跨界生成简笔画

核心思想

用 CLIP 的语义理解能力

生成简笔画

：优化一组贝塞尔曲线的参数，使渲染结果在 CLIP 空间中与目标文本/图像相似。



关键设计

- **表示**: n 条贝塞尔曲线（如 4 条、16 条），每条由控制点定义。
- **优化目标**:
- **语义损失**: CLIP 嵌入相似度（生成图 vs 目标）
- **几何损失**: 与目标图像的感知损失（VGG 特征）
- **可微渲染**: 用可微光栅化器渲染曲线，支持梯度回传。
- **抽象程度控制**: 曲线数量决定抽象程度（4 条 = 极简，16 条 = 较详细）。
- **性能**: 生成的简笔画在语义上可识别，风格抽象。

影响与意义


- 展示 CLIP 作为「通用感知损失」的潜力，开创矢量图形生成。

11. DepthCLIP (2022) — 用文本跨界估计深度

核心思想

零样本单目深度估计

: 利用 CLIP 的图文对齐能力，将深度估计转化为「图像 patch 与深度文本描述的对齐」问题。



关键设计

- **深度文本化**：将深度值离散化为文本描述（如 "very close"、"far"）。
- **Patch-文本对齐**：图像 patch 嵌入与深度文本嵌入计算相似度，得到相对深度。
- **无需深度标注**：完全零样本，不需要任何深度训练数据。
- **局限**：只能估计**相对深度**（排序），无法得到绝对深度值。
- **性能**：在多个数据集上零样本深度排序准确率超越随机。

影响与意义

- 探索 CLIP 在几何任务上的能力边界，启发后续工作。


12. METER (2021) — 多模态 Transformer 的系统性研究

核心思想

对视觉-语言 Transformer 的各个组件做

系统性消融研究

，找出最优设计组合。



关键设计

- 四个组件：
- 视觉编码器：CLIP-ViT（比区域特征好）
- 文本编码器：RoBERTa
- 多模态融合：共同注意力（Co-Attention） 优于其他
- 融合位置：早期融合 vs 晚期融合
- 关键发现：
- CLIP-ViT 视觉编码器显著优于 Faster R-CNN 区域特征
- 共同注意力（图像和文本互相注意）效果最好
- 融合越早越好
- 性能：VQA 上 77.68%（当时 SOTA）。

影响与意义

- 为多模态模型设计提供实证指南，被后续工作广泛参考。


13. BridgeTower (2022) — 桥接视觉与语言

核心思想

在

单模态编码器与跨模态编码器之间架桥

：让跨模态层的每一层都能直接访问单模态特征，缓解「单模态信息在深层丢失」的问题。



关键设计

- **桥接层 (Bridge Layer)**：在跨模态编码器的每一层，将单模态编码器的对应层输出与跨模态表示拼接。
- **架构**：
 - 视觉编码器 (CLIP-ViT) + 文本编码器 (RoBERTa)
 - 跨模态编码器 (多层 Transformer)
 - 每层跨模态层接收：上一层跨模态输出 + 视觉层输出 + 文本层输出
- **优势**：保留单模态细节，提升细粒度理解。
- **性能**：VQA 上 78.73%，且参数量更少。


影响与意义

- 提出有效的多模态融合架构，被后续工作借鉴。

14. ALBEF (2021) — 动量蒸馏

核心思想

解决 VLP 中「噪声图文对」问题：网络爬取的图文对常不匹配。用**动量蒸馏**让模型从「软标签」学习，而非硬标签。



关键设计

- 三个损失：
- ITC (图像文本对比)：对齐图文嵌入
- ITM (图像文本匹配)：二分类判断匹配
- MLM (掩码语言建模)：预测掩码词
- 动量蒸馏 (Momentum Distillation)：
- 维护一个动量模型 (EMA 更新)
- 用动量模型的预测作为**软标签**，蒸馏到主模型
- 解决 ITC 中负样本可能是「假负样本」（实际匹配但被当负样本）
- 困难负样本挖掘：用 ITC 相似度选困难负样本给 ITM。
- 性能：VQA 上 74.54%，且训练数据更少。


影响与意义

- 提出动量蒸馏解决噪声标签问题，被 BLIP 等沿用。

15. BLIP (2022) — 引导语言-图像预训练

核心思想

统一**理解与生成**任务：既能做检索、VQA（理解），也能做图像描述生成（生成）。用**Captioner + Filter** 清洗网络数据。



关键设计

- 三个模型：
- ITC：对比学习（对齐）
- ITM：匹配判断（用 CapFilt 挖掘困难负样本）
- LM：语言建模（生成描述）
- CapFilt (Captioning and Filtering)：
- Captioner：为网络图像生成描述
- Filter：过滤掉低质量图文对
- 用清洗后的数据重新训练，提升质量
- 统一框架：一个模型同时支持理解与生成。
- 性能：图像描述 CIDEr 提升 2.7%，VQA 提升 1.6%。


影响与意义

- 提出数据清洗的自举（bootstrapping）范式，被 BLIP-2 等沿用。

16. ERNIE-ViL 2 (2022) — 多视角视觉-语言预训练

核心思想

用**多视角**（不同图像 + 不同文本描述）构建**跨视角对齐**，学习更鲁棒的图文表示。



关键设计

- **多视角数据构造：**
 - 同一图像的不同描述（多文本视角）
 - 同一描述对应的不同图像（多图像视角）
- **跨视角对比学习：**同一语义的不同视角应相似。
- **场景图预测：**用场景图（物体 + 关系）作为结构化监督。
- **性能：**中文图文检索、VQA 等任务上 SOTA。


影响与意义

- 提出多视角预训练范式，提升图文表示鲁棒性。

17. BLIP-2 (2023) — 冻结大模型，只训练 Q-Former

核心思想

冻结预训练的图像编码器和 LLM，只训练一个轻量的 Q-Former 连接两者，大幅降低训练成本。



关键设计

- **Q-Former (Querying Transformer) :**
- 32 个可学习 query token
- 通过交叉注意力从冻结的图像编码器提取视觉信息
- 输出固定数量的视觉表示
- **两阶段训练:**
- **视觉-语言表示学习:** ITC + ITM + ITG (图像引导文本生成)
- **视觉到语言生成学习:** 将 Q-Former 输出接入冻结的 LLM (如 OPT、FlanT5)
- **优势:**
- 训练参数量极少 (Q-Former 仅 188M)
- 可灵活替换 LLM
- 零样本 VQA 性能超越 Flamingo-80B (参数量 1/54)
- **涌现能力:** 零样本图像描述、VQA、对话。


影响与意义

- 提出高效的「冻结 + 桥接」范式，推动多模态大模型发展。

18. SAM (2023) — 分割一切

核心思想

提示驱动的通用分割：给定任意提示（点、框、掩码、文本），分割出对应物体。用 **11 亿掩码** 训练，实现零样本分割。



关键设计

- **三组件架构：**
- **图像编码器：** MAE 预训练的 ViT（每图只跑一次）
- **提示编码器：** 编码点、框、掩码、文本
- **掩码解码器：** 轻量 Transformer，快速生成掩码（50ms）
- **数据引擎（Data Engine）：**
- 三阶段：辅助标注 → 半自动 → 全自动
- 最终生成 **11 亿掩码**（SA-1B 数据集）
- **可提示分割：** 同一模型处理多种提示类型。
- **歧义处理：** 对同一提示输出多个掩码（整体、部分、子部分）。
- **零样本性能：** 在 23 个分割数据集上零样本超越或接近有监督方法。

影响与意义

- 视觉领域的「GPT-3 时刻」，成为分割基础模型。
- 后续 SAM 2 扩展到视频。


19. Chinese-CLIP (2022) — 中文 CLIP

核心理想

将 CLIP 迁移到

中文

：用中文图文对训练，并针对中文特点优化。



关键设计

- **数据**：2 亿中文图文对（LAION-5B 中文子集 + 自建数据）。
- **模型规模**：ViT-B/16、ViT-L/14、ViT-H/14 等多个规模。
- **中文优化**：
 - 文本编码器用中文 RoBERTa
 - 针对中文分词优化
- **零样本性能**：MUGE、Flickr30K-CN 等中文基准上超越多语言 CLIP。
- **开源**：模型与代码开源，推动中文多模态研究。

影响与意义




- 填补中文多模态预训练空白，成为中文 CLIP 的标准实现。
-

八、自然语言处理 - Transformer

1. Transformer (2017) — 继 MLP、CNN、RNN 后的第四大类架构

核心思想

完全基于注意力，抛弃循环和卷积。用自注意力并行建模序列中任意位置的依赖关系。



关键设计

- 缩放点积注意力:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

除以 $\sqrt{d_k}$ 防止点积过大导致 softmax 梯度消失。

- **多头注意力 (Multi-Head)**：并行多个注意力头，捕捉不同子空间的关系：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O$$

- **位置编码**：正弦/余弦函数注入位置信息：

$$PE_{(pos, 2i)} = \sin(pos/10000^{2i/d_{model}})$$

- **编码器-解码器结构**：
- 编码器：自注意力 + FFN（各带残差 + LayerNorm）
- 解码器：掩码自注意力 + 交叉注意力 + FFN
- **复杂度**： $O(n^2d)$ ，序列长度的平方（长序列的瓶颈）。

影响与意义

- 奠定现代 NLP 与多模态的基础架构。
- 后续 GPT、BERT、ViT 等均基于此。

2. GPT (2018) — 使用 Transformer 解码器做预训练

核心思想

用 **Transformer 解码器** 做 **生成式预训练**：在大规模无标注文本上训练语言模型，再微调下游任务。



关键设计

- **两阶段**：
- **无监督预训练**：标准语言建模目标 $\mathcal{L} = \sum \log P(w_i | w_{<i})$
- **有监督微调**：加任务特定头，微调全部参数
- **单向 (自回归)**：只用左侧上下文（因果掩码）。
- **架构**：12 层解码器，768 维，12 头（GPT-1 为 117M 参数）。
- **输入格式**：用特殊 token 统一不同任务（如 [Start]、[Delim]、[Extract]）。
- **性能**：9 个任务中 7 个超越当时 SOTA。


影响与意义

- 开创「预训练 + 微调」范式，GPT 系列的开端。

3. BERT (2018) — Transformer 一统 NLP 的开始

核心思想

用 Transformer 编码器做双向预训练：同时看左右上下文，学习深层双向表示。



关键设计

- 两个预训练任务：
- **MLM (掩码语言建模)**：随机掩码 15% 的 token，预测被掩码的词
 - 80% 替换为 [MASK]，10% 随机词，10% 保持不变
- **NSP (下一句预测)**：判断两句是否连续
- **双向性**：与 GPT 的单向不同，BERT 可同时利用左右上下文。
- **输入表示**：Token + Segment + Position 三种嵌入相加。
- **特殊 token**：[CLS] (分类)、[SEP] (分隔)。
- **规模**：BERT-Base (110M)、BERT-Large (340M)。
- **性能**：GLUE 上提升 7.7%，11 个任务 SOTA。


影响与意义

- 开启 NLP 预训练时代，催生 RoBERTa、ALBERT、ELECTRA 等。
- [CLS] token 与双向编码思想被 ViT 等借鉴。

4. GPT-2 (2019) — 更大的 GPT，朝 zero-shot 迈了一大步

核心思想

更大 + 更多数据：15 亿参数、40GB 文本（WebText），展示**零样本**多任务能力。



关键设计

- **规模**：1.5B 参数（GPT-1 的 10 倍），48 层，1600 维。
- **数据**：WebText（800 万网页，40GB），从 Reddit 高赞链接爬取。
- **零样本能力**：无需微调即可做翻译、问答、摘要（通过提示）。
- **架构微调**：
 - LayerNorm 移到子层前（Pre-Norm）
 - 最后一层自注意力后加 LayerNorm
 - 初始化缩放 $1/\sqrt{N}$ （ N 为残差层数）
 - 增大词表（50257）与上下文（1024）
- **结论**：语言模型是**无监督多任务学习器**。


影响与意义

- 首次展示大模型的零样本能力，开启「规模即能力」的认知。

5. GPT-3 (2020) — 100 倍更大的 GPT-2，few-shot 效果显著

核心思想

规模爆炸：1750 亿参数，展示**上下文学习**（In-Context Learning）能力——无需梯度更新，仅通过提示中的几个示例即可完成新任务。



关键设计

- **规模**：175B 参数（GPT-2 的 100 倍），96 层，12288 维，96 头。
- **数据**：3000 亿 token（Common Crawl + WebText2 + Books + Wikipedia）。
- **上下文学习**：
- **Zero-shot**：只给任务描述
- **One-shot**：给一个示例
- **Few-shot**：给几个示例（10~100）
- 无需参数更新，仅靠前向推理。
- **稀疏注意力**：交替使用稠密与稀疏注意力层，降低计算量。
- **性能**：Few-shot 在多个任务上接近或超越微调模型。


影响与意义

- 提出「提示 + 上下文学习」新范式，开启大模型时代。
- 催生 ChatGPT、GPT-4 等。

6. InstructGPT (2022) — 用人类反馈对齐语言模型

核心思想

用 RLHF（人类反馈强化学习）让 GPT-3 的输出符合人类意图：更有用、更诚实、更无害。



关键设计

- 三阶段训练：
- **SFT（监督微调）**：用人类标注的「指令-回答」对微调
- **RM（奖励模型）**：人类对多个输出排序，训练奖励模型

$$\text{loss} = -\mathbb{E} [\log \sigma(r_{\theta}(x, y_w) - r_{\theta}(x, y_l))]$$

- **PPO（近端策略优化）**：用奖励模型优化策略

$$\text{objective} = \mathbb{E}[r_{\theta}(x, y)] - \beta \text{KL}(\pi_{RL} | \pi_{SFT})$$

KL 惩罚防止偏离 SFT 模型太远。

- **关键发现**：
- 1.3B 的 InstructGPT 比 175B 的 GPT-3 更受人类偏好
- 对齐税（alignment tax）：RLHF 后某些任务性能略降，可混合预训练梯度缓解
- **数据**：4 万条人类标注。

影响与意义


- 奠定 ChatGPT 的技术基础，RLHF 成为对齐的标准方法。

7. GPT-4 (2023) — 多模态大模型

核心思想

多模态 + 更强推理

：接受图像和文本输入，在专业考试（如律师资格考）上达到人类水平。



关键设计

- **多模态**：支持图像 + 文本输入（视觉理解）。
- **规模**：未公开（传闻 1.8T 参数，MoE 架构）。
- **能力提升**：
 - 专业考试：模拟律师考试前 10%（GPT-3.5 后 10%）
 - 多语言：26 种语言中 24 种超越 GPT-3.5
 - 长上下文：32K token
- **可预测的缩放**：用训练损失可预测下游性能。
- **安全对齐**：RLHF + 规则奖励模型（RBRM）。
- **局限**：仍有幻觉、上下文窗口限制。

影响与意义

- 展示大模型在专业领域的潜力，推动 AGI 讨论。
-


九、分布式训练系统

1. 参数服务器 (2014) — 支持千亿参数的传统机器学习模型

核心思想

参数服务器 (Parameter Server)

架构：将模型参数分布到多台服务器，工作节点并行计算梯度，服务器聚合更新。



关键设计

- 两种角色：
- **Server**：存储参数分片，聚合梯度，更新参数
- **Worker**：拉取参数，计算梯度，推送更新
- **通信模式**：异步、同步、半同步。
- **一致性模型**：
- **Sequential**：完全同步

- **Eventual**: 最终一致 (异步)
- **Bounded Delay**: 有界延迟
- **关键优化**:
- **Range Push/Pull**: 按范围推送/拉取参数
- **用户自定义过滤**: 只通信重要参数
- **压缩**: 减少通信量
- **规模**: 支持千亿参数、数百节点。


影响与意义

- 奠定分布式机器学习系统的基础架构，被 TensorFlow、PyTorch 等借鉴。

2. GPipe (2018) — 流水线并行

核心思想

流水线并行 (Pipeline Parallelism) : 将模型按层切分到多个设备，用**微批次 (Micro-batch)** 填充流水线，减少气泡 (bubble) 。



关键设计

- **模型切分**: L 层模型切到 K 个设备，每个设备 L/K 层。
- **微批次流水线**: 将 mini-batch 分成 M 个 micro-batch，流水执行:
- 设备 k 处理完 micro-batch m 后立即传给设备 $k + 1$
- 同时开始处理 micro-batch $m + 1$
- **气泡率**: $\frac{K-1}{M+K-1}$, $M \gg K$ 时气泡可忽略。
- **重计算 (Re-materialization)** : 只存每层的输入，反向时重算中间激活，节省显存。
- **性能**: 8 倍加速 (4 设备) , 支持 8B 参数模型。


影响与意义

- 提出流水线并行范式，被 PipeDream、Megatron 等改进。

3. Megatron-LM (2019) — 张量并行

核心思想

张量并行 (Tensor Parallelism)：将单个矩阵乘法切分到多个设备，实现层内并行。



关键设计

- 两种切分方式：
- **列并行 (Column Parallel)**： $Y = XA$, A 按列切分，各设备算部分输出，**无需通信**（前向）
- **行并行 (Row Parallel)**： $Y = XA$, A 按行切分，各设备算部分和，需 **All-Reduce**
- **Transformer 中的组合：**
- **MLP**：第一个 FC 用列并行，第二个 FC 用行并行 → 前向只需 1 次 All-Reduce
- **自注意力**：多头注意力天然可并行（每个头一个设备）
- **通信优化**：只在必要处通信，前向 2 次、反向 2 次 All-Reduce。
- **性能**：8.3B 参数模型，8 路张量并行，76% 扩展效率。


影响与意义

- 提出高效的张量并行方案，成为大模型训练的标配（与流水线并行、数据并行组合成 3D 并行）。

4. ZeRO (2019) — 参数分片

核心思想

数据并行中每个设备都存**完整模型状态**（参数 + 梯度 + 优化器状态），显存浪费严重。ZeRO 将模型状态**分片**到各设备，按需通信。



关键设计

- 显存占用分析（混合精度， N 参数）：
- 参数 (FP16) : $2N$
- 梯度 (FP16) : $2N$

- 优化器状态 (FP32 参数 + 动量 + 方差) : $12N$
- **总计**: $16N$ (如 7.5B 模型需 120GB)
- **三级分片**:
 - **ZeRO-1**: 分片优化器状态 (省 4 倍)
 - **ZeRO-2**: 分片梯度 (省 8 倍)
 - **ZeRO-3**: 分片参数 (省 N_d 倍, N_d 为设备数)
- **通信策略**: 用 All-Gather 收集参数, Reduce-Scatter 聚合梯度。
- **性能**: ZeRO-3 可训练 1 万亿参数模型 (1024 张 V100) 。


影响与意义

- 大幅降低大模型训练显存门槛, 成为 DeepSpeed 的核心技术。
-

5. Pathways (2022) — 将 JAX 扩展到上千 TPU 核上

核心思想

异步分布式数据流: 支持在数千 TPU 上运行**多个异构任务**, 实现「单模型多模态、多任务、稀疏激活」。



关键设计

- **异步分布式数据流 (Asynchronous Distributed Dataflow) :**
- 支持并行、分布式、异步执行
- 支持**gang scheduling** (部分任务可独立调度)
- **SPMD + MPMD:** 同时支持单程序多数据与多程序多数据。
- **关键特性:**
- **资源隔离:** 不同任务可共享 TPU 但互不干扰
- **路径 (Pathways) :** 任务间的数据流图
- **稀疏激活:** MoE 模型只激活部分参数
- **规模:** 支持 2048+ TPU v4 芯片。
- **应用:** PaLM、Gemini 等模型的训练基础设施。

影响与意义

- 为超大规模、多任务、稀疏模型提供基础设施。
 - 推动 MoE 与多模态大模型发展。
-

十、图神经网络


1. GNN 介绍 (2021) — GNN 的可视化介绍

核心理念

Distill 的交互式文章，系统介绍图神经网络：

图表示什么、GNN 如何工作、如何设计

。



关键设计

- 图的四要素：
- 节点 (V)：实体（原子、用户、图像区域）
- 边 (E)：关系（化学键、关注、相似度）
- 全局属性 (U)：整图信息（分子性质）
- 三大任务：
- 图级：预测整图属性（分子是否有毒）
- 节点级：预测节点属性（用户是否机器人）
- 边级：预测边属性（两实体是否相关）
- 消息传递 (Message Passing)：
- 消息生成：每条边生成消息 $m_e = f_e(h_v, h_u, e_{uv})$
- 消息聚合：节点聚合所有入边消息 $\rho^{(e \rightarrow v)}$
- 节点更新： $h'_v = f_v(h_v, \text{agg})$
- 全局更新： $u' = f_u(u, \text{agg})$
- 采样与批处理：大图用邻居采样（GraphSAGE）或子图采样。
- 设计空间：GCN、GAT、GraphSAGE、MPNN 等。

影响与意义


- 最优秀的 GNN 入门材料，被广泛引用。

十一、优化算法与理论

1. Adam (2014) — 深度学习里最常用的优化算法之一

核心思想

结合 Momentum（一阶矩）与 RMSProp（二阶矩），自适应调整每个参数的学习率。



关键设计

- 算法流程:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (\text{一阶矩})$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (\text{二阶矩})$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad \text{偏差修正}$$

$$\theta_t = \theta - \alpha \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

- 偏差修正**: 初期 m_t 、 v_t 偏向 0，除以 $1 - \beta^t$ 修正。
- 默认超参**: $\alpha = 0.001$, $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\epsilon = 10^{-8}$ 。
- 优势**: 计算高效、内存少、适合非平稳目标、超参不敏感。
- 变体**: AdamW（解耦权重衰减）、AdaBound、RAdam 等。


影响与意义

- 成为深度学习最常用的优化器，几乎所有大模型训练都用 Adam/AdamW。

2. 为什么超大的模型泛化性不错 (2016) — 重新思考泛化

核心思想

经典学习理论认为「参数量 $\gg$ 样本数 = 过拟合」，但深度网络能拟合随机标签却仍有良好泛化。论文提出用容量度量而非参数量解释泛化。



关键设计

- 实验发现：

- 网络可以**完美记住随机标签**（训练误差 0）
- 但用真实标签训练时，测试误差仍然很低
- 说明**参数量不是泛化的有效度量**
- **解释假说：**
- **有效容量：**SGD 的隐式正则化限制了有效假设空间
- **早停：**训练早期学到简单模式
- **线性区域的平滑性：**ReLU 网络的函数在参数空间分段线性
- **实验：**用随机标签训练，测试误差与训练误差的差距随深度增加而增大。
- **结论：**需要新的理论工具理解深度学习的泛化。

影响与意义

- 引发对深度学习泛化理论的广泛研究（隐式正则、平坦极小值等）。


3. 为什么 Momentum 有效 (2017) — Distill 的可视化介绍

核心思想

Distill 的交互式文章，用

条件数 (condition number)

解释 Momentum 为何加速收敛。



关键设计

- **病态问题：**Hessian 矩阵条件数 $\kappa = \lambda_{\max}/\lambda_{\min}$ 大时，梯度下降在「峡谷」中震荡。
- **Momentum 的作用：**
- 累积历史梯度，抑制震荡方向
- 加速平坦方向

- 有效学习率在平坦方向放大 $\frac{1+\beta}{1-\beta}$ 倍
- 最优动量：**

$$\beta_{opt} = \left(\frac{\kappa - 1}{\kappa + 1} \right)^2$$

收敛速度从 $O(\kappa)$ 提升到 $O(\sqrt{\kappa})$ 。

- Nesterov 加速：**前瞻式梯度，理论收敛率更优。
- 可视化：**交互式展示不同 β 下的优化轨迹。

影响与意义

- 用直观可视化解释优化理论，是 Distill 的经典之作。
-

十二、新领域应用


1. AlphaGo (2016) — 强化学习出圈


核心思想

结合

深度神经网络 + 蒙特卡洛树搜索 (MCTS) + 强化学习

，首次击败人类围棋世界冠军。





关键设计

- 两个网络：
- 策略网络 (Policy Network)：预测下一步落子概率，用人类棋谱监督学习 + 自我对弈强化学习
- 价值网络 (Value Network)：评估局面胜率，用自我对弈数据训练
- 蒙特卡洛树搜索 (MCTS)：
- 选择：用 UCB 公式平衡探索与利用
- 扩展：用策略网络指导扩展
- 评估：用价值网络 + 快速走子
- 回溯：更新节点统计
- 训练流程：
- 监督学习初始化策略网络
- 自我对弈强化学习改进策略
- 训练价值网络
- MCTS 结合两网络对弈
- 性能：5:0 击败欧洲冠军樊麾，4:1 击败李世石。

影响与意义

- 强化学习与深度学习的里程碑，引发全球 AI 热潮。


2. AlphaFold (2020) — 赢得比赛的蛋白质 3D 结构预测

核心思想

用

深度学习

预测蛋白质 3D 结构，在 CASP14 上达到实验精度水平 (GDT_TS 92.4)。



关键设计

- 输入表示：
- **MSA (多序列比对)**：进化信息
- **残基对表示**： $L \times L$ 的距离/角度矩阵
- **Evoformer 模块**：48 个块，交替更新 MSA 表示与残基对表示。
- **结构模块**：
- 等变注意力 (Equivariant Attention)
- 输出主链与侧链的扭转角
- **端到端训练**：用 FAPE (Frame Aligned Point Error) 损失。
- **性能**：CASP14 GDT_TS 92.4 (第二名 75.0)，达到实验精度。

影响与意义

- 解决生物学 50 年难题，被 Science 评为 2021 年度突破。


3. AlphaFold 2 (2021) — 原子级别精度的蛋白质 3D 结构预测

核心思想

AlphaFold 的完整版，实现

原子级精度

，并开源代码与数据库。



关键设计

- 架构细节：
- **Evoformer**: 48 块, MSA + 残基对双轨更新
- **结构模块**: 8 块, 等变注意力 + 三角乘法更新
- **IPA (Invariant Point Attention)** : 在 3D 空间中做注意力, 保持旋转平移不变性
- 训练：
- 用 PDB 数据 (约 17 万结构)
- 自蒸馏 (用预测结构增强数据)
- 损失: FAPE + 辅助损失
- 性能：
- 中位精度 0.96 Å (实验精度约 1 Å)
- 大部分残基误差 < 1 Å
- 开源: 代码 + 数据库 (20 万+ 结构预测) 。

影响与意义

- 推动结构生物学革命, 被 Nature 评为 2021 年度方法。


4. Codex (2021) — 使用注释生成代码

核心思想

用

GPT-3 微调

得到代码生成模型, 从自然语言注释生成可执行代码 (HumanEval 通过率 28.8%) 。



关键设计

- **数据**：GitHub 上 159GB Python 代码（去重、过滤）。
- **模型**：GPT-3 12B 参数版本微调。
- **评估基准 HumanEval**：164 个手写编程题，用单元测试验证。
- **采样策略**： n 次采样取通过率 (pass@k)， $n = 100$ 时通过率 70.2%。
- **能力**：函数补全、注释生成代码、代码翻译。
- **局限**：复杂逻辑、长程序仍困难。


影响与意义

- 开启 AI 编程助手时代（GitHub Copilot 的技术基础）。

5. 指导数学直觉 (2021) — 分析数学物体之间的联系来帮助发现新定理

核心思想

用机器学习辅助数学家发现新定理：通过分析数学对象间的**模式与联系**，提出猜想。



关键设计

- **方法**：用监督学习在数学对象（如纽结、表示）的数据上训练，发现不变量间的关系。
- **案例**：
 - 纽结理论：发现代数不变量与几何不变量间的联系

- 表示论：发现 Kazhdan-Lusztig 多项式的性质
- 人机协作：AI 提出猜想，数学家验证证明。
- 意义：展示 AI 作为「数学直觉放大器」的潜力。

影响与意义

- 开创 AI for Mathematics 领域，后续 AlphaTensor、AlphaGeometry 等跟进。


6. AlphaCode (2022) — 媲美一般程序员的编程解题水平

核心思想

在

竞赛编程

(Codeforces) 上达到人类参赛者中位数水平 (前 54.3%) 。



关键设计

- **大规模采样 + 过滤：**
- 为每题生成**百万级**候选程序
- 用示例测试过滤（去掉编译失败、示例不通过的）
- 聚类去重（按程序行为聚类）
- 从每个簇选一个提交（最多 10 个）
- **模型：**编码器-解码器 Transformer（基于 Codex 架构），参数量 41B。
- **预训练：**GitHub 代码（715GB）+ 微调（竞赛数据）。
- **性能：**Codeforces 前 54.3%（约 1238 分），超越 46% 的人类参赛者。

影响与意义

- 展示大模型在复杂推理任务上的潜力，推动 AI 编程研究。

十三、CLIP 应用生态

13.1 CLIP 检测

论文	核心思想
GLIP (2112.03857)	统一检测与定位为视觉-语言对齐任务，深度融合图像与文本编码器，零样本 COCO 49.8 AP
GLIPv2 (2206.05836)	进一步统一检测、定位、分割，用「定位即分割」的视角，支持短语定位与区域分类
ViLD (2104.13921)	用 CLIP 蒸馏训练开集检测器，区域嵌入对齐 CLIP 文本嵌入，LVIS 稀有类提升 5.5%


共同原理

- 用 CLIP 的**图文对齐空间**作为「通用分类器」
- 检测器的区域特征通过**蒸馏**对齐到 CLIP 空间
- 推理时用**文本嵌入**作为分类权重，支持任意类别


13.2 深度、3D（点云）、音频

论文	核心理念
NeRF (2003.08934)	用 MLP 表示 3D 场景的 辐射场 ：输入 5D 坐标（位置 + 方向），输出颜色 + 密度，体渲染合成新视角
AudioCLIP (2106.13043)	将 CLIP 扩展到 音频 ：三模态（图像-文本-音频）对比学习，支持音频分类与检索
PointCLIP (2112.02413)	点云投影为多视角深度图，用 CLIP 零样本分类 3D 物体
DepthCLIP (2207.01077)	用文本描述深度（"very close"、"far"），零样本单目深度估计
ULIP (2212.05171)	统一 语言-图像-点云 三模态预训练，用 CLIP 对齐点云与文本
Point-E (2212.08751)	用扩散模型从文本生成 3D 点云
Shap-E (2305.02463)	从文本生成 3D 隐式函数 （可渲染为网格/NeRF）
ULIP-2 (2305.08275)	ULIP 的改进版，用多视角渲染图像自动生成点云描述，扩展训练数据
AvatarBooth (2306.09864)	从文本/图像生成 个性化 3D 头像 ，支持细粒度控制

NeRF 架构



Stable Diffusion 架构



共同原理

- **跨模态对齐**：将 3D/音频表示投影到 CLIP 空间
- **多视角投影**：3D → 2D 投影后复用 2D 模型

- **扩散生成**：用扩散模型生成 3D 表示

13.3 使用 CLIP 实现语义分割

论文	核心思想
GroupViT (2202.11094)	层次化分组 token 聚合像素为语义区域，用图文对比学习训练， 无需像素标注
LSeg (2201.03546)	像素嵌入与 CLIP 文本嵌入对齐，实现 语言驱动分割 ，支持零样本类别

共同原理

- 将**像素/区域嵌入**对齐到 CLIP 文本空间
- 用文本查询实现**开放词汇**分割

13.4 视频、动作捕捉

论文	核心思想
ActionCLIP (2109.08472)	动作识别重构为多模态对比学习，视频特征与动作类别文本对齐，支持零样本
CLIP4Clip (2104.08860)	CLIP 迁移到视频-文本检索，帧特征时序聚合
VideoCLIP (2109.14084)	视频-文本对比预训练，用 未来预测 作为额外监督，支持零样本视频理解


共同原理

- 用 CLIP 编码**视频帧**，时序聚合得到视频表示
- 与文本嵌入对比学习，实现零样本视频任务

13.5 图像生成

论文	核心思想
VQGAN (2012.09841)	用 矢量量化 + GAN 学习离散码本，Transformer 在码本上建模，实现高质量图像生成
CLIPDraw (2106.14843)	用 CLIP 作为损失函数，优化 矢量笔画 参数生成简笔画
VQGAN-CLIP (2204.08583)	VQGAN 生成 + CLIP 引导，用 CLIP 相似度作为优化目标实现文本生成图像
Stable Diffusion (CVPR 2022)	潜空间扩散 ：在 VAE 压缩的潜空间做扩散，大幅降低计算量，实现高效文生图
CLIPasso (2202.05822)	优化贝塞尔曲线参数，用 CLIP 语义损失 + 几何损失生成简笔画
Midjourney (2302.08961)	商业文生图系统（论文为技术报告），强调美学质量与用户体验

VQGAN 架构



共同原理

- **CLIP 作为损失/引导**：用 CLIP 相似度指导生成
- **潜空间建模**：在压缩空间做生成，降低计算量
- **扩散 + 引导**：扩散模型 + 分类器/无分类器引导

13.6 语言视觉下游任务

论文	核心思想
Vision-Language Downstream (2107.06383)	综述视觉-语言预训练在下游任务（VQA、检索、定位等）的应用与迁移方法

核心内容

- 预训练模型在下游任务的**迁移策略**（微调、提示、零样本）
 - 任务分类：分类、检索、生成、定位
 - 挑战与未来方向
-

十四、综述类

1. A Comprehensive Survey on Pretrained Foundation Models (2023)

核心内容

从 BERT 到 ChatGPT 的预训练基础模型综述。

关键点

- 模型分类：语言、视觉、多模态、具身
- 技术演进：Transformer → 预训练 → 提示学习 → 指令微调 → RLHF
- 关键能力：涌现能力、上下文学习、思维链
- 挑战：幻觉、对齐、效率、伦理


2. On the Opportunities and Risks of Foundation Models (2021)

核心思想

斯坦福 CRFM 的报告，系统分析基础模型的

机遇与风险

。



关键点

- **定义：**基础模型 = 在大规模数据上预训练、可适配多任务的模型
- **机遇：**同质化（一个模型多任务）、涌现能力
- **风险：**
 - **性能风险：**偏见、鲁棒性、不确定性
 - **误用风险：**虚假信息、恶意使用
 - **系统性风险：**垄断、劳动市场、环境影响
- **建议：**跨学科研究、透明性、参与式设计


3. Holistic Evaluation of Language Models (2022)

核心思想

HELM 基准：

全面

评估语言模型（准确性、校准、鲁棒性、公平性、偏见、毒性、效率）。



关键设计

- **多维度评估**: 7 大指标 × 16 个场景 × 30 个数据集
- **标准化**: 统一提示格式、统一评估协议
- **发现**:
 - 没有模型在所有维度都最优
 - 准确性与鲁棒性/公平性存在权衡
 - 指令微调提升准确性但可能增加偏见
- **开源**: 评估框架与结果公开。


4. Prompt (2107.13586) — 提示工程综述

核心思想

系统综述

提示 (Prompt)

在 NLP 中的应用：从手工设计到自动搜索。



关键内容

- 提示形式：
- 完形填空 (Cloze) : [MASK] 预测
- 前缀 (Prefix) : 生成式提示
- 设计方法：
- 手工模板: 人工设计
- 自动搜索: 离散搜索 (梯度无关)、连续优化 (软提示)

- **多提示集成**：多个提示投票
- **应用**：分类、生成、问答、推理
- **挑战**：提示敏感性、模板选择、评估困难


5. SELF-INSTRUCT (2022) — 用模型自己生成指令数据

核心理念

用

模型自己生成

指令-回答数据，微调自己，减少对人工标注的依赖。



关键设计

- **自举流程**：
- **指令生成**：用 175 个种子任务，让模型生成新指令
- **分类**：判断是否为分类任务
- **实例生成**：为指令生成输入输出实例
- **过滤**：去掉无效/相似指令
- **微调**：用生成的数据微调模型
- **数据量**：52K 指令-回答对。
- **性能**：在 SuperNI 上提升 33.1%，接近 InstructGPT 的 1/10 数据量效果。
- **迭代**：可多轮自举，持续提升。

影响与意义

- 提出「自指令」范式，被 Alpaca、Vicuna 等广泛采用。

十五、大模型时代最新进展 (2023-2025)

本章节补充 2023-2025 年深度学习领域的核心进展，涵盖大语言模型架构、推理模型、对齐技术、多模态大模型、扩散生成、视频生成、3D 重建、具身智能与 Agent 等方向。

15.1 大语言模型架构与效率


1. LLaMA 2 (2023) — 开源可商用的大语言模型

核心思想

Meta 发布的开源 LLM 系列 (7B/13B/70B)，用

更多数据 + 更长训练 + RLHF 对齐

，在开源模型中达到接近闭源模型的水平。



关键设计

- **数据**：2 万亿 token，全部来自公开数据（比 LLaMA 1 多 40%）。
- **GQA**：70B 使用分组查询注意力，推理时 KV cache 减少 8 倍。
- **上下文**：4096 token（LLaMA 1 为 2048）。
- **RLHF 流程**：拒绝采样 + PPO，训练两个独立的奖励模型（有用性、安全性）。
- **Ghost Attention**：解决多轮对话中指令遗忘问题。

- **安全**：红队测试 + 安全微调，发布 Llama Guard 安全分类器。

影响与意义

- 开源可商用，成为开源 LLM 生态的基石（Alpaca、Vicuna、Zephyr 等均基于此）。
- 证明开源模型可以接近闭源模型水平。


2. Mistral 7B (2023) — 小模型的高效设计

核心思想

7.3B 参数模型，通过

GQA + 滑动窗口注意力 (SWA) + SwiGLU

三项工程优化，性能超越 13B 的 LLaMA 2。



关键设计

- **滑动窗口注意力 (SWA)**：每层只关注前 4096 个 token，堆叠后感受野线性增长，KV cache 固定大小。
- **GQA**：8 个 KV 头、32 个查询头，加速推理。
- **SwiGLU**：门控激活函数，提升质量。
- **性能**：超越 LLaMA 2 13B，接近 LLaMA 1 34B。

影响与意义


- 证明架构优化比单纯堆参数更有效。
- SWA 被 Gemma 2 等后续模型采用。

3. Mixtral 8x7B (2024) — 稀疏混合专家

核心理念

稀疏混合专家 (SMoE)

架构：每层 8 个专家网络，每个 token 只激活 2 个，总参数 46.7B 但每 token 只计算 12.9B。



关键设计

- **稀疏激活**：46.7B 总参数，12.9B 激活参数（每 token 只用 2 个专家）。
- **性能**：匹配或超越 LLaMA 2 70B 和 GPT-3.5，推理成本仅 1/5。
- **上下文**：32K token。
- **多语言**：法语、德语、西班牙语、意大利语表现优异。

影响与意义

- 证明 MoE 是「大容量 + 低推理成本」的有效路径。
- 推动 DeepSeek、Qwen 等采用 MoE 架构。


4. DeepSeek-V3 (2024) — 671B MoE 的高效训练

核心理念

671B 总参数 / 37B 激活参数的 MoE 模型，用

MLA + 无辅助损失负载均衡 + FP8 训练 + 多 token 预测

四大创新，以 1/10 成本达到 GPT-4 级别。



关键设计

- **MLA (Multi-head Latent Attention)**：将 KV 压缩为低维潜在向量，KV cache 减少 93.3%，推理吞吐提升 5.76 倍。
- **DeepSeekMoE**：1 个共享专家 + 256 个路由专家，细粒度专家分割，每 token 激活 8 个。
- **无辅助损失负载均衡**：用动态偏置项替代辅助损失，避免性能损失。
- **FP8 混合精度训练**：首次在超大规模模型上验证 FP8，训练速度提升。
- **多 Token 预测 (MTP)**：一次预测多个未来 token，提升数据效率。
- **成本**：14.8T token，2048 张 H800，278.8 万 GPU 小时，约 557 万美元。


影响与意义

- 开源模型首次在多项基准上匹敌 GPT-4o / Claude 3.5。
- 证明训练效率创新可以大幅降低成本。

5. Mamba (2023) — 选择性状态空间模型

核心思想

用**选择性状态空间模型 (S6)** 替代注意力机制，实现**线性复杂度**的序列建模，推理速度比 Transformer 快 5 倍。



关键设计

- **选择机制**：SSM 参数 (Δ 、 B 、 C) 由输入动态决定，实现「内容感知」的过滤与记忆。
- **硬件感知算法**：并行扫描 + 核融合，充分利用 GPU SRAM。
- **复杂度**：训练 $O(n)$ ，推理 $O(1)$ 每步 (RNN 式递推)。
- **性能**：Mamba-3B 超越同规模 Transformer，匹配 2 倍规模 Transformer。
- **Mamba-2**：提出状态空间对偶 (SSD)，与注意力统一框架，速度再提升 8 倍。


影响与意义

- 挑战 Transformer 的统治地位，成为线性序列建模的代表。
- 被 Jamba、Codestral Mamba 等混合架构采用。

6. FlashAttention (2022) — IO 感知的精确注意力

核心思想

注意力瓶颈不在计算而在**显存读写 (HBM $\leftrightarrow$ SRAM)**。用**分块 (tiling)** + **重计算**避免存储 $n \times n$ 注意力矩阵，实现 2-4 倍加速。



关键设计

- **IO 感知**：HBM 读写是瓶颈，目标是最小化 HBM 访问。
- **分块计算**：Q/K/V 分块加载到 SRAM，块内计算注意力。
- **在线 Softmax**：增量式更新 softmax 统计量（最大值、指数和），无需完整行。
- **重计算**：反向传播时重新计算注意力矩阵，不存储中间结果。
- **效果**：BERT 训练提速 15%，GPT-2 提速 3 倍，内存线性而非平方。
- **FlashAttention-2**：优化并行度与工作划分，再提速 2 倍。
- **FlashAttention-3**：针对 Hopper 架构，利用 TMA 与 WGMMMA，达 75% 峰值。

影响与意义

- 成为所有大模型训练/推理的标准组件。
- 开启「IO 感知算法」研究方向。

15.2 推理与测试时计算


7. Chain-of-Thought (2022) — 思维链提示

核心思想

在提示中加入

中间推理步骤

示例，让模型「一步步思考」，大幅提升复杂推理能力。



关键设计

- **少样本 CoT**: 8 个含推理链的示例，模型模仿生成推理步骤。
- **涌现性**: 模型规模需 ~100B 才显著有效（小模型反而变差）。
- **零样本 CoT**: 加一句「Let's think step by step」即可 (Kojima et al.) 。
- **效果**: GSM8K 数学题从 17.9% → 56.9% (PaLM 540B) 。


影响与意义

- 开启「推理增强提示」研究方向。
- 是 o1、DeepSeek-R1 等推理模型的思想源头。

8. Tree of Thoughts (2023) — 思维树

核心思想

将推理从**线性链**扩展为**树搜索**：生成多个思维分支，评估状态，回溯或前瞻，实现深思熟虑的问题求解。



关键设计

- **思维分解**：将问题拆为中间思维步骤。
- **思维生成**：采样或提议多个候选思维。
- **状态评估**：用 LLM 自评估（确定/可能/不可能）或投票。
- **搜索算法**：BFS（广度优先）或 DFS（深度优先）+ 回溯。
- **效果**：24 点游戏从 4% → 74%（GPT-4）。


影响与意义

- 将经典搜索算法与 LLM 结合，推动「系统 2」式推理。
- 影响 o1 等推理模型的搜索式训练。

9. o1 (2024) — 用强化学习训练推理

核心理念

OpenAI 的推理模型：用**大规模强化学习**训练模型生成思维链，推理时通过**测试时计算扩展**提升性能。



关键设计

- **RL 训练**：用强化学习让模型学会「如何思考」，而非模仿人类推理。
- **长思维链**：内部生成数千 token 的推理过程，对用户隐藏。
- **测试时计算扩展**：性能随思考时间对数增长。
- **性能**：AIME 数学竞赛 83%（GPT-4o 仅 13%），Codeforces 第 89 百分位。
- **o1-mini**：更小更便宜，专注 STEM 推理。

影响与意义

- 开启「推理模型」新范式，Scaling Law 从训练扩展到推理。
- 引发 o3、DeepSeek-R1、QwQ 等推理模型浪潮。


10. DeepSeek-R1 (2025) — 纯强化学习涌现推理

核心思想

证明

无需监督微调

，纯 RL 即可让模型涌现推理能力（R1-Zero），并给出可复现的完整训练流程（R1）。



关键设计

- **GRPO**: 组相对策略优化，无需价值网络，用组内奖励均值作基线。
- **R1-Zero**: 纯 RL，无 SFT 冷启动，自发涌现长思维链、自我验证、「啊哈时刻」。
- **规则奖励**: 数学/代码用规则验证（准确率 + 格式），避免奖励模型被钻空子。
- **R1 四阶段**: 冷启动 → 推理 RL → 拒绝采样 SFT → 全场景 RL。
- **蒸馏**: 将 R1 推理能力蒸馏到 Qwen/Llama 小模型（1.5B-70B）。
- **性能**: AIME 2024 79.8%，MATH-500 97.3%，与 o1 相当。
- **开源**: 模型权重 + 训练细节全部公开。

影响与意义

- 首个开源复现 o1 级别推理的模型，引发全球复现浪潮。
- 证明 RL 可以激发而非仅对齐能力。


11. s1 (2025) — 简单的测试时扩展

核心理想

用

1000 条精选样本 + 预算强制 (budget forcing)

，以极低成本实现测试时计算扩展。



关键设计

- **数据**：仅 1000 条高质量样本（含推理轨迹），从 59K 中筛选。
- **预算强制**：通过追加「Wait」或强制结束 token，控制思考长度。
- **测试时扩展**：思考越长性能越好，但超过某点后下降（需截断）。
- **性能**：AIME 2024 从 50% → 57%（仅 26 分钟训练，16 张 H100）。
- **对比**：用 1/50 的数据和成本达到 o1-preview 水平。

影响与意义


- 证明测试时扩展可以「极简」实现，降低复现门槛。
 - 推动「小数据 + 强推理」研究。
-

15.3 对齐与高效微调

12. DPO (2023) — 直接偏好优化

核心思想

跳过奖励模型与 RL，用**闭式解**将 RLHF 目标转化为简单的**分类损失**，直接在偏好数据上优化策略。



关键设计

- **数学推导**: RLHF 最优策略有闭式解 $\pi^*(y|x) \propto \pi_{ref}(y|x)e^{r(x,y)/\beta}$, 反解出奖励函数代入 Bradley-Terry 模型。
- **损失函数**: $\mathcal{L} = -\log \sigma(\beta \log \frac{\pi_{\theta}(y_w)}{\pi_{ref}(y_w)} - \beta \log \frac{\pi_{\theta}(y_l)}{\pi_{ref}(y_l)})$
- **优势**: 无需训练奖励模型、无需在线采样、无需 PPO, 训练稳定。
- **效果**: 在情感控制、摘要、对话任务上匹配或超越 PPO。

影响与意义

- 成为 RLHF 的主流替代方案, 被 Zephyr、Tulu 等广泛采用。
- 衍生出 IPO、KTO、ORPO、SimPO 等变体。


13. Constitutional AI (2022) — 宪法式 AI

核心思想

用

AI 反馈替代人类反馈 (RLAIF)

: 模型根据「宪法」（原则清单）自我批评与修订，实现可扩展的对齐。



关键设计

- 两阶段：
- **SL-CAI**：模型自我批评 + 修订，生成无害回复，监督微调。
- **RL-CAI**：用 AI 生成偏好对训练偏好模型，再做 RL。
- **宪法**：约 16 条原则（如「选择最无害的回复」），源自人权宣言等。
- **RLAIF**：AI 反馈与人类反馈效果相当，成本大幅降低。
- **效果**：无害性大幅提升，且不牺牲有用性（甚至更好）。


影响与意义

- 提出 RLAIF 范式，被 Claude 系列采用。
- 推动「可扩展监督」研究。

14. LoRA (2021) — 低秩适配

核心思想

冻结预训练权重，只训练**低秩分解矩阵** $\Delta W = BA$ ，可训练参数减少 10000 倍。



关键设计

- **低秩假设**：微调时的权重更新具有低内在秩。
- **参数化**： $W = W_0 + BA$, $B \in \mathbb{R}^{d \times r}$, $A \in \mathbb{R}^{r \times k}$, $r \ll \min(d, k)$ 。
- **初始化**：A 用高斯初始化，B 用零初始化（训练开始时 $\Delta W = 0$ ）。
- **推理无延迟**：可将 BA 合并回 W_0 ，不增加推理成本。
- **效果**：GPT-3 175B 可训练参数从 175B 降至 4.7M（10000 倍），性能与全量微调相当。
- **应用**：可插拔任务模块，一个基座 + 多个 LoRA。

影响与意义

- 成为 PEFT（参数高效微调）的事实标准。
- 催生社区 LoRA 生态（如 Stable Diffusion LoRA）。


15. QLoRA (2023) — 4 比特量化微调

核心理想

用

4 比特量化 + 分页优化器

，在单张 48GB GPU 上微调 65B 模型，性能不降。



关键设计

- **NF4 (4-bit NormalFloat)**：信息论最优的 4 比特数据类型，假设权重服从正态分布。
- **双重量化**：对量化常数再量化，每参数再省 0.37 bit。
- **分页优化器**：用 NVIDIA 统一内存，优化器状态在 CPU/GPU 间自动换页，避免 OOM。
- **效果**：65B 模型微调显存从 >780GB 降至 48GB，性能与 16 比特全量微调相当。
- **Guanaco**：在 Vicuna 基准上达到 ChatGPT 99.3% 水平。

影响与意义

- 让个人研究者也能微调大模型，推动开源微调生态。
- 成为消费级 GPU 微调的标准方案。

15.4 多模态大模型


16. LLaVA (2023) — 视觉指令微调

核心思想

用

GPT-4 生成多模态指令数据

，将 CLIP 视觉编码器与 Vicuna 语言模型连接，实现视觉指令跟随。



关键设计

- 架构：CLIP ViT-L/14 + 线性投影 + Vicuna 13B。
- 两阶段训练：
- 特征对齐：冻结视觉与语言模型，只训投影层（595K 图文对）。
- 端到端微调：冻结视觉编码器，微调投影层 + LLM（158K 指令数据）。
- 数据生成：用 GPT-4（仅文本）基于 COCO 标注生成对话、详细描述、复杂推理三类数据。
- LLaVA-1.5：投影层改 2 层 MLP，加入学术 VQA 数据，性能大幅提升。
- LLaVA-NeXT：支持任意分辨率（AnyRes），更强。

影响与意义

- 开创「视觉指令微调」范式，成为开源多模态模型的标准架构。
- 证明高质量数据比复杂架构更重要。


17. Qwen2-VL (2024) — 原生动态分辨率

核心理念

用

朴素动态分辨率 + M-RoPE

，让模型处理任意分辨率的图像与视频，无需固定尺寸。



关键设计

- **朴素动态分辨率**：图像按原生分辨率切分为 28×28 patch，token 数可变，避免形变。
- **M-RoPE（多模态旋转位置编码）**：将位置编码分解为时间、高度、宽度三个分量，统一处理文本/图像/视频。
- **视频理解**：支持长视频，用 M-RoPE 的时间分量建模时序。
- **模型规模**：2B / 7B / 72B。
- **性能**：多项基准超越 GPT-4o 和 Claude 3.5 Sonnet（文档理解、视频理解）。

影响与意义


- 推动多模态模型从「固定分辨率」走向「原生分辨率」。
- 被 Qwen2.5-VL、InternVL 等跟进。

18. GPT-4o (2024) — 原生多模态

核心理念

单一模型端到端

处理文本、视觉、音频，无需多个独立模型拼接，实现实时语音对话（平均 320ms 响应）。



关键设计

- **原生多模态**：一个模型处理所有模态，而非「视觉编码器 + 语音模型 + LLM」拼接。
- **实时交互**：平均 320ms 响应，接近人类对话延迟。
- **跨模态能力**：能感知语音中的情感、语气，理解视觉内容。
- **性能**：文本/视觉能力匹配 GPT-4 Turbo，音频英语性能更强。
- **免费开放**：GPT-4o 对免费用户开放。

影响与意义

- 定义「原生多模态」标准，推动 Gemini、Claude 等跟进。
- 开启实时语音 AI 助手时代。


19. Gemini 1.5 (2024) — 百万级上下文

核心思想

用

MoE 架构 + 长上下文技术

，实现 1M-10M token 上下文，可处理整本书、长视频。



关键设计

- **MoE 架构**：Gemini 1.5 Pro 为稀疏 MoE，训练与服务更高效。
- **上下文窗口**：标准 128K，实验性 1M（Pro） / 10M（研究）。
- **长上下文能力**：10M token 下「大海捞针」召回率 99.7%。
- **多模态长上下文**：可处理 1 小时视频、11 小时音频、3 万行代码。
- **Gemini 1.5 Flash**：轻量版，低延迟高吞吐。

影响与意义

- 将上下文窗口从 100K 级推向 1M-10M 级。

- 开启「长上下文 = 新范式」讨论 (RAG vs 长上下文)。


20. SigLIP (2023) — Sigmoid 损失图文预训练

核心思想

用

成对 Sigmoid 损失

替代 Softmax 对比损失，无需全局归一化，小 batch 下性能更好。



关键设计

- **Sigmoid 损失**: $\mathcal{L} = -\frac{1}{N} \sum_{i,j} \log \sigma(z_{ij}(t \cdot x_i \cdot y_j + b))$, 正对 $z = 1$, 负对 $z = -1$ 。
- **无需全局归一化**: 每对独立计算，不依赖 batch 内所有样本。
- **小 batch 优势**: batch 4096 时与 CLIP 相当，batch 小 4 倍时仍更优。
- **性能**: SigLIP ViT-g/14 在 ImageNet 零样本达 83.1% (CLIP 为 80.2%)。
- **应用**: 被 PaliGemma、LLaVA、OpenVLA 等广泛采用。

影响与意义

- 成为 CLIP 的高效替代，多模态模型的标配视觉编码器。
- 证明损失函数设计对对比学习的重要性。

15.5 扩散与图像生成新进展


21. DiT (2022) — 扩散 Transformer

核心思想

用

Transformer 替代 U-Net

作为扩散模型骨干，证明架构可扩展性（Gflops 越大，FID 越低）。



关键设计

- **Patchify**: 将潜表示切成 patch，线性嵌入为 token 序列。
- **adaLN-Zero**: 用自适应层归一化注入时间步与类别条件，零初始化使训练稳定。
- **可扩展性**: DiT-XL/2 (675M) FID 2.27, Gflops 与 FID 强相关。
- **变体**: DiT、Cross-DiT (交叉注意力)、Context-DiT (上下文拼接)。
- **影响**: Sora、SD3、PixArt 等均基于 DiT。


影响与意义

- 证明 Transformer 是扩散模型的可扩展骨干。
- 成为视频生成 (Sora) 与新一代文生图 (SD3) 的基础。

22. ControlNet (2023) — 可控生成

核心思想

给预训练扩散模型加一个**可训练副本**，用**零卷积**连接，实现空间条件控制（边缘、深度、姿态）。



关键设计

- **可训练副本**：复制 U-Net 编码器（约 361M 参数），原模型冻结。
- **零卷积**：1×1 卷积初始化为 0，训练开始时输出为 0，不破坏原模型。
- **渐进学习**：条件从无到有渐进注入，训练稳定。
- **多种条件**：Canny 边缘、Hough 线、深度图、法线图、人体姿态、涂鸦、分割图。
- **效果**：单张 A100 训练 1 周内即可学会新条件。


影响与意义

- 成为 Stable Diffusion 生态最重要的插件。
- 定义「可控生成」范式，被 T2I-Adapter、IP-Adapter 等跟进。

23. SD3 / MMDDiT (2024) — 多模态扩散 Transformer

核心思想

用 MMDDiT（多模态扩散 Transformer）为文本与图像 token 使用**独立权重**，配合 Rectified Flow 提升生成质量。



关键设计

- **MMDiT**: 文本与图像 token 各自有独立的 Q/K/V 权重，但共享注意力（双向信息流）。
- **三个文本编码器**: CLIP ViT-L/14、OpenCLIP ViT-bigG/14、T5-XXL，兼顾语义与细节。
- **Rectified Flow**: 用直线轨迹连接噪声与数据，采样步数更少、质量更高。
- **模型规模**: 800M - 8B，8B 版本匹配 DALL·E 3。
- **性能**: 在提示跟随、排版、人体结构上大幅超越 SDXL。

影响与意义

- 成为开源文生图新标杆（SD3、Flux 均基于此）。
- 证明 Transformer 在文生图上的可扩展性。


24. Consistency Models (2023) — 一步生成

核心思想

学习

从噪声直接映射到数据

的一致性函数，实现 1-2 步生成，比扩散快 100 倍。



关键设计

- **自一致性**: 概率流 ODE 轨迹上任意点都映射到同一数据点。
- **一致性损失**: $f_\theta(x_{t_{n+1}}) \approx f_\theta(x_{t_n})$, 用相邻时间步的预测互相监督。
- **两种训练**:
 - **CD (一致性蒸馏)**: 从预训练扩散模型蒸馏。
 - **CT (一致性训练)**: 从头训练, 无需预训练模型。
- **效果**: CIFAR-10 FID 3.55 (1 步), ImageNet 64×64 FID 6.20 (1 步)。
- **LCM**: 潜空间一致性模型, 4 步生成, 被 SD 生态广泛采用。

影响与意义


- 开启「少步生成」研究方向。
- 推动实时图像生成 (LCM-LoRA、SDXL Turbo、SD Turbo)。

15.6 视频生成

25. Sora (2024) — 视频生成的世界模拟器

核心思想

将视频视为**时空 patch 序列**，用 **DiT 架构**在潜空间做扩散，实现可变时长/分辨率的高质量视频生成。



关键设计

- **时空 patch**：视频压缩为低维潜表示，再切分为时空 patch，统一处理不同分辨率/时长。
- **DiT 骨干**：扩散 Transformer，可扩展性强。
- **可变时长**：支持 1 分钟视频，可变分辨率（宽屏/竖屏）。
- **世界模拟**：涌现 3D 一致性、物体持久性、物理交互等能力。
- **技术报告**：OpenAI 未公开模型细节，仅发布技术报告。

影响与意义

- 定义视频生成新标准，引发全球视频生成竞赛。
- 提出「世界模拟器」愿景。


26. CogVideoX (2024) — 开源视频生成

核心思想

开源视频生成模型：

3D 因果 VAE + 专家 Transformer

，用 3D 注意力统一时空建模。



关键设计

- **3D 因果 VAE**：时空压缩，因果卷积支持流式生成。
- **专家 Transformer**：3D 注意力 + 专家自适应层归一化，文本-视频对齐。
- **渐进训练**：低分辨率 → 高分辨率，短时长 → 长时长。
- **显式均匀采样**：改善视频字幕生成质量。
- **开源**：2B / 5B 模型权重 + 训练代码全部开源。

影响与意义


- 首个高质量开源视频生成模型之一。
- 推动开源视频生成生态（Open-Sora、Mochi 等）。

15.7 3D 生成与重建

27. 3D Gaussian Splatting (2023) — 实时辐射场渲染

核心理想

用**显式 3D 高斯球**表示场景，配合**瓦片光栅化**，实现 1080p 实时（30+ FPS）渲染，训练仅需数分钟。



关键设计

- **显式表示**：每个高斯有位置、协方差（各向异性）、不透明度、球谐系数（视角相关颜色）。

- **瓦片光栅化**：屏幕分 16×16 瓦片，按深度排序做 α 混合，GPU 友好。
- **自适应密度控制**：根据梯度分裂/克隆高斯，剪枝透明高斯。
- **性能**：训练 30-40 分钟（NeRF 需数小时），渲染 1080p 30+ FPS（NeRF 需数秒/帧）。
- **质量**：与 Mip-NeRF 360 相当或更好。


影响与意义

- 颠覆 NeRF 的隐式表示，成为 3D 重建新范式。
- 推动实时 3D 应用（VR/AR、数字孪生）。

28. LRM (2023) — 单图 3D 重建大模型

核心思想

用大规模 Transformer 从单张图像直接预测 3D 三平面 NeRF，5 秒内完成重建。



关键设计

- **三平面表示**：3 个正交特征平面，紧凑且表达力强。
- **Transformer 架构**：图像 token + 查询 token 交叉注意力，直接回归三平面。
- **大规模训练**：Objaverse 100 万 3D 物体渲染数据。
- **速度**：单图 → 3D 仅需 5 秒（优化类方法需数分钟到数小时）。
- **泛化**：可处理真实世界图像（零样本）。

影响与意义

- 开启「3D 重建大模型」方向。
- 被 TripoSR、InstantMesh、Hunyuan3D 等跟进。


29. TRELLIS (2024) — 结构化 3D 潜表示

核心思想

提出

SLAT (Structured LATent)

: 将 3D 资产表示为稀疏体素结构 + 局部潜特征，统一支持多种输出格式。



关键设计

- **SLAT**: 稀疏体素 + 每体素局部潜特征，兼顾结构与细节。
- **两阶段生成**: 先生成稀疏结构，再生成潜特征。
- **多格式解码**: 同一潜表示可解码为高斯、NeRF、网格、纹理。
- **整 rectified flow**: 用 Rectified Flow 训练生成模型。
- **性能**: 在图像/文本到 3D 任务上超越 LRM、InstantMesh 等。

影响与意义


- 统一 3D 生成表示，支持多格式输出。
- 推动 3D 生成从「单一格式」走向「通用表示」。

15.8 具身智能与世界模型

30. RT-2 (2023) — 视觉-语言-动作模型

核心思想

将机器人动作表示为**文本 token**，与网络数据**联合微调**，让 VLM 直接输出动作，涌现语义推理能力。



关键设计

- **动作即文本**：将 7 维动作离散化为 256 个 bin，表示为文本 token。
- **联合微调**：网络图文数据 + 机器人轨迹数据一起微调，避免灾难性遗忘。
- **涌现能力**：能理解「快没电的电池」「给泰勒·斯威夫特的东西」等抽象指令。
- **泛化**：未见物体、未见指令、未见场景下成功率显著提升。
- **模型**：基于 PaLI-X (55B) 和 PaLM-E (12B) 。

影响与意义

- 开创 VLA (Vision-Language-Action) 模型范式。
- 证明互联网知识可迁移到机器人控制。


31. OpenVLA (2024) — 开源 VLA

核心理念

开源 7B VLA 模型：

Llama 2 + DINOv2/SigLIP 双视觉编码器

，在 97 万机器人演示上训练。



关键设计

- **双视觉编码器**：DINOv2（空间细节）+ SigLIP（语义），特征拼接。
- **Llama 2 7B**：语言骨干，动作离散化为 token。
- **数据**：Open X-Embodiment 97 万演示，覆盖多种机器人。
- **性能**：超越 RT-2-X (55B) 16.5%，参数仅 1/7。
- **开源**：权重 + 代码 + 微调脚本全部开源。
- **LoRA 微调**：可在消费级 GPU 上适配新任务。

影响与意义

- 首个真正开源的通用机器人操作模型。
- 降低具身智能研究门槛。


32. π0 (2024) — 流匹配 VLA

核心理念

用

流匹配 (Flow Matching)

生成连续动作块，实现 50Hz 高频控制，跨机器人形态泛化。



关键设计

- **流匹配**：用连续归一化流生成动作，比扩散采样更快（10 步）。
- **动作块 (Action Chunking)**：一次预测 50 步动作，50Hz 控制频率。
- **跨形态训练**：8 种机器人、1 万小时数据、68 个任务。
- **预训练 + 后训练**：通用预训练 + 任务特定微调。
- **性能**：叠衣服、清理桌子等复杂任务表现优异。


影响与意义

- 证明流匹配在机器人控制上的优势。
- 推动通用机器人策略研究（ $\pi 0.5$ 、GR00T 等）。

33. Genie (2024) — 生成式交互环境

核心思想

从单张图像生成可交互的 2D 游戏环境，用潜在动作模型无监督学习动作空间。



关键设计

- **三组件：**
- **视频 Tokenizer：**时空压缩为离散 token。
- **潜在动作模型：**从帧间变化无监督学习动作表示。
- **动力学模型：**自回归预测下一帧。
- **数据：**3 万小时公开游戏视频，无需动作标注。
- **规模：**11B 参数。
- **交互：**生成的环境可逐帧交互，动作空间由模型自学。

影响与意义

- 提出「生成式交互环境」新范式。
- 为具身智能提供无限训练环境（Genie 2、Genie 3 跟进）。

15.9 Agent 与工具使用


34. ReAct (2022) — 推理与行动协同

核心思想

让 LLM

交替生成推理轨迹与行动

，用外部工具（搜索、计算器）获取信息，实现「思考-行动-观察」循环。



关键设计

- **交错推理与行动**：Thought → Action → Observation 循环。
- **工具调用**：搜索、查找、计算器等外部工具。
- **对比**：
 - 仅推理（CoT）：无法获取外部信息，易幻觉。
 - 仅行动：缺乏推理，无法调整策略。
 - ReAct：两者协同，减少幻觉，提升可解释性。
- **效果**：HotpotQA 问答、ALFWorld 决策任务显著提升。
- **可解释性**：推理轨迹可人工检查与干预。

影响与意义

- 成为 LLM Agent 的基础范式。
- 被 LangChain、AutoGPT 等广泛采用。


35. Toolformer (2023) — 自监督学习使用工具

核心思想

让模型

自己标注

何时调用哪个 API，用自监督方式学会工具使用。



关键设计

- **自监督标注**：在文本中采样位置，尝试插入 API 调用，保留能降低后续 token 困惑度的调用。
- **工具集**：计算器、问答系统、搜索引擎、翻译、日历。

- **过滤标准**：调用结果必须降低后续文本的困惑度（加权交叉熵）。
- **效果**：零样本下工具使用能力接近 GPT-3 少样本，且不损害语言建模能力。
- **模型**：基于 GPT-J 6.7B。

影响与意义

- 证明工具使用可以自监督学习。
- 推动「工具增强语言模型」研究。


36. MCP (2024) — 模型上下文协议

核心思想

Anthropic 提出的

开放协议

，标准化 LLM 与外部数据源/工具的连接方式，类似「AI 的 USB-C」。



关键设计

- **架构**：主机 (Host) → 客户端 (Client) → 服务器 (Server)。
- **三种原语**：
- **工具 (Tools)**：可执行函数。
- **资源 (Resources)**：可读取数据。

- **提示 (Prompts)**：预定义模板。
- **传输**：JSON-RPC 2.0, 支持 stdio 与 HTTP+SSE。
- **开源**：规范 + SDK (Python/TypeScript) 全部开源。
- **生态**：被 OpenAI、Google、VS Code 等采纳。

影响与意义

- 成为 AI 工具集成的事实标准。
 - 推动 Agent 生态标准化 (A2A、AGNTCY 等跟进) 。
-

附录：论文速查表

按年份

年份	论文	类别
2012	AlexNet	CNN
2014	VGG / GoogLeNet / GAN / R-CNN / DeepVideo / Two-Stream / C3D / Adam / 参数服务器	多类
2015	ResNet / DCGAN / Fast R-CNN / Faster R-CNN / Beyond Short Snippets	多类
2016	pix2pix / SRGAN / SSD / YOLO / TSN / Convolutional Fusion / AlphaGo / 泛化理论	多类
2017	MobileNet / WGAN / CycleGAN / Mask R-CNN / YOLOv2 / I3D / R(2+1)D / Non-local / Transformer / Momentum	多类
2018	StyleGAN / YOLOv3 / InstDisc / CPC / MoCo / GPT / BERT / GPipe	多类
2019	EfficientNet / StyleGAN2 / CenterNet / InvaSpread / CMC / MoCo / SimCLR / GPT-2 / Megatron / ZeRO	多类
2020	ViT / DDPM / SimCLR v2 / BYOL / SWaV / SimSiam / DETR / GPT-3 / AlphaFold	多类
2021	Swin / MLP-Mixer / MAE / Improved DDPM / Guided Diffusion / StyleGAN3 / MoCo v3 / DINO / TimeSformer / CLIP / ViLT / ViLD / GLIP / CLIP4Clip / ActionCLIP / PointCLIP / ALBEF / METER / AlphaFold 2 / Codex / GNN 介绍 / 数学直觉	多类
2022	DALL·E 2 / Whisper / Action-GPT / LSeg / GroupViT / CLIPasso / DepthCLIP / BridgeTower / BLIP / ERNIE-ViL 2 / Pathways / AlphaCode / InstructGPT / HELM / SELF-INSTRUCT / Chinese-CLIP	多类
2023	LLaMA / PaLM-E / HuggingGPT / DINOv2 / BLIP-2 / SAM / GPT-4 / Shap-E / ULIP-2 / AvatarBooth / LLaMA 2 / Mistral 7B / LLaVA / SigLIP / DiT / ControlNet / SDXL / Consistency Models / RT-2 / ReAct / Constitutional AI	多类
2024	Mixtral 8x7B / DeepSeek-V3 / Mamba / FlashAttention-2 / o1 / DPO / QLoRA / Qwen2-VL / GPT-4o / Gemini 1.5 / SD3 / Sora / CogVideoX / 3DGS / LRM / TRELIS / OpenVLA / π0 / Genie / Toolformer / MCP	多类
2025	DeepSeek-R1 / s1	推理模型

按技术脉络

CNN 演进：

AlexNet → VGG → GoogLeNet → ResNet → MobileNet → EfficientNet → ParNet

Transformer 演进：

Transformer → GPT/BERT → ViT → Swin → MAE → DINOv2

生成模型演进：

GAN → DCGAN → pix2pix → SRGAN → WGAN → CycleGAN → StyleGAN → StyleGAN2/3

↓

DDPM → Improved DDPM → Guided Diffusion → DALL·E 2 → Stable Diffus

目标检测演进：

R-CNN → Fast R-CNN → Faster R-CNN → Mask R-CNN

↓

YOLO → YOLOv2 → YOLOv3

↓

SSD / CenterNet / DETR

对比学习演进：

InstDisc → CPC → InvaSpread → CMC → MoCo → SimCLR → MoCo v2 → SimCLR v2

↓

BYOL → SimSiam → SWaV → MoCo v3 → DINO → DINOv2

视频理解演进：

DeepVideo → Two-Stream → C3D → Beyond Short Snippets → Convolutional Fusion

→ TSN → I3D → R(2+1)D → Non-local → SlowFast → TimeSformer

多模态演进：

CLIP → ViLT → ViLD → GLIP → ALBEF → BLIP → BLIP-2 → SAM

→ CLIP4Clip / ActionCLIP / PointCLIP / LSeg / GroupViT / CLIPasso / DepthCLIP

NLP 演进：

Transformer → GPT → BERT → GPT-2 → GPT-3 → InstructGPT → GPT-4

→ LLaMA 2 → Mistral 7B → Mixtral 8x7B → DeepSeek-V3 → GPT-4o / Gemini 1.5

推理模型演进：

Chain-of-Thought → Self-Consistency → Tree of Thoughts → o1 → DeepSeek-R1 → s1

对齐技术演进：

RLHF (InstructGPT) → Constitutional AI (RLAIF) → DPO → GRPO (DeepSeek-R1)

高效微调演进：

LoRA → QLoRA → FlashAttention → FlashAttention-2/3

扩散模型演进：

DDPM → Improved DDPM → Guided Diffusion → DALL·E 2 → Stable Diffusion

→ DiT → ControlNet → SDXL → Consistency Models → SD3/MMDiT → Sora

多模态大模型演进：

CLIP → BLIP → BLIP-2 → LLaVA → Qwen2-VL → GPT-4o / Gemini 1.5

3D 生成演进：

NeRF → 3D Gaussian Splatting → LRM → TRELLIS

具身智能演进：

RT-2 → OpenVLA → $\pi 0$ → Genie

Agent 演进：

ReAct → Toolformer → MCP

结语

这份文档覆盖了深度学习发展史上的关键论文，可以按以下线索理解整体脉络：

1. **架构演进**：从 CNN 的局部归纳偏置，到 Transformer 的全局注意力，再到 MLP 的极简主义，以及 Mamba 的线性状态空间模型。
2. **训练范式**：从有监督学习，到自监督/对比学习，再到预训练 + 微调、提示学习、上下文学习、指令微调与 RLHF 对齐。
3. **生成模型**：从 GAN 的对抗博弈，到扩散模型的逐步去噪，再到 DiT/MMDiT 的 Transformer 扩散与视频生成（Sora）。
4. **多模态**：从 CLIP 的图文对齐，到统一的多模态大模型（BLIP-2、SAM），再到原生多模态（GPT-4o、Gemini 1.5）。
5. **系统与规模**：从单卡训练，到数据/流水线/张量并行，再到 ZeRO 分片、Pathways 与 MoE 稀疏激活（Mixtral、DeepSeek-V3）。
6. **对齐与安全**：从纯预训练，到 RLHF（InstructGPT）、Constitutional AI（RLAIF）、DPO，再到推理模型 RL（o1、DeepSeek-R1）。
7. **推理与 Agent**：从 Chain-of-Thought 提示，到 Tree of Thoughts 搜索，再到 RL 训练的推理模型（o1、R1）与工具使用 Agent（ReAct、MCP）。
8. **具身智能**：从 RT-2 的 VLA 范式，到 OpenVLA 开源生态、 $\pi 0$ 流匹配控制与 Genie 世界模型。

建议学习路径

：先掌握 CNN（AlexNet→ResNet）与 Transformer（Attention→BERT/GPT）两大基础，再按兴趣深入生成模型、检测、自监督或多模态方向。最新进展（十五章）建议重点关注：大模型架构（LLaMA 2→DeepSeek-V3）、推理模型（CoT→o1→DeepSeek-R1）、对齐技术（RLHF→DPO）与多模态大模型（LLaVA→GPT-4o）四条主线。