

图像描述子 (Feature Descriptors) 综述：原理、分类与应用

关于参考书的一点说明

本文目标是按 *Computer Vision Metrics: Survey, Taxonomy, and Analysis* (Scott Krig, Apress) 这类 survey 的通用脉络来组织描述子内容，即以 **全局** → **局部** → **纹理** → **学习型** → **颜色** 为主线，并区分 **手工设计 (hand-crafted)** 与 **学习型 (learned)** 两大分支。

该书未能获取原文，因此本文**不引用其具体页码、章节号和原文表述**，只采用这一领域公认的分类框架与数学定义。所有公式与算法描述均来自公开的原始论文与标准定义 (SIFT、SURF、ORB、BRIEF、BRISK、FREAK、HOG、LBP、GLOH、Shape Context、MSER、Census、VLAD、Fisher Vector、SuperPoint 等)。

目录

- 描述子的基本概念
- 描述子的分类体系 (Taxonomy)
- 数学原理基础
- 关键点检测子 (Detectors)
- 局部描述子 (Local Descriptors) 逐类详解
- 全局描述子 (Global Descriptors)
- 纹理描述子 (Texture Descriptors)
- 颜色描述子 (Color Descriptors)
- 形状与轮廓描述子 (Shape / Contour Descriptors)
- 光谱与子空间描述子 (Spectral / Basis / Subspace)

11. 学习型与深度描述子 (Learning-based)
 12. 立体匹配与光流描述子
 13. 视频与时序描述子
 14. 匹配、索引与检索
 15. 评价指标与基准数据集
 16. 应用方向
 17. 选型与设计权衡
 18. 速查表
 19. 结论
-

1. 描述子的基本概念

1.1 什么叫描述子

描述子 (descriptor) 是把图像中某一局部或全局区域的内容压缩成一个 固定维度数值向量的函数。它的作用是让“图像块”变成一个可比较、可匹配、可检索的数学对象。

形式化地说，描述子是一个映射：

$$f : \mathcal{P}(I) \rightarrow \mathbb{R}^d \quad \text{或} \quad \{0, 1\}^d$$


其中：

- I 是图像（灰度或彩色）
- $\mathcal{P}(I)$ 是图像上的一个区域或一个点邻域
- d 是描述子的维度
- 浮点描述子取值于 $\mathbb{R}^d$ ，二进制描述子取值于 $\{0, 1\}^d$

含义：描述子把“一块图像区域”映射成一个固定长度的数值向量，从而把图像比较问题转化为向量比较问题。

描述子本身通常是**向量**；它表达的是“这块图像长什么样”，而不是“这块图像在哪”。

描述子的作用示意：




1.2 检测子、关键点与描述子的关系

一个完整的局部特征系统通常由三部分组成：

环节	作用	输出	典型方法
检测 (detection)	找出图像中"值得描述"的位置	关键点坐标 (x, y) 、尺度 σ 、方向 θ	Harris、FAST、DoG、MSER
描述 (description)	把关键点邻域编码成向量	d 维向量	SIFT、SURF、ORB、BRIEF
匹配 (matching)	比较两个描述子的相似度	对应关系	L2、Hamming、NNDR、RANSAC

检测子 (detector) 与 **描述子 (descriptor)** 是两个可以独立替换的模块。例如 ORB = oFAST (检测) + rBRIEF (描述) , 两者来自不同源头。

局部特征系统的完整流水线：



各环节用到的处理及其作用：

环节	处理	作用
检测	尺度空间 / 结构张量 / 圆周测试	找到稳定、可重复、可定位的位置
描述	梯度统计 / 强度比较 / 滤波响应	把邻域内容编码成可比较的向量
归一化	主方向旋转 / 尺度缩放 / L2 归一化	赋予旋转、尺度、光照不变性
匹配	距离度量 + 比率检验	找出候选对应点
验证	RANSAC 拟合几何模型	剔除外点，保证几何一致

1.3 描述子的数学本质

从数学角度看，描述子的构造基本都遵循同一个模式：

$$\text{descriptor} = \mathcal{N}\left(\mathcal{Q}\left(\mathcal{F}(I, \Omega)\right)\right)$$

其中：

- Ω ：局部区域（点邻域、仿射归一化区域、区域检测结果）
- $\mathcal{F}$ ：特征提取算子（梯度、滤波响应、强度比较、矩、频谱）
- $\mathcal{Q}$ ：量化/编码（直方图分箱、二值化、投影、聚类分配）

- $\mathcal{N}$: 归一化 (L1/L2 归一化、均值-方差归一化、幂律归一化)


含义: 任何描述子都可以拆成"选区域 → 提特征 → 量化编码 → 归一化"四步，不同描述子的差别只是这四步的具体选择不同。

不同的描述子，差别主要在于这四步的具体选择。

四步处理的作用:

步骤	典型处理	作用
选区域 Ω	点邻域、仿射归一化、区域检测	确定"描述哪一块"，并消除位置/形状差异
提特征 $\mathcal{F}$	梯度、滤波、强度比较、矩、频谱	提取对内容敏感、对干扰不敏感的信号
量化 $\mathcal{Q}$	直方图分箱、二值化、投影、聚类	把连续信号压成固定维度、可比较的编码
归一化 $\mathcal{N}$	L1/L2、均值-方差、幂律	消除光照/对比度/尺度差异，提升鲁棒性

四步流水线示意:



1.4 好描述子应具备的性质

性质	含义	数学体现
可重复性 (repeatability)	同一物理点在变换后仍被检测到	检测子在同一点上重复命中
可区分性 (distinctiveness)	不同区域产生不同描述子	描述子空间内类间距离大
紧致性 (compactness)	占用空间小、匹配快	维度 d 小
不变性 (invariance)	对某种变换不敏感	$f(T(I)) = f(I)$
等变性 (equivariance)	随变换而一致变化	$f(T(I)) = T'(f(I))$
鲁棒性 (robustness)	对噪声、压缩、光照稳定	扰动下 $\ \Delta f\ $ 小
效率 (efficiency)	计算与匹配开销低	可用积分图、位运算、LSH


其中不变性是最核心的设计目标，常见有：

- **平移不变:** 通过对局部区域相对坐标编码

- **旋转不变**: 通过主方向分配 + 旋转归一化
 - **尺度不变**: 通过尺度空间极值检测 + 尺度归一化窗口
 - **仿射不变**: 通过二阶矩矩阵做仿射归一化
 - **光照不变**: 通过梯度、强度差、归一化、截断
 - **视角/3D 不变**: 最难, 通常只能做到有限视角内鲁棒
-

2. 描述子的分类体系 (Taxonomy)

描述子分类总览：



2.1 按空间范围分

全局描述子 (global descriptors)

- 对整幅图像产生一个向量
- 典型：颜色直方图、GIST、GLCM、Hu 矩、BoW、Fisher Vector、CNN 全局池化
- 优点：紧凑、适合整图检索与分类
- 缺点：无空间定位能力，遮挡敏感

局部描述子 (local descriptors)

- 对关键点邻域产生一个向量
- 典型：SIFT、SURF、ORB、BRIEF、BRISK、FREAK、LBP
- 优点：可匹配、可定位、对遮挡相对鲁棒
- 缺点：数量多，需要匹配与几何验证

2.2 按设计方式分

手工设计 (hand-crafted)

- 由人根据图像结构先验设计
- 代表：SIFT、SURF、HOG、LBP、Gabor、Shape Context、MSER

学习型 (learned / learned embeddings)

- 参数由数据训练得到
- 代表：PCA-SIFT、LDA 描述子、Random Ferns、L2-Net、HardNet、SuperPoint、DELF

2.3 按数学构造来源分（本文主线）

构造家族	数学工具	代表方法
梯度/方向直方图	一阶微分 + 加权投票	SIFT、SURF、GLOH、HOG、DAISY
强度比较/二进制	比较算子 + 位运算	BRIEF、ORB、BRISK、FREAK、LATCH
矩与正交基	矩展开、正交多项式	Hu、Zernike、Legendre、Tchebichef
纹理/滤波响应	卷积滤波组	LBP、Gabor、MR8、GLCM、Tamura、小波
光谱/子空间	FFT、DCT、PCA、LDA、ICA	Fourier 描述子、DCT、Eigenfaces、Fisherfaces
形状/轮廓	边界参数化、极坐标分箱	Shape Context、链码、CSS、Fourier 形状
区域/分割	连通域、稳定性	MSER、EBR、IBR
学习/嵌入	度量学习、深度网络	Fisher Vector、VLAD、NetVLAD、SuperPoint

2.4 按不变性能力分

能力等级	含义	代表
仅平移	只对位置不敏感	直方图类、LBP（原型）
平移+旋转	加方向归一化	SIFT、SURF、ORB（rBRIEF）、BRISK
平移+旋转+尺度	加尺度空间	SIFT、SURF、KAZE、AKAZE
平移+旋转+尺度+仿射	加仿射归一化	Harris-Affine、Hessian-Affine、MSER+
宽基线/视角	学习型或专用设计	SuperPoint、D2-Net、视角不变特征

2.5 按数据类型与匹配方式分

浮点型描述子

- 存储在 $\mathbb{R}^d$
- 匹配用欧氏距离 L_2 或余弦相似度
- 代表：SIFT(128)、SURF(64/128)、GLOH(128)、HOG

二进制描述子

- 存储在 $\{0, 1\}^d$
- 匹配用汉明距离 (XOR + popcount)
- 代表: BRIEF(128–512)、ORB(256)、BRISK(512)、FREAK(512)、LATCH(256)

二进制描述子的核心优势：匹配极快。

$$D_{Hamming}(\mathbf{a}, \mathbf{b}) = \sum_{i=1}^d [a_i \neq b_i] = \text{popcount}(\mathbf{a} \oplus \mathbf{b})$$

其中：

- $\mathbf{a}, \mathbf{b}$: 两个 d 位二进制描述子。
- a_i, b_i : 第 i 位的取值 (0 或 1) 。
- $[a_i \neq b_i]$: 指示函数，两位不同时为 1，否则为 0。
- $\oplus$: 按位异或 (XOR) 。
- $\text{popcount}(\cdot)$: 统计结果中 1 的个数。
- 含义：汉明距离就是两个二进制串不同的位数，可用一次 XOR + 位计数完成，因此匹配极快。

浮点 vs 二进制描述子的处理差异：

方面	浮点描述子	二进制描述子
特征提取	梯度/滤波响应（连续值）	强度比较 (0/1)
量化	直方图分箱、投影	阈值比较、位打包
归一化	L2/L1、幂律	通常无需（比较已消除幅值）
匹配	L2 / 余弦（浮点运算）	Hamming（位运算）
优势	区分性强、精度高	存储小、匹配快

2.6 按应用任务分

- 匹配/配准类：SIFT、SURF、ORB、SuperPoint
- 检测/分类类：HOG、LBP、Haar-like、DPM
- 检索类：BoW、VLAD、Fisher Vector、R-MAC、DELF
- 识别类：LBPH、Eigenfaces、Fisherfaces、深度嵌入
- 立体/稠密类：Census、NCC、DAISY

3. 数学原理基础

3.1 尺度空间理论 (Scale Space)

尺度不变性的数学基础是**尺度空间**。图像在不同尺度下的表示由高斯卷积给出：

$$L(x, y, \sigma) = G(x, y, \sigma) * I(x, y)$$

其中：

- $L(x, y, \sigma)$ ：尺度 σ 下的图像表示（尺度空间）。
- $I(x, y)$ ：原始图像。
- $G(x, y, \sigma)$ ：高斯核。
- $*$ ：卷积运算。
- 含义**：用不同宽度的高斯核模糊图像，得到一族由粗到细的表示， σ 越大越模糊。

$$G(x, y, \sigma) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

其中：

- σ ：高斯核标准差，即尺度参数。
- x, y ：相对核中心的坐标。
- $\frac{1}{2\pi\sigma^2}$ ：归一化系数，保证核积分为 1。
- 含义**： σ 控制模糊程度，是尺度空间的“尺子”。

尺度空间满足扩散方程（这一性质称为半群性质）：

$$\frac{\partial L}{\partial \sigma} = \sigma \nabla^2 L$$

其中：

- $\frac{\partial L}{\partial \sigma}$ ：表示随尺度变化的速率。
- ∇^2 ：拉普拉斯算子。
- 含义**：高斯模糊等价于热扩散过程，保证尺度空间是“因果”且无新结构产生的。

高斯拉普拉斯 (LoG) 用于斑点检测：

$$\nabla^2 G = \frac{\partial^2 G}{\partial x^2} + \frac{\partial^2 G}{\partial y^2}$$

其中：

- $\nabla^2 G$ ：高斯核的二阶导之和（拉普拉斯）。
- **含义**：LoG 对斑点（blob）响应最强，斑点尺寸与 σ 匹配时响应最大。

尺度归一化 LoG 的极值给出特征尺度：

$$\sigma^2 \nabla^2 L(x, y, \sigma)$$

其中：

- σ^2 ：尺度归一化因子，抵消 LoG 随 σ 增大而衰减的幅值。
- **含义**：在 (x, y, σ) 三维空间中找该响应的极值，即得到特征点的位置与特征尺度。

高斯差分 (DoG) 是对 LoG 的高效近似：

$$\begin{aligned} D(x, y, \sigma) &= (G(x, y, k\sigma) - G(x, y, \sigma)) * I(x, y) \\ &\approx (k - 1)\sigma^2 \nabla^2 L \end{aligned}$$

其中：

- k ：相邻尺度的比例因子（如 $k = 2^{1/s}$ ）。
- $G(x, y, k\sigma) - G(x, y, \sigma)$ ：两个相邻尺度高斯核之差。
- $(k - 1)\sigma^2$ ：近似系数，说明 DoG 正比于尺度归一化 LoG。
- **含义**：DoG 只需两次高斯模糊相减，计算远快于 LoG，却近似其效果。

这就是 SIFT 能在多尺度上检测极值的关键。

非线性尺度空间 (KAZE/AKAZE) 用非线性扩散替代高斯：

$$\frac{\partial L}{\partial t} = \text{div}(c(x, y, t) \nabla L)$$

其中：

- t ：演化时间（对应尺度）。
- div ：散度算子。
- $c(x, y, t)$ ：扩散系数，由局部梯度自适应控制。
- ∇L ：图像梯度。
- **含义**：在平坦区强扩散、在边缘处弱扩散，从而在保边的同时建立尺度。

其中 c 由梯度自适应控制（Perona–Malik 型 diffusivity），从而在保边的同时建立尺度。

尺度空间处理流程与作用：



处理	作用
高斯卷积	建立多尺度表示，模拟"远近观察"
尺度归一化	让不同尺度的响应可比
DoG 相减	高效近似 LoG，定位斑点与特征尺度
3D 极值检测	同时确定位置与尺度，获得尺度不变性

3.2 梯度与局部结构

一阶梯度：

$$I_x = \frac{\partial I}{\partial x}, \quad I_y = \frac{\partial I}{\partial y}$$

其中：

- I_x, I_y ：图像在水平、垂直方向的一阶偏导（梯度分量）。
- **含义**：梯度描述灰度变化最快的方向与强度，是绝大多数描述子的基础信号。

梯度幅值与方向：

$$m = \sqrt{I_x^2 + I_y^2}, \quad \theta = \text{atan2}(I_y, I_x)$$

其中：

- m ：梯度幅值，表示边缘强度。
- θ ：梯度方向，表示边缘朝向。
- atan2 ：四象限反正切，给出 $(-\pi, \pi]$ 的方向。
- **含义**：幅值用于加权投票，方向用于直方图分箱，二者共同构成方向直方图。

自相关矩阵（结构张量）：

$$M = \sum_{(x,y) \in W} w(x,y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}$$

其中：

- W ：局部窗口。
- $w(x,y)$ ：窗口权重（常为高斯）。
- $I_x^2, I_x I_y, I_y^2$ ：梯度的二阶统计量。
- **含义**： M 汇总窗口内梯度的分布方向，其特征值刻画局部结构类型。

特征值 λ_1, λ_2 决定局部结构类型：

特征值关系	结构类型
λ_1, λ_2 都小	平坦区域
一大一小	边缘
都大	角点

Harris 响应：

$$R = \det(M) - k (\text{tr } M)^2$$

其中：

- $\det(M) = \lambda_1 \lambda_2$ ：行列式。
- $\text{tr } M = \lambda_1 + \lambda_2$ ：迹。
- k ：经验常数（常取 0.04–0.06）。
- **含义**：两个特征值都大时 R 大，因此 R 的局部极大即角点。

Shi–Tomasí 响应：

$$R = \min(\lambda_1, \lambda_2)$$

其中：

- $\min(\lambda_1, \lambda_2)$ ：取较小特征值。
- **含义**：直接要求两个方向都强，比 Harris 更稳定，常用于跟踪。

Hessian 矩阵（用于斑点/DoH）：

$$H = \begin{bmatrix} I_{xx} & I_{xy} \\ I_{xy} & I_{yy} \end{bmatrix}, \quad \det(H) = I_{xx}I_{yy} - I_{xy}^2$$

其中：

- I_{xx}, I_{yy} ：二阶偏导。
- I_{xy} ：混合偏导。
- $\det(H)$ ：Hessian 行列式，即 DoH 响应。

- **含义：** $\det(H)$ 在斑点处最大，用于斑点检测（SURF 的基础）。

梯度类处理的作用：

处理	作用
一阶梯度	提取边缘/纹理信号，对光照偏移不敏感
幅值+方向	为方向直方图提供权重与分箱
结构张量	区分平坦/边缘/角点
Harris/Shi-Tomasi	给出角点响应，用于检测
Hessian	给出斑点响应，用于 DoH 检测

3.3 直方图编码与量化

方向直方图是最常见的编码方式。给定方向集合 $\{\theta_i\}$ 与权重 $\{w_i\}$ ：

$$h_b = \sum_i w_i \cdot 1[\theta_i \in \text{bin}_b]$$

其中：

- h_b ：第 b 个方向箱的直方图值。
- θ_i ：第 i 个样本的梯度方向。
- w_i ：第 i 个样本的权重（通常为梯度幅值 $\times$ 高斯窗）。
- $1[\cdot]$ ：指示函数，方向落入该箱时为 1。
- **含义：**把邻域内所有梯度按方向投票累加，得到对方向分布的统计描述。

SIFT 使用**三线形插值**把样本分配到相邻的子区域和相邻的方向箱，避免分箱边界效应：

$$w = w_{sub} \cdot w_{ori}$$

其中：

- w_{sub} ：样本在相邻子区域上的线性权重。
- w_{ori} ：样本在相邻方向箱上的线性权重。
- **含义：**一个样本按距离同时贡献给相邻格点，消除"硬分箱"造成的突变，提升稳定性。

归一化的作用：

- L2 归一化：抑制对比度变化
- 截断（clip 0.2）后再次归一化：抑制主导梯度

- L1 + 开方 (RootSIFT)：改善分布稳定性

RootSIFT 的做法：

$$\mathbf{v}_{root} = \sqrt{\frac{\mathbf{v}_{L1}}{\|\mathbf{v}\|_1}}$$

其中：

- $\mathbf{v}$ ：原始 SIFT 描述子。
- $\|\mathbf{v}\|_1$ ：L1 范数（各元素绝对值之和）。
- $\mathbf{v}_{L1}$ ：L1 归一化后的向量。
- $\sqrt{\cdot}$ ：逐元素开方。
- 含义：L1 归一化 + 开方使分布更接近高斯，配合 Hellinger 距离可显著提升匹配性能。

直方图编码处理的作用：

处理	作用
方向分箱	把连续方向离散成固定维度
幅值加权	让强边缘主导统计，弱噪声被抑制
高斯窗加权	降低离中心较远样本的影响
三线性插值	消除分箱边界效应，提升稳定性
L2 归一化	抑制对比度/光照变化
clip + 再归一化	抑制单个主导梯度的影响
L1 + 开方	改善分布，提升匹配鲁棒性

3.4 二进制测试与汉明度量

二进制描述子由一组**强度比较**构成：

$$\tau(I; \mathbf{p}, \mathbf{q}) = \begin{cases} 1, & I(\mathbf{p}) < I(\mathbf{q}) \\ 0, & \text{否则} \end{cases}$$

其中：

- $I(\mathbf{p}), I(\mathbf{q})$ ：两个采样点处的灰度值。
- $\mathbf{p}, \mathbf{q}$ ：采样点坐标。
- τ ：比较结果，1 位二进制。

- **含义**：只比较两点亮度大小，天然对光照的单调变化（如整体变亮）不敏感。

一个 d 位描述子：

$$f_d(I) = \sum_{i=1}^d 2^{i-1} \tau(I; \mathbf{p}_i, \mathbf{q}_i)$$

其中：

- d ：描述子位数。
- 2^{i-1} ：第 i 位的权重（二进制位权）。
- $\tau(I; \mathbf{p}_i, \mathbf{q}_i)$ ：第 i 个测试的结果。
- **含义**：把 d 个比较结果打包成一个 d 位整数，匹配时用汉明距离。

采样模式 $\{(\mathbf{p}_i, \mathbf{q}_i)\}$ 决定了描述子的性能：

- BRIEF：随机采样，无旋转不变性
- ORB：学习式选择去相关样本对，并把采样模式按主方向旋转
- BRISK：同心圆采样，长短对分开使用
- FREAK：视网膜式采样，带级联

二进制描述子处理的作用：

处理	作用
强度比较	生成 0/1 位，对光照单调变化不敏感
采样模式设计	决定区分性与抗噪性
主方向旋转	赋予旋转不变性（ORB/BRISK）
位打包	压缩存储，支持快速 XOR 匹配
级联比较	提前筛除候选，加速匹配（FREAK）

3.5 矩与正交基

几何矩：

$$m_{pq} = \sum_x \sum_y x^p y^q I(x, y)$$

其中：

- m_{pq} ：阶数为 (p, q) 的几何矩。

- x, y : 像素坐标。
- $I(x, y)$: 像素灰度（或质量）。
- p, q : x, y 的幂次。
- **含义**: 把图像当作二维分布，用坐标幂次的加权和描述其形状统计量。

中心矩:

$$\mu_{pq} = \sum_x \sum_y (x - \bar{x})^p (y - \bar{y})^q I(x, y)$$

其中:

- $\bar{x}, \bar{y}$: 图像质心坐标。
- **含义**: 以质心为原点计算矩，从而消除平移影响，获得平移不变性。

归一化中心矩:

$$\eta_{pq} = \frac{\mu_{pq}}{\mu_{00}^{1 + \frac{p+q}{2}}}$$

其中:

- μ_{00} : 零阶矩（图像总质量）。
- $1 + \frac{p+q}{2}$: 归一化指数。
- **含义**: 除以 μ_{00} 的幂，消除尺度影响，获得尺度不变性。

Hu 七不变矩由 η_{pq} 组合而成，对平移、旋转、尺度不变:

$$\begin{aligned}\phi_1 &= \eta_{20} + \eta_{02} \\ \phi_2 &= (\eta_{20} - \eta_{02})^2 + 4\eta_{11}^2 \\ \phi_3 &= (\eta_{30} - 3\eta_{12})^2 + (3\eta_{21} - \eta_{03})^2 \\ &\dots\end{aligned}$$

其中:

- ϕ_1 : 总惯性（对旋转不敏感）。
- ϕ_2 : 各向异性度量。
- ϕ_3 : 三阶矩组合，描述不对称性。
- **含义**: 七个由归一化中心矩组合而成的量，对平移、旋转、尺度均不变，是经典形状描述子。

Zernike 矩: 在单位圆盘上以正交多项式为基:

$$Z_{nm} = \frac{n+1}{\pi} \int_0^{2\pi} \int_0^1 \overline{V_{nm}(\rho, \theta)} f(\rho, \theta) \rho d\rho d\theta$$

其中：

- n ：阶数； m ：重复度 ($|m| \leq n$)。
- $V_{nm}(\rho, \theta)$ ：Zernike 正交多项式基。
- $\overline{V_{nm}}$ ：共轭。
- ρ, θ ：极坐标； ρ 为积分权重（面积元）。
- $\frac{n+1}{\pi}$ ：归一化系数。
- 含义**：在单位圆盘上用正交基展开图像，矩之间不冗余，取模 $|Z_{nm}|$ 即得旋转不变描述子。

正交性使得矩之间信息不冗余，且可以做到旋转不变（取模）。

矩类处理的作用：

处理	作用
几何矩	描述形状的全局统计量
中心化	消除平移影响
归一化	消除尺度影响
组合 (Hu)	构造旋转不变的不变量
正交基 (Zernike)	去除冗余，支持旋转不变与重建

3.6 滤波与纹理

Gabor 滤波：

$$g(x, y; \lambda, \theta, \psi, \sigma, \gamma) = \exp\left(-\frac{x'^2 + \gamma^2 y'^2}{2\sigma^2}\right) \exp\left(i\left(2\pi\frac{x'}{\lambda} + \psi\right)\right)$$

其中

$$x' = x \cos \theta + y \sin \theta, \quad y' = -x \sin \theta + y \cos \theta$$

其中：

- λ ：波长（频率的倒数）。
- θ ：滤波方向。
- ψ ：相位偏移。
- σ ：高斯包络标准差。
- γ ：空间纵横比（椭圆度）。

- x', y' : 旋转到滤波主方向后的坐标。
- 第一项: 高斯包络 (局部化) ; 第二项: 复正弦 (频率选择) 。
- **含义**: Gabor 是 "局部化 + 方向 + 频率" 的联合滤波器, 能提取特定方向与频率的纹理。

LBP (局部二值模式) :

$$\text{LBP}_{P,R} = \sum_{p=0}^{P-1} s(g_p - g_c) 2^p, \quad s(x) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

其中:

- P : 邻域采样点数。
- R : 邻域半径。
- g_c : 中心像素灰度。
- g_p : 第 p 个邻域像素灰度。
- $s(\cdot)$: 符号函数, 邻域比中心亮为 1。
- 2^p : 位权。
- **含义**: 把邻域与中心的亮度比较编码成一个 P 位二进制数, 描述局部纹理模式。

均匀模式: 0/1 跳变不超过 2 次的模式, 占自然图像绝大多数, 因此 LBP^{u2} 用 $P(P-1) + 3$ 个箱代替 2^P 个箱, 大幅降维。

GLCM (灰度共生矩阵): 给定偏移 δ , 统计灰度对 (i, j) 的出现次数:

$$P_\delta(i, j) = \#\{(x, y) : I(x, y) = i, I(x + \delta_x, y + \delta_y) = j\}$$

其中:

- $\delta = (\delta_x, \delta_y)$: 像素对偏移 (距离与方向) 。
- i, j : 两个灰度级。
- $\#$: 满足条件的像素对个数。
- **含义**: 统计 "灰度 i 旁边出现灰度 j " 的频率, 刻画纹理的空间共生规律。

Haralick 特征从 P_δ 派生:

$$\text{Contrast} = \sum_{i,j} (i - j)^2 P(i, j)$$

$$\text{Energy} = \sum_{i,j} P(i, j)^2, \quad \text{Homogeneity} = \sum_{i,j} \frac{P(i, j)}{1 + |i - j|}$$

$$\text{Correlation} = \sum_{i,j} \frac{(i - \mu_i)(j - \mu_j)P(i, j)}{\sigma_i \sigma_j}$$

其中：

- $P(i, j)$ ：归一化后的共生矩阵元素。
- μ_i, μ_j ：行/列均值； σ_i, σ_j ：行/列标准差。
- Contrast：灰度差越大值越大，反映纹理对比度。
- Energy：矩阵越集中值越大，反映纹理均匀性。
- Homogeneity：相邻灰度越接近值越大，反映局部平滑度。
- Correlation：反映灰度沿方向的线性相关程度。
- 含义：从共生矩阵派生出一组标量，把纹理压缩成可分类的特征向量。

滤波/纹理处理的作用：

处理	作用
Gabor 滤波	提取特定方向/频率的纹理能量
LBP 比较	编码局部微纹理，对光照单调变化鲁棒
均匀模式降维	大幅减少直方图维度
GLCM 统计	刻画灰度空间共生规律
Haralick 特征	把纹理压缩成可分类的标量

3.7 子空间与统计学习

PCA (Eigenfaces) ：对中心化数据求协方差矩阵特征向量：

$$C = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^T$$

其中：

- N ：样本数。
- $\mathbf{x}_i$ ：第 i 个样本向量。
- $\bar{\mathbf{x}}$ ：样本均值。
- C ：协方差矩阵。
- 含义： C 的特征向量给出数据方差最大的方向，取前 k 个作为投影基，实现降维。

保留前 k 个最大特征值对应的特征向量作为投影基。

LDA (Fisherfaces) ：最大化类间散度与类内散度之比：

$$W = \arg \max_W \frac{|W^T S_B W|}{|W^T S_W W|}$$

其中：

- W ：投影矩阵。
- S_B ：类间散度矩阵。
- S_W ：类内散度矩阵。
- $|\cdot|$ ：行列式。
- **含义**：寻找使类间距离大、类内距离小的投影方向，比 PCA 更具判别性。

GMM 与 Fisher Vector：用高斯混合建模局部描述子分布，再对参数求梯度：

$$\mathcal{G}_\mu = \frac{1}{N\sqrt{\pi_k}} \sum_i \gamma_i(k) \frac{\mathbf{x}_i - \boldsymbol{\mu}_k}{\boldsymbol{\sigma}_k}$$

其中：

- N ：描述子总数。
- π_k ：第 k 个高斯分量的权重。
- $\gamma_i(k)$ ：描述子 $\mathbf{x}_i$ 属于第 k 个分量的后验概率。
- $\boldsymbol{\mu}_k, \boldsymbol{\sigma}_k$ ：第 k 个分量的均值与标准差。
- **含义**：对 GMM 参数求梯度，把描述子集合编码成固定维度向量，保留二阶统计信息。

VLAD (Vector of Locally Aggregated Descriptors) :

$$\mathbf{v}_k = \sum_{i: \text{NN}(\mathbf{x}_i)=c_k} (\mathbf{x}_i - c_k)$$

其中：

- c_k ：第 k 个聚类中心。
- $\text{NN}(\mathbf{x}_i)$ ： $\mathbf{x}_i$ 的最近聚类中心。
- $\mathbf{x}_i - c_k$ ：描述子相对中心的残差。
- **含义**：把每个簇内所有描述子的残差求和，得到 $K \times d$ 维聚合向量。

再做幂律归一化与 L2 归一化。

NetVLAD：把硬分配替换为软分配：

$$\bar{a}_k(\mathbf{x}_i) = \frac{e^{\mathbf{w}_k^T \mathbf{x}_i + b_k}}{\sum_{k'} e^{\mathbf{w}_{k'}^T \mathbf{x}_i + b_{k'}}}$$

其中：

- $\mathbf{w}_k, b_k$: 第 k 个簇的可学习权重与偏置。
- $\bar{a}_k(\mathbf{x}_i)$: 软分配权重（类似 softmax）。
- 含义：用可微的软分配代替硬聚类，使 VLAD 可端到端训练。

子空间/聚合处理的作用：

处理	作用
PCA	降维、去相关、保留最大方差
LDA	提升类间判别性
GMM + 梯度	保留分布的二阶统计信息
VLAD 残差聚合	紧凑编码局部描述子集合
软分配 (NetVLAD)	使聚合可微、可学习

3.8 不变性的构造手段

不变性	构造手段	数学操作
平移	使用相对坐标/局部邻域	以关键点为中心建立坐标系
旋转	估计主方向并旋转采样	梯度方向直方图峰值 θ^*
尺度	尺度空间极值 + 尺度归一化窗口	$\sigma^2 \nabla^2 L$ 极值
仿射	二阶矩矩阵归一化	$\Sigma^{-1/2}$ 变换到单位圆
光照对比度	归一化	L2/L1 归一化、clip
光照偏移	差分	梯度、强度比较
视角	多视角数据或学习	度量学习、注意力匹配

主方向估计（SIFT）：

$$\theta^* = \arg \max_{\theta} \sum_i w_i 1[\theta_i \in \text{bin}(\theta)]$$

其中：

- θ^* : 估计出的主方向。
- θ_i : 第 i 个样本的梯度方向。
- w_i : 权重（梯度幅值 × 高斯窗）。

- $\text{bin}(\theta)$: 方向 θ 对应的直方图箱。
- **含义**: 取方向直方图的峰值作为主方向, 后续按此方向旋转采样, 获得旋转不变性。

其中权重为梯度幅值乘以高斯窗。

3.9 相似度度量与匹配

欧氏距离:

$$d_2(\mathbf{a}, \mathbf{b}) = \|\mathbf{a} - \mathbf{b}\|_2$$

其中:

- $\mathbf{a}, \mathbf{b}$: 两个描述子向量。
- $\|\cdot\|_2$: L2 范数。
- **含义**: 向量空间中的直线距离, 用于浮点描述子匹配。

余弦相似度:

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|}$$

其中:

- $\mathbf{a} \cdot \mathbf{b}$: 点积。
- $\|\mathbf{a}\|, \|\mathbf{b}\|$: 向量模长。
- **含义**: 只关心方向夹角, 对向量长度 (幅值) 不敏感, 适合归一化后的描述子。

最近邻距离比 (NNDR / Lowe ratio test) :

$$\frac{d(\mathbf{a}, \mathbf{b}_1)}{d(\mathbf{a}, \mathbf{b}_2)} < \rho$$

其中:

- $\mathbf{b}_1$: 最近邻描述子。
- $\mathbf{b}_2$: 次近邻描述子。
- ρ : 比率阈值 (常取 0.6–0.8)。
- **含义**: 只有当最近邻明显优于次近邻时才接受匹配, 有效剔除模糊/重复纹理的误匹配。

其中 $\mathbf{b}_1$ 是最近邻、 $\mathbf{b}_2$ 是次近邻, ρ 常取 0.6–0.8。

几何验证: 用 RANSAC 拟合单应/基础矩阵, 剔除外点:

$$H^* = \arg \max_H \sum_i 1 [\|\mathbf{x}'_i - H\mathbf{x}_i\| < \epsilon]$$

其中：

- H ：待拟合的单应矩阵。
- $\mathbf{x}_i, \mathbf{x}'_i$ ：一对匹配点。
- ϵ ：内点距离阈值。
- $1[\cdot]$ ：内点指示函数。
- **含义**：寻找使最多匹配点满足几何约束的 H ，从而剔除外点、保留几何一致的匹配。

匹配处理的作用：

处理	作用
欧氏/余弦距离	度量描述子相似度
NNDR 比率检验	剔除模糊匹配
交叉检验	保证互为最近邻
RANSAC	剔除外点，保证几何一致

4. 关键点检测子 (Keypoint Detectors)

4.1 角点检测

检测子	原理	特点
Moravec	各方向灰度差最小值的局部极大	最早，无旋转不变性
Harris-Stephens	结构张量 + 响应函数	旋转不变，光照鲁棒
Shi-Tomasi	$\min(\lambda_1, \lambda_2)$	更稳定的跟踪角点
Förstner	协方差矩阵 + 圆度	精度高，用于配准
Kitchen-Rosenfeld	梯度方向变化率	计算简单
FAST	圆周 Bresenham 测试	极快，无尺度不变
AGAST	FAST 的自适应泛化	更快的 FAST 变体
oFAST	FAST + 强度质心方向	ORB 的检测子

Harris 推导：对邻域做一阶泰勒展开：

$$I(x + \Delta x, y + \Delta y) \approx I(x, y) + I_x \Delta x + I_y \Delta y$$

其中：

- $\Delta x, \Delta y$ ：窗口的小位移。
- I_x, I_y ：图像梯度。
- 含义：**用一阶近似描述窗口移动后的灰度变化，是推导角点响应的起点。

平方误差和：

$$E(\Delta x, \Delta y) = \sum_w (I_x \Delta x + I_y \Delta y)^2 = \mathbf{d}^T M \mathbf{d}$$

其中：

- E ：窗口移动后的灰度平方差。

- $\mathbf{d} = [\Delta x, \Delta y]^T$: 位移向量。
- M : 结构张量（自相关矩阵）。
- **含义**: E 可写成二次型, M 的特征值决定各方向移动时 E 的增长快慢, 从而区分角点。

对 M 做特征值分析, 则得到角点判据。

FAST 判据: 圆形半径 3 的 16 像素圆周上, 若有连续 N (通常 9 或 12) 个像素 都比中心亮/暗超过阈值 t , 则判为角点:

$$\exists \text{ 连续 } N \text{ 个 } p: |I(p) - I(c)| > t$$

其中:

- p : 圆周上的像素。
- c : 中心像素。
- $I(\cdot)$: 灰度值。
- t : 亮度差阈值。
- N : 连续满足条件的像素数 (常取 9 或 12) 。
- **含义**: 只需比较圆周像素与中心, 无需梯度/卷积, 因此极快。

强度质心方向 (oFAST) :

$$m_{pq} = \sum_{x,y} x^p y^q I(x, y), \quad \theta = \text{atan2}(m_{01}, m_{10})$$

其中:

- m_{pq} : 图像矩。
- m_{10}, m_{01} : 一阶矩 (质心坐标) 。
- θ : 主方向。
- **含义**: 用亮度质心相对几何中心的方向作为主方向, 计算极快, 为 ORB 提供旋转不变性。

4.2 斑点与区域检测

检测子	原理	特点
LoG	尺度归一化高斯拉普拉斯极值	尺度不变
DoG	相邻高斯差	SIFT 的核心
DoH	Hessian 行列式	SURF 的基础
SIFT 检测子	DoG 极值 + 亚像素定位 + 边缘剔除	尺度/旋转不变
SURF 检测子	积分图 + 盒滤波 Hessian	速度快
BRISK 检测子	AGAST + 尺度空间	快速多尺度
CenSurE / STAR	多尺度中心环绕滤波	近似尺度不变
MSER	阈值扫描 + 连通域稳定性	仿射不变性强
EBR / IBR	边缘/强度极值区域	早期区域检测
KAZE / AKAZE	非线性尺度空间	保边、重复性好
SUSAN	最小核同值区	角点+边缘统一框架
Hessian-Laplace	Hessian 定位 + LoG 尺度	更稳定的尺度选择
Harris-Laplace	Harris 定位 + LoG 尺度	经典仿射不变检测
Harris-Affine	迭代仿射归一化	仿射不变
Hessian-Affine	Hessian 定位 + 仿射归一化	仿射不变

MSER 稳定性判据：随阈值 θ 扫描，连通域面积变化率取局部极小：

$$q(i) = \frac{|A(i + \Delta) - A(i - \Delta)|}{A(i)}$$

其中：

- $A(i)$ ：阈值 i 下连通域的面积。
- Δ ：阈值步长。
- $q(i)$ ：面积变化率。
- **含义：** $q(i)$ 的局部极小对应面积随阈值变化最稳定的区域，即 MSER 区域，具有强仿射不变性。

4.3 边缘检测子

检测子	原理
Roberts	2×2 差分算子
Sobel	3×3 平滑+差分
Prewitt	均匀加权差分
Scharr	更精确的旋转对称差分
Laplacian	二阶微分零交叉
LoG / Marr–Hildreth	平滑后二阶微分
Canny	高斯平滑 + 非极大抑制 + 双阈值滞后
结构化边缘（SE）	随机森林预测边缘

Canny 的非极大抑制：沿梯度方向比较，只保留局部极大：

keep if $m(x,y) \geq m(x \pm \delta \cos \theta, y \pm \delta \sin \theta)$

其中：


- $m(x,y)$ ：(x,y) 处的梯度幅值。
- θ ：该点梯度方向。
- δ ：沿梯度方向的采样步长。
- **含义：**只有幅值不小于沿梯度方向两侧邻点的像素才保留，从而把粗边缘细化成单像素宽。

边缘检测处理的作用：

处理	作用
高斯平滑	抑制噪声，避免伪边缘
一阶/二阶微分	定位灰度突变（边缘）
非极大抑制	细化边缘到单像素宽
双阈值滞后	连接强边缘、抑制弱噪声边缘

5. 局部描述子 (Local Descriptors) 逐类详解

局部描述子家族总览：



5.1 梯度方向直方图类

SIFT (Scale-Invariant Feature Transform, 128 维)

流程：

- 尺度空间极值： $D(x, y, \sigma)$ 在 3D 邻域 (含相邻尺度) 中比较
- 亚像素定位：泰勒展开求极值偏移

$$\hat{\mathbf{x}} = - \left(\frac{\partial^2 D}{\partial \mathbf{x}^2} \right)^{-1} \frac{\partial D}{\partial \mathbf{x}}$$

其中：

- $\hat{\mathbf{x}}$ ：极值点相对采样点的亚像素偏移。
- $\frac{\partial D}{\partial \mathbf{x}}$ ：DoG 的一阶导 (梯度)。
- $\frac{\partial^2 D}{\partial \mathbf{x}^2}$ ：DoG 的 Hessian (二阶导)。
- 含义：用泰勒展开把极值位置精确到亚像素，提升关键点定位精度。
- 边缘剔除：主曲率比判据


$$\frac{(\text{tr } H)^2}{\det H} < \frac{(r + 1)^2}{r}, \quad r \approx 10$$

其中：

- H ：关键点处的 Hessian。
- $\text{tr } H$ ：迹（主曲率之和）。
- $\det H$ ：行列式（主曲率之积）。
- r ：主曲率比阈值（约 10）。
- **含义**：边缘点的主曲率比很大，该判据剔除不稳定的边缘响应，只保留角点/斑点。
- **方向分配**：36 箱梯度方向直方图，峰值为主方向，达到峰值 80% 的方向作辅方向
- **描述子**：16×16 邻域内 4×4 子区域，每子区域 8 方向 → 128 维
- **归一化**：L2 归一化 → clip 0.2 → 再 L2 归一化

SIFT 的数学核心是"梯度方向统计 + 局部空间分块 + 全局归一化"。

SIFT 特征提取处理流程与作用：



处理	作用
尺度空间	获得尺度不变性
DoG 极值	高效定位斑点/角点
亚像素定位	提升定位精度
边缘剔除	去除不稳定边缘响应
主方向分配	获得旋转不变性
空间分块 + 方向直方图	编码局部结构，提升区分性
L2 + clip + L2	抑制光照/对比度与主导梯度影响

SURF (Speeded-Up Robust Features, 64/128 维)

用盒滤波近似 Hessian：

$$\det(H_{approx}) = D_{xx}D_{yy} - (0.9 D_{xy})^2$$

其中：

- D_{xx}, D_{yy} : 盒滤波近似的二阶偏导。
- D_{xy} : 混合偏导近似。
- 0.9: 经验修正系数, 补偿盒滤波近似误差。
- **含义**: 用积分图 + 盒滤波快速计算 Hessian 行列式, 大幅加速斑点检测。

方向分配: 在半径 6σ 的圆域内计算 Haar 小波响应 d_x, d_y , 用 60° 滑动窗口求和, 最大值方向为主方向。

描述子: 4×4 子区域, 每区域统计

$$(\sum d_x, \sum d_y, \sum |d_x|, \sum |d_y|) \rightarrow 64$$

其中:

- d_x, d_y : Haar 小波在水平/垂直方向的响应。
- $\sum d_x, \sum d_y$: 响应之和 (带符号, 反映方向)。
- $\sum |d_x|, \sum |d_y|$: 响应绝对值之和 (反映强度)。
- **含义**: 每个子区域用 4 个统计量描述, 4×4 子区域共 64 维, 兼顾方向与强度。

扩展版本加入 $\sum d_y$ 的符号 $\rightarrow 128$ 维。

GLOH (Gradient Location and Orientation Histogram, 128 维)

- 采用**对数极坐标**分箱: 3 个半径 $\times$ 8 个角度 = 17 个空间箱
- 每箱 16 个方向箱 $\rightarrow 272$ 维
- 用 PCA 降到 128 维
- 比 SIFT 更具区分性, 但计算更贵

DAISY (200 维)

- 面向**稠密**匹配设计
- 在每个采样点周围用高斯加权方向直方图
- 用可分离卷积快速计算
- 适合宽基线立体匹配

HOG (Histogram of Oriented Gradients)

流程:

- 1. 计算梯度幅值与方向
- 2. 把图像划分为 cell (如 8×8) , 每 cell 统计 9 个方向箱 (0–180°)
- 3. 若干 cell 组成 block (如 2×2) , 对 block 内特征做 **L2-Hys** 归一化
- 4. 拼接所有 block 特征

L2-Hys 归一化:


$$\mathbf{v} \leftarrow \frac{\mathbf{v}}{\sqrt{\|\mathbf{v}\|_2^2 + \epsilon^2}}, \quad v_i \leftarrow \min(v_i, 0.2), \quad \text{再归一化}$$

其中:

- **v**: block 内拼接的梯度直方图向量。
- $\|\mathbf{v}\|_2$: L2 范数。
- ϵ : 防止除零的小常数。
- 0.2: 截断阈值。
- **含义**: 先 L2 归一化抑制对比度, 再截断抑制主导梯度, 最后再归一化, 提升光照鲁棒性。

HOG 是行人检测 (HOG + SVM) 与 DPM 的核心。

HOG 特征提取处理流程与作用:



处理	作用
梯度计算	提取边缘/轮廓信号，对光照偏移不敏感
cell 直方图	局部方向统计，保留空间结构
block 拼接	引入邻域上下文，提升区分性
L2-Hys 归一化	抑制对比度与主导梯度，提升光照鲁棒性

相关变体

名称	特点
PCA-SIFT	对梯度块做 PCA 降维到 20 维
RootSIFT	SIFT 描述子 L1 归一化后开方
RIFT	旋转不变特征变换，用环形分箱
CSIFT	颜色不变 SIFT
OpponentSIFT	在对立色通道上计算 SIFT
DSP-SIFT	尺度池化，提升匹配性能
PHOG	金字塔 HOG，用于形状/场景
HOG3D	时空梯度直方图
PIFF	像素级特征融合的类 HOG 全局特征

5.2 二进制描述子类

BRIEF (Binary Robust Independent Elementary Features, 128–512 bit)

$$f(I) = \sum_i 2^{i-1} \tau(I; \mathbf{p}_i, \mathbf{q}_i)$$

其中：

- $f(I)$ ：BRIEF 描述子（一个整数）。
- $\tau(I; \mathbf{p}_i, \mathbf{q}_i)$ ：第 i 个强度比较结果（0/1）。
- $\mathbf{p}_i, \mathbf{q}_i$ ：第 i 对采样点。
- 2^{i-1} ：位权。
- **含义**：把一组随机采样对的强度比较打包成二进制串，匹配用汉明距离，极快。
- 采样对从高斯分布抽取
- **无旋转不变性、无尺度不变性**，对模糊较敏感
- 匹配用汉明距离，极快

ORB (Oriented FAST and Rotated BRIEF, 256 bit)

- 1. oFAST 检测 + 强度质心方向
- 2. Steered BRIEF：把采样模式按方向 θ 旋转


$$R_{\theta} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$

其中：

- R_{θ} ：旋转矩阵。
- θ ：关键点主方向（由强度质心估计）。
- 含义：把 BRIEF 的采样坐标按主方向旋转，使描述子随图像旋转而一致变化，获得旋转不变性。
- rBRIEF：用贪心搜索在训练集上选出去相关、方差大的 256 个测试对
- 加入金字塔实现尺度不变性

ORB 是 ORB-SLAM 的基石，兼顾速度与质量。

二进制描述子特征提取处理流程与作用：



处理	作用
oFAST 检测	快速定位角点
强度质心方向	估计主方向，提供旋转不变性
旋转采样模式	使描述子随旋转一致变化
强度比较	生成 0/1 位，对光照单调变化不敏感
位打包	压缩存储，支持快速 XOR 匹配

BRISK (Binary Robust Invariant Scalable Keypoints, 512 bit)

- 采样模式：同心圆（半径按指数增长），共 60 个采样点
- 短对 ($< \delta_{max}$)：用于估计方向
- 长对 ($> \delta_{min}$)：用于构造描述子

- 512 bit, 匹配快

FREAK (Fast Retina Keypoint, 512 bit)

- **视网膜式采样**：中心密集、外围稀疏，模拟人眼感受野
- 通过**级联比较**逐步筛选，前面若干位就能筛掉大量候选
- 用 45 个感受野之间的比较构成二进制串

其他二进制描述子

名称	特点
LATCH	学习式三像素比较，抗噪更好
LIOP	局部强度序模式，利用像素排序
BOLD	自适应在线学习二值测试
BinBoost	Boosting 学习二进制哈希
AKAZE-MLDB	非线性尺度空间 + 改进 LDB
KAZE 描述子	非线性尺度 + 类 SURF 浮点描述子
D-BRIEF	面向稠密的 BRIEF 变体

5.3 区域与仿射描述子

名称	特点
MSER 区域	稳定性极强的仿射不变区域
Harris-Affine 区域	迭代估计仿射形状
Hessian-Affine 区域	Hessian 版本
EBR / IBR	早期极值区域
局部强度序	序统计描述

这些区域经过仿射归一化后，再送入 SIFT/SURF 描述子，即可获得仿射不变特征。

5.4 矩型局部描述子

名称	特点
图像矩	可构造平移/旋转/尺度不变
Zernike 矩	正交基，旋转不变，重建能力强
伪 Zernike 矩	放宽正交性，数值更稳
Legendre 矩	正交多项式，在矩形区域定义
Tchebichef / Krawtchouk 矩	离散正交矩，适合数字图像
小波矩	多分辨率 + 矩

6. 全局描述子 (Global Descriptors)

6.1 GIST / 空间包络


对人类场景感知的近似建模：

- 1. 对图像做多尺度、多方向的 Gabor 滤波
- 2. 把每张响应图划成 4×4 网格
- 3. 对每个网格取平均能量

维度 = 尺度数 × 方向数 × 网格数（典型 512）。

GIST 用于场景分类与快速图像检索。

GIST 特征提取处理流程与作用：



处理	作用
Gabor 滤波组	提取多方向/多尺度纹理能量
网格划分	保留粗略空间布局（空间包络）
平均能量	压缩成紧凑的全局向量

6.2 全局颜色统计

- 颜色直方图
- 颜色矩（均值、方差、偏度）
- 颜色聚合向量（CCV）
- 颜色相关图（correlogram）

6.3 全局纹理统计

- GLCM / Haralick
- Tamura 特征：粗糙度、对比度、方向性、线状性、规则性、粗略度
- 小波能量
- MR8 滤波组响应直方图

6.4 全局形状描述


- Hu 矩
- Zernike 矩
- Fourier 描述子
- 骨架图

6.5 全局聚合描述子

- **BoW (Bag of Words)** : 局部描述子聚类成词袋, 统计词频
 - **Fisher Vector**: GMM 梯度聚合
 - **VLAD**: 残差聚合
 - **CNN 全局池化**: VGG/ResNet 特征 + average/max/GeM/R-MAC 池化
-

7. 纹理描述子 (Texture Descriptors)

纹理描述子分类与处理:



类别	方法	原理
统计型	GLCM、GLRLM、LBP、灰度梯度	统计像素对/游程/局部模式
滤波型	Gabor、MR8、小波、可操纵滤波	多方向多尺度响应能量
模型型	马尔可夫随机场、分形维数	用概率模型描述纹理生成
变换型	傅里叶能量、Gabor 谱、小波	频域能量分布
结构型	形态学、纹理单元、Textons	重复基元的排列
感知型	Tamura	按人类视觉描述词汇

LBP 的常用变体:

变体	特点
LBP^{u2}	均匀模式，降维
LBP^{ri}	旋转不变
LBP^{riu2}	旋转不变均匀模式
CLBP	加入幅值与中心像素信息
LBP-HF	傅里叶域的旋转不变 LBP
CS-LBP	中心对称比较，维度更低
LBP-TOP	时空三维 LBP，用于视频
多尺度 LBP	多半径组合

Textons: 先用滤波组响应聚类得到纹理基元，再用基元直方图表示纹理。

8. 颜色描述子 (Color Descriptors)

8.1 颜色直方图族

- RGB / HSV / Lab 三通道直方图
- 联合直方图 vs 边缘分布
- 加空间信息的直方图 (分块、环形)

8.2 颜色矩

一阶矩 (均值)、二阶矩 (标准差)、三阶矩 (偏度) :

$$\mu_k = \frac{1}{N} \sum_i p_{ik}, \quad \sigma_k = \left(\frac{1}{N} \sum_i (p_{ik} - \mu_k)^2 \right)^{1/2}, \quad s_k = \left(\frac{1}{N} \sum_i (p_{ik} - \mu_k)^3 \right)^{1/3}$$

其中:

- k : 颜色通道。
- N : 像素数。
- p_{ik} : 第 i 个像素在第 k 通道的取值。
- μ_k : 均值 (一阶矩), 反映平均亮度/颜色。
- σ_k : 标准差 (二阶矩), 反映对比度/颜色变化。
- s_k : 偏度 (三阶矩), 反映分布不对称性。
- **含义**: 用三个统计量概括每个通道的颜色分布, 维度极低, 适合快速检索。

8.3 颜色结构描述

- **CCV (Color Coherence Vector)**: 区分相干/非相干像素
- **Color Correlogram**: 颜色对的空间相关性
- **Color Names**: 把颜色映射到 11 个语言色名

8.4 颜色 SIFT 家族

在颜色空间中重复 SIFT 流程：

描述子	颜色空间
RGB-SIFT	各 RGB 通道分别做 SIFT
OpponentSIFT	对立色空间
HSV-SIFT / HueSIFT	HSV
rgSIFT	归一化 rg 色度
C-SIFT	色度不变量
Transformed Color SIFT	颜色变换不变

8.5 颜色描述子的匹配

- 直方图交集
- χ^2 距离

$$d_{\chi^2}(\mathbf{h}, \mathbf{g}) = \frac{1}{2} \sum_i \frac{(h_i - g_i)^2}{h_i + g_i}$$

其中：

- $\mathbf{h}, \mathbf{g}$ ：两个直方图。
 - h_i, g_i ：第 i 个箱的值。
 - 含义**：分母 $h_i + g_i$ 对每个箱做归一化，使大箱与小箱公平比较，适合直方图匹配。
 - EMD (Earth Mover's Distance)
-

9. 形状与轮廓描述子 (Shape / Contour Descriptors)

9.1 轮廓参数化

链码 (Freeman Chain Code) : 用 8 方向编码边界。

轮廓点复数表示:

$$z(k) = x(k) + i y(k)$$

其中:

- $z(k)$: 第 k 个轮廓点的复数表示。
- $x(k), y(k)$: 轮廓点坐标。
- i : 虚数单位。
- **含义**: 把二维轮廓点写成复数序列, 便于用傅里叶变换分析。

Fourier 描述子: 对 $z(k)$ 做 DFT:

$$Z(u) = \sum_{k=0}^{N-1} z(k) e^{-i2\pi uk/N}$$

其中:

- $Z(u)$: 第 u 个频率分量。
- N : 轮廓点数。
- $e^{-i2\pi uk/N}$: 傅里叶基。
- **含义**: 把轮廓分解成不同频率的谐波, 低频描述整体形状, 高频描述细节。

性质:

- 平移只改变 $Z(0)$ (去掉即可不变)
- 旋转只改变相位
- 尺度只改变幅值
- 取 $|Z(u)|$ 得到旋转不变描述子

9.2 曲率与尺度空间

曲率尺度空间 (CSS) :

$$\kappa(u, \sigma) = \frac{\dot{x}\ddot{y} - \ddot{x}\dot{y}}{(\dot{x}^2 + \dot{y}^2)^{3/2}}$$

其中:

- κ : 曲率。
- u : 弧长参数。
- σ : 平滑尺度。
- $\dot{x}, \dot{y}$: 一阶导; $\ddot{x}, \ddot{y}$: 二阶导。
- **含义**: 在不同平滑尺度下计算轮廓曲率, 零交叉点对应形状的显著拐点, 形成尺度树。

随 σ 增大, 曲率零交叉点从细节到整体逐层出现, 形成"尺度树"。

转向函数 (Turning Function) : 把边界累积转角作为弧长的函数, 对旋转、平移不变, 对尺度可归一化。

9.3 形状上下文 (Shape Context)

对形状上一点 p_i , 统计其余 $n - 1$ 个点的相对位置分布:

- 对数极坐标分箱: 12 个角度 $\times$ 5 个半径 = 60 箱
- 得到 60 维直方图

匹配代价:

$$C_{ij} = \frac{1}{2} \sum_{k=1}^K \frac{(h_i(k) - h_j(k))^2}{h_i(k) + h_j(k)}$$

其中:

- C_{ij} : 点 i 与点 j 的匹配代价。
- $h_i(k), h_j(k)$: 两点形状上下文直方图的第 k 个箱。
- K : 箱数 (60) 。
- **含义**: 用 χ^2 距离度量两点形状上下文的差异, 再用匈牙利算法求全局最优匹配。

用匈牙利算法求最优匹配。

9.4 其他形状描述子

名称	原理
Hu 矩	七个不变矩组合
Zernike 矩	正交基，旋转不变
距离变换 / 中轴	骨架描述
Chamfer 距离	边缘点距离匹配
多边形近似	Douglas–Peucker
B 样条	平滑轮廓参数化
骨架图	拓扑结构描述
形状上下文	点分布直方图
内距离 (Inner Distance)	基于内部测地距离

10. 光谱与子空间描述子 (Spectral / Basis / Subspace)

10.1 变换域

变换	用途
DFT	频域能量、平移不变
DCT	压缩、能量集中
小波 (Haar、Daubechies)	多分辨率纹理/形状
Gabor 族	方向-频率分解
可操纵滤波	任意方向的可调响应
梅林/傅里叶-梅林	尺度和旋转不变配准

10.2 子空间方法

方法	原理	应用
PCA	最大方差投影	Eigenfaces、降维
LDA	最大类间/类内比	Fisherfaces
ICA	统计独立分量	盲源分离
NMF	非负分解	部件化表示
稀疏编码	稀疏线性组合	图像分类
字典学习	学习过完备基	去噪、分类
谱图 (Spectral Graph)	图拉普拉斯特征	形状匹配

11. 学习型与深度描述子 (Learning-based)

11.1 经典学习型描述子

名称	学习方式
PCA-SIFT	对 SIFT 梯度块做 PCA
LDA 描述子	用判别分析投影
Random Ferns	随机蕨分类器
Random Forests 描述	决策森林输出
Boosting 描述子	AdaBoost 选择特征
度量学习描述子	三元组损失学习距离
DeepCompare / DeepDesc	浅层孪生网络 + 相似度损失
MatchNet	孪生网络 + 全连接度量

11.2 深度局部描述子

名称	核心思想
L2-Net	逐块归一化，改善匹配分布
HardNet	在 batch 内挖掘最难的负样本
SOSNet	引入二阶相似度正则
SuperPoint	自监督：MagicPoint + 单应变换自适应，输出检测+256 维描述子
SuperGlue	注意力图神经网络 + 最优传输匹配
D2-Net	联合检测与描述，单次前向
R2D2	可重复性与可靠性联合学习
DELF	语义特征 + 注意力池化
DELG	全局与局部联合，统一检索与匹配
LF-Net	全监督学习检测与描述
SIFT + 学习式筛选	学习式后处理/筛选

HardNet 的困难负样本挖掘：

$$\mathcal{L} = \frac{1}{N} \sum_i \max \left(0, 1 + d(\mathbf{a}_i, \mathbf{p}_i) - d(\mathbf{a}_i, \mathbf{n}_i^*) \right)$$

其中：

- N ：batch 内样本对数。
- $\mathbf{a}_i$ ：锚点描述子。
- $\mathbf{p}_i$ ：与锚点匹配的正样本。
- $\mathbf{n}_i^*$ ：batch 内最近的非匹配描述子（最难负样本）。
- $d(\cdot, \cdot)$ ：描述子距离。
- 1：边界（margin）。
- 含义：要求正样本距离比最难负样本至少小一个 margin，从而拉开正负样本分布。

其中 $\mathbf{n}^*$ 是批次内最近的非匹配描述子。

SuperPoint 的伪标签自监督：对图像施加随机单应变换，把关键点位置相应地变换，用形状一致的方式生成热力图监督信号。

11.3 深度全局与检索描述子

名称	特点
全连接层特征 (FC7 等)	早期迁移学习特征
全局平均池化 (GAP)	紧凑全局表示
GeM 池化	广义均值池化

$$\text{GeM} = \left(\frac{1}{|\mathcal{X}|} \sum_{x \in \mathcal{X}} x^p \right)^{1/p}$$

其中：

- $\mathcal{X}$ ：特征图上的激活值集合。
 - $|\mathcal{X}|$ ：元素个数。
 - p ：可学习/可调的幂次。
 - **含义**： $p = 1$ 退化为平均池化， $p \rightarrow \infty$ 趋近最大池化， 介于两者之间，可学习最优折中。
- | R-MAC | 多区域最大激活聚合 || NetVLAD | 可微 VLAD 层 || Fisher Vector + CNN | CNN 特征 + FV 编码 || BEBLID | 提升式二进制描述子 |

11.4 学习型描述子的关键损失

- 对比损失 (contrastive)
 - 三元组损失 (triplet)
 - 铰链/边界挖掘 (hard mining)
 - 排序损失 (ranking)
 - 归一化相关 / 相似度匹配损失 (NCC loss)
-

12. 立体匹配与光流描述子

12.1 稠密立体匹配代价

方法	原理
SAD	绝对差之和
SSD	平方差之和
NCC	归一化互相关
Census	强度比较位串 + 汉明距离
BT (Birchfield–Tomasi)	抗采样、对幅值不敏感
互信息 (MI)	统计依赖度，适跨模态
AD-Census	组合代价
半全局匹配 (SGM)	代价聚合 + 一致性检查

Census 变换：

$$C(p) = \bigotimes_{\mathbf{q} \in \mathcal{N}(p)} [I(\mathbf{q}) > I(p)]$$

其中：

- $C(p)$: 像素 p 的 Census 位串。
- $\mathcal{N}(p)$: p 的邻域。
- $\mathbf{q}$: 邻域像素。
- $I(\cdot)$: 灰度值。
- $\bigotimes$: 位串拼接。
- $[\cdot]$: 指示函数，邻域比中心亮为 1。
- 含义**: 把邻域与中心的亮度比较编码成位串，对光照幅值变化不敏感，匹配用汉明距离。

匹配用汉明距离。

12.2 光流

Lucas–Kanade（局部，亮度恒定假设）：

$$I(x + u, y + v) \approx I(x, y) + I_x u + I_y v$$

其中：

- u, v ：待求的光流（位移）。
- I_x, I_y ：空间梯度。
- **含义**：用一阶泰勒展开近似位移后的灰度，是光流约束方程的线性化。

最小化：

$$E(u, v) = \sum_W (I_x u + I_y v + I_t)^2$$

其中：

- E ：窗口内的亮度恒定误差。
- I_t ：时间梯度。
- W ：局部窗口。
- **含义**：在窗口内最小化亮度恒定误差，求解局部光流。

解：

$$\begin{bmatrix} u \\ v \end{bmatrix} = \left(\sum_W \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} \right)^{-1} \sum_W \begin{bmatrix} I_x I_t \\ I_y I_t \end{bmatrix}$$

其中：

- 左侧：待求光流向量。
- 括号内：结构张量之和（可逆性要求纹理丰富）。
- 右侧：梯度与时间梯度的相关向量。
- **含义**：最小二乘解，要求窗口内纹理丰富（结构张量可逆），否则出现孔径问题。

Horn–Schunck（全局，加平滑正则）：

$$E = \iint (I_x u + I_y v + I_t)^2 + \alpha^2 (\|\nabla u\|^2 + \|\nabla v\|^2) dx dy$$

其中：

- 第一项：亮度恒定误差（数据项）。
- 第二项：光流场的平滑正则项。

- α : 正则权重, 控制平滑强度。
- $\nabla u, \nabla v$: 光流场的空间梯度。
- 含义: 在整幅图上最小化\“亮度恒定 + 光流平滑\”, 用全局平滑约束解决孔径问题。

光流/立体匹配处理的作用:

处理	作用
亮度恒定假设	建立可解的约束方程
局部窗口最小二乘	求解局部光流 (LK)
全局平滑正则	解决孔径问题 (HS)
Census 比较	对光照幅值变化鲁棒
代价聚合	提升匹配稳定性 (SGM)

13. 视频与时序描述子

名称	原理
HOG3D	时空梯度方向直方图
HOF	光流方向直方图
MBH	运动边界直方图
iDT	改进稠密轨迹 + 四种描述子融合
Dense Trajectories	稠密采样点轨迹 + 轨迹形状描述
LBP-TOP	三正交平面 LBP
3D SIFT	时空 SIFT
C3D / I3D / Two-Stream	深度时空特征（学习型）
TimeSformer / VideoMAE	基于 Transformer 的视频表示

14. 匹配、索引与检索

14.1 匹配策略

- 暴力匹配 (brute force)
- 最近邻 + 距离比 (NNDR)
- 交叉检验 (cross-check / mutual NN)
- 比率检验 + 几何验证 (RANSAC)
- 互信息/相关 (跨模态)

14.2 近似最近邻索引

方法	原理
KD-Tree	递归空间划分
FLANN	自动选算法与参数
LSH	哈希碰撞近似近邻
Hamming 索引	二进制位串分块
层次 K-means	词袋倒排
乘积量化 (PQ)	子空间分解 + 码本
倒排文件 (IVF)	聚类桶 + 倒排
HNSW	分层可导航小世界图

14.3 检索流程

- 提取局部描述子
- 量化到视觉词 / 聚合 (BoW、VLAD、FV)
- 归一化 (幂律、L2、白化)
- 倒排索引 + 候选排序

5. 几何重排序 (RANSAC、空间验证)

15. 评价指标与基准数据集

15.1 指标

指标	含义
Repeatability	变换后同一物理点被重复检测的比例
Recall / Precision	匹配查全/查准
匹配得分 (matching score)	正确匹配比例
mAP	检索平均精度均值
定位误差	匹配点像素误差
描述子距离分布	正/负样本可分性
计算耗时 / 内存	效率代价

15.2 常用数据集与基准

名称	用途
Oxford VGG Affine	仿射不变性评测
HPatches	局部描述子现代基准
Brown / UBC	宽基线匹配
EVD	视角变化评测
MVS / PhotoTourism	3D 重建匹配
Oxford RobotCar	长时视觉定位
ImageNet / Places	全局表示与检索
Oxford5k / Paris6k / ROxford / RParis	图像检索
KITTI / EuRoC	视觉里程计、SLAM

16. 应用方向

16.1 几何与三维

应用	常用描述子
图像拼接/全景	SIFT、SURF、ORB
运动恢复结构 (SfM)	SIFT (COLMAP 等)
立体视觉与深度	Census、AD-Census、DAISY、SGM
多视图立体	DAISY、PatchMatch + 描述子
相机标定/配准	Harris、SIFT、棋盘角点
图像配准 (医学/遥感)	SIFT、MI、形状上下文

16.2 定位与机器人

应用	常用描述子
SLAM	ORB (ORB-SLAM) 、SuperPoint
视觉里程计	FAST + 光流、ORB
回环检测	BoW、NetVLAD、DELG
重定位	NetVLAD、全局描述子
视觉导航	全局描述子 + 局部匹配

16.3 检测与识别

应用	常用描述子
行人检测	HOG + SVM、DPM
人脸检测	Haar-like + AdaBoost、深度
通用目标检测	CNN 特征（发展自 HOG 思路）
人脸识别	LBPH、Eigenfaces、Fisherfaces、深度嵌入
表情/年龄	LBP、Gabor、深度
字符/OCR	HOG、LBP、投影特征、深度
文档表格/版面	线段、布局特征、深度布局模型

16.4 检索与分类

应用	常用描述子
图像检索	BoW、VLAD、Fisher Vector、DELF/DELG
近重复检测	全局描述子 + 哈希
场景分类	GIST、CNN 全局特征
纹理分类	LBP、Gabor、GLCM、Textons
商品/商标检索	局部描述子 + 聚合
视频检索	iDT、深度时空特征

16.5 跟踪与视频

应用	常用描述子
目标跟踪	LBP、HOG、相关滤波（KCF/MOSSE）、深度特征
动作识别	HOG3D、HOF、MBH、iDT、I3D
行人重识别	颜色直方图 + 深度嵌入
手势/姿态	形状上下文、骨架 + 深度

16.6 工业与其他

应用	常用描述子
表面缺陷检测	LBP、GLCM、Gabor
布料/材料纹理	LBP、Tamura、小波
遥感变化检测	SIFT、全局统计、深度
医学图像分析	LBP、Gabor、形状、深度
生物特征（指纹/虹膜）	方向场、Gabor、纹理编码
增强现实（AR）	ORB、SuperPoint、平面跟踪
文档扫描矫正	边缘 + 线段 + 单应

17. 选型与设计权衡

17.1 选择维度

需求	推荐
最高匹配精度、可离线	SIFT、RootSIFT、GLOH、SuperPoint
实时性需求高	ORB、BRISK、FREAK、AKAZE
极小内存	BRIEF/ORB（二进制）、LBP
强仿射变化	MSER + SIFT、Harris-Affine
非刚性形变	Shape Context、内距离
纹理分类	LBP、Gabor、GLCM、Textons
目标检测（经典）	HOG、Haar-like
大规模检索	VLAD、Fisher Vector、NetVLAD、深度全局
宽基线/难场景	SuperPoint + SuperGlue、D2-Net
跨模态	互信息、学习型嵌入

17.2 主要权衡

权衡	说明
维度 vs 速度	128 维 SIFT 精度高但慢；256 bit ORB 快但精度略低
不变性 vs 区分性	越不变往往越不具区分性
手工 vs 学习	学习型精度高，但依赖数据与算力
稀疏 vs 稠密	稀疏可匹配，稠密可建图
检测 vs 描述强制解耦	耦合（如 D2-Net）可联合优化
归一化强度	过强丢失信息，过弱受光照影响

17.3 设计检查清单

- 需要哪些不变性？（旋转/尺度/仿射/光照/视角）
 - 匹配距离用 L2 还是 Hamming？
 - 需要多少关键点？稠密还是稀疏？
 - 是否可容忍检测失败？
 - 是否需要固定维度以便索引？
 - 是否需要 GPU 加速？
 - 是否有标注数据可做学习？
-

18. 速查表

18.1 主要描述子一览

描述子	维度	类型	不变性	主要应用
SIFT	128	浮点	尺度、旋转	匹配、SfM、拼接
RootSIFT	128	浮点	尺度、旋转	匹配（提升版）
PCA-SIFT	20–36	浮点	尺度、旋转	快速匹配
SURF	64/128	浮点	尺度、旋转	实时匹配
GLOH	128	浮点	尺度、旋转	高精度匹配
DAISY	200	浮点	尺度、旋转（弱）	稠密立体
HOG	可变	浮点	光照（弱）	行人检测
PHOG	可变	浮点	光照（弱）	形状/场景
BRIEF	128–512	二进制	无	快速匹配
ORB	256	二进制	尺度、旋转	SLAM、实时
BRISK	512	二进制	尺度、旋转	实时匹配
FREAK	512	二进制	尺度、旋转	移动端
AKAZE	486	二进制	尺度、旋转	鲁棒匹配
LATCH	256	二进制	无（可加）	稠密匹配
LBP	59/256	整数/直方图	旋转（变体）	纹理、人脸
Gabor	可变	浮点	方向/频率	纹理
GLCM/Haralick	4–14	浮点	无	纹理分类
Tamura	6	浮点	无	纹理感知
Shape Context	60	浮点	平移、尺度	形状匹配
Fourier 描述子	可变	浮点	平移、旋转、尺度	轮廓匹配

描述子	维度	类型	不变性	主要应用
Hu 矩	7	浮点	平移、旋转、尺度	形状识别
Zernike 矩	可变	浮点	旋转	形状识别
MSER	区域	区域	仿射	区域匹配、文字
GIST	512	浮点	无	场景分类
BoW	词袋	稀疏	继承局部	检索
VLAD	$K \times d$	浮点	继承局部	检索
Fisher Vector	$2Kd$	浮点	继承局部	检索/分类
NetVLAD	$K \times d$	浮点	学习	地点识别
Census	位串	二进制	幅值	立体匹配
SuperPoint	256	浮点	学习	SLAM、匹配
SuperGlue	匹配网络	学习	学习	宽基线匹配
DELF	1024	浮点	学习	检索
DELG	全局+局部	学习	学习	统一检索
GeM/R-MAC	可变	浮点	学习	检索

18.2 分类脉络速记

描述子

└ 全局

| └ 颜色：直方图、矩、CCV、correlogram

| └ 纹理：GLCM、Tamura、LBP 直方图、Gabor 能量

| └ 形状：Hu、Zernike、Fourier

| └ 场景：GIST

| └ 聚合：BoW、VLAD、Fisher、CNN 全局池化

└ 局部

| └ 梯度直方图：SIFT、SURF、GLOH、HOG、DAISY

| └ 二进制：BRIEF、ORB、BRISK、FREAK、LATCH

| └ 区域/仿射：MSER、Harris-Affine、Hessian-Affine

| └ 矩：Zernike、Legendre、Tchebichef


| └ 形状：Shape Context、链码、CSS、转向函数

| └ 纹理：LBP、Gabor、MR8、Textons

| └ 学习型：L2-Net、HardNet、SuperPoint、D2-Net、R2D2

18.3 特征提取处理速查

通用特征提取流水线：



各描述子的处理步骤与作用：

描述子	主要处理步骤	各步作用
SIFT	尺度空间 → DoG 极值 → 亚像素定位 → 边缘剔除 → 主方向 → 4×4×8 方向直方图 → L2+clip+L2	尺度/旋转不变；定位精确；编码局部结构；光照鲁棒
SURF	积分图 + 盒滤波 Hessian → Haar 响应 → 4×4 子区域统计	快速检测；方向分配；64/128 维编码
HOG	梯度 → cell 直方图 → block 拼接 → L2-Hys	边缘信号；局部方向统计；上下文；光照鲁棒
BRIEF	随机采样对 → 强度比较 → 位打包	极快匹配；对光照单调变化不敏感
ORB	oFAST → 强度质心方向 → 旋转采样 → rBRIEF 选对	快速检测；旋转不变；去相关提升区分性
BRISK	AGAST + 尺度空间 → 同心圆采样 → 长短对	多尺度；方向估计；二进制编码
FREAK	视网膜采样 → 级联比较	模拟人眼；提前筛除候选加速匹配
LBP	邻域比较 → 位编码 → 直方图	微纹理编码；光照单调不变；均匀模式降维
Gabor	多方向多尺度滤波 → 能量统计	方向/频率纹理提取
GLCM	灰度对统计 → Haralick 特征	空间共生规律；可分类标量
Hu 矩	几何矩 → 中心矩 → 归一化 → 组合	平移/旋转/尺度不变形状描述
Zernike 矩	正交基投影 → 取模	无冗余；旋转不变；可重建
Shape Context	对数极坐标分箱 → χ^2 匹配	点分布描述；非刚性形状匹配
Fourier 描述子	轮廓复数化 → DFT → 取模	平移/旋转/尺度不变轮廓描述
GIST	Gabor 滤波组 → 4×4 网格 → 平均能量	场景空间包络；紧凑全局表示
VLAD	聚类 → 残差聚合 → 幂律+L2	紧凑编码局部描述子集合
Fisher Vector	GMM → 参数梯度 → 归一化	保留二阶统计；高区分性
Census	邻域比较 → 位串 → 汉明距离	对光照幅值变化鲁棒；立体匹配
HardNet	深度网络 → 困难负样本挖掘	拉开正负样本分布；提升匹配

描述子	主要处理步骤	各步作用
SuperPoint	自监督热力图 → 检测+描述头	联合检测与描述；可学习

处理步骤的通用作用总结：

处理类别	代表操作	核心作用
预处理	灰度化、平滑、归一化	降噪、统一输入尺度
检测	角点/斑点/区域检测	找到稳定、可重复的位置
几何归一化	主方向、尺度、仿射归一化	赋予旋转/尺度/仿射不变性
特征提取	梯度、比较、滤波、矩	提取对内容敏感的信号
量化编码	直方图、二值、投影、聚类	压成固定维度、可比较的编码
数值归一化	L2/L1、幂律、clip	抑制光照/对比度，提升鲁棒性
匹配	距离度量、比率检验、RANSAC	找对应点并剔除外点

19. 结论

描述子的核心思想可以浓缩为三步：

1. **选一个区域**——用检测子找出稳定、可重复的位置或区域
2. **编码一个向量**——用梯度、比较、矩、滤波、频谱等算子把内容量化
3. **做一次归一化**——用归一化、主方向、尺度、仿射等手段获得不变性

不同描述子的差别，本质上就是：

- 用什么算子 $\mathcal{F}$
- 用什么量化 $\mathcal{Q}$
- 用什么归一化 $\mathcal{N}$
- 想要哪种不变性
- 是手工设计还是从数据中学习

从历史脉络看，描述子经历了三个阶段：

- **手工几何阶段**：Harris、SIFT、SURF、HOG、LBP、Shape Context
- **二进制与实时阶段**：BRIEF、ORB、BRISK、FREAK、AKAZE
- **学习与深度阶段**：Fisher/VLAD → HardNet、SuperPoint、SuperGlue、D2-Net、DELF/DELG

但即使到了深度学习时代，经典描述子的设计思想（尺度空间、主方向归一化、方向直方图、二值比较、聚合编码）依然是理解现代特征表示的重要基础，也是许多工业场景中低延迟、低功耗方案的首选。