

图像描述子 (Feature Descriptors) 综述： 原理、分类与应用

关于参考书的一点说明

本文目标是按 *Computer Vision Metrics: Survey, Taxonomy, and Analysis* (Scott Krig, Apress) 这类 survey 的通用脉络来组织描述子内容，即以

全局 → 局部 → 纹理 → 学习型 → 颜色 为主线，并区分
手工设计 (hand-crafted) 与学习型 (learned) 两大分支。

该书未能获取原文，因此本文**不引用其具体页码、章节号和原文表述**，
只采用这一领域公认的分类框架与数学定义。所有公式与算法描述均来自公开的
原始论文与标准定义 (SIFT、SURF、ORB、BRIEF、BRISK、FREAK、HOG、LBP、
GLOH、Shape Context、MSER、Census、VLAD、Fisher Vector、SuperPoint 等)。

目录

1. 描述子的基本概念
2. 描述子的分类体系 (Taxonomy)
3. 数学原理基础
4. 关键点检测子 (Detectors)
5. 局部描述子 (Local Descriptors) 逐类详解
6. 全局描述子 (Global Descriptors)
7. 纹理描述子 (Texture Descriptors)
8. 颜色描述子 (Color Descriptors)
9. 形状与轮廓描述子 (Shape / Contour Descriptors)
10. 光谱与子空间描述子 (Spectral / Basis / Subspace)
11. 学习型与深度描述子 (Learning-based)
12. 立体匹配与光流描述子
13. 视频与时序描述子
14. 匹配、索引与检索
15. 评价指标与基准数据集
16. 应用方向
17. 选型与设计权衡

1. 描述子的基本概念

1.1 什么叫描述子

描述子 (descriptor) 是把图像中某一局部或全局区域的内容压缩成一个固定维度数值的函数。它的作用是让“图像块”变成一个可比较、可匹配、可检索的数学对象。

形式化地说，描述子是一个映射：

$$f : \mathcal{P}(I) \rightarrow \mathbb{R}^d \quad \text{或} \quad \{0,1\}^d$$

其中：

- I 是图像（灰度或彩色）
- $\mathcal{P}(I)$ 是图像上的一个区域或一个点邻域
- d 是描述子的维度
- 浮点描述子取值于 $\mathbb{R}^d$ ，二进制描述子取值于 $\{0,1\}^d$

描述子本身通常是**向量**；它表达的是“这块图像长什么样”，而不是“这块图像在哪”。

1.2 检测子、关键点与描述子的关系

一个完整的局部特征系统通常由三部分组成：

环节	作用	输出	典型方法
检测 (detection)	找出图像中“值得描述”的位置	关键点坐标 (x,y) 、尺度 σ 、方向 θ	Harris、FAST、DoG、MSER
描述 (description)	把关键点邻域编码成向量	d 维向量	SIFT、SURF、ORB、BRIEF
匹配 (matching)	比较两个描述子的相似度	对应关系	L2、Hamming、NNDR、RANSAC

检测子 (detector) 与 **描述子 (descriptor)** 是两个可以独立替换的模块。
例如 ORB = oFAST (检测) + rBRIEF (描述)，两者来自不同源头。

1.3 描述子的数学本质

从数学角度看，描述子的构造基本都遵循同一个模式：

$$\text{descriptor} = \mathcal{N}\left(\mathcal{Q}(\mathcal{F}(I, \Omega))\right)$$

其中：

- Ω ：局部区域（点邻域、仿射归一化区域、区域检测结果）
- $\mathcal{F}$ ：特征提取算子（梯度、滤波响应、强度比较、矩、频谱）
- $\mathcal{Q}$ ：量化/编码（直方图分箱、二值化、投影、聚类分配）
- $\mathcal{N}$ ：归一化（L1/L2 归一化、均值-方差归一化、幂律归一化）

不同的描述子，差别主要在于这四步的具体选择。

1.4 好描述子应具备的性质

性质	含义	数学体现
可重复性 (repeatability)	同一物理点在变换后仍被检测到	检测子在同一点上重复命中
可区分性 (distinctiveness)	不同区域产生不同描述子	描述子空间内类间距离大
紧致性 (compactness)	占用空间小、匹配快	维度 d 小
不变性 (invariance)	对某种变换不敏感	$f(T(I)) = f(I)$
等变性 (equivariance)	随变换而一致变化	$f(T(I)) = T'(f(I))$
鲁棒性 (robustness)	对噪声、压缩、光照稳定	扰动下 $\ \Delta f\ $ 小
效率 (efficiency)	计算与匹配开销低	可用积分图、位运算、LSH

其中不变性是最核心的设计目标，常见有：

- **平移不变**：通过对局部区域相对坐标编码
- **旋转不变**：通过主方向分配 + 旋转归一化
- **尺度不变**：通过尺度空间极值检测 + 尺度归一化窗口
- **仿射不变**：通过二阶矩矩阵做仿射归一化
- **光照不变**：通过梯度、强度差、归一化、截断

- **视角/3D 不变**：最难，通常只能做到有限视角内鲁棒

2. 描述子的分类体系（Taxonomy）

2.1 按空间范围分

全局描述子（global descriptors）

- 对整幅图像产生一个向量
- 典型：颜色直方图、GIST、GLCM、Hu 矩、BoW、Fisher Vector、CNN 全局池化
- 优点：紧凑、适合整图检索与分类
- 缺点：无空间定位能力，遮挡敏感

局部描述子（local descriptors）

- 对关键点邻域产生一个向量
- 典型：SIFT、SURF、ORB、BRIEF、BRISK、FREAK、LBP
- 优点：可匹配、可定位、对遮挡相对鲁棒
- 缺点：数量多，需要匹配与几何验证

2.2 按设计方式分

手工设计（hand-crafted）

- 由人根据图像结构先验设计
- 代表：SIFT、SURF、HOG、LBP、Gabor、Shape Context、MSER

学习型（learned / learned embeddings）

- 参数由数据训练得到
- 代表：PCA-SIFT、LDA 描述子、Random Ferns、L2-Net、HardNet、SuperPoint、DELF

2.3 按数学构造来源分（本文主线）

构造家族	数学工具	代表方法
梯度/ 方向直方图	一阶微分 + 加权投票	SIFT、SURF、GLOH、HOG、DAISY

构造家族	数学工具	代表方法
强度比较/ 二进制	比较算子 + 位运算	BRIEF、ORB、BRISK、FREAK、LATCH
矩与正交基	矩展开、正交多项式	Hu、Zernike、Legendre、Tchebichef
纹理/滤波响应	卷积滤波组	LBP、Gabor、MR8、GLCM、Tamura、小波
光谱/子空间	FFT、DCT、PCA、LDA、ICA	Fourier 描述子、DCT、Eigenfaces、Fisherfaces
形状/轮廓	边界参数化、极坐标分箱	Shape Context、链码、CSS、Fourier 形状
区域/分割	连通域、稳定性	MSER、EBR、IBR
学习/嵌入	度量学习、深度网络	Fisher Vector、VLAD、NetVLAD、SuperPoint

2.4 按不变性能力分

能力等级	含义	代表
仅平移	只对位置不敏感	直方图类、LBP（原型）
平移+旋转	加方向归一化	SIFT、SURF、ORB（rBRIEF）、BRISK
平移+旋转+尺度	加尺度空间	SIFT、SURF、KAZE、AKAZE
平移+旋转+尺度+仿射	加仿射归一化	Harris-Affine、Hessian-Affine、MSER+
宽基线/视角	学习型或专用设计	SuperPoint、D2-Net、视角不变特征

2.5 按数据类型与匹配方式分

浮点型描述子

- 存储在 $\mathbb{R}^d$
- 匹配用欧氏距离 L_2 或余弦相似度
- 代表：SIFT(128)、SURF(64/128)、GLOH(128)、HOG

二进制描述子

- 存储在 $\{0, 1\}^d$

- 匹配用汉明距离 (XOR + popcount)
- 代表：BRIEF(128–512)、ORB(256)、BRISK(512)、FREAK(512)、LATCH(256)

二进制描述子的核心优势：匹配极快。

$$D_{Hamming}(\mathbf{a}, \mathbf{b}) = \sum_{i=1}^d [a_i \neq b_i] = \text{popcount}(\mathbf{a} \oplus \mathbf{b})$$

2.6 按应用任务分

- 匹配/配准类：SIFT、SURF、ORB、SuperPoint
- 检测/分类类：HOG、LBP、Haar-like、DPM
- 检索类：BoW、VLAD、Fisher Vector、R-MAC、DELF
- 识别类：LBPH、Eigenfaces、Fisherfaces、深度嵌入
- 立体/稠密类：Census、NCC、DAISY

3. 数学原理基础

3.1 尺度空间理论 (Scale Space)

尺度不变性的数学基础是**尺度空间**。图像在不同尺度下的表示由高斯卷积给出：

$$L(x, y, \sigma) = G(x, y, \sigma) * I(x, y)$$

其中：

$$G(x, y, \sigma) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

尺度空间满足扩散方程（这一性质称为半群性质）：

$$\frac{\partial L}{\partial \sigma} = \sigma \nabla^2 L$$

高斯拉普拉斯 (LoG) 用于斑点检测：

$$\nabla^2 G = \frac{\partial^2 G}{\partial x^2} + \frac{\partial^2 G}{\partial y^2}$$

尺度归一化 LoG 的极值给出特征尺度：

$$\sigma^2 \nabla^2 L(x, y, \sigma)$$

高斯差分 (DoG) 是对 LoG 的高效近似：

$$D(x, y, \sigma) = (G(x, y, k\sigma) - G(x, y, \sigma)) * I(x, y) \\ \approx (k - 1)\sigma^2 \nabla^2 L$$

这就是 SIFT 能在多尺度上检测极值的关键。

非线性尺度空间 (KAZE/AKAZE) 用非线性扩散替代高斯：

$$\frac{\partial L}{\partial t} = \text{div}(c(x, y, t) \nabla L)$$

其中 c 由梯度自适应控制 (Perona–Malik 型 diffusivity)，从而在保边的同时建立尺度。

3.2 梯度与局部结构

一阶梯度：

$$I_x = \frac{\partial I}{\partial x}, \quad I_y = \frac{\partial I}{\partial y}$$

梯度幅值与方向：

$$m = \sqrt{I_x^2 + I_y^2}, \quad \theta = \text{atan2}(I_y, I_x)$$

自相关矩阵 (结构张量)：

$$M = \sum_{(x,y) \in W} w(x, y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}$$

特征值 λ_1, λ_2 决定局部结构类型：

特征值关系	结构类型
λ_1, λ_2 都小	平坦区域
一大一小	边缘
都大	角点

Harris 响应：

$$R = \det(M) - k (\text{tr } M)^2$$

Shi-Tomasi 响应:

$$R = \min(\lambda_1, \lambda_2)$$

Hessian 矩阵（用于斑点/DoH）:

$$H = \begin{bmatrix} I_{xx} & I_{xy} \\ I_{xy} & I_{yy} \end{bmatrix}, \quad \det(H) = I_{xx}I_{yy} - I_{xy}^2$$

3.3 直方图编码与量化

方向直方图是最常见的编码方式。给定方向集合 $\{\theta_i\}$ 与权重 $\{w_i\}$:

$$h_b = \sum_i w_i \cdot 1[\theta_i \in \text{bin}_b]$$

SIFT 使用**三线形插值**把样本分配到相邻的子区域和相邻的方向箱，避免分箱边界效应:

$$w = w_{sub} \cdot w_{ori}$$

其中 w_{sub} 、 w_{ori} 都是在相邻格点上的线性权重。

归一化的作用:

- L2 归一化: 抑制对比度变化
- 截断 (clip 0.2) 后再次归一化: 抑制主导梯度
- L1 + 开方 (RootSIFT): 改善分布稳定性

RootSIFT 的做法:

$$\mathbf{v}_{root} = \sqrt{\frac{\mathbf{v}_{L1}}{\|\mathbf{v}\|_1}}$$

3.4 二进制测试与汉明度量

二进制描述子由一组**强度比较**构成:

$$\tau(I; \mathbf{p}, \mathbf{q}) = \begin{cases} 1, & I(\mathbf{p}) < I(\mathbf{q}) \\ 0, & \text{否则} \end{cases}$$

一个 d 位描述子:

$$f_d(I) = \sum_{i=1}^d 2^{i-1} \tau(I; \mathbf{p}_i, \mathbf{q}_i)$$

采样模式 $\{(\mathbf{p}_i, \mathbf{q}_i)\}$ 决定了描述子的性能：

- BRIEF：随机采样，无旋转不变性
- ORB：学习式选择去相关样本对，并把采样模式按主方向旋转
- BRISK：同心圆采样，长短对分开使用
- FREAK：视网膜式采样，带级联

3.5 矩与正交基

几何矩：

$$m_{pq} = \sum_x \sum_y x^p y^q I(x, y)$$

中心矩：

$$\mu_{pq} = \sum_x \sum_y (x - \bar{x})^p (y - \bar{y})^q I(x, y)$$

归一化中心矩：

$$\eta_{pq} = \frac{\mu_{pq}}{\mu_{00}^{1 + \frac{p+q}{2}}}$$

Hu 七不变矩由 η_{pq} 组合而成，对平移、旋转、尺度不变：

$$\begin{aligned}\phi_1 &= \eta_{20} + \eta_{02} \\ \phi_2 &= (\eta_{20} - \eta_{02})^2 + 4\eta_{11}^2 \\ \phi_3 &= (\eta_{30} - 3\eta_{12})^2 + (3\eta_{21} - \eta_{03})^2 \\ &\dots\end{aligned}$$

Zernike 矩：在单位圆盘上以正交多项式为基：

$$Z_{nm} = \frac{n+1}{\pi} \int_0^{2\pi} \int_0^1 \overline{V_{nm}(\rho, \theta)} f(\rho, \theta) \rho d\rho d\theta$$

正交性使得矩之间信息不冗余，且可以做到旋转不变（取模）。

3.6 滤波与纹理

Gabor 滤波：

$$g(x, y; \lambda, \theta, \psi, \sigma, \gamma) = \exp\left(-\frac{x'^2 + \gamma^2 y'^2}{2\sigma^2}\right) \exp\left(i\left(2\pi\frac{x'}{\lambda} + \psi\right)\right)$$

其中

$$x' = x \cos \theta + y \sin \theta, \quad y' = -x \sin \theta + y \cos \theta$$

LBP (局部二值模式)：

$$\text{LBP}_{P,R} = \sum_{p=0}^{P-1} s(g_p - g_c) 2^p, \quad s(x) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

均匀模式：0/1 跳变不超过 2 次的模式，占自然图像绝大多数，因此

LBP^{u2} 用 $P(P-1) + 3$ 个箱代替 2^P 个箱，大幅降维。

GLCM (灰度共生矩阵)：给定偏移 δ ，统计灰度对 (i, j) 的出现次数：

$$P_\delta(i, j) = \#\{(x, y) : I(x, y) = i, I(x + \delta_x, y + \delta_y) = j\}$$

Haralick 特征从 P_δ 派生：

$$\text{Contrast} = \sum_{i,j} (i - j)^2 P(i, j)$$

$$\text{Energy} = \sum_{i,j} P(i, j)^2, \quad \text{Homogeneity} = \sum_{i,j} \frac{P(i, j)}{1 + |i - j|}$$

$$\text{Correlation} = \sum_{i,j} \frac{(i - \mu_i)(j - \mu_j)P(i, j)}{\sigma_i \sigma_j}$$

3.7 子空间与统计学习

PCA (Eigenfaces)：对中心化数据求协方差矩阵特征向量：

$$C = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^T$$

保留前 k 个最大特征值对应的特征向量作为投影基。

LDA (Fisherfaces)：最大化类间散度与类内散度之比：

$$W = \arg \max_W \frac{|W^T S_B W|}{|W^T S_W W|}$$

GMM 与 Fisher Vector：用高斯混合建模局部描述子分布，再对参数求梯度：

$$\mathcal{G}_\mu = \frac{1}{N\sqrt{\pi_k}} \sum_i \gamma_i(k) \frac{\mathbf{x}_i - \boldsymbol{\mu}_k}{\boldsymbol{\sigma}_k}$$

VLAD (Vector of Locally Aggregated Descriptors)：

$$\mathbf{v}_k = \sum_{i: \text{NN}(\mathbf{x}_i)=c_k} (\mathbf{x}_i - c_k)$$

再做幂律归一化与 L2 归一化。

NetVLAD：把硬分配替换为软分配：

$$\bar{a}_k(\mathbf{x}_i) = \frac{e^{\mathbf{w}_k^T \mathbf{x}_i + b_k}}{\sum_{k'} e^{\mathbf{w}_{k'}^T \mathbf{x}_i + b_{k'}}}$$

3.8 不变性的构造手段

不变性	构造手段	数学操作
平移	使用相对坐标/局部邻域	以关键点为中心建立坐标系
旋转	估计主方向并旋转采样	梯度方向直方图峰值 θ^*
尺度	尺度空间极值 + 尺度归一化窗口	$\sigma^2 \nabla^2 L$ 极值
仿射	二阶矩矩阵归一化	$\Sigma^{-1/2}$ 变换到单位圆
光照对比度	归一化	L2/L1 归一化、clip
光照偏移	差分	梯度、强度比较
视角	多视角数据或学习	度量学习、注意力匹配

主方向估计 (SIFT)：

$$\theta^* = \arg \max_{\theta} \sum_i w_i 1[\theta_i \in \text{bin}(\theta)]$$

其中权重为梯度幅值乘以高斯窗。

3.9 相似度度量与匹配

欧氏距离：

$$d_2(\mathbf{a}, \mathbf{b}) = \|\mathbf{a} - \mathbf{b}\|_2$$

余弦相似度：

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|}$$

最近邻距离比（NNDR / Lowe ratio test）：

$$\frac{d(\mathbf{a}, \mathbf{b}_1)}{d(\mathbf{a}, \mathbf{b}_2)} < \rho$$

其中 $\mathbf{b}_1$ 是最近邻、 $\mathbf{b}_2$ 是次近邻， ρ 常取 0.6–0.8。

几何验证：用 RANSAC 拟合单应/基础矩阵，剔除外点：

$$H^* = \arg \max_H \sum_i 1 [\|\mathbf{x}'_i - H\mathbf{x}_i\| < \epsilon]$$

4. 关键点检测子（Keypoint Detectors）

4.1 角点检测

检测子	原理	特点
Moravec	各方向灰度差最小值的局部极大	最早，无旋转不变性
Harris–Stephens	结构张量 + 响应函数	旋转不变，光照鲁棒
Shi–Tomasi	$\min(\lambda_1, \lambda_2)$	更稳定的跟踪角点
Förstner	协方差矩阵 + 圆度	精度高，用于配准
Kitchen–Rosenfeld	梯度方向变化率	计算简单
FAST	圆周 Bresenham 测试	极快，无尺度不变
AGAST	FAST 的自适应泛化	更快的 FAST 变体

检测子	原理	特点
oFAST	FAST + 强度质心方向	ORB 的检测子

Harris 推导：对邻域做一阶泰勒展开：

$$I(x + \Delta x, y + \Delta y) \approx I(x, y) + I_x \Delta x + I_y \Delta y$$

平方误差和：

$$E(\Delta x, \Delta y) = \sum_W \left(I_x \Delta x + I_y \Delta y\right)^2 = \mathbf{d}^T M \mathbf{d}$$

对 M 做特征值分析，则得到角点判据。

FAST 判据：圆形半径 3 的 16 像素圆周上，若有连续 N （通常 9 或 12）个像素都比中心亮/暗超过阈值 t ，则判为角点：

$$\exists \text{连续 } N \text{ 个 } p: |I(p) - I(c)| > t$$

强度质心方向（oFAST）：

$$m_{pq} = \sum_{x,y} x^p y^q I(x, y), \quad \theta = \text{atan2}(m_{01}, m_{10})$$

4.2 斑点与区域检测

检测子	原理	特点
LoG	尺度归一化高斯拉普拉斯极值	尺度不变
DoG	相邻高斯差	SIFT 的核心
DoH	Hessian 行列式	SURF 的基础
SIFT 检测子	DoG 极值 + 亚像素定位 + 边缘剔除	尺度/旋转不变
SURF 检测子	积分图 + 盒滤波 Hessian	速度快
BRISK 检测子	AGAST + 尺度空间	快速多尺度
CenSurE / STAR	多尺度中心环绕滤波	近似尺度不变
MSER	阈值扫描 + 连通域稳定性	仿射不变强
EBR / IBR	边缘/强度极值区域	早期区域检测

检测子	原理	特点
KAZE / AKAZE	非线性尺度空间	保边、重复性好
SUSAN	最小核同值区	角点+边缘统一框架
Hessian-Laplace	Hessian 定位 + LoG 尺度	更稳定的尺度选择
Harris-Laplace	Harris 定位 + LoG 尺度	经典仿射不变检测
Harris-Affine	迭代仿射归一化	仿射不变
Hessian-Affine	Hessian 定位 + 仿射归一化	仿射不变

MSER 稳定性判据：随阈值 θ 扫描，连通域面积变化率取局部极小：

$$q(i) = \frac{|A(i + \Delta) - A(i - \Delta)|}{A(i)}$$

4.3 边缘检测子

检测子	原理
Roberts	2×2 差分算子
Sobel	3×3 平滑+差分
Prewitt	均匀加权差分
Scharr	更精确的旋转对称差分
Laplacian	二阶微分零交叉
LoG / Marr–Hildreth	平滑后二阶微分
Canny	高斯平滑 + 非极大抑制 + 双阈值滞后
结构化边缘（SE）	随机森林预测边缘

Canny 的非极大抑制：沿梯度方向比较，只保留局部极大：

$$\text{keep if } m(x, y) \geq m(x \pm \delta \cos \theta, y \pm \delta \sin \theta)$$

5. 局部描述子 (Local Descriptors) 逐类详解

5.1 梯度方向直方图类

SIFT (Scale-Invariant Feature Transform, 128 维)

流程：

1. 尺度空间极值： $D(x, y, \sigma)$ 在 3D 邻域（含相邻尺度）中比较
2. 亚像素定位：泰勒展开求极值偏移

$$\hat{\mathbf{x}} = - \left(\frac{\partial^2 D}{\partial \mathbf{x}^2} \right)^{-1} \frac{\partial D}{\partial \mathbf{x}}$$

3. 边缘剔除：主曲率比判据

$$\frac{(\text{tr } H)^2}{\det H} < \frac{(r + 1)^2}{r}, \quad r \approx 10$$

4. 方向分配：36 箱梯度方向直方图，峰值为主方向，达到峰值 80% 的方向作辅方向
5. 描述子：16×16 邻域内 4×4 子区域，每子区域 8 方向 → 128 维
6. 归一化：L2 归一化 → clip 0.2 → 再 L2 归一化

SIFT 的数学核心是"梯度方向统计 + 局部空间分块 + 全局归一化"。

SURF (Speeded-Up Robust Features, 64/128 维)

用盒滤波近似 Hessian：

$$\det(H_{approx}) = D_{xx}D_{yy} - (0.9 D_{xy})^2$$

方向分配：在半径 6σ 的圆域内计算 Haar 小波响应 d_x, d_y ，
用 60° 滑动窗口求和，最大值方向为主方向。

描述子：4×4 子区域，每区域统计

$$(\sum d_x, \sum d_y, \sum |d_x|, \sum |d_y|) \rightarrow 64$$

扩展版本加入 $\sum d_y$ 的符号 → 128 维。

GLOH (Gradient Location and Orientation Histogram, 128 维)

- 采用对数极坐标分箱：3 个半径 × 8 个角度 = 17 个空间箱
- 每箱 16 个方向箱 → 272 维

- 用 PCA 降到 128 维
- 比 SIFT 更具区分性，但计算更贵

DAISY (200 维)

- 面向稠密匹配设计
- 在每个采样点周围用高斯加权方向直方图
- 用可分离卷积快速计算
- 适合宽基线立体匹配

HOG (Histogram of Oriented Gradients)

流程：

1. 计算梯度幅值与方向
2. 把图像划分为 cell（如 8×8），每 cell 统计 9 个方向箱（0–180°）
3. 若干 cell 组成 block（如 2×2），对 block 内特征做 **L2-Hys** 归一化
4. 拼接所有 block 特征

L2-Hys 归一化：

$$\mathbf{v} \leftarrow \frac{\mathbf{v}}{\sqrt{\|\mathbf{v}\|_2^2 + \epsilon^2}}, \quad v_i \leftarrow \min(v_i, 0.2), \quad \text{再归一化}$$

HOG 是行人检测（HOG + SVM）与 DPM 的核心。

相关变体

名称	特点
PCA-SIFT	对梯度块做 PCA 降维到 20 维
RootSIFT	SIFT 描述子 L1 归一化后开方
RIFT	旋转不变特征变换，用环形分箱
CSIFT	颜色不变 SIFT
OpponentSIFT	在对立色通道上计算 SIFT
DSP-SIFT	尺度池化，提升匹配性能
PHOG	金字塔 HOG，用于形状/场景
HOG3D	时空梯度直方图

名称	特点
PIFF	像素级特征融合的分类 HOG 全局特征

5.2 二进制描述子类

BRIEF (Binary Robust Independent Elementary Features, 128–512 bit)

$$f(I) = \sum_i 2^{i-1} \tau(I; \mathbf{p}_i, \mathbf{q}_i)$$

- 采样对从高斯分布抽取
- **无旋转不变性、无尺度不变性**，对模糊较敏感
- 匹配用汉明距离，极快

ORB (Oriented FAST and Rotated BRIEF, 256 bit)

1. **oFAST** 检测 + 强度质心方向
2. **Steered BRIEF**：把采样模式按方向 θ 旋转

$$R_\theta = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$

3. **rBRIEF**：用贪心搜索在训练集上选出去相关、方差大的 256 个测试对
4. 加入金字塔实现尺度不变性

ORB 是 ORB-SLAM 的基石，兼顾速度与质量。

BRISK (Binary Robust Invariant Scalable Keypoints, 512 bit)

- **采样模式**：同心圆（半径按指数增长），共 60 个采样点
- **短对** ($< \delta_{max}$)：用于估计方向
- **长对** ($> \delta_{min}$)：用于构造描述子
- 512 bit，匹配快

FREAK (Fast Retina Keypoint, 512 bit)

- **视网膜式采样**：中心密集、外围稀疏，模拟人眼感受野
- 通过**级联比较**逐步筛选，前面若干位就能筛掉大量候选
- 用 45 个感受野之间的比较构成二进制串

其他二进制描述子

名称	特点
LATCH	学习式三像素比较，抗噪更好
LIOP	局部强度序模式，利用像素排序
BOLD	自适应在线学习二值测试
BinBoost	Boosting 学习二进制哈希
AKAZE-MLDB	非线性尺度空间 + 改进 LDB
KAZE 描述子	非线性尺度 + 类 SURF 浮点描述子
D-BRIEF	面向稠密的 BRIEF 变体

5.3 区域与仿射描述子

名称	特点
MSER 区域	稳定性极强的仿射不变区域
Harris-Affine 区域	迭代估计仿射形状
Hessian-Affine 区域	Hessian 版本
EBR / IBR	早期极值区域
局部强度序	序统计描述

这些区域经过仿射归一化后，再送入 SIFT/SURF 描述子，即可获得仿射不变特征。

5.4 矩型局部描述子

名称	特点
图像矩	可构造平移/旋转/尺度不变
Zernike 矩	正交基，旋转不变，重建能力强
伪 Zernike 矩	放宽正交性，数值更稳
Legendre 矩	正交多项式，在矩形区域定义

名称	特点
Tchebichef / Krawtchouk 矩	离散正交矩，适合数字图像
小波矩	多分辨率 + 矩

6. 全局描述子（Global Descriptors）

6.1 GIST / 空间包络

对人类场景感知的近似建模：

- 1. 对图像做多尺度、多方向的 Gabor 滤波
- 2. 把每张响应图划成 4×4 网格
- 3. 对每个网格取平均能量

维度 = 尺度数 × 方向数 × 网格数（典型 512）。

GIST 用于场景分类与快速图像检索。

6.2 全局颜色统计

- 颜色直方图
- 颜色矩（均值、方差、偏度）
- 颜色聚合向量（CCV）
- 颜色相关图（correlogram）

6.3 全局纹理统计

- GLCM / Haralick
- Tamura 特征：粗糙度、对比度、方向性、线状性、规则性、粗略度
- 小波能量
- MR8 滤波组响应直方图

6.4 全局形状描述

- Hu 矩
- Zernike 矩

- Fourier 描述子
- 骨架图

6.5 全局聚合描述子

- **BoW (Bag of Words)**: 局部描述子聚类成词袋，统计词频
- **Fisher Vector**: GMM 梯度聚合
- **VLAD**: 残差聚合
- **CNN 全局池化**: VGG/ResNet 特征 + average/max/GeM/R-MAC 池化

7. 纹理描述子 (Texture Descriptors)

类别	方法	原理
统计型	GLCM、GLRLM、LBP、灰度梯度	统计像素对/游程/局部模式
滤波型	Gabor、MR8、小波、可操纵滤波	多方向多尺度响应能量
模型型	马尔可夫随机场、分形维数	用概率模型描述纹理生成
变换型	傅里叶能量、Gabor 谱、小波	频域能量分布
结构型	形态学、纹理单元、Textons	重复基元的排列
感知型	Tamura	按人类视觉描述词汇

LBP 的常用变体:

变体	特点
LBP^{u2}	均匀模式，降维
LBP^{ri}	旋转不变
LBP^{riu2}	旋转不变均匀模式
CLBP	加入幅值与中心像素信息
LBP-HF	傅里叶域的旋转不变 LBP
CS-LBP	中心对称比较，维度更低

变体	特点
LBP-TOP	时空三维 LBP，用于视频
多尺度 LBP	多半径组合

Textons：先用滤波组响应聚类得到纹理基元，再用基元直方图表示纹理。

8. 颜色描述子（Color Descriptors）

8.1 颜色直方图族

- RGB / HSV / Lab 三通道直方图
- 联合直方图 vs 边缘分布
- 加空间信息的直方图（分块、环形）

8.2 颜色矩

一阶矩（均值）、二阶矩（标准差）、三阶矩（偏度）：

$$\mu_k = \frac{1}{N} \sum_i p_{ik}, \quad \sigma_k = \left(\frac{1}{N} \sum_i (p_{ik} - \mu_k)^2 \right)^{1/2}, \quad s_k = \left(\frac{1}{N} \sum_i (p_{ik} - \mu_k)^3 \right)^{1/3}$$

8.3 颜色结构描述

- **CCV（Color Coherence Vector）**：区分相干/非相干像素
- **Color Correlogram**：颜色对的空间相关性
- **Color Names**：把颜色映射到 11 个语言色名

8.4 颜色 SIFT 家族

在颜色空间中重复 SIFT 流程：

描述子	颜色空间
RGB-SIFT	各 RGB 通道分别做 SIFT
OpponentSIFT	对立色空间

描述子	颜色空间
HSV-SIFT / HueSIFT	HSV
rgSIFT	归一化 rg 色度
C-SIFT	色度不变量
Transformed Color SIFT	颜色变换不变

8.5 颜色描述子的匹配

- 直方图交集
- χ^2 距离

$$d_{\chi^2}(\mathbf{h}, \mathbf{g}) = \frac{1}{2} \sum_i \frac{(h_i - g_i)^2}{h_i + g_i}$$

- EMD (Earth Mover's Distance)

9. 形状与轮廓描述子 (Shape / Contour Descriptors)

9.1 轮廓参数化

链码 (Freeman Chain Code): 用 8 方向编码边界。

轮廓点复数表示:

$$z(k) = x(k) + i y(k)$$

Fourier 描述子: 对 $z(k)$ 做 DFT:

$$Z(u) = \sum_{k=0}^{N-1} z(k)e^{-i2\pi uk/N}$$

性质:

- 平移只改变 $Z(0)$ (去掉即可不变)
- 旋转只改变相位
- 尺度只改变幅值

- 取 $|Z(u)|$ 得到旋转不变描述子

9.2 曲率与尺度空间

曲率尺度空间 (CSS):

$$\kappa(u, \sigma) = \frac{\dot{x}\ddot{y} - \ddot{x}\dot{y}}{(\dot{x}^2 + \dot{y}^2)^{3/2}}$$

随 σ 增大，曲率零交叉点从细节到整体逐层出现，形成"尺度树"。

转向函数 (Turning Function): 把边界累积转角作为弧长的函数，对旋转、平移不变，对尺度可归一化。

9.3 形状上下文 (Shape Context)

对形状上一点 p_i ，统计其余 $n - 1$ 个点的相对位置分布：

- 对数极坐标分箱：12 个角度 $\times$ 5 个半径 = 60 箱
- 得到 60 维直方图

匹配代价：

$$C_{ij} = \frac{1}{2} \sum_{k=1}^K \frac{(h_i(k) - h_j(k))^2}{h_i(k) + h_j(k)}$$

用匈牙利算法求最优匹配。

9.4 其他形状描述子

名称	原理
Hu 矩	七个不变矩组合
Zernike 矩	正交基，旋转不变
距离变换 / 中轴	骨架描述
Chamfer 距离	边缘点距离匹配
多边形近似	Douglas–Peucker
B 样条	平滑轮廓参数化

名称	原理
骨架图	拓扑结构描述
形状上下文	点分布直方图
内距离（Inner Distance）	基于内部测地距离

10. 光谱与子空间描述子（Spectral / Basis / Subspace）

10.1 变换域

变换	用途
DFT	频域能量、平移不变
DCT	压缩、能量集中
小波（Haar、Daubechies）	多分辨率纹理/形状
Gabor 族	方向-频率分解
可操纵滤波	任意方向的可调响应
梅林/傅里叶-梅林	尺度和旋转不变配准

10.2 子空间方法

方法	原理	应用
PCA	最大方差投影	Eigenfaces、降维
LDA	最大类间/类内比	Fisherfaces
ICA	统计独立分量	盲源分离
NMF	非负分解	部件化表示
稀疏编码	稀疏线性组合	图像分类
字典学习	学习过完备基	去噪、分类

方法	原理	应用
谱图（Spectral Graph）	图拉普拉斯特征	形状匹配

11. 学习型与深度描述子（Learning-based）

11.1 经典学习型描述子

名称	学习方式
PCA-SIFT	对 SIFT 梯度块做 PCA
LDA 描述子	用判别分析投影
Random Ferns	随机蕨分类器
Random Forests 描述	决策森林输出
Boosting 描述子	AdaBoost 选择特征
度量学习描述子	三元组损失学习距离
DeepCompare / DeepDesc	浅层孪生网络 + 相似度损失
MatchNet	孪生网络 + 全连接度量

11.2 深度局部描述子

名称	核心思想
L2-Net	逐块归一化，改善匹配分布
HardNet	在 batch 内挖掘最难的负样本
SOSNet	引入二阶相似度正则
SuperPoint	自监督：MagicPoint + 单应变换自适应，输出检测+256 维描述子
SuperGlue	注意力图神经网络 + 最优传输匹配
D2-Net	联合检测与描述，单次前向

名称	核心理念
R2D2	可重复性与可靠性联合学习
DELF	语义特征 + 注意力池化
DELG	全局与局部联合，统一检索与匹配
LF-Net	全监督学习检测与描述
SIFT + 学习式筛选	学习式后处理/筛选

HardNet 的困难负样本挖掘：

$$\mathcal{L} = \frac{1}{N} \sum_i \max \left(0, 1 + d(\mathbf{a}_i, \mathbf{p}_i) - d(\mathbf{a}_i, \mathbf{n}_i^*) \right)$$

其中 $\mathbf{n}^*$ 是批次内最近的非匹配描述子。

SuperPoint 的伪标签自监督：对图像施加随机单应变换，把关键点位置相应地变换，用形状一致的方式生成热力图监督信号。

11.3 深度全局与检索描述子

名称	特点
全连接层特征（FC7 等）	早期迁移学习特征
全局平均池化（GAP）	紧凑全局表示
GeM 池化	广义均值池化

$$\text{GeM} = \left(\frac{1}{|\mathcal{X}|} \sum_{x \in \mathcal{X}} x^p \right)^{1/p}$$

- | R-MAC | 多区域最大激活聚合 |
- | NetVLAD | 可微 VLAD 层 |
- | Fisher Vector + CNN | CNN 特征 + FV 编码 |
- | BEBLID | 提升式二进制描述子 |

11.4 学习型描述子的关键损失

- 对比损失（contrastive）

- 三元组损失 (triplet)
- 铰链/边界挖掘 (hard mining)
- 排序损失 (ranking)
- 归一化相关 / 相似度匹配损失 (NCC loss)

12. 立体匹配与光流描述子

12.1 稠密立体匹配代价

方法	原理
SAD	绝对差之和
SSD	平方差之和
NCC	归一化互相关
Census	强度比较位串 + 汉明距离
BT (Birchfield–Tomasi)	抗采样、对幅值不敏感
互信息 (MI)	统计依赖度，适跨模态
AD-Census	组合代价
半全局匹配 (SGM)	代价聚合 + 一致性检查

Census 变换：

$$C(p) = \bigotimes_{\mathbf{q} \in \mathcal{N}(p)} [I(\mathbf{q}) > I(p)]$$

匹配用汉明距离。

12.2 光流

Lucas–Kanade（局部，亮度恒定假设）：

$$I(x + u, y + v) \approx I(x, y) + I_x u + I_y v$$

最小化：

$$E(u, v) = \sum_W (I_x u + I_y v + I_t)^2$$

解：

$$\begin{bmatrix} u \\ v \end{bmatrix} = \left(\sum_W \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} \right)^{-1} \sum_W \begin{bmatrix} I_x I_t \\ I_y I_t \end{bmatrix}$$

Horn–Schunck（全局，加平滑正则）：

$$E = \iint (I_x u + I_y v + I_t)^2 + \alpha^2 (\|\nabla u\|^2 + \|\nabla v\|^2) dx dy$$

13. 视频与时序描述子

名称	原理
HOG3D	时空梯度方向直方图
HOF	光流方向直方图
MBH	运动边界直方图
iDT	改进稠密轨迹 + 四种描述子融合
Dense Trajectories	稠密采样点轨迹 + 轨迹形状描述
LBP-TOP	三正交平面 LBP
3D SIFT	时空 SIFT
C3D / I3D / Two-Stream	深度时空特征（学习型）
TimeSformer / VideoMAE	基于 Transformer 的视频表示

14. 匹配、索引与检索

14.1 匹配策略

- 暴力匹配 (brute force)
- 最近邻 + 距离比 (NNDR)
- 交叉检验 (cross-check / mutual NN)
- 比率检验 + 几何验证 (RANSAC)
- 互信息/相关 (跨模态)

14.2 近似最近邻索引

方法	原理
KD-Tree	递归空间划分
FLANN	自动选算法与参数
LSH	哈希碰撞近似近邻
Hamming 索引	二进制位串分块
层次 K-means	词袋倒排
乘积量化 (PQ)	子空间分解 + 码本
倒排文件 (IVF)	聚类桶 + 倒排
HNSW	分层可导航小世界图

14.3 检索流程

1. 提取局部描述子
2. 量化到视觉词 / 聚合 (BoW、VLAD、FV)
3. 归一化 (幂律、L2、白化)
4. 倒排索引 + 候选排序
5. 几何重排序 (RANSAC、空间验证)

15. 评价指标与基准数据集

15.1 指标

指标	含义
Repeatability	变换后同一物理点被重复检测的比例
Recall / Precision	匹配查全/查准
匹配得分（matching score）	正确匹配比例
mAP	检索平均精度均值
定位误差	匹配点像素误差
描述子距离分布	正/负样本可分性
计算耗时 / 内存	效率代价

15.2 常用数据集与基准

名称	用途
Oxford VGG Affine	仿射不变性评测
HPatches	局部描述子现代基准
Brown / UBC	宽基线匹配
EVD	视角变化评测
MVS / PhotoTourism	3D 重建匹配
Oxford RobotCar	长时视觉定位
ImageNet / Places	全局表示与检索
Oxford5k / Paris6k / ROxford / RParis	图像检索
KITTI / EuRoC	视觉里程计、SLAM

16. 应用方向

16.1 几何与三维

应用	常用描述子
图像拼接/全景	SIFT、SURF、ORB
运动恢复结构（SfM）	SIFT（COLMAP 等）
立体视觉与深度	Census、AD-Census、DAISY、SGM
多视图立体	DAISY、PatchMatch + 描述子
相机标定/配准	Harris、SIFT、棋盘角点
图像配准（医学/遥感）	SIFT、MI、形状上下文

16.2 定位与机器人

应用	常用描述子
SLAM	ORB（ORB-SLAM）、SuperPoint
视觉里程计	FAST + 光流、ORB
回环检测	BoW、NetVLAD、DELG
重定位	NetVLAD、全局描述子
视觉导航	全局描述子 + 局部匹配

16.3 检测与识别

应用	常用描述子
行人检测	HOG + SVM、DPM
人脸检测	Haar-like + AdaBoost、深度
通用目标检测	CNN 特征（发展自 HOG 思路）
人脸识别	LBPH、Eigenfaces、Fisherfaces、深度嵌入

应用	常用描述子
表情/年龄	LBP、Gabor、深度
字符/OCR	HOG、LBP、投影特征、深度
文档表格/版面	线段、布局特征、深度布局模型

16.4 检索与分类

应用	常用描述子
图像检索	BoW、VLAD、Fisher Vector、DELF/DELG
近重复检测	全局描述子 + 哈希
场景分类	GIST、CNN 全局特征
纹理分类	LBP、Gabor、GLCM、Textons
商品/商标检索	局部描述子 + 聚合
视频检索	iDT、深度时空特征

16.5 跟踪与视频

应用	常用描述子
目标跟踪	LBP、HOG、相关滤波（KCF/MOSSE）、深度特征
动作识别	HOG3D、HOF、MBH、iDT、I3D
行人重识别	颜色直方图 + 深度嵌入
手势/姿态	形状上下文、骨架 + 深度

16.6 工业与其他

应用	常用描述子
表面缺陷检测	LBP、GLCM、Gabor
布料/材料纹理	LBP、Tamura、小波
遥感变化检测	SIFT、全局统计、深度

应用	常用描述子
医学图像分析	LBP、Gabor、形状、深度
生物特征（指纹/虹膜）	方向场、Gabor、纹理编码
增强现实（AR）	ORB、SuperPoint、平面跟踪
文档扫描矫正	边缘 + 线段 + 单应

17. 选型与设计权衡

17.1 选择维度

需求	推荐
最高匹配精度、可离线	SIFT、RootSIFT、GLOH、SuperPoint
实时性需求高	ORB、BRISK、FREAK、AKAZE
极小内存	BRIEF/ORB（二进制）、LBP
强仿射变化	MSER + SIFT、Harris-Affine
非刚性形变	Shape Context、内距离
纹理分类	LBP、Gabor、GLCM、Textons
目标检测（经典）	HOG、Haar-like
大规模检索	VLAD、Fisher Vector、NetVLAD、深度全局
宽基线/难场景	SuperPoint + SuperGlue、D2-Net
跨模态	互信息、学习型嵌入

17.2 主要权衡

权衡	说明
维度 vs 速度	128 维 SIFT 精度高但慢；256 bit ORB 快但精度略低

权衡	说明
不变性 vs 区分性	越不变往往越不具区分性
手工 vs 学习	学习型精度高，但依赖数据与算力
稀疏 vs 稠密	稀疏可匹配，稠密可建图
检测 vs 描述强制解耦	耦合（如 D2-Net）可联合优化
归一化强度	过强丢失信息，过弱受光照影响

17.3 设计检查清单

- 需要哪些不变性？（旋转/尺度/仿射/光照/视角）
- 匹配距离用 L2 还是 Hamming？
- 需要多少关键点？稠密还是稀疏？
- 是否可容忍检测失败？
- 是否需要固定维度以便索引？
- 是否需要 GPU 加速？
- 是否有标注数据可做学习？

18. 速查表

18.1 主要描述子一览

描述子	维度	类型	不变性	主要应用
SIFT	128	浮点	尺度、旋转	匹配、SfM、拼接
RootSIFT	128	浮点	尺度、旋转	匹配（提升版）
PCA-SIFT	20–36	浮点	尺度、旋转	快速匹配
SURF	64/128	浮点	尺度、旋转	实时匹配
GLOH	128	浮点	尺度、旋转	高精度匹配
DAISY	200	浮点	尺度、旋转（弱）	稠密立体
HOG	可变	浮点	光照（弱）	行人检测

描述子	维度	类型	不变性	主要应用
PHOG	可变	浮点	光照（弱）	形状/场景
BRIEF	128–512	二进制	无	快速匹配
ORB	256	二进制	尺度、旋转	SLAM、实时
BRISK	512	二进制	尺度、旋转	实时匹配
FREAK	512	二进制	尺度、旋转	移动端
AKAZE	486	二进制	尺度、旋转	鲁棒匹配
LATCH	256	二进制	无（可加）	稠密匹配
LBP	59/256	整数/直方图	旋转（变体）	纹理、人脸
Gabor	可变	浮点	方向/频率	纹理
GLCM/Haralick	4–14	浮点	无	纹理分类
Tamura	6	浮点	无	纹理感知
Shape Context	60	浮点	平移、尺度	形状匹配
Fourier 描述子	可变	浮点	平移、旋转、尺度	轮廓匹配
Hu 矩	7	浮点	平移、旋转、尺度	形状识别
Zernike 矩	可变	浮点	旋转	形状识别
MSER	区域	区域	仿射	区域匹配、文字
GIST	512	浮点	无	场景分类
BoW	词袋	稀疏	继承局部	检索
VLAD	$K \times d$	浮点	继承局部	检索
Fisher Vector	$2Kd$	浮点	继承局部	检索/分类
NetVLAD	$K \times d$	浮点	学习	地点识别
Census	位串	二进制	幅值	立体匹配
SuperPoint	256	浮点	学习	SLAM、匹配
SuperGlue	匹配网络	学习	学习	宽基线匹配

描述子	维度	类型	不变性	主要应用
DELF	1024	浮点	学习	检索
DELG	全局+局部	学习	学习	统一检索
GeM/R-MAC	可变	浮点	学习	检索

18.2 分类脉络速记

描述子

- └ 全局
 - | └ 颜色：直方图、矩、CCV、correlogram
 - | └ 纹理：GLCM、Tamura、LBP 直方图、Gabor 能量
 - | └ 形状：Hu、Zernike、Fourier
 - | └ 场景：GIST
 - | └ 聚合：BoW、VLAD、Fisher、CNN 全局池化
- └ 局部
 - | └ 梯度直方图：SIFT、SURF、GLOH、HOG、DAISY
 - | └ 二进制：BRIEF、ORB、BRISK、FREAK、LATCH
 - | └ 区域/仿射：MSER、Harris-Affine、Hessian-Affine
 - | └ 矩：Zernike、Legendre、Tchebichef
 - | └ 形状：Shape Context、链码、CSS、转向函数
 - | └ 纹理：LBP、Gabor、MR8、Textons
 - | └ 学习型：L2-Net、HardNet、SuperPoint、D2-Net、R2D2

19. 结论

描述子的核心思想可以浓缩为三步：

1. **选一个区域**——用检测子找出稳定、可重复的位置或区域
2. **编码一个向量**——用梯度、比较、矩、滤波、频谱等算子把内容量化
3. **做一次归一化**——用归一化、主方向、尺度、仿射等手段获得不变性

不同描述子的差别，本质上就是：

- 用什么算子 $\mathcal{F}$
- 用什么量化 $\mathcal{Q}$
- 用什么归一化 $\mathcal{N}$

- 想要哪种不变性
- 是手工设计还是从数据中学习

从历史脉络看，描述子经历了三个阶段：

- **手工几何阶段**：Harris、SIFT、SURF、HOG、LBP、Shape Context
- **二进制与实时阶段**：BRIEF、ORB、BRISK、FREAK、AKAZE
- **学习与深度阶段**：Fisher/VLAD → HardNet、SuperPoint、SuperGlue、D2-Net、DELF/DELG

但即使到了深度学习时代，经典描述子的设计思想（尺度空间、主方向归一化、方向直方图、二值比较、聚合编码）依然是理解现代特征表示的重要基础，也是许多工业场景中低延迟、低功耗方案的首选。