

十大机器学习算法详解：原理、逐变量解析、图像应用与深度学习联系

本文是一份纯理论整理，不涉及任何代码改动。目标是围绕"十大机器学习算法"这一经典提法，做到三件事：

- 把每个算法的原理讲透**——每个公式都给出**逐项符号解释**（每个变量是什么、量纲、取值范围、物理含义）；
- 厘清"十大"的版本差异**——不同教材/榜单给出的名单并不一致，本文列出主流版本并补齐差异项；
- 落到图像领域**——每个算法在图像处理/计算机视觉中的具体用法，并说明它与后续**深度学习**部分的联系。

与仓库中 `feature-descriptors-notes.md`、`cnn-transformer-notes.md` 一脉相承：前者讲"手工描述子"，后者讲"深度表示学习"，本文正好补上中间那一层——**经典机器学习**，即"浅层学习"这一代。

目录

- 总览：什么是"十大机器学习算法"
- "十大"的版本差异与本文取舍
- 监督学习 (Supervised Learning)
 - 3.1 最近邻 (KNN)
 - 3.2 贝叶斯分类 (朴素贝叶斯)
 - 3.3 逻辑回归
 - 3.4 支持向量机 (SVM)

- 8. 3.5 决策树与森林 (随机森林)
 - 9. 无监督学习 (Unsupervised Learning)
 - 10. 4.1 聚类
 - 11. 4.2 K-means 与高斯混合模型
 - 12. 4.3 主成分分析 (PCA)
 - 13. 4.4 流形学习
 - 14. 4.5 半监督学习
 - 15. 其他版本中的扩展算法 (ICDM 2008 版差异项)
 - 16. 5.1 C4.5
 - 17. 5.2 CART
 - 18. 5.3 PageRank
 - 19. 5.4 神经网络 / 深度学习
 - 20. 5.5 AdaBoost
 - 21. 5.6 EM 算法
 - 22. 5.7 Apriori
 - 23. 图像领域应用总览
 - 24. 与深度学习的联系 (重点)
 - 25. 速查表
 - 26. 结论
-

1. 总览：什么是"十大机器学习算法"

1.1 提法的来源

"十大机器学习算法" (Top 10 Algorithms in Data Mining / Machine Learning) 并不是一个 有严格定义的官方名单，而是源于若干**综述性文章与教材**的归纳。最常被引用的是：

- **Wu et al., 2008, *Top 10 algorithms in data mining*** (发表于 *Knowledge and Information Systems*)，由 IEEE ICDM 组织投票产生，名单为：C4.5、K-Means、SVM、Apriori、EM、PageRank、AdaBoost、kNN、Naive Bayes、CART。
- 各类**入门教材与在线课程**（如 Python 数据科学、机器学习入门）给出的"十大"，则更偏向**可上手、覆盖监督+无监督**的实用清单，即用户给出的这一版：KNN、朴素贝叶斯、逻辑回归、SVM、决策树/森林、聚类、K-means/GMM、PCA、流形学习、半监督学习。


两者**视角不同**：前者是"数据挖掘领域最具影响力的算法"，后者是"机器学习入门必学的算法"。

1.2 三大范式

所有算法都可以归入三大学习范式：

范式	数据	目标	代表
监督学习	有标签 (x_i, y_i)	学 $x \rightarrow y$ 的映射	KNN、贝叶斯、逻辑回归、SVM、决策树
无监督学习	无标签 x_i	发现结构（簇、子空间、流形）	聚类、K-means、GMM、PCA、流形学习
半监督学习	少量标签 + 大量无标签	用无标签数据辅助监督任务	自训练、协同训练、图半监督

范式关系示意：



1.3 统一视角：都是"目标函数 + 优化"

尽管形式各异，几乎所有算法都可以写成同一个模板：

$$\hat{\theta} = \arg\min_{\theta} \underbrace{\frac{1}{N} \sum_{i=1}^N L(y_i, f_{\theta}(x_i))}_{\text{经验风险 (拟合数据)}} + \underbrace{\lambda \Omega(\theta)}_{\text{正则项}}$$

其中：

- θ ：模型参数（要学的东西）。
- N ：样本数量。
- x_i ：第 i 个样本的**特征向量**（图像里常是描述子、像素块、颜色直方图等）。
- y_i ：第 i 个样本的**标签**（分类标签或回归值）。
- f_{θ} ：由参数 θ 决定的**预测函数**。
- $L(\cdot, \cdot)$ ：**损失函数**，衡量预测与真值的差距（如平方损失、交叉熵、Hinge 损失）。
- $\Omega(\theta)$ ：**正则项**，惩罚模型复杂度（如 L2、L1、树深度）。
- λ ：**正则化系数**，权衡"拟合数据"与"保持简单"。
- $\hat{\theta}$ ：使总目标最小的最优参数。

含义：不同算法的差别，本质上就是 L 、 Ω 、 f_{θ} 三者的不同选择。例如 SVM 用 Hinge 损失 + L2 正则，逻辑回归用交叉熵 + L2 正则，决策树用不纯度下降作为"隐式损失"。

2. "十大"的版本差异与本文取舍

2.1 主流版本对照

算法	用户给出的版本	ICDM 2008 版	常见入门教材版	本文是否详解
KNN	✓	✓	✓	✓ 3.1
朴素贝叶斯	✓	✓	✓	✓ 3.2
逻辑回归	✓	✗	✓	✓ 3.3
SVM	✓	✓	✓	✓ 3.4
决策树 / 森林	✓	✓ (C4.5、CART)	✓	✓ 3.5
聚类	✓	✓ (K-Means)	✓	✓ 4.1
K-means / GMM	✓	✓ (K-Means)	✓	✓ 4.2
PCA	✓	✗	✓	✓ 4.3
流形学习	✓	✗	⚠ 部分	✓ 4.4
半监督学习	✓	✗	⚠ 部分	✓ 4.5
C4.5	✗	✓	✓	✓ 5.1
CART	✗	✓	✓	✓ 5.2
PageRank	✗	✓	✗	✓ 5.3
神经网络 / 深度学习	✗	✗	✓	✓ 5.4
AdaBoost	✗	✓	✓	✓ 5.5
EM	✗	✓	⚠ 部分	✓ 5.6
Apriori	✗	✓	⚠ 部分	✓ 5.7

说明：用户给出的版本是"入门实用版"，ICDM 2008 是"数据挖掘影响力版"。两者交集是 KNN、朴素贝叶斯、SVM、决策树、K-means；差异项（逻辑回归、PCA、流形学习、半监督 vs AdaBoost、EM、Apriori、PageRank）本文全部补齐，做到"两版通吃"。

2.2 为什么会有差异

- **ICDM 版**偏重"数据挖掘": 强调关联规则 (Apriori)、图排序 (PageRank)、概率推断 (EM), 这些在数据库/推荐系统里更重要。
 - **入门版**偏重"机器学习基础": 强调降维 (PCA)、流形 (t-SNE/LLE)、半监督, 这些在**图像与高维数据**里更常用。
 - **图像领域**的特殊性: 图像是高维、强相关、带空间结构的数据, 因此 PCA、流形学习、K-means (用于视觉词袋) 在图像里地位极高, 而 Apriori、PageRank 在图像里较少直接使用。
-

3. 监督学习 (Supervised Learning)

3.1 最近邻 (Nearest Neighbors / KNN)

3.1.1 核心思想

KNN 是最"懒惰"的算法：**不训练、不建模型**，把全部训练样本存起来，预测时找最近的 k 个邻居投票。它属于**非参数方法**（模型复杂度随数据增长）。

3.1.2 距离度量

最常用的是**欧氏距离**：

$$d(x, x') = \sqrt{\sum_{j=1}^D (x_j - x'_j)^2}$$

其中：

- x, x' ：两个样本的特征向量（各 D 维）。
- D ：特征维度（图像里可能是描述子维度，如 SIFT 的 128）。
- x_j ：向量 x 的第 j 个分量。
- x'_j ：向量 x' 的第 j 个分量。
- $(x_j - x'_j)$ ：第 j 维上的差。
- 平方后求和再开方：即"直线距离"（L2 范数）。
- $d(x, x')$ ：两样本的**不相似度**，越小越相似。

其他常用度量：

度量	公式	适用
曼哈顿距离	$\sum_j x_j - x'_j $	稀疏、鲁棒
余弦距离	$1 - \frac{x \cdot x'}{\ x\ \ x'\ }$	方向敏感（文本、描述子）
汉明距离	$\sum_j [x_j \neq x'_j]$	二进制描述子（BRIEF/ORB）
马氏距离	$\sqrt{(x - x')^\top \Sigma^{-1} (x - x')}$	各维尺度/相关性不同

其中 Σ 是特征的协方差矩阵， Σ^{-1} 是它的逆，用于"白化"各维尺度。

3.1.3 分类决策规则

多数投票：

$$\hat{y} = \arg \max_{c \in \mathcal{C}} \sum_{i \in \mathcal{N}_k(x)} 1[y_i = c]$$

其中：

- x ：待预测样本。
- $\mathcal{N}_k(x)$ ： x 的 k 个最近邻的下标集合。
- k ：邻居个数（超参数）。
- $\mathcal{C}$ ：类别集合。
- y_i ：第 i 个训练样本的真实标签。
- $1[\cdot]$ ：指示函数，条件成立取 1，否则取 0。
- $\sum_{i \in \mathcal{N}_k(x)} 1[y_i = c]$ ：邻居中属于类别 c 的个数。
- $\arg \max_c$ ：取票数最多的类别。
- $\hat{y}$ ：预测标签。

距离加权投票（更常用，近的邻居权重更大）：

$$\hat{y} = \arg \max_c \sum_{i \in \mathcal{N}_k(x)} w_i 1[y_i = c], \quad w_i = \frac{1}{d(x, x_i) + \epsilon}$$


其中：

- w_i ：第 i 个邻居的权重。
- $d(x, x_i)$ ：待测样本与第 i 个邻居的距离。
- ϵ ：极小正数，防止除零。
- 含义：距离越小， w_i 越大，投票越有分量。

回归时则取邻居标签的（加权）平均：

$$\hat{y} = \frac{\sum_{i \in \mathcal{N}_k(x)} w_i y_i}{\sum_{i \in \mathcal{N}_k(x)} w_i}$$

3.1.4 算法步骤



3.1.5 关键问题

- **k 的选择**: k 太小 $\rightarrow$ 对噪声敏感 (过拟合) ; k 太大 $\rightarrow$ 决策边界过于平滑 (欠拟合) 。 常用交叉验证选 k , 经验值 $k \approx \sqrt{N}$ 。
- **维度灾难**: 高维空间中所有点距离趋于相等, KNN 失效。 解决: 先降维 (PCA) 或特征选择。
- **计算复杂度**: 预测时 $O(ND)$, 大数据需 KD-Tree、Ball-Tree、LSH 加速。

3.1.6 图像领域用法

- **图像分类基线**: 把图像表示为特征向量 (颜色直方图、HOG、CNN 特征), 用 KNN 分类。
- **图像检索**: 以图搜图, 找特征空间最近邻。
- **特征匹配**: SIFT 描述子的最近邻匹配 (Lowe 的 ratio test 就是 "最近邻 / 次近邻" 比值) 。
- **超像素 / 像素分类**: 对每个像素的特征做 KNN 分类 (如遥感图像分割) 。

3.1.7 与深度学习的联系

- **度量学习 (Metric Learning)** : 深度网络学一个嵌入空间, 使同类近、异类远, 再用 KNN 分类——即 孪生网络 / Triplet Loss / 对比学习。
- **原型网络 (Prototypical Networks)** : few-shot 学习中, 用类中心做 "最近邻"。
- **KNN 是 "无参数" 的极端**, 深度网络是 "全参数" 的极端, 二者在表示学习上互补。

3.2 贝叶斯分类 (Bayesian Classification)

3.2.1 贝叶斯定理

$$P(c | x) = \frac{P(x | c) P(c)}{P(x)}$$

其中:

- c : 类别 (如 "猫") 。
- x : 样本特征向量。
- $P(c | x)$: **后验概率**——看到特征 x 后, 样本属于 c 的概率 (我们想要的) 。
- $P(x | c)$: **似然**——类别 c 产生特征 x 的概率 (从数据估计) 。
- $P(c)$: **先验概率**——不看特征时, 类别 c 出现的概率 (类别频率) 。
- $P(x)$: **证据**——特征 x 出现的概率, 对所有类别相同, 分类时可忽略。

- 含义：后验 $\propto$ 似然 $\times$ 先验。

分类决策（最大后验 MAP）：

$$\hat{y} = \arg \max_c P(c \mid x) = \arg \max_c P(x \mid c) P(c)$$

其中 $\hat{y}$ 是预测类别；因为 $P(x)$ 与 c 无关，可省略。

3.2.2 朴素贝叶斯：条件独立假设

直接估计 $P(x \mid c)$ 需要 D 维联合分布，参数爆炸。朴素贝叶斯假设各维条件独立：

$$P(x \mid c) = \prod_{j=1}^D P(x_j \mid c)$$

其中：

- D ：特征维度。
- x_j ：特征向量的第 j 维。
- $P(x_j \mid c)$ ：在类别 c 下，第 j 维取值的概率（一维分布，易估计）。
- $\prod$ ：连乘，把 D 维联合概率拆成 D 个一维概率之积。
- 含义：假设“给定类别后，各特征互不影响”——这个假设通常不成立，但效果出奇地好。

最终判别式：

$$\hat{y} = \arg \max_c P(c) \prod_{j=1}^D P(x_j \mid c)$$

3.2.3 三种常见变体

变体	假设 $P(x_j \mid c)$	适用特征
高斯朴素贝叶斯	$\mathcal{N}(\mu_{jc}, \sigma_{jc}^2)$	连续特征（图像像素、描述子）
多项式朴素贝叶斯	多项分布	计数特征（词频、直方图）
伯努利朴素贝叶斯	伯努利分布	二值特征（二值描述子）

高斯形式：

$$P(x_j | c) = \frac{1}{\sqrt{2\pi\sigma_{jc}^2}} \exp\left(-\frac{(x_j - \mu_{jc})^2}{2\sigma_{jc}^2}\right)$$

其中：

- μ_{jc} ：类别 c 下第 j 维的**均值**。
- σ_{jc}^2 ：类别 c 下第 j 维的**方差**。
- σ_{jc} ：标准差。
- x_j ：待测样本第 j 维取值。
- 含义：假设该维在类内服从正态分布，用均值和方差刻画。

3.2.4 数值稳定：对数化

连乘易下溢，取对数变连加：

$$\hat{y} = \arg \max_c \left[\log P(c) + \sum_{j=1}^D \log P(x_j | c) \right]$$

其中 $\log$ 单调递增，不改变 $\arg \max$ 结果，但把乘积变求和，避免浮点下溢。

3.2.5 图像领域用法

- **垃圾邮件 / 文本分类**（经典应用，非图像）。
- **图像分类**：像素或描述子作为特征，高斯朴素贝叶斯做基线。
- **肤色检测**：在 YCbCr 空间对 Cb、Cr 建模高斯分布，判断像素是否肤色。
- **贝叶斯分割**：结合先验形状与似然做 MRF/CRF 分割（贝叶斯框架的推广）。
- **朴素贝叶斯是"生成式模型"**，与逻辑回归（判别式）形成对照。

3.2.6 与深度学习的联系

- **贝叶斯深度学习**：对网络权重加先验，做后验推断（变分推断、MC Dropout），得到**不确定性估计**。
 - **生成模型**：VAE 的 ELBO 就是贝叶斯推断的变分下界。
 - **Softmax 分类器**可看作"判别式"版本，而朴素贝叶斯是"生成式"版本。
-

3.3 逻辑回归 (Logistic Regression)

3.3.1 从线性回归到概率

线性模型输出 $z = w^\top x + b$ 是实数，要变成概率需Sigmoid压缩：

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

其中：

- z ：线性得分 (logit) 。
- e ：自然常数。
- $\sigma(z) \in (0, 1)$ ：把实数映射到概率区间。
- 性质： $\sigma(0) = 0.5$, $z \rightarrow +\infty$ 时趋近 1, $z \rightarrow -\infty$ 时趋近 0。

二分类概率：

$$P(y = 1 | x) = \sigma(w^\top x + b) = \frac{1}{1 + e^{-(w^\top x + b)}}$$

其中：

- $w \in \mathbb{R}^D$ ：**权重向量**，每个分量 w_j 表示第 j 维特征对"正类"的贡献。
- b ：**偏置**，控制决策边界的位置。
- $w^\top x = \sum_j w_j x_j$ ：特征的加权和。
- $P(y = 1 | x)$ ：样本属于正类的概率。
- $P(y = 0 | x) = 1 - P(y = 1 | x)$ 。

3.3.2 决策边界

令 $P(y = 1 | x) = 0.5$ ，即 $w^\top x + b = 0$ ：

$$w^\top x + b = 0$$

这是一个**超平面**，把特征空间一分为二。 w 是超平面的**法向量**（决定方向）， b 决定**偏移**。逻辑回归是**线性分类器**。

3.3.3 损失函数：交叉熵

从最大似然推导。单样本似然：

$$P(y | x) = \hat{p}^y (1 - \hat{p})^{1-y}, \quad \hat{p} = \sigma(w^\top x + b)$$

其中：

- $y \in 0, 1$ ：真实标签。
- $\hat{p}$ ：预测为正类的概率。
- 当 $y = 1$ 时取 $\hat{p}$ ，当 $y = 0$ 时取 $1 - \hat{p}$ 。

取负对数得**交叉熵损失**：

$$L(w, b) = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i) \right]$$

其中：

- N ：样本数。
- y_i ：第 i 个样本标签。
- $\hat{p}_i = \sigma(w^\top x_i + b)$ ：第 i 个样本的预测概率。
- 第一项 $y_i \log \hat{p}_i$ ：当 $y_i = 1$ 时惩罚"预测概率低"。
- 第二项 $(1 - y_i) \log(1 - \hat{p}_i)$ ：当 $y_i = 0$ 时惩罚"预测概率高"。
- 负号：把"最大化似然"变成"最小化损失"。

3.3.4 梯度下降

对 w 求梯度：

$$\nabla_w L = \frac{1}{N} \sum_{i=1}^N (\hat{p}_i - y_i) x_i$$

其中：

- $\hat{p}_i - y_i$ ：**预测误差**（残差）。
- x_i ：第 i 个样本特征。
- 含义：梯度 = 误差 × 特征的平均。误差越大，更新越猛。
- 更新： $w \leftarrow w - \eta \nabla_w L$ ， η 是**学习率**。

这个形式与线性回归的梯度完全一致，区别只在 $\hat{p}$ 是 Sigmoid 输出。

3.3.5 多分类：Softmax 回归

$$P(y = c \mid x) = \frac{e^{w_c^\top x + b_c}}{\sum_{c'=1}^C e^{w_{c'}^\top x + b_{c'}}}$$

其中：

- C ：类别数。
- w_c ：类别 c 的权重向量。
- b_c ：类别 c 的偏置。
- 分母：所有类别的指数和，做**归一化**，使概率和为 1。
- 含义：把每个类别的得分转成概率分布。

3.3.6 图像领域用法

- **二分类任务**：人脸/非人脸、有缺陷/无缺陷。
- **多标签分类**：一张图多个标签（每个标签一个逻辑回归）。
- **作为网络最后一层**：CNN 分类头就是 Softmax 回归。
- **概率输出**：需要置信度时优于 SVM。

3.3.7 与深度学习的联系

- **逻辑回归 = 单层神经网络**（无隐藏层）。
- **Softmax 回归 = CNN 分类头**，是深度分类器的最后一步。
- **交叉熵损失**是深度分类的标准损失。
- 逻辑回归的局限（线性边界）正是深度网络要突破的：**加隐藏层 + 非线性激活**。

3.4 支持向量机 (Support Vector Machines, SVM)

3.4.1 核心思想：最大间隔

SVM 要找一条**离两类样本都最远**的分界线（超平面），使**间隔 (margin) 最大**。只有少数“支撑”边界的样本（**支持向量**）决定分界线。

超平面：

$$w^\top x + b = 0$$

其中：

- w ：超平面的**法向量**，决定方向。
- b ：偏置，决定与原点的距离。
- x ：特征向量。

点到超平面的距离：

$$d(x) = \frac{|w^\top x + b|}{\|w\|}$$

其中 $\|w\| = \sqrt{\sum_j w_j^2}$ 是法向量的模长。

3.4.2 硬间隔优化问题

要求所有样本正确分类且间隔最大：

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_i(w^\top x_i + b) \geq 1, \forall i$$

其中：

- $\frac{1}{2} \|w\|^2$ ：目标函数，最小化它等价于**最大化间隔** $2/\|w\|$ 。
- $y_i \in -1, +1$ ：标签（SVM 用 ± 1 而非 0/1）。
- $y_i(w^\top x_i + b)$ ：**函数间隔**，要求 ≥ 1 表示"分类正确且离边界足够远"。
- 约束对所有 i 成立。

3.4.3 软间隔与松弛变量

现实数据有噪声，允许少量越界，引入**松弛变量** ξ_i ：

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \quad \text{s.t.} \quad y_i(w^\top x_i + b) \geq 1 - \xi_i, \xi_i \geq 0$$

其中：

- $\xi_i \geq 0$ ：第 i 个样本的**违反程度**（越界多少）。
- $C > 0$ ：**惩罚系数**，权衡"间隔大"与"少犯错"。
- C 大 $\rightarrow$ 不容忍错误 $\rightarrow$ 过拟合风险。

- C 小 $\rightarrow$ 容忍错误 $\rightarrow$ 欠拟合风险。

3.4.4 对偶问题与核技巧

用拉格朗日乘子转成对偶问题：

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) \\ \text{s.t.} \quad & 0 \leq \alpha_i \leq C, \quad \sum_{i=1}^N \alpha_i y_i = 0 \end{aligned}$$

其中：

- α_i ：第 i 个样本的**拉格朗日乘子**。
- $\alpha_i = 0$ ：该样本不影响边界（非支持向量）。
- $\alpha_i > 0$ ：该样本是**支持向量**。
- $K(x_i, x_j)$ ：**核函数**，计算两样本在高维空间的内积，无需显式升维。
- 含义：决策只依赖支持向量之间的核函数值。

常用核函数：

核	公式	参数
线性核	$x_i^\top x_j$	无
多项式核	$(\gamma x_i^\top x_j + r)^d$	γ, r, d
RBF / 高斯核	$\exp(-\gamma \ x_i - x_j\ ^2)$	γ
Sigmoid 核	$\tanh(\gamma x_i^\top x_j + r)$	γ, r

其中：

- γ ：核宽度参数，控制"影响半径"。
- d ：多项式次数。
- r ：常数项。
- RBF 核把数据映射到**无穷维**空间，是最常用的非线性核。

预测函数：

$$f(x) = \text{sign!} \left(\sum_{i \in SV} \alpha_i y_i K(x_i, x) + b \right)$$

其中：

- SV ：支持向量集合。
- $\text{sign}(\cdot)$ ：符号函数，输出 ± 1 。
- 含义：新样本的类别由它与支持向量的核函数加权和决定。

3.4.5 图像领域用法

- **HOG + SVM**：行人检测的经典组合 (Dalal & Triggs, 2005)。
- **图像分类**：在 CNN 之前，SVM 是图像分类的主力 (如 Caltech-101)。
- **目标检测**：滑动窗口 + SVM 分类。
- **多类 SVM**：一对多 (OvR) 或一对一 (OvO) 扩展。

3.4.6 与深度学习的联系

- **Hinge 损失**被深度度量学习沿用 (如 Deep SVM、大间隔 softmax)。
- **核方法 vs 深度**：核方法固定特征映射，深度网络**学习**特征映射。
- **神经正切核 (NTK)**：无限宽网络的极限等价于核方法，架起两者桥梁。
- **SVM 的间隔思想**影响深度学习的 margin-based 损失 (如 ArcFace、CosFace)。

3.5 决策树与森林 (Decision Trees and Forests)

3.5.1 决策树：递归划分

决策树通过一系列 "if-else" 问题把特征空间**递归划分**成若干区域，每个叶子给出预测。核心是**如何选划分特征和阈值**。

3.5.2 不纯度度量

信息熵：

$$H(S) = - \sum_{c=1}^C p_c \log_2 p_c$$

其中：

- S ：当前节点上的样本集合。
- C ：类别数。
- p_c ： S 中属于类别 c 的**比例**。
- $\log_2$ ：以 2 为底，单位是比特。
- $H(S)$ ：**不确定性**，越纯越小（纯节点 $H = 0$ ）。

基尼不纯度：

$$\text{Gini}(S) = 1 - \sum_{c=1}^C p_c^2$$

其中 p_c 同上；基尼不纯度衡量"随机抽两个样本类别不同的概率"，计算比熵快。

信息增益（ID3 / C4.5）：

$$\text{Gain}(S, A) = H(S) - \sum_{v \in \text{values}(A)} \frac{|S_v|}{|S|} H(S_v)$$

其中：

- A ：候选划分特征。
- $\text{values}(A)$ ：特征 A 的取值集合。
- S_v ： S 中特征 A 取值为 v 的子集。
- $|S_v|/|S|$ ：子集权重。
- 含义：用 A 划分后，不确定性下降多少；选增益最大的特征。

C4.5 的改进——信息增益率：

$$\text{GainRatio}(S, A) = \frac{\text{Gain}(S, A)}{\text{SplitInfo}(S, A)}, \quad \text{SplitInfo}(S, A) = - \sum_v \frac{|S_v|}{|S|} \log_2 \frac{|S_v|}{|S|}$$

其中 SplitInfo 惩罚"取值过多的特征"，避免偏向 ID 类特征。

CART 用基尼不纯度，且只做**二叉划分**，可同时处理分类与回归。

3.5.3 剪枝

- **预剪枝**：提前停止（限制深度、最小样本数）。

- **后剪枝**：先长满再剪掉不提升泛化的子树（代价复杂度剪枝）。

3.5.4 随机森林：集成学习

随机森林 = **Bagging** + **特征随机**：

1. **Bootstrap 采样**：从 N 个样本有放回抽 N 个，训练一棵树。
2. **特征随机**：每次分裂只从随机 m 个特征中选最优 ($m \approx \sqrt{D}$) 。
3. **投票/平均**：多棵树结果聚合。

预测：

$$\hat{y} = \text{majority}\{h_t(x)\}_{t=1}^T \quad \text{或} \quad \hat{y} = \frac{1}{T} \sum h_t(x)$$

其中：

- T ：树的数量。
- h_t ：第 t 棵树。
- 分类用多数投票，回归用平均。
- 含义：多棵"弱相关"的树平均，方差下降，泛化提升。

为什么有效：单棵树方差大（易过拟合），Bagging 通过**平均**降低方差；特征随机进一步**去相关**，使平均更有效。

3.5.5 特征重要性

$$\text{Importance}(j) = \sum_{\text{节点 } t \text{ 用 } j \text{ 分裂}} \frac{|S_t|}{N} \cdot \Delta \text{Impurity}(t)$$

其中：

- j ：特征下标。
- S_t ：节点 t 的样本数。
- $\Delta \text{Impurity}(t)$ ：该次分裂带来的不纯度下降。
- 含义：某特征在所有树中带来的不纯度下降的加权和，越大越重要。

3.5.6 图像领域用法

- **像素级分类**：随机森林做语义分割（早期方法，如 TextonForest）。
- **关键点分类**：随机森林做**随机蕨 (Random Ferns)**，用于特征匹配、姿态估计。
- **目标检测**：Viola-Jones 人脸检测用 AdaBoost + 决策树桩。

- **特征选择**：用特征重要性筛选描述子维度。

3.5.7 与深度学习的联系

- **随机森林** = 深度网络的"浅层集成"对照：前者靠集成降方差，后者靠层次降偏差。
 - **梯度提升树** (GBDT/XGBoost/LightGBM) 是表格数据王者，与深度网络互补。
 - **深度森林** (Deep Forest / gcForest) 尝试用树堆叠模拟深度。
 - **随机藤**的思想被用于深度特征匹配的加速。
-

4. 无监督学习 (Unsupervised Learning)

4.1 聚类 (Clustering)

4.1.1 问题定义

给定无标签数据 $x_{i=1}^N$ ，把它们分成若干簇，使簇内相似、簇间相异。

4.1.2 聚类目标 (一般形式)

$$\min_{C_1, \dots, C_K} \sum_{k=1}^K \sum_{x_i \in C_k} d(x_i, \mu_k)$$

其中：

- K ：簇数。
- C_k ：第 k 个簇（样本集合）。
- μ_k ：第 k 个簇的**中心**（如均值）。
- $d(\cdot, \cdot)$ ：距离度量。
- 含义：让每个样本离自己簇中心尽量近。

4.1.3 聚类方法分类

类型	代表	思想
划分式	K-means、K-medoids	直接划分成 K 簇
层次式	凝聚/分裂层次聚类	建树状结构（树状图）
密度式	DBSCAN、Mean Shift	按密度连通区域成簇
模型式	GMM	假设数据由概率模型生成
图论式	谱聚类	用图的割划分

DBSCAN 的两个参数：

- ϵ ：邻域半径。
- MinPts：成为核心点所需的最少邻居数。
- 核心点： ϵ 邻域内点数 $\geq$ MinPts；可发现任意形状簇并识别噪声。

谱聚类：用相似度矩阵 W 的拉普拉斯矩阵 $L = D - W$ 的前 K 个特征向量嵌入，再 K-means。其中 D 是度矩阵（对角元 $D_{ii} = \sum_j W_{ij}$ ）。

4.1.4 图像领域用法

- **图像分割**：像素聚类成区域（颜色/位置特征）。
- **视觉词袋 (BoW)**：对局部描述子聚类得到“视觉单词”。
- **图像检索与组织**：按内容聚类相册。
- **超像素**：SLIC 用 K-means 在颜色+空间上聚类。

4.1.5 与深度学习的联系

- **深度聚类**：用网络学嵌入再聚类（DEC、DeepCluster）。
- **自监督学习**：聚类伪标签作为预训练目标（DeepCluster、SwAV）。
- **对比学习**：正负样本对构造与聚类思想相通。

4.2 K-means 与高斯混合模型 (K-means and Gaussian Mixture Models)

4.2.1 K-means 目标函数

$$J = \sum_{k=1}^K \sum_{i: z_i=k} \|x_i - \mu_k\|^2$$

其中：

- K ：簇数（超参数）。
- x_i ：第 i 个样本。
- $z_i \in 1, \dots, K$ ：样本 i 的**簇分配**（隐变量）。
- μ_k ：第 k 个簇的**质心**。

- $\|x_i - \mu_k\|^2$: 样本到质心的平方距离。
- J : 簇内平方和 (WCSS) , 越小越紧凑。

4.2.2 交替优化 (EM 的特例)

分配步:

$$z_i = \arg \min_k \|x_i - \mu_k\|^2$$

更新步:

$$\mu_k = \frac{1}{|C_k|} \sum_{i \in C_k} x_i$$

其中:

- $C_k = \{i : z_i = k\}$: 分配给簇 k 的样本集合。
- $|C_k|$: 该簇样本数。
- 含义: 先固定质心分配样本, 再固定分配更新质心, 交替直到收敛。

收敛性: 每步都使 J 不增, 故必收敛到局部最优 (非全局) 。

4.2.3 K-means 的局限与改进

- 需预设 K : 用肘部法、轮廓系数、Gap Statistic 选 K 。
- 对初值敏感: 用 K-means++ 初始化。
- 只适合球形簇: 各向异性/非凸簇需 GMM 或谱聚类。
- 对异常值敏感: 改用 K-medoids (用真实样本做中心) 。

K-means++ 初始化: 第一个中心随机选, 之后每个中心以正比于 "到已有中心最近距离的平方" 的概率选取, 使初始中心分散。

4.2.4 高斯混合模型 (GMM)

GMM 假设数据由 K 个高斯分布混合生成:

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k)$$

其中:

- π_k : 第 k 个分量的混合系数 (权重) , 满足 $\sum_k \pi_k = 1, \pi_k \geq 0$ 。

- μ_k : 第 k 个高斯的**均值向量**。
- Σ_k : 第 k 个高斯的**协方差矩阵**（刻画形状与方向）。
- $\mathcal{N}(x | \mu_k, \Sigma_k)$: 多元高斯密度：

$$\mathcal{N}(x | \mu, \Sigma) = \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (x - \mu)^\top \Sigma^{-1} (x - \mu) \right)$$

其中：

- D : 维度。
- $|\Sigma|$: 协方差矩阵的行列式（体积）。
- Σ^{-1} : 精度矩阵。
- $(x - \mu)^\top \Sigma^{-1} (x - \mu)$: **马氏距离平方**。

4.2.5 GMM 的 EM 求解

E 步（责任度）：

$$\gamma_{ik} = \frac{\pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x_i | \mu_j, \Sigma_j)}$$

其中：

- γ_{ik} : 样本 i 属于分量 k 的**后验概率**（软分配）。
- 分母：所有分量的加权密度和（归一化）。
- 与 K-means 的硬分配 z_i 对比：GMM 是**软分配**。

M 步（参数更新）：

$$\mu_k = \frac{\sum_i \gamma_{ik} x_i}{\sum_i \gamma_{ik}}, \quad \Sigma_k = \frac{\sum_i \gamma_{ik} (x_i - \mu_k)(x_i - \mu_k)^\top}{\sum_i \gamma_{ik}}, \quad \pi_k = \frac{\sum_i \gamma_{ik}}{N}$$

其中：

- $N_k^{\text{eff}} = \sum_i \gamma_{ik}$: 分量 k 的**有效样本数**。
- 含义：用责任度加权计算均值、协方差、权重。

K-means 是 GMM 的特例：当所有 $\Sigma_k = \sigma^2 I$ 且 $\sigma \rightarrow 0$ 时，软分配退化为硬分配，GMM 退化为 K-means。

4.2.6 图像领域用法

- **颜色量化**：K-means 把图像颜色压缩到 K 种（GIF 调色板）。

- **图像分割**：GMM 对颜色/纹理建模，做像素聚类。
- **背景建模**：GMM 对每个像素的颜色随时间建模，检测运动目标（MOG）。
- **视觉词袋**：K-means 生成视觉词典。

4.2.7 与深度学习的联系

- **VQ-VAE**：用离散码本（等价于 K-means 的质心）做深度量化。
- **MoE (混合专家)**：GMM 的"软分配"思想用于门控网络。
- **EM 是深度生成模型 (VAE) 变分推断的雏形。**

4.3 主成分分析 (Principal Component Analysis, PCA)

4.3.1 核心思想

PCA 找一组**正交方向**，使数据投影后方差最大，用少数方向表示高维数据，实现**降维**。

4.3.2 数学推导

数据中心化：

$$\tilde{x}_i = x_i - \bar{x}, \quad \bar{x} = \frac{1}{N} \sum x_i$$

其中：

- x_i ：第 i 个样本 (D 维)。
- $\bar{x}$ ：样本均值向量。
- $\tilde{x}_i$ ：中心化后的样本。

协方差矩阵：

$$\Sigma = \frac{1}{N} \sum_{i=1}^N \tilde{x}_i \tilde{x}_i^\top = \frac{1}{N} \tilde{X}^\top \tilde{X}$$

其中：

- $\Sigma \in \mathbb{R}^{D \times D}$ ：**协方差矩阵**，对角元是各维方差，非对角元是维间协方差。
- $\tilde{X} \in \mathbb{R}^{N \times D}$ ：中心化数据矩阵（每行一个样本）。

- 含义：刻画各维的波动与相关性。

特征分解：

$$\Sigma u_j = \lambda_j u_j, \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D \geq 0$$

其中：

- u_j ：第 j 个**特征向量**（主成分方向），单位向量且互相正交。
- λ_j ：第 j 个**特征值**，等于数据在该方向上的**方差**。
- 含义：特征值越大，该方向越"重要"。

投影降维：取前 K 个特征向量组成 $U_K = [u_1, \dots, u_K]$ ：

$$y_i = U_K^\top \tilde{x}_i \in \mathbb{R}^K$$

其中：

- $U_K \in \mathbb{R}^{D \times K}$ ：投影矩阵。
- y_i ：降维后的**主成分得分**（ K 维）。
- 含义：把 D 维数据压到 K 维，保留最大方差。

重构：

$$\hat{x}_i = U_K y_i + \bar{x}$$

其中 $\hat{x}_i$ 是重构样本；重构误差 = 被丢弃方向上的方差之和。

4.3.3 方差解释率

$$\text{EVR}(K) = \frac{\sum_{j=1}^K \lambda_j}{\sum_{j=1}^D \lambda_j}$$

其中：

- $\text{EVR}(K)$ ：前 K 个主成分解释的**方差比例**。
- 常取 $\text{EVR} \geq 0.95$ 确定 K 。

4.3.4 与 SVD 的关系

对中心化矩阵做 SVD： $\tilde{X} = U S V^\top$ ，则：

- 主成分方向 = V 的列（右奇异向量）。
- 特征值 $\lambda_j = s_j^2 / N$ （ s_j 是奇异值）。

- 得分 = US 。

SVD 更数值稳定，实践中常用 SVD 实现 PCA。

4.3.5 图像领域用法

- **特征脸 (Eigenfaces)**：人脸图像 PCA 降维，前几个主成分是“脸的基本模式”。
- **图像压缩**：保留前 K 个主成分重构图像。
- **去噪**：丢弃小方差方向（多为噪声）。
- **描述子降维**：SIFT 128 维 $\rightarrow$ PCA 降到 20~64 维，加速匹配。
- **白化**：PCA 后各维除以 $\sqrt{\lambda_j}$ ，使各维等方差。

4.3.6 与深度学习的联系

- **PCA = 线性自编码器**：单层线性 AE 的最优解就是 PCA 子空间。
- **白化**是深度网络输入预处理的常用手段。
- **注意力/低秩分解**：PCA 的低秩思想用于网络压缩（SVD 分解权重）。
- **对比**：PCA 是线性无监督降维，自编码器是非线性版本。

4.4 流形学习 (Manifold Learning)

4.4.1 核心假设

流形假设：高维数据实际上分布在一个**低维流形**上（局部像欧氏空间）。流形学习的目标是**恢复这个低维结构**，做**非线性降维**。

形式化：存在映射

$$\phi: \mathcal{M} \subset \mathbb{R}^d \rightarrow \mathbb{R}^D, \quad D \gg d$$

其中：

- $\mathcal{M}$ ：低维流形（内在维度 d ）。
- D ：观测空间维度。
- ϕ ：嵌入映射（把低维坐标映到高维观测）。
- 目标：找逆映射 ϕ^{-1} ，即从高维数据恢复低维坐标。

4.4.2 代表方法

(1) LLE (局部线性嵌入)

假设每个点可由其近邻**线性重构**，且重构权重在低维保持：

$$\min_W \sum_i \left\| x_i - \sum_{j \in \mathcal{N}(i)} W_{ij} x_j \right\|^2, \quad \sum_j W_{ij} = 1$$

其中：

- W_{ij} : 样本 j 对重构 i 的**权重**。
- $\mathcal{N}(i)$: i 的近邻集合。
- 约束 $\sum_j W_{ij} = 1$: 权重归一化（平移不变）。

再固定 W ，求低维坐标 y_i ：

$$\min_Y \sum_i \left\| y_i - \sum_j W_{ij} y_j \right\|^2, \quad Y^\top Y = I$$

其中：

- $Y \in \mathbb{R}^{N \times d}$: 低维嵌入坐标。
- $Y^\top Y = I$: 约束防止退化解（尺度/旋转不定）。
- 解为矩阵 $(I - W)^\top (I - W)$ 的最小 d 个特征向量。

(2) Isomap

用**测地距离**（图上最短路径）替代欧氏距离，再做 MDS：

$$d_{\text{geo}}(i, j) = \min_{\text{path}} \sum \|x_a - x_b\|$$

其中 d_{geo} 是流形上的**测地距离**，通过近邻图的最短路径近似。

(3) t-SNE

把高维相似度转成概率，低维也转成概率，最小化两者 KL 散度：

$$\text{KL}(P \| Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}$$

其中：

- p_{ij} : 高维空间中 i, j 的**相似度概率**（高斯核）。
- q_{ij} : 低维空间中的相似度概率（**t 分布核**，重尾，缓解拥挤）。

- KL: KL 散度, 衡量两个分布的差异。
- 含义: 让低维的邻接关系尽量匹配高维。

(4) **UMAP**: 基于拓扑数据分析, 比 t-SNE 更快且更好保留全局结构。

4.4.3 图像领域用法

- **可视化**: 把 CNN 特征降到 2D 看类别可分性 (t-SNE 最常用)。
- **人脸/姿态流形**: 人脸图像随姿态、光照变化形成低维流形。
- **检索**: 流形上的近邻检索。
- **降维预处理**: Isomap/LLE 用于手写数字、人脸识别。

4.4.4 与深度学习的联系

- **流形假设是深度学习的理论基石之一**: 深度网络学的是"把流形展平"的映射。
- **自编码器 / VAE 是参数化、可泛化的流形学习** (能处理新样本)。
- **t-SNE/UMAP 用于分析深度特征空间**, 是理解网络的常用工具。
- **对比学习**的目标就是让同类在嵌入流形上聚集。

4.5 半监督学习 (Semi-supervised Learning)

4.5.1 问题设定

有少量有标签数据 $\{(x_i, y_i)\}_{i=1}^L$ 和大量无标签数据 $\{x_j\}$, 利用无标签数据提升性能。核心假设: $\mathcal{X}^{L+U}$

- **平滑假设**: 相近样本有相近标签。
- **聚类假设**: 同一簇内样本同类。
- **流形假设**: 数据在低维流形上, 沿流形标签平滑。

4.5.2 主要方法

(1) 自训练 (Self-training)

1. 用有标签数据训练模型。

2. 预测无标签数据，取**高置信度**样本加入训练集。
3. 重复。

置信度阈值 τ ：只把 $\max_c P(c | x) \geq \tau$ 的样本加入。

(2) 协同训练 (Co-training)

用两个**不同视图**（特征子集）各训一个分类器，互相给对方标注高置信样本。

(3) 图半监督 (Label Propagation)

在相似度图上传播标签。目标函数：

$$E(f) = \sum_{i,j} W_{ij} \|f_i - f_j\|^2$$

其中：

- W_{ij} ：样本 i, j 的**相似度**（如高斯核）。
- f_i ：样本 i 的**预测分数**（软标签）。
- 含义：相似样本的预测应接近；有标签样本固定为真值。
- 解： $f = (I - \alpha S)^{-1} y$ ，其中 $S = D^{-1/2} W D^{-1/2}$ 是归一化相似度矩阵， α 是传播强度。

(4) **半监督 SVM (S3VM)**：让超平面穿过低密度区域。

(5) **一致性正则 (深度半监督)**：对同一输入加不同扰动，要求输出一致（ Π -model、Mean Teacher、FixMatch）。

4.5.3 图像领域用法

- **医学图像分割**：标注昂贵，用少量标注 + 大量未标注。
- **遥感分类**：标注成本高。
- **网页图像分类**：少量标注 + 海量未标注。
- **伪标签 (Pseudo-labeling)**：竞赛与工业界常用。

4.5.4 与深度学习的联系

- 半监督是深度学习的核心训练范式之一：FixMatch、Mean Teacher、Noisy Student。
 - **自监督学习** (SimCLR、MAE、MoCo) 可看作“无标签预训练 + 少量标签微调”，是半监督的极端形式。
 - **伪标签**是知识蒸馏与半监督的桥梁。
-

5. 其他版本中的扩展算法 (ICDM 2008 版差异项)

本节补齐 ICDM 2008 版名单中用户版本未列出的算法：**C4.5**、**CART**、**PageRank**、**AdaBoost**、**EM**、**Apriori**，以及入门教材版常列的**神经网络 / 深度学习**。这些算法在图像领域未必是主力，但在数据挖掘、推荐系统、集成学习、概率推断等领域地位极高，因此本节同时给出**非图像用途**。

5.1 C4.5

5.1.1 定位

C4.5 是 **ID3 的改进版** (Quinlan, 1993)，是决策树算法史上最著名的版本之一，也是 ICDM 2008 榜单的**第一名**。它解决了 ID3 的两个致命缺陷：

- ID3 只能处理**离散特征**，C4.5 可处理**连续特征**（二分阈值）。
- ID3 用信息增益会**偏向取值多的特征**，C4.5 改用**信息增益率**。

5.1.2 信息增益率

$$\text{GainRatio}(S, A) = \frac{\text{Gain}(S, A)}{\text{SplitInfo}(S, A)}$$

其中：

- S ：当前节点的样本集合。
- A ：候选划分特征。
- $\text{Gain}(S, A) = H(S) - \sum_v \frac{|S_v|}{|S|} H(S_v)$ ：**信息增益**，即用 A 划分后熵的下降量。
- $H(S) = -\sum_c p_c \log_2 p_c$ ： S 的**信息熵**， p_c 是类别 c 的占比。
- S_v ： S 中特征 A 取值为 v 的子集； $|S_v|/|S|$ 是子集权重。
- $\text{SplitInfo}(S, A) = -\sum_v \frac{|S_v|}{|S|} \log_2 \frac{|S_v|}{|S|}$ ：**分裂信息**，衡量 A 把数据切得多碎。
- 含义：分母惩罚“取值过多”的特征（如身份证号），使增益率不被这类特征主导。

5.1.3 连续特征处理

对连续特征 A ，把取值排序后取相邻中点作为候选阈值 t ：

$$t = \frac{a_i + a_{i+1}}{2}$$

其中：

- a_i, a_{i+1} ：排序后相邻的两个取值。
- t ：候选**二分阈值**，把 $A \leq t$ 与 $A > t$ 分成两支。
- 对所有候选 t 计算增益率，取最优者。

5.1.4 缺失值处理

- **划分时**：把缺失样本按权重比例分到各分支。
- **预测时**：把缺失样本同时送入所有分支，按权重加权投票。

5.1.5 剪枝：悲观剪枝

C4.5 用**悲观错误剪枝 (PEP)**：把训练集上的错误率加上一个惩罚项（基于二项分布的标准差），若剪枝后惩罚错误率不升则剪掉子树。

$$e_{\text{pes}} = e + z \sqrt{\frac{e(1-e)}{N}}$$

其中：

- e ：节点上的**训练错误率**。
- N ：该节点覆盖的样本数。
- z ：置信度对应的正态分位数（如 95% 对应 1.645）。
- e_{pes} ：**悲观错误率**，样本越少惩罚越大，避免小样本子树过拟合。

5.1.6 非图像用途

- **信用评分**：银行用 C4.5 建可解释的违约预测树。
- **医疗诊断**：规则可读，医生能理解判断路径。
- **客户流失预测**：电信、银行经典应用。
- **遥感/生物分类**：特征混合（连续+离散）时优势明显。

5.1.7 与深度学习的联系

- **可解释性对照**：C4.5 输出的是人能读的规则，深度网络是黑箱；可解释 AI（XAI）常拿决策树做"代理模型"解释网络。
- **软决策树**：把硬分裂换成可微的软分裂，即可端到端训练（Deep Neural Decision Trees）。

5.2 CART

5.2.1 定位

CART（Classification and Regression Trees, Breiman et al., 1984）是**随机森林与 GBDT 的基学习器**，也是 ICDM 2008 榜单成员。与 C4.5 的关键区别：

维度	C4.5	CART
划分方式	多叉（按取值）	二叉（是/否）
不纯度	信息增益率	基尼不纯度
任务	仅分类	分类 + 回归
剪枝	悲观剪枝	代价复杂度剪枝
输出	规则集	二叉树

5.2.2 基尼不纯度

$$\text{Gini}(S) = 1 - \sum_{c=1}^C p_c^2 = \sum_{c \neq c'} p_c p_{c'}$$

其中：

- S ：节点样本集合。
- C ：类别数。
- p_c ： S 中类别 c 的**占比**。
- $\sum_c p_c^2$ ：随机抽两个样本**同类**的概率。
- $1 - \sum_c p_c^2$ ：随机抽两个样本**异类**的概率，即不纯度。
- 与熵对比：基尼**无对数运算**，计算更快，且曲线形状接近，实践中效果相当。

5.2.3 回归树的划分准则

回归任务用平方误差代替不纯度：

$$\text{SSE}(S) = \sum_{i \in S} (y_i - \bar{y}_S)^2, \quad \bar{y}_S = \frac{1}{|S|} \sum y_i$$

其中：

- y_i ：样本 i 的连续目标值。
- $\bar{y}_S$ ：节点 S 内目标值的均值（叶子的预测值）。
- SSE：平方误差和，越小越纯。
- 划分时选使左右子节点 SSE 之和最小的特征与阈值。

5.2.4 代价复杂度剪枝（CCP）

$$R_\alpha(T) = R(T) + \alpha|T|$$

其中：

- T ：一棵子树。
- $R(T)$ ：子树 T 在训练集上的误差（如误分类率或 SSE）。
- $|T|$ ：子树 T 的叶子数（复杂度）。
- $\alpha \geq 0$ ：复杂度惩罚系数，越大越倾向剪枝。
- $R_\alpha(T)$ ：代价复杂度，权衡“误差”与“复杂度”。
- 做法：从小到大取一系列 α ，得到嵌套的子树序列，再用交叉验证选最优。

5.2.5 非图像用途

- 随机森林 / GBDT / XGBoost / LightGBM 的基学习器——表格数据的事实标准。
- 金融风控：信用评分卡、反欺诈。
- 医疗：疾病风险预测、疗效分析。
- 工业：设备故障预测、销量预测（回归树）。
- 特征工程：用 CART 的特征重要性做特征筛选。

5.2.6 与深度学习的联系

- 表格数据上 GBDT 常胜过深度网络，是深度学习的强劲对手。
- 深度森林（gcForest）：用 CART 森林堆叠成多层，模拟深度结构。
- NODE / 可微树：把 CART 的软分裂嵌入网络，实现端到端训练。

5.3 PageRank

5.3.1 定位

PageRank (Page & Brin, 1998) 是 **Google 搜索的奠基算法**，也是 ICDM 2008 榜单成员。它把网页看成图的节点，超链接看成有向边，用**迭代**方式计算每个节点的重要性。

5.3.2 核心公式

$$\text{PR}(u) = \frac{1-d}{N} + d \sum_{v \in B_u} \frac{\text{PR}(v)}{L(v)}$$

其中：

- $\text{PR}(u)$ ：节点 u 的**重要性得分**（PageRank 值）。
- N ：图中节点总数。
- $d \in (0, 1)$ ：**阻尼系数**（damping factor），通常取 0.85，表示用户继续点击链接的概率。
- $1 - d$ ：**随机跳转概率**，用户随机打开任意网页的概率。
- B_u ：**指向 u 的所有节点集合**（入链来源）。
- $L(v)$ ：节点 v 的**出链数量**。
- $\text{PR}(v)/L(v)$ ： v 把自己的重要性**均分**给它的每个出链。
- 含义：一个网页的重要性 = 随机跳转的基线 + 所有入链网页分来的重要性之和。

5.3.3 矩阵形式

$$\mathbf{r} = \frac{1-d}{N} \mathbf{1} + d M^\top \mathbf{r}$$

其中：

- $\mathbf{r} \in \mathbb{R}^N$ ：所有节点的 PageRank 向量。
- $\mathbf{1}$ ：全 1 向量。
- M ：**列随机转移矩阵**， $M_{uv} = 1/L(v)$ 表示从 v 跳到 u 的概率（ v 有链到 u 时）。
- $M^\top$ ：转置，使 $\mathbf{r}$ 按列更新。
- 含义：这是一个**不动点方程**，用幂迭代 $\mathbf{r}^{(t+1)} = \frac{1-d}{N} \mathbf{1} + d M^\top \mathbf{r}^{(t)}$ 求解。

5.3.4 收敛性

- 阻尼系数 $d < 1$ 保证转移矩阵本原，幂迭代必收敛到唯一平稳分布。
- 收敛速度由 d 决定， d 越大收敛越慢（通常迭代几十次即可）。
- 等价于求矩阵 $\frac{1-d}{N}\mathbf{1}\mathbf{1}^\top + dM^\top$ 的主特征向量。

5.3.5 非图像用途

- **网页搜索排序**：Google 的原始排序信号。
- **社交网络影响力**：找关键意见领袖（KOL）。
- **学术引用分析**：论文重要性（类似 Eigenfactor）。
- **推荐系统**：用户-物品二部图上的重要性传播。
- **生物网络**：蛋白质互作网络中的关键蛋白识别。
- **交通网络**：路网节点重要性、拥堵传播分析。

5.3.6 图像领域用法

- **显著性检测**：把图像块建图，用 PageRank 找"最受关注"的区域。
- **图像检索重排序**：在相似度图上做流形排序（Manifold Ranking），本质是 PageRank 的变体。
- **超像素图**：超像素为节点、相似度为边，做图上的重要性传播。
- **点云/网格分析**：网格顶点的重要性排序。

5.3.7 与深度学习的联系

- **图神经网络 (GNN)**：GCN 的传播规则 $H^{(l+1)} = \sigma(\hat{A}H^{(l)}W^{(l)})$ 与 PageRank 的迭代传播同源，都是"邻居信息聚合"。
 - **注意力即传播**：自注意力可看作带权、可学习的 PageRank 式传播。
 - **随机游走**：Node2Vec、DeepWalk 用随机游走学图嵌入，直接继承 PageRank 思想。
-

5.4 神经网络 / 深度学习 (Neural Networks / Deep Learning)

5.4.1 单神经元

$$a = \phi\left(\sum_{j=1}^D w_j x_j + b\right) = \phi(w^\top x + b)$$

其中:

- x_j : 输入第 j 维。
- w_j : 权重。
- b : 偏置。
- ϕ : 激活函数 (Sigmoid、ReLU、tanh) 。
- a : 神经元输出。

5.4.2 多层感知机 (MLP)

$$h^{(l)} = \phi\left(W^{(l)}h^{(l-1)} + b^{(l)}\right)$$

其中:

- $h^{(l)}$: 第 l 层激活。
- $W^{(l)}$: 第 l 层权重矩阵。
- $b^{(l)}$: 第 l 层偏置。
- $h^{(0)} = x$: 输入。

万能逼近定理: 足够宽的单隐层网络可逼近任意连续函数。

5.4.3 反向传播

链式法则:

$$\frac{\partial L}{\partial W^{(l)}} = \delta^{(l)}(h^{(l-1)})^\top, \quad \delta^{(l)} = \left((W^{(l+1)})^\top \delta^{(l+1)}\right) \odot \phi'\left(z^{(l)}\right)$$

其中:

- L : 损失。

- $\delta^{(l)}$: 第 l 层的**误差项** (损失对该层预激活的梯度)。
- $z^{(l)} = W^{(l)}h^{(l-1)} + b^{(l)}$: 预激活。
- $\odot$: 逐元素乘。
- ϕ' : 激活函数导数。

5.4.4 与前面算法的关系

- 逻辑回归 = 无隐层网络。
- SVM = 单层 + Hinge 损失。
- PCA = 线性自编码器。
- K-means = 硬分配的自编码器。
- 深度学习是这些经典算法的**非线性、端到端、可扩展**版本。

详细内容见仓库 `cnn-transformer-notes.md`。

5.5 AdaBoost

5.5.1 核心思想

自适应提升: 串行训练多个**弱分类器**，每个关注前一个分错的样本，最后加权投票成强分类器。

5.5.2 算法

样本权重 $D_t(i)$: 第 t 轮中样本 i 的权重，初始均匀 $1/N$ 。

弱分类器误差:

$$\epsilon_t = \sum_{i=1}^N D_t(i) 1[h_t(x_i) \neq y_i]$$

其中:

- h_t : 第 t 个弱分类器。
- ϵ_t : **加权错误率**。
- $D_t(i)$: 样本 i 在第 t 轮的权重。

分类器权重:

$$\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \epsilon_t}{\epsilon_t} \right)$$

其中:

- α_t : 第 t 个弱分类器的**话语权**。
- ϵ_t 越小 $\rightarrow \alpha_t$ 越大 (越准的越有发言权)。
- $\epsilon_t = 0.5$ 时 $\alpha_t = 0$ (等于瞎猜, 无贡献)。

权重更新:

$$D_{t+1}(i) = \frac{D_t(i) \exp(-\alpha_t y_i h_t(x_i))}{Z_t}$$

其中:

- $y_i \in -1, +1$: 真实标签。
- $h_t(x_i) \in -1, +1$: 预测。
- $y_i h_t(x_i) = +1$ 表示分对, -1 表示分错。
- 分错时指数项 > 1 , 权重**增大**; 分对时权重**减小**。
- Z_t : 归一化因子, 使 $\sum_i D_{t+1}(i) = 1$ 。

最终分类器:

$$H(x) = \text{sign} \left(\sum_{t=1}^T \alpha_t h_t(x) \right)$$

其中 T 是弱分类器个数。

5.5.3 图像领域用法

- **Viola-Jones 人脸检测**: AdaBoost + Haar 特征 + 级联, 实时人脸检测的里程碑。
- **目标检测**: 级联分类器逐级过滤背景。
- **特征选择**: AdaBoost 天然做特征选择 (只选有用的弱分类器)。

5.5.4 非图像用途

- **信用评分与风控**: 多弱分类器集成提升违约预测精度。
- **生物信息学**: 基因表达数据分类、蛋白质功能预测。
- **文本分类与情感分析**: 与决策树桩组合。

- **医学诊断**：多指标融合的辅助诊断。
- **竞赛基线**：Kaggle 早期表格数据常用。

5.5.5 与深度学习的联系

- **Boosting 思想**：梯度提升 (GBDT) 是 AdaBoost 的推广。
- **级联思想**：被深度检测器 (Cascade R-CNN) 继承。
- **与 Bagging 对比**：Bagging 并行降方差，Boosting 串行降偏差。

5.6 EM 算法 (Expectation-Maximization)

5.6.1 问题

含隐变量 Z 时，最大似然难解：

$$\log p(X | \theta) = \log \sum_Z p(X, Z | \theta)$$

其中：

- X ：观测数据。
- Z ：隐变量（如 GMM 的簇归属）。
- θ ：参数。
- 难点：对数内有求和，无法直接求导。

5.6.2 EM 两步

E 步：计算隐变量后验（责任度）：

$$Q(\theta | \theta^{(t)}) = \mathbb{E}_{Z|X, \theta^{(t)}} [\log p(X, Z | \theta)]$$

M 步：最大化：

$$\theta^{(t+1)} = \arg \max_{\theta} Q(\theta | \theta^{(t)})$$

其中：

- $\theta^{(t)}$ ：第 t 轮参数。
- Q ：期望对数似然（对隐变量求期望）。

- 含义：E 步"猜"隐变量，M 步"更新"参数，交替上升。

5.6.3 收敛性

EM 保证 $\log p(X | \theta^{(t+1)}) \geq \log p(X | \theta^{(t)})$ ，即**单调不减**，收敛到局部最优。

5.6.4 图像领域用法

- **GMM-EM 图像分割**：对颜色/纹理建模，做像素聚类。
- **背景建模**：GMM 对像素颜色随时间建模，检测运动目标。
- **缺失像素/遮挡填补**：把缺失值当隐变量做 EM 推断。

5.6.5 非图像用途

- **GMM 训练**（见 4.2.5）。
- **隐马尔可夫模型（HMM）** 的 Baum-Welch：语音识别、基因序列分析。
- **缺失数据填补**：统计调查、临床试验中的缺失值。
- **混合模型聚类**：客户分群、市场细分。
- **混合专家（MoE）**：门控网络的参数估计。

5.6.6 与深度学习的联系

- **VAE 的变分推断**是 EM 的推广（用神经网络参数化 q ）。
 - **EM 是"硬/软分配"的统一框架**，K-means 与 GMM 都是特例。
-

5.7 Apriori

5.7.1 问题：关联规则挖掘

从交易数据中发现"买了 A 也会买 B"的规则 $A \Rightarrow B$ 。

5.7.2 关键指标

支持度：

$$\text{supp}(A \Rightarrow B) = \frac{|T : A \cup B \subseteq T|}{|T_{\text{all}}|}$$

其中：

- T ：一笔交易（项集）。
- $A \cup B \subseteq T$ ：同时包含 A 和 B 的交易。
- $|T_{\text{all}}|$ ：总交易数。
- 含义：规则覆盖的交易比例。

置信度：

$$\text{conf}(A \Rightarrow B) = \frac{\text{supp}(A \cup B)}{\text{supp}(A)}$$

其中 $\text{supp}(A)$ 是只含 A 的交易比例；含义：买了 A 的人中买 B 的比例。

提升度：

$$\text{lift}(A \Rightarrow B) = \frac{\text{conf}(A \Rightarrow B)}{\text{supp}(B)}$$

其中 $\text{supp}(B)$ 是 B 的基础频率； $\text{lift} > 1$ 表示正相关。

5.7.3 Apriori 原理

先验性质：频繁项集的所有子集也频繁（反之，非频繁项集的超集非频繁）。据此逐层生成候选并剪枝。

5.7.4 图像领域用法

- **图像共现模式：**发现常一起出现的视觉元素（如"天空+草地"）。
- **场景理解：**物体共现关系建模。
- **图像标注：**标签关联规则。
- 图像中直接使用较少，更多用于**推荐/购物篮分析**。

5.7.5 非图像用途

- **购物篮分析：**超市发现"啤酒 + 尿布"式关联规则。
- **推荐系统：**"看了 A 也看 B"的关联推荐。
- **交叉销售：**电商捆绑销售策略。
- **医疗处方分析：**药物共现与不良反应挖掘。

- **网络安全**：入侵检测中的事件关联。
- **生物信息**：基因/蛋白共表达模式。


5.7.6 与深度学习的联系

- **共现统计**被用于**图神经网络**的边构建。
 - **注意力中的共现**：自注意力可看作学习特征间的"关联强度"。
-

6. 图像领域应用总览

算法	图像中的典型任务	输入特征	备注
KNN	检索、匹配、分类基线	描述子、CNN 特征	需加速结构
朴素贝叶斯	肤色检测、分割	颜色、像素	生成式
逻辑回归	二分类、多标签	任意特征	网络分类头
SVM	行人检测、分类	HOG、SIFT	核方法
决策树/森林	分割、关键点、检测	像素、Texon	随机蕨
C4.5	像素分类、遥感	混合特征	可解释规则
CART	分割、回归（深度/视差）	像素、描述子	随机森林基学习器
聚类	分割、词袋、超像素	颜色+位置	无监督
K-means/GMM	颜色量化、背景建模	颜色	GMM 背景建模
PCA	特征脸、压缩、降维	图像、描述子	线性
流形学习	可视化、检索	CNN 特征	非线性
半监督	医学分割、遥感	图像	标注稀缺
AdaBoost	人脸检测	Haar	级联
EM	GMM 分割	颜色	隐变量
Apriori	场景共现	标签	较少
PageRank	显著性、检索重排序	图像块图	流形排序

图像处理流水线中的位置：



7. 与深度学习的联系（重点）

7.1 经典算法是深度网络的"积木"

经典算法	深度对应	关系
逻辑回归	单层网络 / Softmax 头	完全相同
SVM	Hinge 损失 / 大间隔 softmax	损失函数沿用
PCA	线性自编码器	最优解等价
K-means	VQ-VAE 码本 / 硬分配 AE	量化思想
GMM	MoE 门控 / VAE 先验	软分配
EM	VAE 变分推断	推广
决策树	深度森林 / 注意力路由	结构类比
C4.5 / CART	软决策树 / NODE / gcForest	可微化
AdaBoost	梯度提升 / 级联检测	思想继承
KNN	度量学习 / 原型网络	嵌入空间近邻
流形学习	自编码器 / 对比学习	参数化版本
半监督	FixMatch / 自监督	训练范式
PageRank	GNN 消息传递 / 随机游走嵌入	邻居聚合

7.2 三代特征表示（与仓库其他文档呼应）

阶段	代表	人的参与	对应文档
手工设计	SIFT、HOG、LBP	高	feature-descriptors-notes.md
浅层学习	PCA、K-means、SVM、GMM	中	本文
深度表示学习	CNN、Transformer	低	cnn-transformer-notes.md

7.3 为什么深度学习"取代"了经典方法

- **特征学习**：经典方法依赖手工特征，深度网络端到端学特征。
- **非线性**：核方法靠固定核，深度靠**多层非线性**。
- **可扩展**：深度网络能吃海量数据，经典方法在高维大数据上受限。
- **统一**：分类、检测、分割统一到一个网络。

7.4 经典方法为何仍然重要

- **小数据**：样本少时，SVM、随机森林常优于深度网络。
- **可解释**：决策树、逻辑回归系数可解释。
- **轻量**：嵌入式/实时场景，KNN、PCA、AdaBoost 仍高效。
- **理论**：理解深度网络需要经典理论（偏差-方差、流形、核）。
- **基线**：任何深度模型都该与经典基线对比。

7.5 偏差-方差视角

$$\mathbb{E}[\text{误差}] = \underbrace{\text{偏差}^2}_{\text{欠拟合}} + \underbrace{\text{方差}}_{\text{过拟合}} + \underbrace{\text{噪声}}_{\text{不可约}}$$

其中：

- **偏差**：模型假设与真实规律的差距（模型太简单）。
 - **方差**：模型对训练集扰动的敏感度（模型太复杂）。
 - **噪声**：数据本身的随机性，无法消除。
 - **含义**：Bagging/随机森林**降方差**，Boosting**降偏差**，深度网络靠**层次**同时降两者。
-


8. 速查表

8.1 算法速查

算法	类型	关键公式	超参数	优点	缺点
KNN	监督/非参数	$d(x, x')$	k 、距离	简单、无训练	慢、维度灾难
朴素贝叶斯	监督/生成	$P(c) \prod_j P(x_j c)$	分布类型	快、小数据好	独立假设强
逻辑回归	监督/判别	$\sigma(w^\top x + b)$	λ, η	概率输出、可解释	线性
SVM	监督/判别	max 间隔 + 核	C, γ	高维有效、核灵活	大数据慢、调参
决策树	监督	不纯度下降	深度、叶子数	可解释、混合特征	易过拟合
C4.5	监督	信息增益率	置信度	连续+缺失值	多叉树、慢
CART	监督	基尼 / SSE	α	分类+回归、二叉树	贪心、不稳定
随机森林	监督/集成	Bagging + 特征随机	T, m	稳健、特征重要性	模型大
聚类	无监督	簇内距离和	K, ϵ	发现结构	需选参
K-means	无监督	$\sum \ x_i - \mu_k\ ^2$	K	快、简单	球形假设
GMM	无监督/生成	$\sum \pi_k \mathcal{N}$	K 、协方差型	软分配、灵活	局部最优
PCA	无监督/线性	$\Sigma u = \lambda u$	K	降维、去噪	仅线性
流形学习	无监督/非线性	保持邻域	近邻数、 d	非线性结构	慢、难泛化
半监督	半监督	一致性/传播	阈值	省标注	假设依赖
AdaBoost	集成	α_t 加权投票	T 、弱学习器	高精度	对噪声敏感
EM	通用	E 步 + M 步	初值	隐变量框架	局部最优

算法	类型	关键公式	超参数	优点	缺点
Apriori	关联规则	支持度/置信度	支持度阈值	可解释	组合爆炸
PageRank	图/排序	$\frac{1-d}{N} + d \sum \frac{PR(v)}{L(v)}$	d	无监督、全局	需建图、静态

8.2 选择指南



9. 结论

1. **"十大"没有唯一版本**：ICDM 2008 版偏数据挖掘（C4.5、K-Means、SVM、Apriori、EM、PageRank、AdaBoost、kNN、Naive Bayes、CART），入门教材版偏机器学习基础（含逻辑回归、PCA、流形、半监督）。本文两版通吃。
2. **所有算法都是"损失 + 正则 + 优化"的特例**，差别在 L 、 Ω 、 f_θ 的选择。
3. **图像领域**：KNN/SVM/随机森林用于分类检测，K-means/GMM 用于分割与词袋，PCA/流形用于降维与可视化，半监督用于标注稀缺场景。
4. **非图像领域同样重要**：C4.5/CART 是表格数据与风控医疗的主力，PageRank 是搜索与图排序的基石，Apriori 是推荐与购物篮分析的核心，EM 是含隐变量问题的通用框架。
5. **与深度学习一脉相承**：逻辑回归→网络分类头，PCA→自编码器，K-means→VQ-VAE，EM→变分推断，AdaBoost→梯度提升，KNN→度量学习，C4.5/CART→软决策树与深度森林，PageRank→GNN 消息传递。
6. **经典方法不会消失**：小数据、可解释、轻量、理论、基线——五个理由让它们长期有用。

与仓库其他文档的关系： `feature-descriptors-notes.md`（手工描述子）→ **本文（浅层机器学习）** → `cnn-transformer-notes.md`（深度表示学习），三者构成"特征表示三代演进"的完整链条。