

十大机器学习算法详解：原理、逐变量解析、变体谱系、多领域应用与深度学习联系

本文是一份纯理论整理，不涉及任何代码改动。目标是围绕"十大机器学习算法"这一经典提法，做到四件事：

1. **把每个算法的原理讲透**——每个公式都给出**逐项符号解释**（每个变量是什么、量纲、取值范围、物理含义）；
2. **厘清"十大"的版本差异**——不同教材/榜单给出的名单并不一致，本文列出主流版本并补齐差异项；
3. **把每个算法的变体讲全**——每个算法都给出**算法族总览表与各类变体的公式**，说明“同一个思想在不同约束下派生出哪些方法”（如 SVM $\rightarrow$ L2-SVC / ν -SVC / LS-SVM / SVR / One-Class；K-means $\rightarrow$ K-means++ / K-medoids / Mini-batch；EM $\rightarrow$ GEM / ECM / ECME / 变分 EM / MCEM）；
4. **落到应用**——给出每个算法在图像处理/计算机视觉中的具体用法，并**扩展其应用方向**，同时说明它与后续**深度学习**部分的联系。

与仓库中 `feature-descriptors-notes.md`、`cnn-transformer-notes.md` 一脉相承：前者讲"手工描述子"，后者讲"深度表示学习"，本文正好补上中间那一层——**经典机器学习**，即"浅层学习"这一代。

目录

1. 总览：什么是"十大机器学习算法"
2. "十大"的版本差异与本文取舍
3. 监督学习 (Supervised Learning)
4. 3.1 最近邻 (KNN)
5. 3.2 贝叶斯分类 (朴素贝叶斯)

- 6. 3.3 逻辑回归
 - 7. 3.4 支持向量机 (SVM)
 - 8. 3.5 决策树与森林 (随机森林)
 - 9. 无监督学习 (Unsupervised Learning)
 - 10. 4.1 聚类
 - 11. 4.2 K-means 与高斯混合模型
 - 12. 4.3 主成分分析 (PCA)
 - 13. 4.4 流形学习
 - 14. 4.5 半监督学习
 - 15. 其他版本中的扩展算法 (ICDM 2008 版差异项)
 - 16. 5.1 C4.5
 - 17. 5.2 CART
 - 18. 5.3 PageRank
 - 19. 5.4 神经网络 / 深度学习
 - 20. 5.5 AdaBoost
 - 21. 5.6 EM 算法
 - 22. 5.7 Apriori
 - 23. 应用总览
 - 24. 与深度学习的联系 (重点)
 - 25. 速查表
 - 26. 结论
-

1. 总览：什么是"十大机器学习算法"

1.1 提法的来源

"十大机器学习算法" (Top 10 Algorithms in Data Mining / Machine Learning) 并不是一个 有严格定义的官方名单，而是源于若干**综述性文章与教材**的归纳。最常被引用的是：

- **Wu et al., 2008, *Top 10 algorithms in data mining*** (发表于 *Knowledge and Information Systems*) ， 由 IEEE ICDM 组织投票产生， 名单为： C4.5、 K-Means、 SVM、 Apriori、 EM、 PageRank、 AdaBoost、 kNN、 Naive Bayes、 CART。
- 各类**入门教材与在线课程** (如 Python 数据科学、 机器学习入门) 给出的"十大"， 则更偏向**可上手、覆盖监督+无监督**的实用清单， 即用户给出的这一版： KNN、 朴素贝叶斯、 逻辑回归、 SVM、 决策树/森林、 聚类、 K-means/GMM、 PCA、 流形学习、 半监督学习。


两者**视角不同**： 前者是"数据挖掘领域最具影响力的算法"， 后者是"机器学习入门必学的算法"。

1.2 三大范式

所有算法都可以归入三大学习范式：

范式	数据	目标	代表
监督学习	有标签 (x_i, y_i)	学 $x \rightarrow y$ 的映射	KNN、 贝叶斯、 逻辑回归、 SVM、 决策树
无监督学习	无标签 x_i	发现结构 (簇、 子空间、 流形)	聚类、 K-means、 GMM、 PCA、 流形学习
半监督学习	少量标签 + 大量无标签	用无标签数据辅助监督任务	自训练、 协同训练、 图半监督

范式关系示意：



1.3 统一视角：都是"目标函数 + 优化"

尽管形式各异，几乎所有算法都可以写成同一个模板：

$$\hat{\theta} = \arg \min_{\theta} \underbrace{\frac{1}{N} \sum_{i=1}^N L(y_i, f_{\theta}(x_i))}_{\text{经验风险 (拟合数据)}} + \underbrace{\lambda \Omega(\theta)}_{\text{正则化 (控制复杂度)}}$$

其中：

- θ ：模型参数（要学的东西）。
- N ：样本数量。
- x_i ：第 i 个样本的**特征向量**（图像里常是描述子、像素块、颜色直方图等）。
- y_i ：第 i 个样本的**标签**（分类标签或回归值）。
- f_{θ} ：由参数 θ 决定的**预测函数**。
- $L(\cdot, \cdot)$ ：**损失函数**，衡量预测与真值的差距（如平方损失、交叉熵、Hinge 损失）。
- $\Omega(\theta)$ ：**正则项**，惩罚模型复杂度（如 L2、L1、树深度）。
- λ ：**正则化系数**，权衡"拟合数据"与"保持简单"。
- $\hat{\theta}$ ：使总目标最小的最优参数。

含义：不同算法的差别，本质上就是 L 、 Ω 、 f_{θ} 三者的不同选择。例如 SVM 用 Hinge 损失 + L2 正则，逻辑回归用交叉熵 + L2 正则，决策树用不纯度下降作为"隐式损失"。

2. "十大"的版本差异与本文取舍

2.1 主流版本对照

算法	用户给出的版本	ICDM 2008 版	常见入门教材版	本文是否详解
KNN	✓	✓	✓	✓ 3.1
朴素贝叶斯	✓	✓	✓	✓ 3.2
逻辑回归	✓	✗	✓	✓ 3.3
SVM	✓	✓	✓	✓ 3.4
决策树 / 森林	✓	✓ (C4.5、CART)	✓	✓ 3.5
聚类	✓	✓ (K-Means)	✓	✓ 4.1
K-means / GMM	✓	✓ (K-Means)	✓	✓ 4.2
PCA	✓	✗	✓	✓ 4.3
流形学习	✓	✗	⚠ 部分	✓ 4.4
半监督学习	✓	✗	⚠ 部分	✓ 4.5
C4.5	✗	✓	✓	✓ 5.1
CART	✗	✓	✓	✓ 5.2
PageRank	✗	✓	✗	✓ 5.3
神经网络 / 深度学习	✗	✗	✓	✓ 5.4
AdaBoost	✗	✓	✓	✓ 5.5
EM	✗	✓	⚠ 部分	✓ 5.6
Apriori	✗	✓	⚠ 部分	✓ 5.7

说明：用户给出的版本是"入门实用版"，ICDM 2008 是"数据挖掘影响力版"。两者交集是 KNN、朴素贝叶斯、SVM、决策树、K-means；差异项（逻辑回归、PCA、流形学习、半监督 vs AdaBoost、EM、Apriori、PageRank）本文全部补齐，做到"两版通吃"。

2.2 为什么会有差异

- **ICDM 版**偏重"数据挖掘": 强调关联规则 (Apriori)、图排序 (PageRank)、概率推断 (EM), 这些在数据库/推荐系统里更重要。
 - **入门版**偏重"机器学习基础": 强调降维 (PCA)、流形 (t-SNE/LLE)、半监督, 这些在**图像与高维数据**里更常用。
 - **图像领域**的特殊性: 图像是高维、强相关、带空间结构的数据, 因此 PCA、流形学习、K-means (用于视觉词袋) 在图像里地位极高, 而 Apriori、PageRank 在图像里较少直接使用。
-

3. 监督学习 (Supervised Learning)

3.1 最近邻 (Nearest Neighbors / KNN)

3.1.1 核心思想

KNN 是最"懒惰"的算法：**不训练、不建模型**，把全部训练样本存起来，预测时找最近的 k 个邻居投票。它属于**非参数方法**（模型复杂度随数据增长）。

3.1.2 距离度量

最常用的是**欧氏距离**：

$$d(x, x') = \sqrt{\sum_{j=1}^D (x_j - x'_j)^2}$$

其中：

- x, x' ：两个样本的特征向量（各 D 维）。
- D ：特征维度（图像里可能是描述子维度，如 SIFT 的 128）。
- x_j ：向量 x 的第 j 个分量。
- x'_j ：向量 x' 的第 j 个分量。
- $(x_j - x'_j)$ ：第 j 维上的差。
- 平方后求和再开方：即"直线距离"（L2 范数）。
- $d(x, x')$ ：两样本的**不相似度**，越小越相似。

其他常用度量：

度量	公式	适用
曼哈顿距离	$\sum_j x_j - x'_j $	稀疏、鲁棒
余弦距离	$1 - \frac{x \cdot x'}{\ x\ \ x'\ }$	方向敏感（文本、描述子）
汉明距离	$\sum_j [x_j \neq x'_j]$	二进制描述子（BRIEF/ORB）
马氏距离	$\sqrt{(x - x')^\top \Sigma^{-1} (x - x')}$	各维尺度/相关性不同

其中 Σ 是特征的协方差矩阵, Σ^{-1} 是它的逆, 用于"白化"各维尺度。

3.1.3 分类决策规则

多数投票:

$$\hat{y} = \arg \max_{c \in \mathcal{C}} \sum_{i \in \mathcal{N}_k(x)} 1[y_i = c]$$

其中:

- x : 待预测样本。
- $\mathcal{N}_k(x)$: x 的 k 个最近邻的下标集合。
- k : 邻居个数 (超参数)。
- $\mathcal{C}$: 类别集合。
- y_i : 第 i 个训练样本的真实标签。
- $1[\cdot]$: **指示函数**, 条件成立取 1, 否则取 0。
- $\sum_{i \in \mathcal{N}_k(x)} 1[y_i = c]$: 邻居中属于类别 c 的个数。
- $\arg \max_c$: 取票数最多的类别。
- $\hat{y}$: 预测标签。

距离加权投票 (更常用, 近的邻居权重大):

$$\hat{y} = \arg \max_c \sum_{i \in \mathcal{N}_k(x)} w_i 1[y_i = c], \quad w_i = \frac{1}{d(x, x_i) + \epsilon}$$


其中:

- w_i : 第 i 个邻居的**权重**。
- $d(x, x_i)$: 待测样本与第 i 个邻居的距离。
- ϵ : 极小正数, 防止除零。
- 含义: 距离越小, w_i 越大, 投票越有分量。

回归时则取邻居标签的 (加权) 平均:

$$\hat{y} = \frac{\sum_{i \in \mathcal{N}_k(x)} w_i y_i}{\sum_{i \in \mathcal{N}_k(x)} w_i}$$

3.1.4 算法步骤



3.1.5 关键问题

- **k 的选择**: k 太小 $\rightarrow$ 对噪声敏感 (过拟合) ; k 太大 $\rightarrow$ 决策边界过于平滑 (欠拟合) 。 常用交叉验证选 k , 经验值 $k \approx \sqrt{N}$ 。
- **维度灾难**: 高维空间中所有点距离趋于相等, KNN 失效。 解决: 先降维 (PCA) 或特征选择。
- **计算复杂度**: 预测时 $O(ND)$, 大数据需 KD-Tree、Ball-Tree、LSH 加速。

3.1.6 KNN 变体总览

以上是"欧氏距离 + k 近邻 + 多数投票"的标准形式。KNN 的改动点集中在三处: **用什么距离、取哪些邻居、怎么投票**。下表先给出全局印象:

变体	改动点	解决的问题
距离加权 KNN (WKNN)	票权正比于 $1/d$	近邻应更有分量
核加权 KNN	票权为核函数 $K(d)$	平滑、可调尺度
半径近邻 (R-NN)	固定半径而非固定 k	密度不均的数据
模糊 KNN (FKNN)	隶属度而非硬投票	边界样本、软标签
证据 KNN (EKNN)	DS 证据理论融合	不确定性与冲突建模
加权/优化 KNN	学最优权重	特征重要性差异
LMNN	学马氏度量 M	欧氏距离不合适
NCA	学线性变换 A	直接优化留一精度
压缩近邻 (CNN/RNN)	约简训练集	存储与预测速度
近似近邻 (ANN)	KD-Tree/LSH/HNSW	海量数据检索
反 kNN	反向邻居计数	异常 / 离群检测
局部加权回归	局部线性拟合	非参数回归
Parzen 窗	核密度估计	概率密度 / 生成式分类

其中前五个只改**投票规则**, LMNN/NCA 改**距离本身**, 后四个改**邻居集合或任务形式**。

3.1.7 投票与邻域变体

(1) 距离加权 KNN (WKNN)

$$\hat{y} = \arg \max_c \sum_{i \in \mathcal{N}_k(x)} w_i 1[y_i = c], \quad w_i = \frac{1}{d(x, x_i)^p}$$

其中：

- $p \geq 1$: **权重衰减指数**, $p = 1$ 为反比权重, $p = 2$ 衰减更快 (近邻占绝对主导)。
- $d \rightarrow 0$ 时 $w \rightarrow \infty$: 实际中加 ϵ 或改用核形式避免病态。

(2) 核加权 KNN (即 Parzen 窗分类器)

$$\hat{y} = \arg \max_c \sum_{i: y_i = c} K\left(\frac{x - x_i}{h}\right), \quad \hat{p}(x) = \frac{1}{Nh^D} \sum_{i=1}^N K\left(\frac{x - x_i}{h}\right)$$

其中：

- $K(\cdot)$: **核函数** (高斯、Epanechnikov、均匀核), 满足 $K \geq 0$ 、 $\int K = 1$ 。
- $h > 0$: **带宽**, 控制平滑程度; h 小 $\rightarrow$ 尖峰 (过拟合), h 大 $\rightarrow$ 过度平滑 (欠拟合)。
- D : 维度; Nh^D 是归一化因子。
- 含义: KNN 的"硬窗口"换成"软核"后, 就得到**非参数密度估计** (Parzen 窗), 它与 KNN 是同一个对象: **固定 k 是"自适应带宽", 固定 h 是"固定带宽"**。

(3) 半径近邻 (Radius NN / R-NN)

邻居集合改为固定半径内的全部样本：

$$\mathcal{N}_r(x) = \{i : d(x, x_i) \leq r\}$$

其中：

- r : **邻域半径** (超参数), 与 k 互斥使用。
- 优点: 在**密度极不均匀**的数据里, 高密度区不会取到远处的异类点。
- 缺点: 稀疏区可能**邻居为空** (需设置最小邻居数或回退到 k NN)。

(4) 模糊 KNN (FKNN)

给每个类别一个**隶属度**而非 0/1 投票：

$$u_c(x) = \frac{\sum_i 1[y_i = c] d(x, x_i)^{-\frac{2}{m-1}}}{\sum_i d(x, x_i)^{-\frac{2}{m-1}}}$$

其中：

- $m > 1$: **模糊化指数**, $m \rightarrow 1$ 退化为最近邻 (硬), $m \rightarrow \infty$ 退化为等权平均。
- $u_c(x) \in [0, 1]$: 样本属于类 c 的隶属度, $\sum_c u_c = 1$ 。
- 含义: 输出软标签, 适合**多标签 / 样本标注不确定**的场景。

(5) 证据 KNN (EKNN)

用 Dempster-Shafer 证据理论组合各邻居的"类别证据":

$$m_c = \frac{1}{\sum_{\text{正常}} m} \sum_{i \in \mathcal{N}_k(x)} \alpha_i m_{i,c}, \quad \alpha_i = \alpha_0 \exp(-\gamma d(x, x_i)^2)$$

其中:

- $m_{i,c}$: 第 i 个邻居对类 c 的**基本概率指派 (BPA)**。
- α_i : 邻居的**可信度权重**, 随距离指数衰减。
- α_0 : 基础可信度; γ : 衰减率。
- 含义: 能显式表达"**不知道**" (把概率指派给全集), 处理**冲突证据**比硬投票稳健。

3.1.8 度量学习变体 (LMNN 与 NCA)

动机

: 欧氏距离隐含"各维等权、互不相关"的假设。若特征尺度差异大或存在相关性, 应学一个

马氏距离:

$$d_M(x, x') = \sqrt{(x - x')^\top M (x - x')}, \quad M \succeq 0$$

其中:

- $M \in \mathbb{R}^{D \times D}$: **半正定矩阵** ($M \succeq 0$ 保证距离非负且满足三角不等式)。
- $M = I$: 退化为欧氏距离; $M = A^\top A$: 等价于先线性变换 Ax 再算欧氏距离。
- 含义: **学距离 = 学一个能突出问题结构的坐标变换**。

(1) LMNN (Large Margin Nearest Neighbor, Weinberger & Saul, 2009)

把"每个样本的 k 个同类近邻"称为**目标邻居**, 要求它们拉近; 不同类样本推远到间隔之外:

$$\varepsilon_{\text{pull}}(M) = \sum_i \sum_{j \in \mathcal{N}_i^{\text{tgt}}} d_M(x_i, x_j)^2$$

$$\varepsilon_{\text{push}}(M) = \sum_i \sum_{j \in \mathcal{N}_i^{\text{tgt}}} \sum_l (1 - y_{il}) \left[1 + d_M^2(x_i, x_j) - d_M^2(x_i, x_l) \right]_+$$

$$\min_{M \geq 0} (1 - \mu) \varepsilon_{\text{pull}}(M) + \mu \varepsilon_{\text{push}}(M)$$

其中：

- $\mathcal{N}_i^{\text{tgt}}$: 样本 i 的 k 个**同类**目标邻居。
- $y_{il} = 1$ 表示 i 与 l 同类, $y_{il} = 0$ 表示异类。
- $[\cdot]_+ = \max(0, \cdot)$: **合页函数**, 只有"异类比目标邻居更近 (差不足 1)"时才产生惩罚。
- $\mu \in [0, 1]$: 拉近与推远的**权衡系数**, 通常取 0.5。
- 含义: 把 SVM 的**大间隔思想**搬到度量学习上——不是学分类面, 而是学"让 kNN 好用的距离"。
- 求解: 转化为**半正定规划 (SDP)**, 用子梯度 / 块坐标下降。

(2) NCA (Neighborhood Components Analysis, Goldberger 等, 2004)

不显式设间隔, 而是**直接最大化留一法分类正确率**。先用软化的邻居概率:

$$p_{ij} = \frac{\exp(-\|Ax_i - Ax_j\|^2)}{\sum_{k \neq i} \exp(-\|Ax_i - Ax_k\|^2)}$$

其中:

- $A \in \mathbb{R}^{d \times D}$: **线性变换矩阵** (要学的参数, $A^\top A = M$)。
- p_{ij} : 在随机"最近邻"规则下, j 被选为 i 的邻居的**概率**。
- $p_{ii} = 0$: 不把自己当邻居。

样本 i 被正确分类的概率是其同类邻居概率之和:

$$p_i = \sum_{j: y_j = y_i} p_{ij}, \quad \max_A f(A) = \sum_{i=1}^N p_i$$

其中 $f(A)$ 就是**期望留一准确率**。它可按梯度上升优化:

$$\frac{\partial f}{\partial A} = 2A \sum_i \left(p_i \sum_k p_{ik} \tilde{x}_{ik} \tilde{x}_{ik}^\top - \sum_{j: y_j = y_i} p_{ij} \tilde{x}_{ij} \tilde{x}_{ij}^\top \right), \quad \tilde{x}_{ij} = x_i - x_j$$

其中:

- $\tilde{x}_{ij}$: 样本对的**差分向量**。
- 含义: 第一项"拉近所有邻居", 第二项"推远同类邻居", 两项之差即梯度方向。
- 与 LMNN 对比: NCA **无间隔、无约束**, 更简单但容易过拟合; LMNN 有显式间隔、凸性更好。

3.1.9 近似最近邻与加速结构

精确 kNN 的查询复杂度随维度指数上升, 大规模场景必须用**近似最近邻 (ANN)** :

结构	划分方式	查询复杂度	特点
穷举 (Brute)	无	$O(ND)$	精确, 小数据
KD-Tree	轴对齐、按中位数切分	平均 $O(\log N)$	低维 ($D \lesssim 20$)
Ball-Tree	超球划分	类似 KD-Tree	高维略优, 度量可换
LSH	随机哈希	$O(1)$ 近似	理论保证, 需调参
HNSW	分层可导航小世界图	近似 $O(\log N)$	当前 工业首选
IVF-PQ	倒排 + 乘积量化	压缩 + 快查	十亿级向量
Annoy / ScaNN	随机投影树 / 各向异性量化	近似 $O(\log N)$	工程落地成熟

LSH 的核心保证：对一族哈希函数 h , 若

$$P(h(x) = h(x')) = \text{sim}(x, x')$$

即**"越相似的向量碰撞概率越高"**, 则用 L 个哈希表、每表 m 位, 相似度高的点会以高概率落入同一桶, 只需在同桶内做精确比较。

IVF-PQ 的两步：

- 1. **IVF (倒排)**：用 K-means 把向量空间分成若干**倒排列表** (粗聚类), 查询只看最近的几个簇;
- 2. **PQ (乘积量化)**：把 D 维向量切成 m 段, 每段各用一个小码书 (K-means) 量化, 距离用**查表求和**近似:

$$d(x, y)^2 \approx \sum_{s=1}^m \|q_s(x) - q_s(y)\|^2, \quad \|y - x\| \approx \text{查表}$$

其中：

- $q_s(\cdot)$: 第 s 段的**量化器** (码书中心)。
- m : 段数; 每段码书大小通常 256 (1 字节), 故存储量降至原向量的 m/D 。
- 含义：**用一点点精度换巨大的速度与内存收益**, 是 RAG 向量库的底层机制。

3.1.10 邻居约简与非标准用法

(1) 压缩近邻 (CNN rule, Condensed Nearest Neighbor)

迭代筛选：先用第一个样本初始化集合, 再逐个测试; **凡是当前集合能正确分类的样本就丢弃**, 否则加入：

$$S \leftarrow S \cup \{x_i\} \iff \text{NN}_S(x_i) \neq y_i$$

其中 S 是约简后的训练集。含义：只保留**"必要"**的样本, 典型可压到原来的 10%~30% 而不降低精度。

(2) 约简近邻 (RNN rule, Reduced NN)

先用 CNN 约简，再删除**不改变决策边界的内部点**，只留下靠近边界（互为近邻）的样本。另外还有 IB2 / IB3（实例基于学习），在噪声数据上更稳健。

(3) 反 kNN (Reverse kNN)

定义"以 x 为最近邻的样本集合":

$$kNN^R(x) = \{x' : x \in \mathcal{N}_k(x')\}$$

其中:

- $|kNN^R(x)|$ 越大, x 影响的样本越多, 越可能是"中心/正常"点;
- 反之, 反 kNN 数量少 (或为空) 的点是**离群 / 异常点**。
- 常见异常分数: $INFLO(x) = \frac{1}{|kNN^R(x)|} \sum_{x' \in kNN^R(x)} \frac{1}{d(x, x')}$ 。

(4) 局部加权回归 (LOESS / LOWESS)

在待测点附近用**局部加权最小二乘**拟合一个低阶多项式:

$$\min_{\beta} \sum_{i=1}^N w_i(x) (y_i - \beta_0 - \beta_1^T (x_i - x))^2, \quad w_i(x) = K\left(\frac{d(x, x_i)}{h}\right)$$

其中:

- β_0, β_1 : 局部截距与斜率 (只在该点邻域内有效)。
- $w_i(x)$: **随查询点变化的权重** (这是它区别于普通回归的关键)。
- 含义: KNN 的"投票/平均"升级为"**局部线性拟合**", 消除边界处的系统性偏差。

3.1.11 应用方向

(1) 图像 / 视觉

- **图像分类基线**: 把图像表示为特征向量 (颜色直方图、HOG、CNN 特征), 用 KNN 分类。
- **图像检索**: 以图搜图, 找特征空间最近邻。
- **特征匹配**: SIFT 描述子的最近邻匹配 (Lowe 的 ratio test 就是"最近邻 / 次近邻"比值)。
- **超像素 / 像素分类**: 对每个像素的特征做 KNN 分类 (如遥感图像分割)。
- **视频 / 点云**: 视频帧检索、点云配准中的最近邻匹配。

(2) 文本与自然语言

- **文本分类**: TF-IDF / 词向量 + 余弦距离的 KNN 分类 (垃圾邮件、新闻主题)。

- **语义检索 / 问答**：句向量最近邻检索——大模型 RAG 中的向量库召回，本质就是近似 kNN (ANN)。
- **相似词 / 拼写纠错**：在词向量空间找近邻词。

(3) 推荐与检索系统

- **协同过滤**：用户/物品向量最近邻做"相似用户 / 相似物品"推荐。
- **多模态召回**：电商"以图搜商品 / 以文搜商品"。
- **近重复检测**：文档、商品、网页去重。

(4) 生物、医学与化学

- **基因表达分类**：样本在表达谱空间中的近邻分类（肿瘤分型）。
- **蛋白质功能预测**：序列 / 结构特征的近邻投票。
- **药物虚拟筛选**：分子指纹的最近邻检索。

(5) 金融、工业与地理

- **异常检测**：到第 k 近邻的距离作为异常分数（kNN 密度估计）。
- **信用 / 欺诈比对**：与历史案例的相似度比对。
- **地理信息**：POI 推荐、空间最近邻查询（KD-Tree / R-tree 加速）。
- **时序检索**：DTW 距离下的最近邻序列匹配。

(6) 作为通用工具

- **缺失值填补**：用最近邻样本的值填补（KNN Imputer）。
- **近似加速**：用 kNN 近似复杂模型的输出（缓存、蒸馏）。

3.1.12 与深度学习的联系

- **度量学习 (Metric Learning)**：深度网络学一个嵌入空间，使同类近、异类远，再用 KNN 分类——即孪生网络 / Triplet Loss / 对比学习。
 - **原型网络 (Prototypical Networks)**：few-shot 学习中，用类中心做"最近邻"。
 - **KNN 是"无参数"的极端**，深度网络是"全参数"的极端，二者在表示学习上互补。
 - **DDM / 对比学习的"软 kNN"**：SwAV、SupCon 的预训练目标本质上就是让 kNN 分类器好用。
 - **LMNN / NCA 的深度版**：把线性变换 A 换成神经网络，即深度度量学习。
 - **ANN 检索是 RAG 的底层**：HNSW / IVF-PQ 把 kNN 变成大模型记忆的取数通道。
-

3.2 贝叶斯分类 (Bayesian Classification)

3.2.1 贝叶斯定理

$$P(c | x) = \frac{P(x | c) P(c)}{P(x)}$$

其中：

- c : 类别 (如"猫")。
- x : 样本特征向量。
- $P(c | x)$: **后验概率**——看到特征 x 后, 样本属于 c 的概率 (我们想要的)。
- $P(x | c)$: **似然**——类别 c 产生特征 x 的概率 (从数据估计)。
- $P(c)$: **先验概率**——不看特征时, 类别 c 出现的概率 (类别频率)。
- $P(x)$: **证据**——特征 x 出现的概率, 对所有类别相同, 分类时可忽略。
- 含义: 后验 $\propto$ 似然 $\times$ 先验。

分类决策 (最大后验 MAP) :

$$\hat{y} = \arg \max_c P(c | x) = \arg \max_c P(x | c) P(c)$$

其中 $\hat{y}$ 是预测类别; 因为 $P(x)$ 与 c 无关, 可省略。

3.2.2 朴素贝叶斯: 条件独立假设

直接估计 $P(x | c)$ 需要 D 维联合分布, 参数爆炸。 **朴素贝叶斯** 假设各维**条件独立**:

$$P(x | c) = \prod_{j=1}^D P(x_j | c)$$

其中：

- D : 特征维度。
- x_j : 特征向量的第 j 维。
- $P(x_j | c)$: 在类别 c 下, 第 j 维取值的概率 (一维分布, 易估计)。
- $\prod$: 连乘, 把 D 维联合概率拆成 D 个一维概率之积。
- 含义: 假设"给定类别后, 各特征互不影响"——这个假设通常不成立, 但效果出奇地好。

最终判别式:

$$\hat{y} = \arg \max_c P(c) \prod_{j=1}^D P(x_j | c)$$

3.2.3 三种常见变体

变体	假设 $P(x_j c)$	适用特征
高斯朴素贝叶斯	$\mathcal{N}(\mu_{jc}, \sigma_{jc}^2)$	连续特征（图像像素、描述子）
多项式朴素贝叶斯	多项分布	计数特征（词频、直方图）
伯努利朴素贝叶斯	伯努利分布	二值特征（二值描述子）

高斯形式：

$$P(x_j | c) = \frac{1}{\sqrt{2\pi\sigma_{jc}^2}} \exp\left(-\frac{(x_j - \mu_{jc})^2}{2\sigma_{jc}^2}\right)$$

其中：

- μ_{jc} ：类别 c 下第 j 维的**均值**。
- σ_{jc}^2 ：类别 c 下第 j 维的**方差**。
- σ_{jc} ：标准差。
- x_j ：待测样本第 j 维取值。
- 含义：假设该维在类内服从正态分布，用均值和方差刻画。

3.2.4 数值稳定：对数化

连乘易下溢，取对数变连加：

$$\hat{y} = \arg \max_c \left[\log P(c) + \sum_{j=1}^D \log P(x_j | c) \right]$$

其中 $\log$ 单调递增，不改变 $\arg \max$ 结果，但把乘积变求和，避免浮点下溢。

3.2.5 贝叶斯分类器变体总览

朴素贝叶斯的"朴素"之处在于**条件独立假设**。所有变体都在做同一件事：**在"独立假设太强"与"联合分布参数太多"之间做权衡**。

变体	对独立假设的处理	参数规模	解决的问题
朴素贝叶斯 (NB)	完全独立	$O(DC)$	基线, 速度快
半朴素贝叶斯 SPODE / AODE	每个特征依赖 1 个父特征	$O(D^2C)$	缓解独立性假设
半朴素贝叶斯 TAN	依赖结构是一棵树	$O(D^2C)$	兼顾精度与复杂度
半朴素贝叶斯 KDB	每个特征依赖 k 个父特征	$O(D^{k+1}C)$	可调依赖强度
贝叶斯网络 (BN)	学完整有向无环图	取决于图	通用联合建模
补集朴素贝叶斯 (CNB)	仍独立, 改估计量	$O(DC)$	类不平衡文本
加权朴素贝叶斯	仍独立, 加特征权重	$O(DC)$	特征重要性不同
隐马尔可夫模型 (HMM)	时序上的贝叶斯网络	$O(N_c^2 + N_c D)$	序列建模
贝叶斯逻辑回归	改为判别式 + 权重先验	$O(D)$	不确定性估计

3.2.6 半朴素贝叶斯 (Semi-naive Bayes)

核心想法：**不要求完全独立，也不学完整联合分布**，只允许每个特征依赖**少量**其他特征，在 BIC 与精度间取平衡。

(1) SPODE (Super-Parent One-Dependence Estimator)

选定一个特征 x_j 作为**超父**，所有其他特征都条件依赖于它：

$$P(c, x) = P(c, x_j) \prod_{i \neq j} P(x_i \mid c, x_j)$$

其中：

- x_j ：**超父属性** (super-parent) 。
- $P(c, x_j)$ ：类与超父的**二维联合分布** (直接计数，无需独立假设) 。
- $P(x_i \mid c, x_j)$ ：其余特征在给定"类 + 超父"下的条件概率。
- 含义：只把三元关系降为"三个变量"的规模，参数从 $O(DC)$ 升到 $O(D^2C)$ ，但比完整贝叶斯网络小得多。

(2) AODE (Averaged One-Dependence Estimators, Webb 等, 2005)

不选单一超父，而是**把所有特征都当超父，再平均**：

$$P(c \mid x) \propto \sum_{j=1}^{\tilde{D}} P(c, x_j) \prod_{i \neq j} P(x_i \mid c, x_j)$$

其中：

- $\tilde{D}$: 满足最小样本数阈值的超父个数（避免小样本估计不稳）。
- 求和后的结果需要归一化: $P(c|x) = \text{上式} / \sum_{c'} \text{上式}_{c'}$ 。
- 含义: AODE 几乎不需要调参, 在大量数据集上精度可与 TAN 匹敌甚至更好, 且因"平均"效果而对超父选择不敏感。

(3) TAN (Tree-Augmented Naïve Bayes, Friedman 等, 1997)

允许特征之间的依赖构成一棵树（每个特征最多一个父节点），由条件互信息确定树的连接：

$$I(X_j; X_k | C) = \sum_{x_j, x_k, c} P(x_j, x_k, c) \log \frac{P(x_j, x_k | c)}{P(x_j | c) P(x_k | c)}$$

其中：

- $I(X_j; X_k | C)$: 在已知类别条件下的条件互信息，度量两个特征的相关程度。
- 做法: 以 I 为边权, 用最大生成树 (Maximum Spanning Tree) 算法求出主干树。
- 最终模型:

$$P(c, x) = P(c) \prod_{j=1}^D P(x_j | c, \pi_j)$$

其中 π_j 是 x_j 在树上的父节点（唯一，可为空）。- 含义: TAN 是在 NB 与完整 BN 之间的最优折中；当树退化为星形（都依赖类别节点）时，TAN 退化为 NB。

(4) KDB (k-Dependence Bayesian Classifier, Sahami, 1996)

推广 TAN: 允许每个特征依赖最多 k 个父特征 (TAN 是 $k = 1$, NB 是 $k = 0$) :

$$P(c, x) = P(c) \prod_{j=1}^D P(x_j | c, \pi_j^{(k)})$$

其中 $\pi_j^{(k)}$ 是 x_j 的 k 个（按条件互信息排序的）最强父特征。- k 越大，模型越强但参数越多（ $O(D^{k+1}C)$ ），且高次条件概率的样本稀疏问题更严重。

(5) 结构学习的一般贝叶斯网络 (BN)

不再限定"类为根"的结构：

$$P(X_1, X_2, \dots, X_D) = \prod_{i=1}^D P(X_i | \text{Pa}(X_i))$$

其中：

- $\text{Pa}(X_i)$: X_i 的父节点集合。

- 含义：有向无环图（DAG）把 D 维联合分布**因式分解**为 D 个局部条件分布，参数量由指数级降到与图结构成正比。
- 分类时用 $P(c | x) \propto P(c, x)$ 直接计算。
- 学习：结构学习（评分 + 搜索） + 参数学习（最大似然 / 贝叶斯估计）。

3.2.7 其他变体：CNB、加权 NB、HMM 与贝叶斯逻辑回归

(1) 补集朴素贝叶斯 (Complement NB, Rennie 等, 2003)

专为**类不平衡文本分类**设计。不是估计"类 c 里词 j 的频率"，而是估计" c 的补集里"的频率：

$$\hat{\theta}_{cj} = \frac{N_{\bar{c}j} + \alpha_j}{\sum_{j'} N_{\bar{c}j'} + \alpha}, \quad \hat{c} = \arg \max_c \left[\log P(c) - \sum_j x_j \hat{\theta}_{cj} \right]$$

其中：

- $N_{\bar{c}j}$ ：不属于类 c 的样本中，特征 j 的计数（互补计数）。
- α_j ：平滑参数； $\alpha = \sum_j \alpha_j$ 。
- x_j ：待测样本的特征值（词频）。
- 含义：注意判决式是 $-$ 号——补集里出现得越多的词，越支持"**不是这个类**"。
- 效果：在不平衡文本上往往比标准多项式 NB 好得多。

(2) 加权朴素贝叶斯 (Weighted NB / Attribute-Weighted NB)

给每个特征加一个**重要性指数**：

$$\hat{y} = \arg \max_c \left[\log P(c) + \sum_{j=1}^D w_j \log P(x_j | c) \right]$$

其中：

- $w_j \in \mathbb{R}$ ：第 j 个特征的**权重**（可以为负）。
- 三种典型选择：
 - **信息增益加权**： $w_j \propto I(X_j; C)$;
 - **卡方统计量加权**： $w_j \propto \chi^2(X_j, C)$;
 - **基于优化**：把 w_j 当作参数，用梯度下降最小化分类损失（即 **WANBIA**）。
- 含义：NB 假设所有特征同等重要，加权后可在**保持 O(DC) 成本的同时大幅提精度**。
- 与逻辑回归的关系： w_j 把乘法型 NB 推向**加法型判别式**——权重为 1 时就是标准 NB。

(3) 隐马尔可夫模型 (HMM)

把贝叶斯思想用到**序列**上，是动态贝叶斯网络最简单的形式：

$$P(O, Q | \lambda) = \underbrace{\pi_{q_1} b_{q_1}(o_1)}_{\text{初始}} \prod_{t=2}^T \underbrace{a_{q_{t-1} q_t} b_{q_t}(o_t)}_{\text{转移 发射}}$$

其中：

- $O = (o_1, \dots, o_T)$ ：观测序列（语音帧、词、像素）。
- $Q = (q_1, \dots, q_T)$ ：隐藏状态序列（音素、词性、状态）。
- $\lambda = (\pi, A, B)$ ：模型参数， π 初始分布、 A 转移矩阵、 B 发射分布。
- $a_{ij} = P(q_t = j | q_{t-1} = i)$ ； $b_j(o) = P(o | q_t = j)$ 。

前向算法（高效计算 $P(O|\lambda)$ ，避免枚举 N_c^T 条路径）：

$$\alpha_t(j) = \left[\sum_{i=1}^{N_c} \alpha_{t-1}(i) a_{ij} \right] b_j(o_t), \quad P(O | \lambda) = \sum_j \alpha_T(j)$$

其中 $\alpha_t(j)$ 是“到时刻 t 观测为 $o_1..o_t$ 、且状态为 j ”的**前向概率**； N_c 是隐状态个数。参数训练用 **Baum-Welch**（即 EM，见 5.6）。

(4) 贝叶斯逻辑回归

把贝叶斯思想用到**判别式**模型上，对权重加先验：

$$p(w | \mathcal{D}) \propto \underbrace{p(\mathcal{D} | w)}_{\text{似然}} \underbrace{\mathcal{N}(w | 0, \sigma^2 I)}_{\text{高斯先验}}$$

预测时对权重积分（**贝叶斯模型平均**）：

$$P(y = 1 | x, \mathcal{D}) = \int \sigma(w^\top x) p(w | \mathcal{D}) dw$$

其中：

- 高斯先验等价于 **L2 正则**（ σ^2 越小正则越强）。
- 积分不可解析，需**拉普拉斯近似**、**变分推断**或 **MCMC**。
- 好处：除预测值外还能给出**预测不确定性**（ $p(w|\mathcal{D})$ 的方差）。

3.2.8 平滑与零概率问题

若某特征在某个类中从未出现，则 $P(x_j | c) = 0$ ，导致整个连乘积为 0——这就是朴素贝叶斯的**零概率灾难**。解决方案是对计数做平滑：

方法	公式	说明
无平滑 (MLE)	$\frac{N_{jc}}{N_c}$	零概率风险
拉普拉斯平滑	$\frac{N_{jc} + 1}{N_c + K}$	加 1, 最简单
Lidstone 平滑	$\frac{N_{jc} + \lambda}{N_c + \lambda K}$	λ 可调
M 估计	$\frac{N_{jc} + \alpha p_j}{N_c + \alpha}$	向先验 p_j 收缩
贝叶斯估计	$\frac{N_{jc} + \alpha_j}{N_c + \sum_j \alpha_j}$	Dirichlet 先验后验均值

其中：

- N_{jc} : 类 c 下特征 j 的**出现计数**。
- $N_c = \sum_j N_{jc}$: 类 c 的**总计数**。
- K : 特征 j 的**取值个数**。
- $\lambda, \alpha > 0$: 平滑强度 (先验等效样本数) 。
- p_j : 特征 j 的**先验概率** (M 估计算法中向它收缩) 。
- 含义：平滑本质是**加一个 Dirichlet 先验**，后验均值就是上表的形式；拉普拉斯平滑是 $\alpha_j = 1$ 的特例。

3.2.9 应用方向

(1) 图像 / 视觉

- **图像分类**：像素或描述子作为特征，高斯朴素贝叶斯做基线。
- **肤色检测**：在 YCbCr 空间对 Cb、Cr 建模高斯分布，判断像素是否肤色。
- **贝叶斯分割**：结合先验形状与似然做 MRF/CRF 分割（贝叶斯框架的推广）。
- **图像标注**：标签的条件概率建模。

(2) 文本与自然语言（最经典）

- **垃圾邮件过滤**：词袋 + 多项式朴素贝叶斯，历史上最著名的应用。
- **新闻 / 主题分类**：词频特征的多类分类，训练快、小样本好。
- **情感分析**：评论、舆情的正负极性判别。
- **语言识别 / 拼写检查**：字符 n-gram 上的贝叶斯判别。

(3) 推荐与用户建模

- **用户画像 / 兴趣预测**: 对用户行为特征做贝叶斯判别。
- **冷启动分类**: 新物品按类别特征归类。

(4) 医学与生物

- **疾病诊断辅助**: 症状 / 检验指标 $\rightarrow$ 疾病概率, 是经典医疗专家系统的概率基础。
- **基因序列分类**: 序列 k-mer 特征判别。
- **流行病风险评估**: 风险因素的生成式概率建模。

(5) 工业与安全

- **故障诊断**: 传感器读数的工况判别。
- **入侵检测 / 日志分类**: 网络流量与日志的快速分类。
- **舆情监控**: 海量文本的快速极性判定。

(6) 模型定位

- 朴素贝叶斯是**生成式模型**, 与逻辑回归 (判别式) 形成对照: 前者建模 $P(x | c)$, 后者直接建模 $P(c | x)$ 。

3.2.10 与深度学习的联系

- **贝叶斯深度学习**: 对网络权重加先验, 做后验推断 (变分推断、MC Dropout), 得到**不确定性估计**。
- **生成模型**: VAE 的 ELBO 就是贝叶斯推断的变分下界。
- **Softmax 分类器**可看作"判别式"版本, 而朴素贝叶斯是"生成式"版本。
- **朴素贝叶斯的参数估计 = 一层线性变换**: 取对数后 $\log P(c) + \sum_j \log P(x_j | c)$ 正是**线性分类器的形式**, 权重由计数决定 (无需梯度下降)。
- **半朴素贝叶斯与注意力**: TAN 学"特征依赖树", 与 Transformer 学"特征间注意力" 目标一致, 只是一个用互信息、一个用梯度。
- **HMM / BN 是现代序列模型的前身**: CRF 是 HMM 的判别式版本, RNN / Transformer 用神经网络替代了转移与发射概率。
- **贝叶斯深度学习 (BNN)** 与 MC Dropout 把"不确定性"带回深度网络, 与贝叶斯逻辑回归一脉相承。

3.3 逻辑回归 (Logistic Regression)

3.3.1 从线性回归到概率

线性模型输出 $z = w^\top x + b$ 是实数, 要变成概率需**Sigmoid**压缩:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

其中：

- z : 线性得分 (logit) 。
- e : 自然常数。
- $\sigma(z) \in (0, 1)$: 把实数映射到概率区间。
- 性质: $\sigma(0) = 0.5$, $z \rightarrow +\infty$ 时趋近 1, $z \rightarrow -\infty$ 时趋近 0。

二分类概率:

$$P(y = 1 | x) = \sigma(w^\top x + b) = \frac{1}{1 + e^{-(w^\top x + b)}}$$

其中：

- $w \in \mathbb{R}^D$: **权重向量**, 每个分量 w_j 表示第 j 维特征对"正类"的贡献。
- b : **偏置**, 控制决策边界的位置。
- $w^\top x = \sum_j w_j x_j$: 特征的加权和。
- $P(y = 1 | x)$: 样本属于正类的概率。
- $P(y = 0 | x) = 1 - P(y = 1 | x)$ 。

3.3.2 决策边界

令 $P(y = 1 | x) = 0.5$, 即 $w^\top x + b = 0$:

$$w^\top x + b = 0$$

这是一个**超平面**, 把特征空间一分为二。 w 是超平面的**法向量** (决定方向), b 决定**偏移**。逻辑回归是**线性分类器**。

3.3.3 损失函数：交叉熵

从最大似然推导。单样本似然：

$$P(y | x) = \hat{p}^y (1 - \hat{p})^{1-y}, \quad \hat{p} = \sigma(w^\top x + b)$$

其中：

- $y \in \{0, 1\}$: 真实标签。
- $\hat{p}$: 预测为正类的概率。
- 当 $y = 1$ 时取 $\hat{p}$, 当 $y = 0$ 时取 $1 - \hat{p}$ 。

取负对数得**交叉熵损失**：

$$L(w, b) = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i) \right]$$

其中：

- N ：样本数。
- y_i ：第 i 个样本标签。
- $\hat{p}_i = \sigma(w^\top x_i + b)$ ：第 i 个样本的预测概率。
- 第一项 $y_i \log \hat{p}_i$ ：当 $y_i = 1$ 时惩罚"预测概率低"。
- 第二项 $(1 - y_i) \log(1 - \hat{p}_i)$ ：当 $y_i = 0$ 时惩罚"预测概率高"。
- 负号：把"最大化似然"变成"最小化损失"。

3.3.4 梯度下降

对 w 求梯度：

$$\nabla_w L = \frac{1}{N} \sum_{i=1}^N (\hat{p}_i - y_i) x_i$$

其中：

- $\hat{p}_i - y_i$ ：**预测误差**（残差）。
- x_i ：第 i 个样本特征。
- 含义：梯度 = 误差 × 特征的平均。误差越大，更新越猛。
- 更新： $w \leftarrow w - \eta \nabla_w L$ ， η 是**学习率**。

这个形式与线性回归的梯度完全一致，区别只在 $\hat{p}$ 是 Sigmoid 输出。

3.3.5 多分类：Softmax 回归

$$P(y = c \mid x) = \frac{e^{w_c^\top x + b_c}}{\sum_{c'=1}^C e^{w_{c'}^\top x + b_{c'}}}$$

其中：

- C ：类别数。
- w_c ：类别 c 的权重向量。
- b_c ：类别 c 的偏置。
- 分母：所有类别的指数和，做**归一化**，使概率和为 1。
- 含义：把每个类别的得分转成概率分布。

3.3.6 逻辑回归变体总览

逻辑回归的改动点集中在三处：**正则项、链接函数、输出结构**。

变体	改动点	解决的问题
标准 LR (MLE)	无正则	基线（易过拟合 / 分离）
Ridge LR (L2)	$\lambda \ w\ ^2$	共线性、过拟合
Lasso LR (L1)	$\lambda \ w\ _1$	特征选择（稀疏）
Elastic Net	L1 + L2	相关特征组选择
Firth LR	Fisher 信息惩罚	完全分离
加权 LR	每样本代价 c_i	类不平衡 / 代价敏感
有序 LR	累积链接	有序类别（星级、分期）
名义 LR (Softmax)	多类链接	名义多分类
条件 LR	层内选择	配对病例对照
核 LR	核化 + 表示定理	非线性边界
贝叶斯 LR	权重新验	不确定性估计
最大熵模型	特征函数形式	与 Softmax 等价
GLM 家族	换链接函数与分布	计数 / 频率数据
深度逻辑回归	多层 + 非线性	复杂边界

3.3.7 正则化变体与完全分离

(1) L2 正则 (Ridge Logistic Regression)

$$\min_{w,b} -\frac{1}{N} \sum_{i=1}^N \left[y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i) \right] + \frac{\lambda}{2} \|w\|^2$$

其中：

- $\lambda \geq 0$ ：**正则强度**，越大则权重越小（收缩越强）。
- 梯度多出一项： $\nabla_w = \frac{1}{N} \sum_i (\hat{p}_i - y_i) x_i + \lambda w$ 。
- 含义：等价于**高斯先验的 MAP 估计** ($w \sim \mathcal{N}(0, \lambda^{-1} I)$) 。
- 作用：解决特征共线性导致的权重爆炸，是最常用的默认设置。

(2) L1 正则 (Lasso Logistic Regression)

$$\min_{w,b} -\frac{1}{N} \sum_{i=1}^N \left[y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i) \right] + \lambda \|w\|_1$$

其中：

- $\|w\|_1 = \sum_j |w_j|$ ：L1 范数。
- 几何直觉：L1 的等高线是**菱形**（带尖角），目标函数极小值**大概率落在坐标轴上**，因此 w_j 会被直接压到 **0**——得到**稀疏解**。
- 含义：等价于**拉普拉斯先验**的 MAP，天然做**特征选择**。
- 求解：因不可导点，需用**近端梯度法 (ISTA/FISTA)** 或坐标下降：

$$w_j \leftarrow \text{soft}\left(w_j - \eta g_j, \eta \lambda\right), \quad \text{soft}(z, \gamma) = \text{sign}(z) \max(|z| - \gamma, 0)$$

其中 g_j 是无关正则的梯度分量， $\text{soft}(\cdot)$ 是**软阈值算子**。

(3) Elastic Net

$$\min_{w,b} -\frac{1}{N} \sum_{i=1}^N \left[y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i) \right] + \lambda_1 \|w\|_1 + \frac{\lambda_2}{2} \|w\|^2$$

其中：

- λ_1 ：稀疏强度； λ_2 ：收缩强度。
- 含义：L1 单独使用时，**一组高度相关的特征**会随机只留一个；Elastic Net 用 L2 项把它们**成组保留或删除**，稳定性更好。

(4) Firth 惩罚逻辑回归（完全分离问题）

当数据可被完全分开时，MLE 的 $\|w\| \rightarrow \infty$ 。Firth 用 Fisher 信息做惩罚：

$$L_{\text{Firth}}(w) = L(w) - \frac{1}{2} \log \det(I(w)), \quad I(w) = X^\top W X, \quad W = \text{diag}(\hat{p}_i(1 - \hat{p}_i))$$

其中：

- $I(w)$ ：**Fisher 信息矩阵**（Logistic 中等于 Hessian）。
- $-\frac{1}{2} \log \det I(w)$ ：**Jeffreys 先验**，在 $|w|$ 大时急剧增长，阻止发散。
- 附带好处：**小样本的偏差校正**（比 MLE 更接近无偏）。
- 常用于**临床研究中**样本量小而事件率低的情形。

3.3.8 输出结构变体：有序、多项与条件 LR

(1) 有序逻辑回归 (Ordinal / Proportional Odds)

当类别有**顺序**（1-5 星、疾病分期）时，不应应用 Softmax，而用**累积链接**：

$$P(y \leq k | x) = \sigma(\theta_k - w^\top x), \quad k = 1, \dots, K-1$$

各类别概率由相邻累积概率之差得到：

$$P(y = k | x) = P(y \leq k | x) - P(y \leq k-1 | x)$$

其中：

- $\theta_1 < \theta_2 < \dots < \theta_{K-1}$ ：切点（阈值），满足单调约束。
- w ：所有类别共享的权重向量（比例优势假设）。
- 含义：模型只有一个 w ，参数量从 $O(KD)$ 降到 $O(D + K)$ ，且保证序关系。
- 比例优势假设：自变量对“跨过任何切点”的影响相同；否则用偏比例优势模型或有序 Probit（把 σ 换成正态 CDF Φ ）。

(2) 名义逻辑回归 / 多项逻辑回归 (已见 3.3.5 的 Softmax)

若用其中一个类作为基准类，可以写成更紧凑的对数几率形式：

$$\log \frac{P(y = c | x)}{P(y = K | x)} = w_c^\top x + b_c, \quad c = 1, \dots, K-1$$

其中 K 是基准类（其权重恒为 0，否则参数不唯一）；这个形式直接说明：Softmax 就是 $K-1$ 个对数几率回归的组合。

(3) 条件逻辑回归 (Conditional LR, 配对病例对照)

数据来自分层 / 配对设计时，每个层内只有“选中的样本”被观测：

$$P(y_i = 1 | x_i, \{x_{ik}\}_k) = \frac{\exp(w^\top x_{i1})}{\sum_k \exp(w^\top x_{ik})}$$

其中：

- $\{x_{ik}\}_k$ ：第 i 个层（匹配组）内的全部候选样本。
- 分母：层内所有样本的得分之和（类似 Softmax，但归一化在层内）。
- 含义：截距被层本身吸收（不同层的基准风险差异不进入模型），只估计层内相对效应——这正是配对设计想要的。

3.3.9 加权、非线性与贝叶斯变体

(1) 加权逻辑回归 (类不平衡 / 代价敏感)

$$\min_{w,b} -\frac{1}{N} \sum_{i=1}^N c_i \left[y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i) \right]$$

其中:

- $c_i > 0$: 第 i 个样本的**代价权重**。
- 常用设置: $c_i = w_{y_i}$, 而 $w_c = N / (K N_c)$ (**按类频率的反比**), 使两类在损失中"等权"。
- 含义: **不改模型形式, 只改损失权重**——这是处理不平衡最轻量的做法; 也可以直接调整判决策略 (阈值补偿: $\hat{y} = 1$ 当 $\hat{p} > \tau$, $\tau \neq 0.5$)。

(2) 核逻辑回归 (Kernel LR)

把线性得分换成核展开 (由**表示定理**, 解必可写成训练样本的组合):

$$f(x) = \sum_{i=1}^N \alpha_i K(x_i, x), \quad \min_{\alpha} \sum_{i=1}^N \log \left(1 + \exp \left(-\tilde{y}_i f(x_i) \right) \right) + \frac{\lambda}{2} \alpha^\top K \alpha$$

其中:

- $\tilde{y}_i \in \{-1, +1\}$: 编码后的标签。
- K : **Gram 矩阵** ($K_{ij} = K(x_i, x_j)$)。
- $\frac{\lambda}{2} \alpha^\top K \alpha$: 核空间的 **L2 正则** (等价于原始空间的 $\|w\|^2$ 在 $w = \sum \alpha_i \varphi(x_i)$ 下的展开)。
- 含义: 逻辑回归从**线性分类器**升级为**非线性分类器**, 且输出仍是**校准过的概率** (比 SVM 更直接适用于风险决策)。
- 与 SVM 对比: 只差一个损失函数 (**逻辑损失 vs Hinge 损失**)。

(3) 贝叶斯逻辑回归

$$p(w | \mathcal{D}) \propto \left[\prod_{i=1}^N \hat{p}_i^{y_i} (1 - \hat{p}_i)^{1-y_i} \right] \mathcal{N}(w | \mu_0, \Sigma_0)$$

预测时**对权重积分** (而非取点估计):

$$P(y = 1 | x, \mathcal{D}) = \int \sigma(w^\top x) p(w | \mathcal{D}) dw$$

其中:

- $\mathcal{N}(\mu_0, \Sigma_0)$: 权重的高斯先验 ($\Sigma_0 = \sigma^2 I$ 时等价于 L2)。
- 积分可用 **拉普拉斯近似** (在 MAP 处高斯近似后验)、**变分推断**或 **MCMC**。

- 好处：给出**预测不确定性**——这对医疗、风控等高风险场景至关重要。

3.3.10 广义线性模型（GLM）视角

逻辑回归只是 GLM 家族的一个成员。GLM 由三要素定义：

$$\underbrace{\mathbb{E}[y \mid x] = \mu}_{\text{响应均值}}, \quad \underbrace{g(\mu) = w^\top x}_{\text{链接函数}}, \quad y \sim \text{指数族分布}$$

其中：

- $g(\cdot)$ ：**链接函数**，把均值的取值域拉到实数域。
- μ ：响应变量的期望。
- 常见组合：

模型	分布	链接 $g(\mu)$	逆链接（预测）	适用
线性回归	高斯	恒等 μ	$\mu = w^\top x$	连续对称
逻辑回归	伯努利	logit $\log \frac{\mu}{1-\mu}$	$\sigma(w^\top x)$	二分类
Probit 回归	伯努利	$\Phi^{-1}(\mu)$	$\Phi(w^\top x)$	二分类（正态潜变量）
泊松回归	泊松	$\log \mu$	$\exp(w^\top x)$	计数 （事故数、点击量）
负二项回归	负二项	$\log \mu$	$\exp(w^\top x)$	过离散计数
Gamma 回归	Gamma	$1/\mu$	$1/(w^\top x)$	正值连续（时长、金额）

统一的对数似然与梯度：

$$\nabla_w \ell = \frac{1}{N} \sum_{i=1}^N \frac{y_i - \mu_i}{\text{Var}(y_i)} \frac{\partial \mu_i}{\partial \eta_i} x_i, \quad \eta_i = w^\top x_i$$

其中：

- η_i ：**线性预测子**（linear predictor）。
- $\text{Var}(y_i)$ ：响应方差函数（高斯为 1、伯努利为 $\mu(1 - \mu)$ 、泊松为 μ ）。
- $\frac{\partial \mu_i}{\partial \eta_i}$ ：逆链接的导数。
- 含义：**所有 GLM 的梯度形式同构**，差别只在方差函数与链接函数，故可用同一套 IRLS 算法求解。

3.3.11 求解算法

(1) 牛顿-拉夫逊法与 IRLS

对 $L(w)$ 做二阶展开，得更新：

$$w^{(t+1)} = w^{(t)} - H^{-1} \nabla L = (X^\top W X)^{-1} X^\top W z$$

其中：

- $H = X^\top W X$ ：Hessian 矩阵。
- $W = \text{diag}(\hat{p}_i(1 - \hat{p}_i))$ ：权重矩阵。
- $z = \eta + W^{-1}(y - \hat{p})$ ：工作响应 (working response)，其中 $\eta = Xw$ 。
- 含义：每一次迭代就是一个**加权最小二乘 (WLS)** 问题，故该算法叫 **IRLS (迭代重加权最小二乘)**。
- 特点：**二阶收敛** (迭代次数很少)，但每次需 $O(ND^2)$ 构 Hessian、 $O(D^3)$ 求逆。
- 正则化版 (Ridge) 只需把 H 换成 $X^\top W X + \lambda I$ 。

(2) 其他求解路线

方法	阶	优缺点
梯度下降 (GD)	一阶	简单但收敛慢， η 难调
牛顿 / IRLS	二阶	迭代少， D 大时内存贵
L-BFGS	拟二阶	无约束场景的工业首选
坐标下降	一阶	L1 正则下的高效算法
近端梯度 (ISTA/FISTA)	一阶	L1/Elastic Net 通用
SGD / Adam	一阶	大数据流式、可在线
信赖域 (trust-region)	二阶	数值稳健，L1 可用

(3) 收敛与病态问题

- **完全分离**：若两类可被超平面完全分开，MLE 不存在 (权重发散) → 用正则化 / Firth。
- **准完全分离**：仅有部分样本导致分离，也会使权重偏离，需平滑处理。
- **共线性**： H 接近奇异 → 加 L2 或用 QR 分解代替直接求逆。
- **样本量经验**：每个自变量至少需要 **10~20 个"少数类"样本** (EPV 准则)。

3.3.12 应用方向

(1) 图像 / 视觉

- **二分类任务**：人脸/非人脸、有缺陷/无缺陷。
- **多标签分类**：一张图多个标签 (每个标签一个逻辑回归)。

- 作为网络最后一层：CNN 分类头就是 Softmax 回归。
- 概率输出：需要置信度时优于 SVM。
- 图像质量与美学评分：回归式打分。

(2) 金融与风控（最经典）

- 信用评分卡：违约概率建模，是银行业事实标准（WOE + 逻辑回归）。
- 欺诈检测：交易风险概率输出，便于设定阈值。
- 营销响应预测：用户是否会点击 / 购买。
- 可解释性要求高的场景：系数即特征贡献，监管友好。

(3) 医疗与生物统计

- 临床风险模型：疾病发生概率（如 Framingham 风险评分）。
- 流行病学：暴露因素与结局的关联（优势比 = e^{w_j} ）。
- 基因关联分析：病例-对照研究。

(4) 文本、推荐与广告

- 点击率（CTR）预估：广告 / 推荐系统的基石模型。
- 内容分类 / 情感极性：词袋特征的线性分类。
- 搜索排序：特征融合的点击概率估计。

(5) 工业、传感与时序

- 设备故障预警：从传感器特征预测故障概率。
- A/B 实验分析：转化率差异的建模。
- 用户流失预测：留存概率估计。

(6) 作为通用积木

- Logit 变换：把概率映射到实数域（后续做线性建模）。
- 概率校准：作为复杂模型的校准层。

3.3.13 与深度学习的联系

- 逻辑回归 = 单层神经网络（无隐藏层）。
- Softmax 回归 = CNN 分类头，是深度分类器的最后一步。
- 交叉熵损失是深度分类的标准损失。
- 逻辑回归的局限（线性边界）正是深度网络要突破的：加隐藏层 + 非线性激活。
- 正则化一脉相承：L2 → 权重衰减，L1 → 稀疏网络 / 剪枝，Elastic Net → 结构化稀疏。

- **IRLS / L-BFGS / SGD** 全部是当前深度优化器的前身；对数几率与 Sigmoid 仍是门控/注意力的基础单元。
 - **有序回归与概率校准**：分类头加上温度缩放（Temperature Scaling）就是一种 Platt 式后处理。
 - **GLM 与深度分布头**：泊松回归对应"计数预测头"，推荐 / 保险领域很常见。
-

3.4 支持向量机 (Support Vector Machines, SVM)

3.4.1 核心思想：最大间隔

SVM 要找一条离两类样本都最远的分界线（超平面），使**间隔（margin）最大**。只有少数"支撑"边界的样本（**支持向量**）决定分界线。

超平面：

$$w^\top x + b = 0$$

其中：

- w ：超平面的**法向量**，决定方向。
- b ：偏置，决定与原点的距离。
- x ：特征向量。

点到超平面的距离：

$$d(x) = \frac{|w^\top x + b|}{\|w\|}$$

其中 $\|w\| = \sqrt{\sum_j w_j^2}$ 是法向量的模长。

3.4.2 硬间隔优化问题

要求所有样本正确分类且间隔最大：

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_i(w^\top x_i + b) \geq 1, \quad \forall i$$

其中：

- $\frac{1}{2} \|w\|^2$ ：目标函数，最小化它等价于**最大化间隔** $2/\|w\|$ 。

- $y_i \in \{-1, +1\}$: 标签 (SVM 用 ± 1 而非 0/1)。
- $y_i(w^\top x_i + b)$: **函数间隔**, 要求 ≥ 1 表示"分类正确且离边界足够远"。
- 约束对所有 i 成立。

3.4.3 软间隔与松弛变量

现实数据有噪声, 允许少量越界, 引入**松弛变量** ξ_i (**L1 软间隔**, 即 C-SVC) :

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \quad \text{s.t.} \quad y_i(w^\top x_i + b) \geq 1 - \xi_i, \xi_i \geq 0$$

其中:

- $\xi_i \geq 0$: 第 i 个样本的**违反程度** (越界多少)。
- $C > 0$: **惩罚系数**, 权衡"间隔大"与"少犯错"。
- C 大 $\rightarrow$ 不容忍错误 $\rightarrow$ 过拟合风险。
- C 小 $\rightarrow$ 容忍错误 $\rightarrow$ 欠拟合风险。

等价的无约束形式 (Hinge 损失): 消去 ξ_i 得

$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \max(0, 1 - y_i(w^\top x_i + b))$$

其中:

- $\max(0, 1 - y_i f(x_i))$: **合页 (Hinge) 损失** L_{hinge} 。
- $y_i f(x_i) \geq 1$ (分类正确且超出间隔) 时损失为 0, 否则随越界程度**线性增长**。
- 含义: SVM 本质上就是"**L2 正则 + Hinge 损失**"的经验风险最小化, 与逻辑回归 (L2 正则 + 交叉熵) 在 1.3 节的统一模板下形成对照。

L2 软间隔 (L2-SVC): 把线性惩罚换成平方惩罚

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + \frac{C}{2} \sum_{i=1}^N \xi_i^2 \quad \text{s.t.} \quad y_i(w^\top x_i + b) \geq 1 - \xi_i$$

其中:

- $\frac{C}{2} \sum_i \xi_i^2$: **平方松弛**, 对大越界样本惩罚更重, 且处处可微 (不产生折点)。
- 因为平方项的最优解已保证 $\xi_i \geq 0$, 故**不再需要**显式约束 $\xi_i \geq 0$ 。
- 对偶中 α_i **没有上界** (只有 $0 \leq \alpha_i$, 无 $\alpha_i \leq C$)。
- 效果等价于把核矩阵对角线上加一个常数:

$$K_{ij} \rightarrow K_{ij} + \frac{1}{C} \delta_{ij}, \quad \delta_{ij} = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$$

其中 δ_{ij} 是克罗内克符号。加入该项后对偶问题**强凸**、解唯一，数值上更稳定；代价是对噪声更敏感（不再有稀疏的边界支持向量截断）。

3.4.4 对偶问题与核技巧

用拉格朗日乘子转成对偶问题：

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) \\ \text{s.t.} \quad & 0 \leq \alpha_i \leq C, \quad \sum_{i=1}^N \alpha_i y_i = 0 \end{aligned}$$

其中：

- α_i ：第 i 个样本的**拉格朗日乘子**。
- $\alpha_i = 0$ ：该样本不影响边界（非支持向量）。
- $\alpha_i > 0$ ：该样本是**支持向量**。
- $K(x_i, x_j)$ ：**核函数**，计算两样本在高维空间的内积，无需显式升维。
- 含义：决策只依赖支持向量之间的核函数值。

常用核函数：

核	公式	参数
线性核	$x_i^\top x_j$	无
多项式核	$(\gamma x_i^\top x_j + r)^d$	γ, r, d
RBF / 高斯核	$\exp(-\gamma \ x_i - x_j\ ^2)$	γ
Sigmoid 核	$\tanh(\gamma x_i^\top x_j + r)$	γ, r

其中：

- γ ：核宽度参数，控制"影响半径"。
- d ：多项式次数。
- r ：常数项。
- RBF 核把数据映射到**无穷维**空间，是最常用的非线性核。

预测函数：

$$f(x) = \text{sign} \left(\sum_{i \in SV} \alpha_i y_i K(x_i, x) + b \right)$$

其中：

- SV ：支持向量集合。
- $\text{sign}(\cdot)$ ：符号函数，输出 ± 1 。
- 含义：新样本的类别由它与支持向量的核函数加权和决定。

KKT 条件（原始-对偶最优性的完整刻画）：

$$\begin{aligned} \text{平稳性:} \quad w &= \sum_{i=1}^N \alpha_i y_i x_i, & C - \alpha_i - \mu_i &= 0 \\ \text{原始可行:} \quad y_i(w^\top x_i + b) &\geq 1 - \xi_i, & \xi_i &\geq 0 \\ \text{对偶可行:} \quad \alpha_i &\geq 0, & \mu_i &\geq 0 \\ \text{互补松弛:} \quad \alpha_i [y_i(w^\top x_i + b) - 1 + \xi_i] &= 0, & \mu_i \xi_i &= 0 \end{aligned}$$

其中：

- μ_i ：松弛变量 $\xi_i \geq 0$ 对应的**拉格朗日乘子**。
- $w = \sum_i \alpha_i y_i x_i$ ：**表示定理 (Representer Theorem)** 的具体形式——法向量是支持向量的线性组合。
- 由 $\alpha_i + \mu_i = C$ 与 $\mu_i \xi_i = 0$ ，可得 α_i 的**三种取值情形**：

α_i	样本类型	几何位置	是否影响决策
$\alpha_i = 0$	非支持向量	间隔外侧，分类正确	否
$0 < \alpha_i < C$	自由支持向量	恰好在间隔边界上 ($\xi_i = 0$)	是（用于解 b ）
$\alpha_i = C$	边界支持向量	间隔内侧或分错 ($\xi_i > 0$)	是

- 偏置 b 由**自由支持向量**求出（对任一 $0 < \alpha_i < C$ 的样本均成立，实践中取平均）：

$$b = y_i - \sum_{j=1}^N \alpha_j y_j K(x_j, x_i)$$

3.4.5 SVM 变体总览

以上给出的是 **C-SVC + 核技巧** 这一核心形式。SVM 实际是一个庞大的**家族**，不同变体的改动点各不相同。下表先给出全局印象，后面逐类展开：

变体	关键改动点	解决的问题	应用场景
硬间隔 SVM	无松弛变量	数据严格线性可分	理论基线
C-SVC (L1 软间隔)	线性松弛 ξ_i	噪声 / 不可分	通用分类 (默认)
L2-SVC	平方松弛 ξ_i^2	对偶强凸、解唯一	小样本、数值敏感
ν -SVC	用 ν 取代 C	自动控制错误率与 SV 比例	调参困难时
LS-SVM	等式约束 + 平方损失	转为线性方程组	快速求解、在线学习
ϵ -SVR	引入 ϵ 不敏感带	回归 (连续输出)	函数拟合、预测
ν -SVR	用 ν 自动定 ϵ	免去选 ϵ	回归调参
One-Class SVM	无标签, 原点一侧最大间隔	只有正类样本	异常 / 新颖性检测
SVDD	最小包围超球	只有正类样本	异常检测、数据描述
加权 SVM	每样本 C_i	类不平衡 / 代价敏感	医疗、风控
OvR / OvO	分解为多个二分类	多分类	通用多分类
Crammer-Singer	单一多类优化	多分类全局最优	多分类
ECOC	多类 $\rightarrow$ 二分类码位	纠错、类别多	多分类鲁棒性
SVM-struct	结构化输出 + 结构化 Hinge	输出间有依赖	序列 / 树 / 图标注
Platt 概率	Sigmoid 拟合 $f(x)$	需要后验概率	风险决策、级联

一个重要的统一视角

: 以上分类、回归、单类三大任务可以写成

同一个模板:

$$\min_w \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N L(y_i, f_w(x_i)), \quad f_w(x) = w^\top \varphi(x)$$

其中:

- L 取 **Hinge 损失** $\rightarrow$ 分类 (C-SVC) ;
- L 取 **ϵ -不敏感损失** $L_\epsilon(r) = \max(0, |r| - \epsilon)$ $\rightarrow$ 回归 (ϵ -SVR) ;
- L 取**单类损失** (把原点当唯一负类) $\rightarrow$ 单类 (One-Class SVM) 。
- 含义: **三大任务的差别只是损失函数 L 的不同**, 优化与对偶推导完全平行。

3.4.6 分类变体：L2-SVC、v-SVC、LS-SVM

(1) L2-SVC (平方软间隔)

原始问题见 3.4.3，其对偶问题为：

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \left(K(x_i, x_j) + \frac{1}{C} \delta_{ij} \right) \quad \text{s.t.} \quad \alpha_i \geq 0, \sum_{i=1}^N \alpha_i y_i = 0$$

其中：

- $\frac{1}{C} \delta_{ij}$ ：对角加载项，使二次型正定。
- $\alpha_i \geq 0$ ：与 C-SVC 相比丢掉了上界 $\alpha_i \leq C$ 。
- 含义：L1 与 L2 软间隔的区别仅在“惩罚形状”（线性 vs 平方），其余完全平行。

(2) v-SVC (Schölkopf 等, 2000)

引入位置参数 ρ 与比例参数 ν ：

$$\min_{w, b, \rho, \xi} \frac{1}{2} \|w\|^2 - \nu \rho + \frac{1}{N} \sum_{i=1}^N \xi_i \quad \text{s.t.} \quad y_i (w^\top x_i + b) \geq \rho - \xi_i, \xi_i \geq 0, \rho \geq 0$$

其中：

- $\nu \in (0, 1]$ ：可调参数，同时控制两件事——
- 训练错误率不超过 ν ；
- 支持向量比例不低于 ν 。
- ρ ：间隔的位置/宽度参数，代替了原式的常数 1。
- $-\nu \rho$ ：最小化它的相反数即最大化间隔。
- 对偶形式： $0 \leq \alpha_i \leq 1/N$ ， $\sum_i \alpha_i y_i = 0$ ，且 $\sum_i \alpha_i \geq \nu$ 。
- 含义： ν 与 C 在单调意义下一一对应，但 ν 有直观的概率含义，调参更容易。

(3) LS-SVM (最小二乘 SVM, Suykens 等, 1999)

把不等式约束换成等式约束，并用平方损失：

$$\min_{w, b, e} \frac{1}{2} \|w\|^2 + \frac{\gamma}{2} \sum_{i=1}^N e_i^2 \quad \text{s.t.} \quad y_i (w^\top \varphi(x_i) + b) = 1 - e_i$$

其中：

- e_i ：等式残差（可正可负，不再是 ≥ 0 的松弛变量）。
- γ ：正则化系数，作用类似 C ，含义是“平方惩罚的强度”。
- $\varphi(\cdot)$ ：隐式特征映射（由核函数定义）。

用拉格朗日乘子得**线性方程组** (KKT 系统) :

$$\begin{bmatrix} 0 & y^\top \\ y & \Omega + \gamma^{-1}I \end{bmatrix} \begin{bmatrix} b \\ \alpha \end{bmatrix} = \begin{bmatrix} 0 \\ \mathbf{1} \end{bmatrix}, \quad \Omega_{ij} = y_i y_j K(x_i, x_j)$$

其中:

- $\Omega \in \mathbb{R}^{N \times N}$: **核矩阵** (经标签加权)。
- I : 单位矩阵; $\gamma^{-1}I$: 对角正则项, 保证矩阵可逆。
- $\alpha = [\alpha_1, \dots, \alpha_N]^\top$: 待解乘子向量。
- $\mathbf{1}$: 全 1 向量。
- 含义: 只需解一个 $O(N^3)$ 的线性方程组 (可用共轭梯度加速), 无需二次规划。
- **缺点**: 解**不稀疏** (几乎所有 $\alpha_i \neq 0$) , 丢失了 SVM 的稀疏性优势; 因此更适合样本量中等、要求快速与**在线增量更新**的场景。

3.4.7 回归变体: ϵ -SVR 与 ν -SVR

(1) ϵ -SVR (ϵ -不敏感损失回归, Smola & Schölkopf)

允许预测值落在真值两侧 $\pm\epsilon$ 的"**不敏感带**"内, 带内不计损失:

$$\begin{aligned} \min_{w, b, \xi, \xi^*} \quad & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N (\xi_i + \xi_i^*) \\ \text{s.t.} \quad & \begin{cases} y_i - w^\top \varphi(x_i) - b \leq \epsilon + \xi_i \\ w^\top \varphi(x_i) + b - y_i \leq \epsilon + \xi_i^* \\ \xi_i \geq 0, \xi_i^* \geq 0 \end{cases} \end{aligned}$$

其中:

- ξ_i : **上方越界量** (预测偏低, $f(x_i) < y_i - \epsilon$) 。
- ξ_i^* : **下方越界量** (预测偏高, $f(x_i) > y_i + \epsilon$) 。
- $\epsilon \geq 0$: **不敏感带半宽**, 带内误差被视为 0; ϵ 越大, 支持向量越少。
- C : 权衡"平坦度"与"越界惩罚", 含义同分类。

对应的**不敏感损失**:

$$L_\epsilon(r) = \max(0, |r| - \epsilon), \quad r = y - f(x)$$

其中 r 是残差; $|r| \leq \epsilon$ 时损失为 0, 超出部分线性惩罚。

对偶问题:

$$\begin{aligned} \max_{\alpha, \alpha^*} \quad & -\frac{1}{2} \sum_{i,j} (\alpha_i - \alpha_i^*)(\alpha_j - \alpha_j^*) K(x_i, x_j) - \varepsilon \sum_i (\alpha_i + \alpha_i^*) + \sum_i y_i (\alpha_i - \alpha_i^*) \\ \text{s.t.} \quad & \sum_{i=1}^N (\alpha_i - \alpha_i^*) = 0, \quad 0 \leq \alpha_i, \alpha_i^* \leq C \end{aligned}$$

其中：

- α_i, α_i^* ：上下两侧的拉格朗日乘子（同一个样本**最多只有一个非零**）。
- $\beta_i = \alpha_i - \alpha_i^* \in [-C, C]$ ：**净权重**，即该样本对预测的贡献。
- $K(x_i, x_j)$ ：核函数。

预测函数（不再有 sign）：

$$f(x) = \sum_{i=1}^N (\alpha_i - \alpha_i^*) K(x_i, x) + b$$

其中只有 $\beta_i \neq 0$ 的样本是**支持向量**（即落在不敏感带外或恰在带边界）。

(2) ν -SVR

用 ν 自动确定 ε ：

$$\min_{w, b, \varepsilon, \xi, \xi^*} \frac{1}{2} \|w\|^2 + C \left(\nu \varepsilon + \frac{1}{N} \sum_{i=1}^N (\xi_i + \xi_i^*) \right)$$

其中：

- $\nu \in (0, 1]$ ：控制**支持向量比例**（下界为 ν ）与**越界比例**（上界为 ν ）。
- ε ：从参数变为**待优化变量**，无需手动设定。
- 含义： ε 自动适配数据的噪声尺度，省去一个难调的超参数。

3.4.8 单类变体：One-Class SVM 与 SVDD

(1) One-Class SVM (Schölkopf 等, 1999)

只有正类样本时，求一个“把数据与**原点**分开且间隔最大”的超平面：

$$\min_{w, \rho, \xi} \frac{1}{2} \|w\|^2 - \rho + \frac{1}{\nu N} \sum_{i=1}^N \xi_i \quad \text{s.t.} \quad w^\top \varphi(x_i) \geq \rho - \xi_i, \quad \xi_i \geq 0$$

其中：

- ρ ：阈值（决策面的截距）。

- $\nu \in (0, 1]$: **异常比例的上界**，同时是支持向量比例的下界。
- $\frac{1}{\nu N}$: 等价于惩罚系数 C 的倒数式写法 (ν 越小，惩罚越重)。
- 决策函数:

$$f(x) = \text{sign}(w^\top \varphi(x) - \rho) = \text{sign}\left(\sum_i \alpha_i K(x_i, x) - \rho\right)$$

输出 $+1$ 表示"正常", -1 表示"异常"。

(2) SVDD (Support Vector Data Description, Tax & Duin, 1999)

换个几何视角: 找一个**最小半径的超球**把数据包住, 球外的点算异常:

$$\min_{R, a, \xi} R^2 + C \sum_{i=1}^N \xi_i \quad \text{s.t.} \quad \|\varphi(x_i) - a\|^2 \leq R^2 + \xi_i, \quad \xi_i \geq 0$$

其中:

- R : 超球**半径** (要最小化)。
- a : 超球**球心** (隐空间中的向量)。
- ξ_i : 允许样本落在球外的松弛量。
- 对偶形式只依赖核函数:

$$\max_{\alpha} \sum_i \alpha_i K(x_i, x_i) - \sum_{i,j} \alpha_i \alpha_j K(x_i, x_j) \quad \text{s.t.} \quad 0 \leq \alpha_i \leq C, \quad \sum_i \alpha_i = 1$$

- 判据: 新样本离球心的距离 $\|\varphi(x) - a\|^2$ 超过 R^2 则为异常。

(3) **两者的关系**: 使用 RBF 核 (且数据已中心化) 时, **One-Class SVM 与 SVDD 给出等价的解**; 差别主要在于参数化方式与几何解释。两者共同构成了**无监督异常检测**的经典基线 (在深度自编码器出现之前是主力)。

3.4.9 多分类与结构化输出变体

(1) OvR (One-vs-Rest, 一对多)

训练 K 个二分类器, 第 k 个把"类 k "与"其余所有类"分开:

$$\hat{y} = \arg \max_{k \in \{1, \dots, K\}} f_k(x)$$

其中:

- K : 类别数; 共需 K 个分类器。
- f_k : 第 k 个二分类器的判别值。

- 含义：简单、可并行；缺点是**类别不平衡**（每类样本少）且各类得分尺度不可比。

(2) OvO (One-vs-One)

对每一对类别训练一个分类器，共 $\frac{K(K-1)}{2}$ 个，投票定类：

$$\hat{y} = \arg \max_k \#\{\text{把 } x \text{ 判为类 } k \text{ 的分类器}\}$$

其中：

- 分类器总数 $\frac{K(K-1)}{2}$ ，每个只需两类样本（**训练更快、更均衡**）。
- 缺点：**预测代价高**（需调用所有分类器），且可能出现票数平局。
- 实践中（libsvm 默认）**OvO 通常优于 OvR**。

(3) Crammer-Singer (单一多类优化)

把所有类别放进一个优化问题（真正的多类 SVM）：

$$\min_w \frac{1}{2} \sum_{k=1}^K \|w_k\|^2 + C \sum_{i=1}^N \max_{k \neq y_i} \left(1 + w_k^\top \varphi(x_i) - w_{y_i}^\top \varphi(x_i) \right)$$

其中：

- w_k ：类 k 的权重向量；共 K 组参数，**联合优化**。
- $1 + w_k^\top \varphi(x_i) - w_{y_i}^\top \varphi(x_i)$ ：**多类 Hinge 损失**，要求真类得分比其他类至少高 1。
- $\max_{k \neq y_i}$ ：只惩罚“最竞争的那个错误类”，即**最大间隔思想**的多类推广。
- 含义：避免了 OvR/OvO 的分解误差，但优化更复杂（常用对偶坐标下降）。

(4) ECOC (纠错输出码)

把 K 类映射到 L 位**码字**（ L 个二分类器），预测时找**最小汉明距离**的码字：

$$\hat{y} = \arg \min_k \sum_{l=1}^L 1[h_l(x) \neq M_{kl}]$$

其中：

- $M \in \{-1, +1\}^{K \times L}$ ：**编码矩阵**，第 k 行是类 k 的码字。
- h_l ：第 l 位对应的二分类器。
- $1[\cdot]$ ：指示函数（异或计 1）。
- 含义：借**纠错码**思想，个别分类器出错不影响整体判决，类别多时鲁棒性强。

(5) SVM-struct (结构化 SVM, Tsochantaridis 等, 2005)

当输出 y 是**结构化对象**（序列、树、图、集合）时，用联合特征 $\Phi(x, y)$ 与判别式：

$$f(x) = \arg \max_{y \in \mathcal{Y}} w^\top \Phi(x, y)$$

优化目标为**结构化 Hinge 损失**：

$$\min_w \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \max_{y \in \mathcal{Y}} \left(\Delta(y_i, y) + w^\top \Phi(x_i, y) - w^\top \Phi(x_i, y_i) \right)$$

其中：

- $\mathcal{Y}$ ：结构化输出空间（所有可能的标注）。
- $\Phi(x, y)$ ：**联合特征**，刻画"输入 + 完整输出"的组合。
- $\Delta(y_i, y)$ ：**任务损失**，衡量预测 y 与真值 y_i 的差距（如错误标签数、编辑距离）。
- $\max_y(\cdot)$ ：**损失增强推理** (loss-augmented inference)，把损失加进 $\arg \max$ ，惩罚"错得离谱"的解。
- 含义：把"预测结构"与"评估质量"统一到一个凸优化中；典型应用包括序列标注、句法分析、图像结构预测。
- 求解：割平面法 (cutting-plane) 或对偶坐标下降，依赖于能高效求解 $\arg \max_y w^\top \Phi(x, y)$ 的**推理算法**（如 Viterbi）。

3.4.10 加权、概率输出与核的扩展

(1) 加权 SVM / 代价敏感 SVM

给每个样本（或每个类）单独的惩罚系数 C_i ：

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + \sum_{i=1}^N C_i \xi_i \quad \text{s.t.} \quad y_i(w^\top x_i + b) \geq 1 - \xi_i, \xi_i \geq 0$$

其中：

- $C_i > 0$ ：第 i 个样本的**个体惩罚**。
- 常见设置： $C_i = C \cdot w_{y_i}$ ，其中 w_{y_i} 与类频率成反比（即 $w_c \propto 1/n_c$ ）。
- 对偶中 $0 \leq \alpha_i \leq C_i$ （上界逐样本不同）。
- 含义：把"少犯哪类的错"编码进模型，直接对应**代价敏感学习**（医疗漏诊的代价远高于误诊，欺诈漏检的代价远高于误拦）。

(2) 概率输出 (Platt Scaling)

SVM 的输出 $f(x)$ 只是到超平面的**带符号距离**，不是概率。Platt 用一个 Sigmoid 拟合：

$$P(y = 1 | x) = \frac{1}{1 + \exp(Af(x) + B)}$$

其中：

- $f(x)$: SVM 的判别值（未归一化距离）。
- A, B : 由独立验证集通过最大似然拟合的两个参数。
- $A < 0$: f 越大，正类概率越高（正常情况）。
- B : 偏置，用于校正类别先验偏移。
- 拟合目标（验证集上）：

$$\min_{A,B} - \sum_{i=1}^M \left[t_i \log p_i + (1 - t_i) \log(1 - p_i) \right], \quad t_i = \frac{y_i + 1}{2}, \quad p_i = \frac{1}{1 + e^{Af(x_i) + B}}$$

其中 M 是验证集大小， $t_i \in \{0, 1\}$ 是目标标签， p_i 是预测概率。 - 常配合**成对耦合法**（pairwise coupling）把 OvO 的多个二分类概率合成为多类概率。 - 含义：概率输出让 SVM 可以进入**风险决策、级联过滤、模型融合（stacking）**等流程。

(3) 更多核函数

核	公式	特点 / 适用
线性核	$x_i^\top x_j$	高维稀疏（文本）、可解释
多项式核	$(\gamma x_i^\top x_j + r)^d$	特征交叉， d 控制阶数
RBF / 高斯核	$\exp(-\gamma \ x_i - x_j\ ^2)$	无穷维、通用首选
拉普拉斯核	$\exp(-\gamma \ x_i - x_j\ _1)$	比 RBF 更重尾，鲁棒
幂指数核	$\exp(-\gamma \ x_i - x_j\ ^d), 0 < d \leq 2$	$d = 2$ 退化为 RBF
Sigmoid 核	$\tanh(\gamma x_i^\top x_j + r)$	与神经网络同源， 非 PSD
余弦核	$\frac{x_i^\top x_j}{\ x_i\ \ x_j\ }$	方向敏感（文本、描述子）
χ^2 核	$\exp\left(-\gamma \sum_d \frac{(x_{id} - x_{jd})^2}{x_{id} + x_{jd}}\right)$	直方图 / 词袋（图像、文本）
直方图交叉核（HIK）	$\sum_d \min(x_{id}, x_{jd})$	直方图特征，快速
预计算核（Gram）	直接给 K 矩阵	字符串核、图核、自定义相似度

其中：

- $\|\cdot\|_1$: L1 范数； $\|\cdot\|$: L2 范数。
- $\gamma > 0$: 核宽度， γ 越大核越“尖”，模型越复杂。
- r : 常数项； d : 次数 / 幂指数。

- **Mercer 条件**：合法的核函数必须使 Gram 矩阵 K 对任意样本集**对称半正定 (PSD)**，即 $\forall c, c^\top K c \geq 0$ 。这保证存在内积空间使 $K(x, x') = \langle \varphi(x), \varphi(x') \rangle$ 。Sigmoid 核只在部分参数下满足，因此是"条件合法"的。
- **表示定理**：最优解必可写成 $w^* = \sum_i \alpha_i \varphi(x_i)$ ，这正是"核技巧可用"的根本原因（对偶只依赖内积）。

(4) 近似与加速核

样本量 N 大时 Gram 矩阵 $O(N^2)$ 存储与 $O(N^3)$ 求解不可行，用**低秩近似**：

$$K \approx \tilde{K} = \Phi \Phi^\top, \quad \Phi \in \mathbb{R}^{N \times m}, m \ll N$$

- **Nystrom 方法**：从 N 个样本中抽样 m 个"地标点" (landmarks)，用 $\tilde{K} = K_{Nm} K_{mm}^{-1} K_{mN}$ 近似整个核矩阵。
- **随机傅里叶特征 (RFF, Rahimi & Recht)**：对平移不变核，用 D 个随机频率显式构造特征：

$$z_\omega(x) = \sqrt{\frac{2}{D}} [\cos(\omega^\top x), \sin(\omega^\top x)], \quad \hat{K}(x, x') = z(x)^\top z(x') \approx K(x, x')$$

其中 $\omega \sim p(\omega)$ 为核的**谱分布**（RBF 核对应高斯分布）， D 越大近似越准。这样可以把核 SVM 变成**线性 SVM**，用 SGD 大规模训练。- 含义：把"核方法"与"深度 / 大规模学习"在工程上打通。

3.4.11 求解算法：SMO、分解法与次梯度

对偶问题是一个**带盒约束与等式约束的二次规划 (QP)**，直接用通用 QP 求解器需要 $O(N^2)$ 内存与 $O(N^3)$ 时间。实用算法都基于**分解 (decomposition)** 思想：每次只优化一小部分变量，其余固定。

(1) SMO (Sequential Minimal Optimization, Platt, 1998)

每次只取**两个**乘子 α_i, α_j （因为等式约束 $\sum_i \alpha_i y_i = 0$ 意味着一次至少动两个才能保持可行）：

$$\alpha_j^{\text{new}} = \alpha_j + \frac{y_j (E_i - E_j)}{\eta}, \quad \eta = 2K_{ij} - K_{ii} - K_{jj}$$

其中：

- $E_i = f(x_i) - y_i$ ：第 i 个样本的**预测误差**（SMO 的启发式选择就基于 $|E_i - E_j|$ 最大）。
- η ：目标函数沿该方向的**二阶导 (曲率)**； $\eta > 0$ 保证是极小值方向。
- α_j^{new} ：更新后的乘子，需**裁剪**到 $[L, H]$ 区间以保持盒约束：

$$L = \max(0, \alpha_j - \alpha_i), \quad H = \min(C, C + \alpha_j - \alpha_i) \quad (y_i \neq y_j)$$

$$L = \max(0, \alpha_i + \alpha_j - C), \quad H = \min(C, \alpha_i + \alpha_j) \quad (y_i = y_j)$$

- 再由 $\alpha_i^{\text{new}} = \alpha_i + y_i y_j (\alpha_j - \alpha_j^{\text{new}})$ 回代 α_i ，并按下式更新偏置（两候选取平均）：

$$b_1 = b - E_i - y_i(\alpha_i^{\text{new}} - \alpha_i)K_{ii} - y_j(\alpha_j^{\text{new}} - \alpha_j)K_{ij}$$

- 含义：每步只做 $O(N)$ 的核计算，外层迭代若干轮即收敛；这是 libsvm 的核心，让小规模到中等规模 SVM 训练变得轻而易举。

(2) 其他求解路线

方法	思想	复杂度 / 适用
通用 QP (内点法)	直接解 QP	$O(N^3)$, 仅小样本
SMO	每次两个变量, 解析更新	中等规模事实标准
分解法 / SVM ^{light}	每次工作集大小 $q > 2$	大规模、可用缓存
割平面法	用于 SVM-struct, 逐步加约束	结构化输出
Pegasos (次梯度)	直接在原始问题上 SGD	$O(1)$ 每步、在线/流式
LS-SVM 解方程	共轭梯度解线性系统	无稀疏性但极快

Pegasos 的更新式 (原始问题 + 次梯度)：

$$w_{t+1} = (1 - \eta_t \lambda) w_t + \eta_t 1[y_i w_t^\top x_i < 1] y_i x_i$$

其中：

- λ ：正则化系数 (对应 $1/(CN)$ 的量级)。
- $\eta_t = 1/(\lambda t)$ ：第 t 步学习率。
- $1[\cdot]$ ：指示函数——只有**违反间隔**的样本才产生梯度 (Hinge 损失的次梯度)。
- 含义：单样本更新、内存 $O(d)$ ，是**在线 / 流式 / 大数据**场景的核 SVM 替代方案。

3.4.12 应用方向

(1) 图像 / 视觉

- **HOG + SVM**：行人检测的经典组合 (Dalal & Triggs, 2005)。
- **图像分类**：在 CNN 之前，SVM 是图像分类的主力 (如 Caltech-101)。
- **目标检测**：滑动窗口 + SVM 分类。
- **多类 SVM**：一对多 (OvR) 或一对一 (OvO) 扩展。
- **多模态 / 遥感**：高光谱像素分类 (高维小样本时优势明显)。

(2) 文本与自然语言

- **文本分类**：TF-IDF + 线性 SVM 是强基线。

- 情感分析 / 垃圾评论：高维稀疏特征下的线性可分。
- 命名实体识别 (NER)：结构化 SVM ($\text{SVM}^{\text{struct}}$) 序列标注。

(3) 生物、医学与化学

- 基因 / 蛋白分类：样本数远小于特征维数时的首选 ($p \gg n$ 问题)。
- 药物活性预测：分子描述子 + SVM 的 QSAR 建模。
- 脑电 / fMRI 解码：高维神经信号分类。

(4) 工业、金融与安全

- 故障诊断：振动 / 声学信号的工况分类。
- 信用评分：线性 SVM 的可解释性强。
- 入侵检测：高维流量特征的异常判别。
- 手写数字识别：MNIST 上的经典核方法基线。

(5) 作为通用工具

- 异常检测：One-Class SVM 只需正类样本。
- 支持向量回归 (SVR)：连续目标的高维回归。
- 特征选择：用 $\|w\|$ 做稀疏化 (L1-SVM)。

3.4.13 与深度学习的联系

- Hinge 损失被深度度量学习沿用 (如 Deep SVM、大间隔 softmax)。
- 核方法 vs 深度：核方法固定特征映射，深度网络学习特征映射。
- 神经正切核 (NTK)：无限宽网络的极限等价于核方法，架起两者桥梁。
- SVM 的间隔思想影响深度学习的 margin-based 损失 (如 ArcFace、CosFace)。

3.5 决策树与森林 (Decision Trees and Forests)

3.5.1 决策树：递归划分

决策树通过一系列 "if-else" 问题把特征空间递归划分成若干区域，每个叶子给出预测。核心是如何选划分特征和阈值。

3.5.2 不纯度度量

信息熵：

$$H(S) = - \sum_{c=1}^C p_c \log_2 p_c$$

其中：

- S ：当前节点上的样本集合。
- C ：类别数。
- p_c ： S 中属于类别 c 的比例。
- $\log_2$ ：以 2 为底，单位是比特。
- $H(S)$ ：不确定性，越纯越小（纯节点 $H = 0$ ）。

基尼不纯度：

$$\text{Gini}(S) = 1 - \sum_{c=1}^C p_c^2$$

其中 p_c 同上；基尼不纯度衡量"随机抽两个样本类别不同的概率"，计算比熵快。

信息增益 (ID3 / C4.5)：

$$\text{Gain}(S, A) = H(S) - \sum_{v \in \text{values}(A)} \frac{|S_v|}{|S|} H(S_v)$$

其中：

- A ：候选划分特征。
- $\text{values}(A)$ ：特征 A 的取值集合。
- S_v ： S 中特征 A 取值为 v 的子集。
- $|S_v|/|S|$ ：子集权重。
- 含义：用 A 划分后，不确定性下降多少；选增益最大的特征。

C4.5 的改进——信息增益率：

$$\text{GainRatio}(S, A) = \frac{\text{Gain}(S, A)}{\text{SplitInfo}(S, A)}, \quad \text{SplitInfo}(S, A) = - \sum_v \frac{|S_v|}{|S|} \log_2 \frac{|S_v|}{|S|}$$

其中 SplitInfo 惩罚"取值过多的特征"，避免偏向 ID 类特征。

CART 用基尼不纯度，且只做**二叉划分**，可同时处理分类与回归。

3.5.3 剪枝

- **预剪枝**：提前停止（限制深度、最小样本数）。
- **后剪枝**：先长满再剪掉不提升泛化的子树（代价复杂度剪枝）。

3.5.4 随机森林：集成学习

随机森林 = Bagging + 特征随机：

1. **Bootstrap 采样**：从 N 个样本有放回抽 N 个，训练一棵树。
2. **特征随机**：每次分裂只从随机 m 个特征中选最优 ($m \approx \sqrt{D}$) 。
3. **投票/平均**：多棵树结果聚合。

预测：

$$\hat{y} = \text{majority}\{h_t(x)\}_{t=1}^T \quad \text{或} \quad \hat{y} = \frac{1}{T} \sum_{t=1}^T h_t(x)$$

其中：

- T ：树的数量。
- h_t ：第 t 棵树。
- 分类用多数投票，回归用平均。
- 含义：多棵“弱相关”的树平均，方差下降，泛化提升。

为什么有效：单棵树方差大（易过拟合），Bagging 通过**平均**降低方差；特征随机进一步**去相关**，使平均更有效。

3.5.5 特征重要性

$$\text{Importance}(j) = \sum_{\text{节点 } t \text{ 用 } j \text{ 分裂}} \frac{|S_t|}{N} \cdot \Delta \text{Impurity}(t)$$

其中：

- j ：特征下标。
- S_t ：节点 t 的样本数。
- $\Delta \text{Impurity}(t)$ ：该次分裂带来的不纯度下降。
- 含义：某特征在所有树中带来的不纯度下降的加权和，越大越重要。

3.5.6 决策树算法族总览

决策树是一个**算法族**：单树的差异在**"怎么分裂、怎么剪枝"**，多树集成的差异在**"怎么生成、怎么聚合"**。

算法	类型	分裂准则	输出	特点
ID3	单树	信息增益	分类	仅离散特征
C4.5	单树	信息增益率	分类	连续值 + 缺失值 (见 5.1)
CART	单树	基尼 / SSE	分类 + 回归	二叉 (见 5.2)
CHAID	单树	卡方检验	分类	多叉、统计显著性
条件推断树	单树	条件分布置换检验	分类 + 回归	无选择偏差
M5 / 模型树	单树	标准差缩减	回归	叶子是线性模型
Bagging	集成	基学习器不变	任意	并行降方差
随机森林	集成	基尼 + 特征随机	任意	降方差 + 去相关
Extra Trees	集成	随机阈值	任意	更快、方差更小
GBDT / XGBoost	集成	负梯度拟合	任意	串行降偏差
LightGBM	集成	直方图 + leaf-wise	任意	大数据首选
CatBoost	集成	有序提升	任意	类别特征原生支持
Isolation Forest	集成	随机划分	异常分	无监督异常检测
随机蕨	集成	随机特征组合	分类	极快，实时匹配
深度森林	集成	多粒度 + 级联	任意	模拟深度结构

3.5.7 单树变体：分裂准则与叶子形式

(1) 分裂准则变体

准则	公式	算法	倾向
信息增益	$H(S) - \sum_v \frac{ S_v }{ S } H(S_v)$	ID3	偏好多取值特征
信息增益率	Gain/SplitInfo	C4.5	修正上述偏好
基尼不纯	$1 - \sum_c p_c^2$	CART	无对数，更快
误分类率	$1 - \max_c p_c$	理论	对不纯不敏感
卡方统计量	χ^2 检验	CHAID	统计显著性
方差缩减	$\text{Var}(S) - \sum_v \frac{ S_v }{ S } \text{Var}(S_v)$	CART 回归	连续目标

关键结论：基尼与熵曲线形状非常接近，但基尼无需对数运算，且对"类概率接近 0.5"的节点惩罚更平滑，因此工业实现（CART / LightGBM）普遍用基尼。

(2) 条件推断树 (Conditional Inference Tree)

针对"特征选择偏差"（取值多的特征/连续特征总被优先选中）问题，用置换检验代替不纯度：

$$T_j = \sum_{k=1}^K \frac{(\text{观测}_{jk} - \text{期望}_{jk})^2}{\text{期望}_{jk}}, \quad P \text{ 值由置换分布计算}$$

其中：

- T_j ：特征 j 与响应变量独立性检验的卡方统计量（对应 K 个响应类别）。
- 期望值由"强制独立"（行和 $\times$ 列和 / 总数）计算。
- 含义：只有 P 值小于阈值的特征才被考虑分裂；由于检验统计量已做了"自由度校正"，不再偏好高基数特征，统计严谨性更好。

(3) 模型树 (Model Tree, M5 家族的叶子)

普通回归树的叶子是常数，模型树的叶子是线性模型：

$$\hat{y} = \begin{cases} w_1^\top x + b_1, & x \in R_1 \\ w_2^\top x + b_2, & x \in R_2 \\ \vdots \end{cases}$$

其中：

- R_k ：第 k 个叶子对应的特征空间区域。
- w_k, b_k ：该区域上拟合的局部线性模型（用落入该区域的样本最小二乘拟合）。
- 分裂准则用"标准差缩减"（而不是方差），因为叶子内部本身就能拟合斜率。
- 含义：把"分片常数逼近"换成"分片线性逼近"，同样深度下精度高得多（M5P、模型树）。

3.5.8 Bagging 与随机森林族

(1) Bagging 的方差缩减原理

若 T 个基学习器的预测两两平均相关为 ρ 、方差均为 σ^2 ，则平均预测的方差为：

$$\text{Var}\left(\frac{1}{T} \sum_{t=1}^T h_t(x)\right) = \rho \sigma^2 + \frac{1-\rho}{T} \sigma^2$$

其中：

- ρ ：基学习器之间的平均相关系数。
- 第一项 $\rho \sigma^2$ ：无法通过增加 T 消除（这就是为何要"去相关"）。
- 第二项：随 T 增大而趋于 0。
- 含义：**Bagging 只能消除第二项**；要降第一项，必须让树"长得不一样"——这正是随机森林加"特征随机"的原因。
- Bagging 的泛化误差上界（Breiman）： $\text{PE}^* \leq \frac{\bar{\rho}(1-s^2)}{s^2}$ ，其中 s 是"单棵树强于随机猜测"的程度， $\bar{\rho}$ 是平均相关度。

(2) 随机森林的三层随机化

随机源	具体做法	超参数
样本	Bootstrap 有放回抽样	采样数（默认 N ）
特征	每次分裂随机选 m 个候选	$m \approx \sqrt{D}$ （分类） / $D/3$ （回归）
阈值	（仅 Extra Trees）随机抽切分点	切分数

袋外（OOB）估计：每棵树有约 $1 - e^{-1} \approx 36.8\%$ 的样本未被抽中，它们构成该棵树的**袋外样本**，可用来无额外代价地估计泛化误差：

$$\text{Err}_{\text{OOB}} = \frac{1}{N} \sum_{i=1}^N 1\left[\bar{h}_{\text{OOB}(i)}(x_i) \neq y_i\right]$$

其中 $\bar{h}_{\text{OOB}(i)}$ 是只用不含样本 i 的树做出的聚合预测。含义：**OOB 误差近似等于留一交叉验证**，省去了昂贵的重训练。

(3) Extra Trees (Extremely Randomized Trees)

与随机森林的两点不同：**不做 Bootstrap**（用全部样本）+ **阈值完全随机**：

$$t \sim \mathcal{U}\left(\min_j x_j, \max_j x_j\right)$$

其中 t 是从特征取值范围内**均匀随机**抽取的切分点（而非搜索最优阈值）。含义：速度更快、方差更低（但偏差略高），特征数很多时尤为有效。

(4) Isolation Forest（孤立森林，无监督异常检测）

思路反转：**异常点更容易被“孤立”**（随机切几次就单独成叶）。用路径长度判断：

$$h(x) = \text{从根到 } x \text{ 所在叶子的边数}, \quad s(x, n) = 2^{-\frac{\mathbb{E}[h(x)]}{c(n)}}$$

其中：

- $\mathbb{E}[h(x)]$ ：样本 x 在森林中的**平均路径长度**。
- $c(n) = 2H(n-1) - \frac{2(n-1)}{n}$ ：**归一化常数**（二叉搜索树的平均路径长度），其中 $H(k) \approx \ln k + 0.577$ 是调和数。
- $s(x, n) \in (0, 1]$ ：**异常分数**——接近 1 为异常，接近 0.5 为正常，明显小于 0.5 为密集点。
- 含义：**无需标签、无需距离度量**， $O(N)$ 级别的训练与推理，是高维表格数据异常检测的工业标准。

(5) 其他集成形式

- **Random Subspace**：只在随机特征子集上训练（不抽样本），适合高维。
- **Totally Random Trees Embedding**：用树把数据映射到**叶索引的 one-hot 空间**，做非线性降维 / 特征构造。
- **随机蕨（Random Ferns）**：不做树，而是把特征分组为“蕨”，每蕨内不关心顺序，存储量远低于决策树，用于实时特征匹配与姿态估计。

3.5.9 Boosting 变体：从 GBDT 到 XGBoost / LightGBM / CatBoost

(1) 梯度提升的统一形式

把模型写成**加法模型**，每轮拟合当前损失的**负梯度**（伪残差）：

$$F_m(x) = F_{m-1}(x) + \nu h_m(x), \quad r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F=F_{m-1}}$$

其中：

- F_m ：第 m 轮后的强学习器。
- h_m ：拟合伪残差 r_{im} 的**回归树**。
- $\nu \in (0, 1]$ ：**学习率（收缩系数）**，通常 0.01~0.1；越小需要越多轮。
- r_{im} ：**伪残差**——平方损失下恰好等于 $y_i - F_{m-1}(x_i)$ ，但对其他损失（如 $\log$ 损失）它是负梯度而非残差。

- 含义：Boosting 是在函数空间做梯度下降（前向分步算法）。

(2) XGBoost: 二阶泰勒 + 显式正则

$$\text{Obj} = \sum_{i=1}^N L(y_i, \hat{y}_i) + \sum_{k=1}^M \Omega(f_k), \quad \Omega(f) = \gamma T + \frac{\lambda}{2} \sum_{j=1}^T w_j^2$$

其中：

- T ：叶子数（模型复杂度）； w_j ：叶子权重。
- γ ：每片叶子的固定代价（相当于预剪枝阈值）； λ ：叶子权重的 L2 惩罚。
- 含义：相比 GBDT，XGBoost 把"正则项"写法入了目标函数，而不是开列超参数。

对损失做二阶泰勒展开，把常数项去掉：

$$\text{Obj}^{(t)} \approx \sum_{i=1}^N \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \gamma T + \frac{\lambda}{2} \sum_{j=1}^T w_j^2$$

其中：

- $g_i = \partial_{\hat{y}^{(t-1)}} L(y_i, \hat{y}^{(t-1)})$ ：一阶导（梯度）。
- $h_i = \partial_{\hat{y}^{(t-1)}}^2 L(y_i, \hat{y}^{(t-1)})$ ：二阶导（曲率 / Hessian）。
- 含义：只用 g_i, h_i 就能适配任意二阶可导损失——这是 XGBoost 通用性的根源。

把同叶子样本的 g, h 汇总 ($G_j = \sum_{i \in I_j} g_i, H_j = \sum_{i \in I_j} h_i$)，可得叶子最优权重与最优目标值的闭式解：

$$w_j^* = -\frac{G_j}{H_j + \lambda}, \quad \text{Obj}^* = -\frac{1}{2} \sum_{j=1}^T \frac{G_j^2}{H_j + \lambda} + \gamma T$$

相应的分裂增益（用于贪婪找切分点）：

$$\text{Gain} = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma$$

其中：

- 下标 L, R ：左 / 右子节点。
- 前三项："分裂后比不分裂好多少"； $-\gamma$ ：分裂的代价。
- 只有 $\text{Gain} > 0$ 才真正分裂——这就是内置的预剪枝。
- 含义：XGBoost 的整个树生长过程都基于这两个统计量，因此训练快、可并行（预排序 + 直方图）。

(3) LightGBM 的两个核心加速

- **GOSS (Gradient-based One-Side Sampling)**：保留**梯度大**的样本（硬例），从梯度小的样本中随机抽样并**放大权重**：

$$\tilde{g}_i = \begin{cases} g_i, & |g_i| \geq \theta \\ \frac{1-a}{b} g_i, & \text{否则（采样后放大 } \frac{1-a}{b} \text{ 倍）} \end{cases}$$

其中 a 是保留大梯度的比例， b 是小梯度样本的采样比例；放大系数 $\frac{1-a}{b}$ 保证**梯度求和的期望不变**（无偏）。

- **EFB (Exclusive Feature Bundling)**：把“很少同时非零”的稀疏特征**捆绑**成一维，把特征数从 D 降到 $\approx D'$ ，大幅减少直方图构建的成本。
- **Leaf-wise (按叶生长)** vs **Level-wise (按层生长)**：每次只分裂**增益最大**的叶子，同样叶子数下损失更低，但需限制最大深度以防过拟合。

(4) CatBoost 的两个核心改进

- **有序提升 (Ordered Boosting)**：用“只看排在当前样本之前的样本”的模型来算梯度，**消除预测偏移 (prediction shift)**，缓解过拟合。
- **有序目标统计 (Ordered Target Statistics)**：对类别特征做目标编码时，用前缀样本的均值代替全局均值，避免**目标泄漏**：

$$\hat{x}_{ik} = \frac{\sum_{j \in \text{前缀}, x_{jk}=x_{ik}} y_j + \alpha p}{|\{j \in \text{前缀}, x_{jk} = x_{ik}\}| + \alpha}$$

其中 p 是先验均值（如全局均值）， α 是平滑强度。- 另有**对称树 (oblivious trees)** 结构，使预测可在 $O(\log T)$ 内完成且抗过拟合。

3.5.10 其他树变体：软决策树、深度森林与可微树

(1) 软决策树 (Soft Decision Tree)

把硬“if-else”换成**可微的 sigmoid 门控**，使树能端到端梯度训练：

$$\mu_l(x) = \prod_{\text{路径上的内部节点 } i} \sigma(\alpha_i (x_{j(i)} - \beta_i))^{s_i}, \quad s_i \in \{+1, -1\}$$

其中：

- α_i ：节点 i 的**分裂锐度**（越大越接近硬分裂）。
- β_i ：**阈值**； $j(i)$ ：节点 i 使用的特征。
- s_i ：方向符号（左子树取 σ ，右子树取 $1 - \sigma$ ）。
- $\mu_l(x)$ ：样本到达叶子 l 的**软概率**。
- 预测： $\hat{y} = \sum_l \mu_l(x) \pi_l$ ，其中 π_l 是叶子参数（可直接求导）。

- 含义：**每一片叶子都是一个可学习参数**，整棵树可用反向传播训练；代价是失去了硬决策树"可解释规则"的优势。

(2) 深度森林 (gcForest, 周志华, 2017)

用"森林级联"模拟深度，不依赖反向传播：

- **多粒度扫描**：用多个滑动窗口尺寸提取子序列，分布式表征（对序列/图像有效）。
- **级联层**：每层由多个随机森林 / 完全随机森林组成；第 l 层的输入是"原始特征 + 前 $l - 1$ 层的类概率向量"：

$$\mathbf{v}^{(l)} = [\mathbf{x}; \mathbf{p}^{(1)}; \dots; \mathbf{p}^{(l-1)}]$$

其中 $\mathbf{p}^{(k)}$ 是第 k 层的**类分布向量**。 - **自适应深度**：若验证集精度不再提升则**自动停止**增加层数，无需手设深度。 - 含义：保留了森林"少调参、抗过拟合"的优点，同时获得**层次表征能力**。

(3) NODE (Neural Oblivious Decision Ensembles)

用**可微的各类别特征门控**代替 sigmoid 树（基于 entmax）：

$$h_l = \sum_j w_j \cdot \left(\prod_{\text{可选特征}} \tilde{\sigma}(x) \right)$$

其中用 **entmax / sparsemax** 代替 sigmoid，可产生**稀疏选择**（真正忽略某些特征），使模型同时具备"树的特征选择"与"网络的可微性"。

3.5.11 应用方向

(1) 图像 / 视觉

- **像素级分类**：随机森林做语义分割（早期方法，如 TextonForest）。
- **关键点分类**：随机森林做**随机蕨 (Random Ferns)**，用于特征匹配、姿态估计。
- **目标检测**：Viola-Jones 人脸检测用 AdaBoost + 决策树桩。
- **特征选择**：用特征重要性筛选描述子维度。
- **深度 / 视差 / 光流回归**：随机森林做连续值的逐像素回归。

(2) 表格数据 (随机森林最强场景)

- **金融风控**：信用评分、反欺诈、反洗钱。
- **医疗**：疾病风险预测、住院时长预测、电子病历挖掘。
- **营销**：客户流失、响应预测、客户分群特征。
- **工业**：设备故障预测、质量检测、能耗预测。

(3) 生物信息与科学

- **基因表达 / 分型**：高维小样本的稳健分类。
- **生态与环境**：物种分布建模、遥感地物分类、气候变量重要性分析。
- **材料 / 化学**：性质预测与特征筛选。

(4) 时序、信号与地理

- **传感器分类**：加速度计、EEG/ECG 信号的活动识别。
- **语音特征分类**：MFCC 特征的声学事件识别。
- **地理空间**：土地利用分类、滑坡易发性评价。

(5) 作为通用工具

- **缺失值填补**：Iterative Imputer / MissForest。
- **异常检测**：孤立森林 (Isolation Forest) 。
- **特征重要性排序**：特征工程的首选工具。

3.5.12 与深度学习的联系

- **随机森林 = 深度网络的"浅层集成"对照**：前者靠集成降方差，后者靠层次降偏差。
 - **梯度提升树 (GBDT/XGBoost/LightGBM)** 是表格数据王者，与深度网络互补。
 - **深度森林 (Deep Forest / gcForest)** 尝试用树堆叠模拟深度。
 - **随机森林**的思想被用于深度特征匹配的加速。
 - **XGBoost 的"二阶泰勒 + 显式正则"**思想被诸多深度模型借鉴 (如 DART、可微树) 。
 - **Isolation Forest 的"孤立难易"思想** 与深度异常检测 (Deep SVDD、自编码重构误差) 互补；深模型能处理图像，森林则主导高维表格。
 - **可微树的梯度**与 Transformer 的"稀疏路由 / 混合专家 (MoE)"是一回事：都是**"软地选择子网络"**。
-

4. 无监督学习 (Unsupervised Learning)

4.1 聚类 (Clustering)

4.1.1 问题定义

给定无标签数据 $\{x_i\}_{i=1}^N$ ，把它们分成若干簇，使簇内相似、簇间相异。

4.1.2 聚类目标 (一般形式)

$$\min_{\{C_1, \dots, C_K\}} \sum_{k=1}^K \sum_{x_i \in C_k} d(x_i, \mu_k)$$

其中：

- K ：簇数。
- C_k ：第 k 个簇（样本集合）。
- μ_k ：第 k 个簇的**中心**（如均值）。
- $d(\cdot, \cdot)$ ：距离度量。
- 含义：让每个样本离自己簇中心尽量近。

4.1.3 聚类方法分类

类型	代表	思想
划分式	K-means、K-medoids	直接划分成 K 簇
层次式	凝聚/分裂层次聚类	建树状结构（树状图）
密度式	DBSCAN、Mean Shift	按密度连通区域成簇
模型式	GMM	假设数据由概率模型生成
图论式	谱聚类	用图的割划分

DBSCAN 的两个参数：

- ϵ ：邻域半径。
- MinPts：成为核心点所需的最少邻居数。
- 核心点： ϵ 邻域内点数 $\geq$ MinPts；可发现任意形状簇并识别噪声。

谱聚类：用相似度矩阵 W 的拉普拉斯矩阵 $L = D - W$ 的前 K 个特征向量嵌入，再 K-means。其中 D 是度矩阵（对角元 $D_{ii} = \sum_j W_{ij}$ ）。

4.1.4 聚类算法族总览

聚类没有唯一正确的答案——不同算法对应**不同的簇定义**：

簇的"定义"	家族	代表算法	超参数
离中心最近	划分式	K-means、K-medoids、FCM	K
层次嵌套	层次式	AGNES、DIANA、BIRCH、CURE	切树位置
密度连通	密度式	DBSCAN、OPTICS、Mean Shift、HDBSCAN	ϵ , MinPts
同分布生成	模型式	GMM、SOM、潜在 Dirichlet	K / 拓扑
图割代价小	图论式	谱聚类、Ncut、MinCut	K / 相似度
相似度互传	消息传递	Affinity Propagation	偏好值
隶属度连续	模糊	模糊 C 均值	K, m
低维子空间	子空间	CLIQUE、PROCLUS	网格 / 子空间维
神经网络表征	深度	DEC、DeepCluster、SwAV	网络 + K

4.1.5 划分式变体：K-medoids、CLARA 与 CLARANS

(1) K-medoids / PAM

K-means 用**均值**作中心，对离群点敏感；K-medoids 改用**真实样本点 (medoid)**：

$$\min_{\{C_k\}} \sum_{k=1}^K \sum_{x_i \in C_k} d(x_i, o_k), \quad o_k \in C_k$$

其中：

- o_k ：第 k 个簇的**中心点 (medoid)**，必须是真实样本之一。
- $d(\cdot, \cdot)$ ：**任意距离**（不要求欧氏，可为曼哈顿、编辑距离、任意自定义距离）。
- 含义：中心一定是真实点，因此对**离群点更鲁棒**，且可处理**非欧氏距离**。

- 代价：寻找最优 medoid 是 NP-hard，PAM 用贪婪交换 (swap) 迭代，复杂度 $O(K(N - K)^2)$ 。

(2) CLARA (Clustering LARge Applications)

从全数据中**反复抽样** (大小 $40 + 2K$)，在每个样本上跑 PAM，取最优结果：

$$\text{近似度} \approx 1 - \frac{\sum_i d(x_i, o_i^{(\text{nearest})})}{\sum_i d(x_i, \bar{x})}$$

其中 $\bar{x}$ 是**全局均值** (作归一化参考)。含义：用小样本代替全数据，把 $O(N^2)$ 降到可用的量级，代价是结果依赖抽样。

(3) CLARANS (Clustering Large Applications based on RANdomized Search)

把 medoid 搜索看成**在图上搜索**：节点是 " K 个 medoid 的组合"，邻域是 "换一个 medoid"。基本流程：从随机节点出发，检查最多 `maxneighbor` 个邻居，**只在发现更优时移动**；重复 `numlocal` 次取全局最优。含义：不要求每次都检查全部邻居，**显著快于 CLARA**，且没有抽样偏差。

4.1.6 层次式变体：AGNES、DIANA、BIRCH、CURE、ROCK 与 Chameleon

(1) 凝聚式 AGNES / 分裂式 DIANA

- **AGNES**：自下而上，初始每点一簇，反复合并**距离最近**的两簇。
- **DIANA**：自上而下，初始全部一簇，反复分裂"最不内聚"的簇。
- 簇间距离的四种定义：

连结方式	簇间距离 $d(C_a, C_b)$	倾向
单链 (Single Link)	$\min_{x \in C_a, y \in C_b} d(x, y)$	长链状簇 (易粘连)
全链 (Complete Link)	$\max_{x \in C_a, y \in C_b} d(x, y)$	紧凑簇
平均链 (Average Link)	$\frac{1}{ C_a C_b } \sum_{x,y} d(x, y)$	折中 (UPGMA)
Ward 法	合并后 SSE 增量最小	类欧氏 K-means

其中 **Lance-Williams 公式**使四种方法可用同一套递推更新：

$$d(C_i, C_j \cup C_k) = \alpha_x d(C_i, C_j) + \alpha_y d(C_i, C_k) + \beta d(C_j, C_k) + \gamma |d(C_i, C_j) - d(C_i, C_k)|$$

其中 $\alpha_x, \alpha_y, \beta, \gamma$ 随连结方式不同而变 (单链 $\alpha_x = \alpha_y = \frac{1}{2}, \beta = 0, \gamma = -\frac{1}{2}$)。

(2) BIRCH (聚类特征树)

用**聚类特征 CF** 三元组概括一个子簇：

$$CF = (N, \mathbf{LS}, SS), \quad \mathbf{LS} = \sum_{i=1}^N x_i, \quad SS = \sum_{i=1}^N \|x_i\|^2$$

其中：

- N ：子簇内**点数**。
- $\mathbf{LS}$ ：**线性和** (linear sum) , D 维向量。
- SS ：**平方和** (scalar) 。
- 由此可常量时间算出中心与半径：

$$\bar{x} = \frac{\mathbf{LS}}{N}, \quad R = \sqrt{\frac{SS - \|\mathbf{LS}\|^2/N}{N}}$$

- 合并两个 CF 只需相加： $CF_1 + CF_2 = (N_1 + N_2, \mathbf{LS}_1 + \mathbf{LS}_2, SS_1 + SS_2)$ 。
- 含义：CF 树把数据压缩成**摘要**，**一次扫描**即可完成预聚类，适合大数据流式场景。

(3) CURE (代表点收缩)

用**多个代表点**（而非中心）描述一个簇，并把它们向中心**收缩**：

$$x' = \bar{x} + \alpha(x - \bar{x}), \quad \alpha \in [0, 1]$$

其中：

- $\bar{x}$ ：簇的**质心**； x ：选出的**代表点**（离中心最远的那些）。
- α ：**收缩因子**（如 0.2），把代表点往中心拉，降低离群点影响。
- 簇间距离取**所有代表点对的最小距离**（单链变体）。
- 含义：单中心无法表示**非球形长条簇**，多代表点可；该方法发现**任意形状簇**且对离群点鲁棒。

(4) ROCK (面向分类属性的链接聚类)

对布尔 / 类别属性，“距离”无意义，改用**共同邻居数（链接数）**：

$$\text{link}(x_i, x_j) = |\mathcal{N}(x_i) \cap \mathcal{N}(x_j)|, \quad \text{Goodness}(C_i, C_j) = \frac{\sum_{x \in C_i, y \in C_j} \text{link}(x, y)}{(|C_i| + |C_j|)^{f(\theta)}}$$

其中：

- $\mathcal{N}(x)$ ： x 的**邻居集合**（相似度超过阈值 θ 的点）。
- $f(\theta)$ ：与阈值相关的缩放指数（常取 $1 + 2f(\theta)$ 形式）。
- 分母：**防止大簇天然得分高**（归一化）。
- 含义：ROCK 不看“离得多近”，而看“**共享多少邻居**”——这是在**类别型 / 购物篮数据**上做层次聚类的关键发明。

(5) Chameleon (动态建模)

先用 k -最近邻图把数据切成小簇，再用两个**动态指标**合并：

$$\text{RI}(C_i, C_j) = \frac{2 |\text{EC}(C_i, C_j)|}{|\text{EC}(C_i)| + |\text{EC}(C_j)|}, \quad \text{RC}(C_i, C_j) = \frac{\bar{S}_{\text{EC}}(C_i, C_j)}{\frac{|C_i| \bar{S}_{\text{EC}}(C_i) + |C_j| \bar{S}_{\text{EC}}(C_j)}{|C_i| + |C_j|}}$$

其中：

- $\text{EC}(\cdot)$ ：**割边集合**（连接两个簇的边）。
- $\bar{S}_{\text{EC}}$ ：割边的**平均边长**（越小越紧密）。
- RI ：**相对互连性**（两个簇之间相对自己内部的连接密度）。
- RC ：**相对紧密度**（跨簇边的平均长度相对于各自内部）。
- 合并准则： $\text{RI} \cdot \text{RC}^\alpha$ 最大（ α 调节两者权重）。
- 含义：能同时发现**不同密度、不同形状**的簇，优于 CURE 与 ROCK。

4.1.7 密度式变体：DBSCAN、OPTICS、DENCLUE、Mean Shift 与 HDBSCAN

(1) DBSCAN 的形式化定义

$$\mathcal{N}_\epsilon(p) = \{q \mid d(p, q) \leq \epsilon\}, \quad p \text{ 是核心点} \iff |\mathcal{N}_\epsilon(p)| \geq \text{MinPts}$$

其中：

- $\mathcal{N}_\epsilon(p)$ ： p 的 ϵ -邻域。
- 三种点的角色：
- **核心点**：邻域点数 $\geq \text{MinPts}$ ；
- **边界点**：自身非核心，但在某核心点的邻域内；
- **噪声点**：既不是核心也不是边界。
- 两个关键关系：
- **密度直达**： $q \in \mathcal{N}_\epsilon(p)$ 且 p 为核心点；
- **密度可达**：存在链 $p_1 \rightarrow \dots \rightarrow p_n$ 每步密度直达；
- **密度相连**：存在 o 使 p, q 都从 o 密度可达（簇 = 密度相连点的最大集合）。
- 优点：**无需预设 K 、能发现任意形状簇、能识别噪声**；缺点：密度不均时参数难调，且对 ϵ 极敏感。

(2) OPTICS (用可达距离代替单一 ϵ)

不输出单一聚类，而是输出**所有 ϵ 下的聚类顺序**：

$$\text{core-dist}_\epsilon(p) = \text{到第 MinPts 近邻的距离}, \quad \text{reach-dist}(p, o) = \max(\text{core-dist}(o), d(o, p))$$

其中：

- $\text{core-dist}(p)$: p 成为**核心点**所需的最小半径（即到第 MinPts 个近邻的距离）。
- $\text{reach-dist}(p, o)$: 从 o 看 p 的**可达距离**。
- 输出：**可达性图**（横轴为处理顺序，纵轴为可达距离），**谷底就是簇**——且一个图同时包含所有密度层级。

(3) DENCLUE (密度吸引子)

用**核密度估计**定义簇：簇 = 密度函数的**局部极大点（吸引子）**的吸引盆。

$$f(x) = \frac{1}{Nh^D} \sum_{i=1}^N K\left(\frac{x - x_i}{h}\right), \quad K_{\text{Gauss}}(u) = e^{-\|u\|^2/2}$$

爬山（梯度上升）迭代：

$$x \leftarrow x + \delta \frac{\nabla f(x)}{\|\nabla f(x)\|}$$

其中：

- h : 带宽（核宽度）； D : 特征维数（归一化因子使 f 积分为 1）。
- $\nabla f(x)$: 密度梯度，指向密度上升最快的方向。
- δ : 步长。
- 含义：每个点沿梯度爬到最近的密度极大点，**爬到同一点的就是同簇**。

(4) Mean Shift (均值漂移)

与 DENCLUE 同源，但用**核函数的均值偏移向量**直接迭代：

$$m(x) = \frac{\sum_{i=1}^N x_i g\left(\left\|\frac{x-x_i}{h}\right\|^2\right)}{\sum_{i=1}^N g\left(\left\|\frac{x-x_i}{h}\right\|^2\right)} - x$$

其中：

- $g(\cdot)$: 核的**影子核**（高斯核的 g 仍是高斯）。
- 迭代: $x \leftarrow x + m(x)$, 直到 $\|m(x)\| < \tau$ 。
- 含义：**不需要预设簇数 K** ，带宽 h 直接决定簇尺度；这是**图像分割与目标跟踪**中最经典的均值漂移应用。

(5) HDBSCAN (层次密度聚类)

解决 DBSCAN “单一密度阈值” 的局限：

1. 用**互达距离** $d_{\text{mreach}}(a, b) = \max(\text{core}_k(a), \text{core}_k(b), d(a, b))$ 建图；
2. 构建**最小生成树**，再做**层次聚类**，得到簇的层次结构；
3. 用**簇稳定性**选最优层：

$$\text{Stability}(C) = \sum_{x \in C} \left(\frac{1}{\lambda_x^{\min}} - \frac{1}{\lambda_C^{\text{birth}}} \right), \quad \lambda = 1/d$$

其中：

- λ ：逆距离（密度度量）， λ 越大越密。
- λ_C^{birth} ：簇 C 诞生的密度（从什么密度开始追踪到该簇）。
- $\lambda_x^{\min}$ ：点 x 离开该簇时的密度。
- 含义：自动选出生命周期最长的簇（最稳定的层次），因此 HDBSCAN 几乎不需要调参，且能处理多密度簇。
- OPTICS 与 HDBSCAN 的关系：后者相当于“自动切好”的 OPTICS。

4.1.8 模型式、图论式与其他变体

(1) 自组织映射 (SOM, Self-Organizing Map)

把神经元排在低维网格上，用竞争学习 + 邻域合作保持拓扑：

$$w_i(t+1) = w_i(t) + \eta(t) h_{c,i}(t) (x - w_i(t)), \quad h_{c,i}(t) = \exp\left(-\frac{\|r_i - r_c\|^2}{2\sigma(t)^2}\right)$$

其中：

- c ：获胜神经元（权重与 x 最近）， $c = \arg \min_i \|x - w_i\|$ 。
- $h_{c,i}$ ：邻域函数，获胜元附近的神经元也一起更新（拓扑保持的关键）。
- r_i, r_c ：神经元在网格上的坐标。
- $\eta(t), \sigma(t)$ ：学习率与邻域半径，随时间递减以收敛。
- 含义：SOM 同时做聚类与降维（降维到网格），适合高维可视化。

(2) 谱聚类的两种割准则与求解

把数据看成图 $G = (V, E)$ ，顶点是样本，边权是相似度 W_{ij} 。划分的目标是让“跨簇边的权重之和尽量小”：

$$\text{cut}(A, B) = \sum_{i \in A, j \in B} W_{ij}$$

准则	定义	特点
MinCut	$\text{cut}(A, B)$	易切出孤立点
RatioCut	$\frac{\text{cut}(A, B)}{ A } + \frac{\text{cut}(A, B)}{ B }$	按顶点数归一
Ncut	$\frac{\text{cut}(A, B)}{\text{vol}(A)} + \frac{\text{cut}(A, B)}{\text{vol}(B)}$	按度归一（最常用）

其中 $\text{vol}(A) = \sum_{i \in A} D_{ii}$ 是集合 A 的度之和。

Ncut / RatioCut 的松弛形式分别对应两个拉普拉斯矩阵的 Rayleigh 商：

$$L = D - W \Rightarrow \text{RatioCut}, \quad L_{\text{sym}} = I - D^{-1/2} W D^{-1/2} \Rightarrow \text{Ncut}$$

其中：

- $D = \text{diag}(d_i)$, $d_i = \sum_j W_{ij}$: 度矩阵。
- L : 未归一化拉普拉斯; L_{sym} : 对称归一化拉普拉斯。
- 两者最小特征值均为 0, 对应的特征向量是常量向量 (无用); 取第二小的 K 个特征向量 (Ncut 用 L_{sym} 的, RatioCut 用 L 的) 拼成 $N \times K$ 矩阵, 把它当新特征跑 K-means 即得结果。
- 含义: 拉普拉斯特征向量 = 最优松弛割, 这就是谱聚类能发现非线性形状簇的数学根源。
- 常用相似度: $W_{ij} = \exp(-\|x_i - x_j\|^2 / (2\sigma^2))$, σ 是 “尺度”, 常用 local scaling: $W_{ij} = \exp(-\|x_i - x_j\|^2 / (\sigma_i \sigma_j))$ 。

(3) Affinity Propagation (AP, 近邻传播)

把每个点都视为候选代表点, 通过双向消息传递选出代表点 (exemplar) :

$$r(i, k) \leftarrow s(i, k) - \max_{k' \neq k} [a(i, k') + s(i, k')]$$
$$a(i, k) \leftarrow \min \left\{ 0, r(k, k) + \sum_{i' \notin \{i, k\}} \max(0, r(i', k)) \right\}, \quad a(k, k) \leftarrow \sum_{i' \neq k} \max(0, r(i', k))$$

其中：

- $s(i, k)$: 点 i 选 k 为示例的相似度 (常取负平方距离); 对角元 $s(k, k)$ 叫偏好值, 越大越倾向自成一类。
- $r(i, k)$: 责任度 (responsibility) —— k 有多适合当 i 的代表。
- $a(i, k)$: 可用度 (availability) —— i 有多支持选 k 作代表。
- 判决: k 为示例 $\iff r(k, k) + a(k, k) > 0$ 。
- 含义: 不需要预设簇数 (由偏好值自动决定), 代价是 $O(N^2)$ 内存。

(4) 模糊 C 均值 (FCM)

隶属度不再是 0/1, 而是 $[0, 1]$ 连续值:

$$\min_{\{u_{ik}\}, \{c_k\}} J_m = \sum_{i=1}^N \sum_{k=1}^K u_{ik}^m \|x_i - c_k\|^2, \quad \sum_{k=1}^K u_{ik} = 1$$

交替更新 (坐标下降) :

$$u_{ik} = \frac{1}{\sum_{j=1}^K \left(\frac{\|x_i - c_k\|}{\|x_i - c_j\|} \right)^{\frac{2}{m-1}}}, \quad c_k = \frac{\sum_{i=1}^N u_{ik}^m x_i}{\sum_{i=1}^N u_{ik}^m}$$

其中：

- $m > 1$: **模糊指数** (模糊程度), $m \rightarrow 1$ 退化为硬 K-means, 常用 $m = 2$ 。
- u_{ik} : 点 i 对簇 k 的**隶属度**。
- c_k : 簇中心, 是**加权均值** (权重 u_{ik}^m)。
- 含义: J_m 关于 u 和 c 分别求导可得闭式解, 是**交替优化的经典案例**。

(5) 子空间聚类 (CLIQUE、PROCLUS)

高维下不同簇可能只存在于**不同的特征子集**上：

- **CLIQUE (网格法)**：把每维划成网格，**密度超过阈值**的网格单元视为稠密；用 Apriori 式的“**向下封闭**”性质提升维：

若单元在 k 维上稠密，则它在所有 $k - 1$ 维子空间上的投影也稠密

- 优点：自动确定子空间与簇数；适合**高维、带噪声数据**。
- **PROCLUS**：先随机选 medoid、用**贪婪法**给每个簇选维度、再迭代改进。
- 两者与**矩阵分解类方法** (子空间聚类 SSC、LRR) 思路互相补充。

4.1.9 聚类评价指标

无标签时无法用精度度量，“好坏”需用**内部 / 外部 / 稳定性**三类指标。

(1) 内部指标 (只看数据与划分，不看标签)

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}, \quad SC = \frac{1}{N} \sum_{i=1}^N s(i)$$

其中：

- $a(i)$: 点 i 到**同簇其他点的平均距离** (凝聚度)。
- $b(i)$: 点 i 到**最近其他簇内点的平均距离** (分离度)。
- $s(i) \in [-1, 1]$: **轮廓系数**, 越接近 1 越好 (负数表示可能分错簇)。

指标	公式	越小 / 越大好
轮廓系数 SC	$\frac{1}{N} \sum_i s(i)$	越大越好
CH 指数	$\frac{\text{tr}(B)/(K-1)}{\text{tr}(W)/(N-K)}$	越大越好
DB 指数	$\frac{1}{K} \sum_k \max_{j \neq k} \frac{\sigma_k + \sigma_j}{d(c_k, c_j)}$	越小越好
Dunn 指数	$\frac{\min_{i \neq j} d(C_i, C_j)}{\max_k \text{diam}(C_k)}$	越大越好
SSE / 肘部	$\sum_k \sum_{x \in C_k} \ x - \mu_k\ ^2$	越小越好

其中 B 是簇间散度矩阵、 W 是簇内散度矩阵； σ_k 是簇 k 的平均内部距离； diam 是簇的直径。注意 SSE 会随 K 单调下降，故只看拐点（肘部）。

(2) 外部指标（有真标签时）

$$\text{ARI} = \frac{\text{RI} - \mathbb{E}[\text{RI}]}{\max(\text{RI}) - \mathbb{E}[\text{RI}]}, \quad \text{RI} = \frac{a + b}{\binom{N}{2}}$$

$$\text{NMI} = \frac{I(U; V)}{\sqrt{H(U) H(V)}}$$

其中：

- a ：在划分与真标签中**都是同簇**的点对数； b ：**都不是同簇**的点对数。
- $\mathbb{E}[\text{RI}]$ ：随机划分下 RI 的期望（由组合数算得），故 **ARI 在随机猜测时为 0，完全一致时为 1**——这是比 RI 好得多的性质。
- $I(U; V)$ ：划分 U 与真标签 V 的**互信息**。
- $H(\cdot)$ ：**信息熵**；归一化使 $\text{NMI} \in [0, 1]$ 。
- 另有 **Purity、F-measure、V-measure、调整互信息（AMI）**。
- 含义：ARI 与 AMI 都做了“**随机基线校正**”，是聚类评测中最常用的两个。

(3) 稳定性指标

对数据做扰动（抽样 / 加噪）后重新聚类，比较两次划分的一致性（如 ARI），一致性高则 Cluster 更可靠。**Consensus Clustering** 就是在此基础上的集成聚类。

4.1.10 应用方向

(1) 图像 / 视觉

- **图像分割**：像素聚类成区域（颜色/位置特征）。

- **视觉词袋 (BoW)**：对局部描述子聚类得到"视觉单词"。
- **图像检索与组织**：按内容聚类相册。
- **超像素**：SLIC 用 K-means 在颜色+空间上聚类。

(2) 文本与自然语言

- **主题发现**：文档聚类成新闻专题 / 话题。
- **语料探索与去重**：相似文档归为同簇。
- **搜索日志分析**：查询意图自动分组。

(3) 用户、推荐与营销

- **客户分群**：RFM 特征聚类做市场细分。
- **推荐系统**：物品 / 用户向量聚类做召回与多样性。
- **用户行为分群**：会话、点击流聚类。

(4) 生物、医学与基因

- **基因表达聚类**：共表达基因模块发现。
- **单细胞测序**：细胞类型自动划分 (Leiden/Louvain) 。
- **病历 / 患者分型**：疾病亚型发现。

(5) 金融、工业与网络

- **异常与欺诈检测**：小簇、离群簇作为可疑对象。
- **工业质控**：产品缺陷模式分组。
- **社交 / 网络分析**：社区发现、网络安全事件分组。
- **天文与物理**：星系、粒子轨迹分类。

4.1.11 与深度学习的联系

- **深度聚类**：用网络学嵌入再聚类 (DEC、IDEC、DeepCluster) 。
 - **自监督学习**：聚类伪标签作为预训练目标 (DeepCluster、SwAV) 。
 - **对比学习**：正负样本对构造与聚类思想相通。
 - **谱聚类 ↔ 图神经网络**：拉普拉斯矩阵的特征分解与 GNN 的消息传递共享同一数学基础。
 - **AP / FCM 的可微化**：把隶属度矩阵当成可学习参数 (软分配) 即可嵌入神经网络。
-

4.2 K-means 与高斯混合模型 (K-means and Gaussian Mixture Models)

4.2.1 K-means 目标函数

$$J = \sum_{k=1}^K \sum_{i: z_i=k} \|x_i - \mu_k\|^2$$

其中：

- K ：簇数（超参数）。
- x_i ：第 i 个样本。
- $z_i \in \{1, \dots, K\}$ ：样本 i 的簇分配（隐变量）。
- μ_k ：第 k 个簇的质心。
- $\|x_i - \mu_k\|^2$ ：样本到质心的平方距离。
- J ：簇内平方和（WCSS），越小越紧凑。

4.2.2 交替优化（EM 的特例）

分配步：

$$z_i = \arg \min_k \|x_i - \mu_k\|^2$$

更新步：

$$\mu_k = \frac{1}{|C_k|} \sum_{i \in C_k} x_i$$

其中：

- $C_k = \{i : z_i = k\}$ ：分配给簇 k 的样本集合。
- $|C_k|$ ：该簇样本数。
- 含义：先固定质心分配样本，再固定分配更新质心，交替直到收敛。

收敛性：每步都使 J 不增，故必收敛到局部最优（非全局）。

4.2.3 K-means 的局限与改进

- 需预设 K ：用肘部法、轮廓系数、Gap Statistic 选 K 。

- **对初值敏感**：用 K-means++ 初始化。
- **只适合球形簇**：各向异性/非凸簇需 GMM 或谱聚类。
- **对异常值敏感**：改用 K-medoids（用真实样本做中心）。

K-means++ 初始化：第一个中心随机选，之后每个中心以正比于 "到已有中心最近距离的平方" 的概率选取，使初始中心分散。

4.2.4 高斯混合模型 (GMM)

GMM 假设数据由 K 个高斯分布混合生成：

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k)$$

其中：

- π_k ：第 k 个分量的**混合系数**（权重），满足 $\sum_k \pi_k = 1, \pi_k \geq 0$ 。
- μ_k ：第 k 个高斯的**均值向量**。
- Σ_k ：第 k 个高斯的**协方差矩阵**（刻画形状与方向）。
- $\mathcal{N}(x \mid \mu_k, \Sigma_k)$ ：多元高斯密度：

$$\mathcal{N}(x \mid \mu, \Sigma) = \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right)$$

其中：

- D ：维度。
- $|\Sigma|$ ：协方差矩阵的行列式（体积）。
- Σ^{-1} ：精度矩阵。
- $(x - \mu)^\top \Sigma^{-1}(x - \mu)$ ：**马氏距离平方**。

4.2.5 GMM 的 EM 求解

E 步（责任度）：

$$\gamma_{ik} = \frac{\pi_k \mathcal{N}(x_i \mid \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x_i \mid \mu_j, \Sigma_j)}$$

其中：

- γ_{ik} ：样本 i 属于分量 k 的**后验概率**（软分配）。
- 分母：所有分量的加权密度和（归一化）。
- 与 K-means 的硬分配 z_i 对比：GMM 是**软分配**。

M 步（参数更新）：

$$\mu_k = \frac{\sum_i \gamma_{ik} x_i}{\sum_i \gamma_{ik}}, \quad \Sigma_k = \frac{\sum_i \gamma_{ik} (x_i - \mu_k)(x_i - \mu_k)^\top}{\sum_i \gamma_{ik}}, \quad \pi_k = \frac{\sum_i \gamma_{ik}}{N}$$

其中：

- $N_k^{\text{eff}} = \sum_i \gamma_{ik}$ ：分量 k 的**有效样本数**。
- 含义：用责任度加权计算均值、协方差、权重。

K-means 是 GMM 的特例：当所有 $\Sigma_k = \sigma^2 I$ 且 $\sigma \rightarrow 0$ 时，软分配退化为硬分配，GMM 退化为 K-means。

4.2.6 K-means 与 GMM 变体总览

变体	改动点	解决的问题
K-means++	概率化初始化	初值敏感
K-medians	L_1 + 中位数	高维稀疏 / 高鲁棒
K-medoids / PAM	真实点作中心	任意距离、离群点
Mini-batch K-means	小批量更新	大数据流式训练
二分 K-means	逐步二分	避免局部最优
球形 K-means	单位化 + 余弦	方向型数据（文本）
核 K-means	核空间	非线性可分簇
稀疏 K-means	加 L_1 约束	可解释中心 / 特征选择
X-means	分裂 + BIC	自动定 K
模糊 C 均值	软隶属度	边界模糊的簇
GMM	概率生成模型	椭球形簇
变分贝叶斯 GMM	参数先验	自动定 K
DPMM	非参贝叶斯	簇数不确定
t 分布混合	重尾成分	强离群点
半监督 GMM	部分标签	少标签下的聚类

4.2.7 初始化与加速变体

(1) K-means++ 初始化 (形式化)

1. 第一个中心 c_1 从数据中**均匀随机**选取;
2. 计算每个点 x 到已有最近中心的距离平方 $D(x)^2$;
3. 以如下的**概率**选取下一个中心:

$$p(x) = \frac{D(x)^2}{\sum_{x' \in \mathcal{D}} D(x')^2}$$

其中:

- $D(x) = \min_{c \in \mathcal{C}} \|x - c\|$: 到已有中心集 $\mathcal{C}$ 的**最近距离**。
- 含义: 距离远的点被选中的概率大, 从而实现 “**远者优先、不堆在一起**” 。
- 理论保证: K-means++ 的期望目标值满足 $\mathbb{E}[J] \leq 8(\ln K + 2) J_{\text{opt}}$ ($O(\log K)$ 近似比) 。

(2) Mini-batch K-means

每步只取一个小批量 $\mathcal{B}$, 用**增量均值**更新被命中簇的中心:

$$c_k \leftarrow c_k + \frac{1}{n_k} (\bar{x}_{\mathcal{B} \cap C_k} - c_k)$$

其中:

- n_k : 簇 k 累计命中的样本数。
- $\bar{x}_{\mathcal{B} \cap C_k}$: 小批量中属于簇 k 的样本均值。
- 含义: 等价于用**随机近似**估计簇均值, 每步代价由 $O(NK)$ 降到 $O(|\mathcal{B}|K)$, 可在**十亿级样本**上训练。

(3) 二分 K-means (Bisecting K-means) 与 X-means

- **二分 K-means**: 从一个大簇开始, 反复选择“**SSE 最大**”的簇用 $K = 2$ 再分, 直到得到 K 个。因为每次只做 $K = 2$, **局部最优风险小**, 且可用树结构输出层次。
- **X-means**: 在每次二分后, 用 **BIC 判断子簇是否真的存在** (若两子簇的 BIC 优于单簇则不分裂), 从而**自动确定** K 。

(4) 加速技巧: Elkan 三角形不等式

利用三角不等式 $d(x, c_k) \geq d(x, c_{k'}) - d(c_{k'}, c_k) \geq \frac{1}{2}d(c_{k'}, c_k)$ 提前排除不可能获胜的中心, 再加上**上下界缓存**, 可把每次迭代的 $O(NKD)$ 降到接近 $O(ND)$, 加速 10~100 倍。

4.2.8 距离与形状变体

(1) K-medians (中位数中心)

$$\min_{\{C_k\}} \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - c_k\|_1, \quad c_k = \text{med}(C_k)$$

其中：

- $\|\cdot\|_1$: L_1 范数 (曼哈顿距离)。
- c_k : 逐维**中位数** (使 L_1 之和最小, 而均值是最小 L_2 和的解)。
- 含义: 对**离群点与稀疏数据**更鲁棒; 在高维稀疏文本上表现常优于 K-means。

(2) 核 K-means (Kernel K-means)

在核空间做 K-means, 目标转为**只依赖核函数**的形式:

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} \|\varphi(x_i) - m_k\|^2 = \sum_{i=1}^N K(x_i, x_i) - \sum_{k=1}^K \frac{1}{|C_k|} \sum_{x_i, x_j \in C_k} K(x_i, x_j)$$

其中：

- $\varphi(\cdot)$: **隐式特征映射**; $m_k = \frac{1}{|C_k|} \sum_{i \in C_k} \varphi(x_i)$: 核空间中心。
- $K(x_i, x_j) = \langle \varphi(x_i), \varphi(x_j) \rangle$: **核函数** (无需显式算 φ)。
- 分配规则: 把每个点分到**核空间中最近**的中心: $k^* = \arg \min_k [K(x_i, x_i) - \frac{2}{|C_k|} \sum_{j \in C_k} K(x_i, x_j)]$ 。
- 含义: **无需知道中心坐标**, 只要有 Gram 矩阵就能算; 可发现非线性形状簇, 与谱聚类有深刻联系。

(3) 球形 K-means (Spherical K-means)

先把样本 $\tilde{x} = x/\|x\|$ 归一化到单位球, 目标改为**最大化余弦相似度**:

$$\max_{\{\tilde{C}_k\}} \sum_{k=1}^K \sum_{x_i \in C_k} \tilde{x}_i^\top \tilde{c}_k, \quad \tilde{c}_k = \frac{\sum_{i \in C_k} \tilde{x}_i}{\|\sum_{i \in C_k} \tilde{x}_i\|}$$

其中：

- $\tilde{x}_i$: **单位化**后的样本 (只保留方向)。
- $\tilde{c}_k$: 归一化后的中心 (也落在单位球上)。
- 等价变换: $\|\tilde{x}_i - \tilde{c}_k\|^2 = 2 - 2\tilde{x}_i^\top \tilde{c}_k$, 故"最大化余弦"与"最小化欧氏距离"等价。
- 含义: 适合**方向而非模长**重要的数据 (TF-IDF 文本向量、词向量), 是文本聚类标配。

(4) 稀疏 K-means (Sparse K-means)

加入 L_1 约束以获得可解释的中心：

$$\min_{\{C_k\}, \{c_k\}} \sum_k \sum_{i \in C_k} \|x_i - c_k\|^2 \quad \text{s.t.} \quad \|c_k\|_1 \leq s, \|c_k\|_2 \leq 1$$

其中 s 控制**中心的稀疏程度**；中心只有少数维度非零， 可用来做**簇层面的特征选择**（哪些基因 / 词定义了该簇）。

4.2.9 GMM 的协方差结构变体

GMM 的表达力与**每个分量能取什么形状**直接相关：

类型	约束	参数数	簇形状
全协方差 (full)	每个分量各自一个 Σ_k	$K \frac{D(D+1)}{2}$	任意椭圆
绑定 (tied)	所有分量共享 Σ	$\frac{D(D+1)}{2}$	同形状椭圆
对角 (diag)	Σ_k 为对角	KD	轴对齐椭圆
球面 (spherical)	$\Sigma_k = \sigma_k^2 I$	K	球

其中：

- **全协方差**：表达力最强，但 D 大时参数爆炸且易过拟合（需大量样本）。
- **绑定**：样本少但簇形状相同时非常有效（**ASR 中的 GMM-HMM 常用**）。
- **对角 / 球面**：参数少、计算快，适合高维（先做 PCA 降维后常用对角）。
- 与 K-means 的关系：**球面 + 所有 σ_k 相等 + $\sigma \rightarrow 0$ 就是 K-means**。
- 参数估计要点：需保证 Σ_k **正定**，否则似然无界；实践中加 $\Sigma_k \leftarrow \Sigma_k + \varepsilon I$ (**对角加载**) 或设下界 $\sigma_{\min}^2$ 。

4.2.10 GMM 的扩展：变分贝叶斯、DPMM、 t 分布与半监督

(1) 变分贝叶斯 GMM (VB-GMM, 自动定 K)

给参数加**共轭先验**（Dirichlet 先验于 π ，Normal-Wishart 于 (μ_k, Σ_k) ）， 然后对后验做**因子分解近似**：

$$q(\pi, \{\mu_k, \Sigma_k\}, \{z_i\}) = q(\pi) \prod_{k=1}^K q(\mu_k, \Sigma_k) \prod_{i=1}^N q(z_i), \quad \ln q^*(\theta) \propto \mathbb{E}_{q(\text{其他})} [\ln p(\mathcal{D}, \theta)]$$

其中：

- K ：设一个**上界**（如 20）， 允许比真实簇数更大。

- Dirichlet 先验的作用：某个分量**长期没有样本**时，其后验权重的期望会**自动趋近 0**，该分量被**"剪掉"**。
- 含意：不需要交叉验证选 K ——让模型**自动决定有多少个簇**。
- 另一条路：**DPMM (Dirichlet Process Mixture Model)**，用

$$G \sim \text{DP}(\alpha, G_0), \quad x_i \sim G$$

其中 α 是**集中度参数**（越大分量越多）， G_0 是**基分布**；其对应的预测分布是中餐馆过程（CRP）：

$$P(\text{新分量}) = \frac{\alpha}{\alpha + N - 1}, \quad P(\text{已有分量 } k) = \frac{N_k}{\alpha + N - 1}$$

含义：**非参数贝叶斯**——分量数随数据自动增长（抽样时用 Gibbs 或截断变分近似）。

(2) t 分布混合 (Robust GMM)

高斯是**轻尾**分布，一个极端离群点会把一个分量整个拉走。换成重尾的 **Student- t** ：

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{T}_\nu(x \mid \mu_k, \Sigma_k), \quad \mathcal{T}_\nu \propto \left[1 + \frac{(x - \mu)^\top \Sigma^{-1} (x - \mu)}{\nu} \right]^{-\frac{\nu+D}{2}}$$

其中：

- ν ：**自由度**， $\nu \rightarrow \infty$ 退化为高斯； ν 小则尾巴越重。
- 等价写法： t 分布可看作“高斯 + Gamma 先验的**尺度混合**”，引入隐变量 $u_i \sim \text{Gamma}(\nu/2, \nu/2)$ 后仍是 EM 可解的。
- 含义：**自动降低离群点的责任感**（其 u_i 小），大幅提升鲁棒性。

(3) 半监督 GMM (Semi-Supervised GMM)

若部分样本有标签，只需在 E 步**固定已知样本的责任度**：

$$\gamma_{ik} = \begin{cases} 1, & y_i = k \text{ (已知标签)} \\ \frac{\pi_k \mathcal{N}(x_i \mid \mu_k, \Sigma_k)}{\sum_j \pi_j \mathcal{N}(x_i \mid \mu_j, \Sigma_j)}, & \text{未知} \end{cases}$$

其中 y_i 是样本 i 的**已知类别**；M 步公式完全不变。含义：这就是 **EM 处理缺失数据**的自然推广，见 4.5 半监督学习。

(4) 其他扩展

- **约束 GMM**：给 μ_k 加先验 / 约束（如要求某些分量均值已知）。
- **共享 / 异方差 GMM**：声学模型中把说话人差异建模为多个协方差。
- **GMM + 因子分析 (FA)**：先降维再混合，用于高维数据 (MFA)。

4.2.11 求解算法与模型选择

(1) 求解路线

方法	思路	优点
标准 EM	交替 E/M 步	单调增似然，简单
变分 EM	交替最优变分分布	有先验、免过拟合
随机 EM / 在线 EM	每次用部分数据	大数据流式
ECM / ECME	只优化部分参数	高维时加速
梯度 / 牛顿法	直接最大化似然	可与约束混用
岭回归式正则 EM	参数加惩罚	奇异性 / 退化解

(2) 模型选择: BIC / AIC / ICL

$$\text{BIC} = -2 \ln \hat{L} + p \ln N, \quad \text{AIC} = -2 \ln \hat{L} + 2p, \quad \text{ICL} = \text{BIC} - 2 \sum_i \sum_k \gamma_{ik} \ln \gamma_{ik}$$

其中:

- $\hat{L}$: 最大化的似然值; p : 模型自由参数个数。
- BIC 的惩罚 $p \ln N$ 比 AIC 的 $2p$ 更重, 倾向更简单的模型 (一致估计)。
- $-2 \sum_i \sum_k \gamma_{ik} \ln \gamma_{ik}$: 分类熵项 (entropy of the partition), 当责任度模糊 ($\gamma \approx 1/K$) 时该值大, 惩罚 “不确定的归类”。
- ICL 比 BIC 更适合聚类, 因为它直接衡量 “分类是否确定”。

(3) LBG 算法 (矢量量化的分裂法)

在颜色量化 / 码本设计中, K 常用 2 的幂且需层次构造:

1. 先求全局均值作唯一的码字: $c_1 = \frac{1}{N} \sum_i x_i$;
2. 分裂: $c_{2k} = c_k(1 + \varepsilon), c_{2k+1} = c_k(1 - \varepsilon)$ (ε 是小扰动) ;
3. 以新码字为初值跑 K-means (广义 Lloyd 迭代) 至收敛;
4. 重复 2-3 直到码本大小 K 。

含义: 因为每步只从 K 增到 $2K$, 且初始中心离得近, 所以收敛稳定、质量优于直接 K-means; 这就是 GIF 调色板、语音编码的经典做法。

4.2.12 应用方向

(1) 图像 / 视觉

- **颜色量化**: K-means 把图像颜色压缩到 K 种 (GIF 调色板)。
- **图像分割**: GMM 对颜色/纹理建模, 做像素聚类。
- **背景建模**: GMM 对每个像素的颜色随时间建模, 检测运动目标 (MOG)。
- **视觉词袋**: K-means 生成视觉词典。
- **矢量量化 / 码本**: 特征编码与压缩。

(2) 客户分群与市场细分

- **客户价值分层**: RFM、消费行为分群。
- **零售选址与品类分析**: 门店 / 商品按销售模式聚类。

(3) 语音与音频

- **GMM-HMM 声学模型**: 语音识别经典框架 (深度之前的标配)。
- **说话人识别**: 高斯混合做声纹建模。
- **音频事件分类**: 对音频特征建模。

(4) 生物、医学与基因

- **基因表达聚类**: 共表达模块挖掘。
- **医学影像分型**: 组织 / 病灶的混合建模。
- **流式细胞与单细胞**: 细胞群自动划分。

(5) 金融、工业与网络

- **异常检测**: 低概率密度区域作为异常 (GMM 密度估计)。
- **金融状态识别**: 市场行情分状态 (牛市 / 震荡 / 熊市)。
- **工业过程监测**: 多工况识别与故障诊断。
- **网络流量分析**: 流量模式分群。

4.2.13 与深度学习的联系

- **VQ-VAE**: 用离散码本 (等价于 K-means 的质心) 做深度量化。
- **MoE (混合专家)**: GMM 的 "软分配" 思想用于门控网络。
- **EM 是深度生成模型 (VAE) 变分推断的雏形**。
- **VB-GMM $\leftrightarrow$ 层次化 VAE / DPVAE**: 变分贝叶斯自动定簇数的思想被用于无监督表征学习。

- **在线 / Mini-batch 聚类** ↔ **动量更新**：动编码器（momentum encoder）与 Mini-batch K-means 共用“慢速均值”思路。
 - **LBG 的分裂法** ↔ **渐进式增长（Progressive Growing）** 与层次化码本设计。
-

4.3 主成分分析（Principal Component Analysis, PCA）

4.3.1 核心思想

PCA 找一组**正交方向**，使数据投影后方差最大，用少数方向表示高维数据，实现**降维**。

4.3.2 数学推导

数据中心化：

$$\tilde{x}_i = x_i - \bar{x}, \quad \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

其中：

- x_i ：第 i 个样本（ D 维）。
- $\bar{x}$ ：样本均值向量。
- $\tilde{x}_i$ ：中心化后的样本。

协方差矩阵：

$$\Sigma = \frac{1}{N} \sum_{i=1}^N \tilde{x}_i \tilde{x}_i^\top = \frac{1}{N} \tilde{X}^\top \tilde{X}$$

其中：

- $\Sigma \in \mathbb{R}^{D \times D}$ ：**协方差矩阵**，对角元是各维方差，非对角元是维间协方差。
- $\tilde{X} \in \mathbb{R}^{N \times D}$ ：中心化数据矩阵（每行一个样本）。
- 含义：刻画各维的波动与相关性。

特征分解：

$$\Sigma u_j = \lambda_j u_j, \quad \lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_D \geq 0$$

其中：

- u_j ：第 j 个**特征向量**（主成分方向），单位向量且互相正交。
- λ_j ：第 j 个**特征值**，等于数据在该方向上的**方差**。
- 含义：特征值越大，该方向越"重要"。

投影降维：取前 K 个特征向量组成 $U_K = [u_1, \dots, u_K]$ ：

$$y_i = U_K^\top \tilde{x}_i \in \mathbb{R}^K$$

其中：

- $U_K \in \mathbb{R}^{D \times K}$ ：投影矩阵。
- y_i ：降维后的**主成分得分**（ K 维）。
- 含义：把 D 维数据压到 K 维，保留最大方差。

重构：

$$\hat{x}_i = U_K y_i + \bar{x}$$

其中 $\hat{x}_i$ 是重构样本；重构误差 = 被丢弃方向上的方差之和。

4.3.3 方差解释率

$$\text{EVR}(K) = \frac{\sum_{j=1}^K \lambda_j}{\sum_{j=1}^D \lambda_j}$$

其中：

- $\text{EVR}(K)$ ：前 K 个主成分解释的**方差比例**。
- 常取 $\text{EVR} \geq 0.95$ 确定 K 。

4.3.4 与 SVD 的关系

对中心化矩阵做 SVD： $\tilde{X} = USV^\top$ ，则：

- 主成分方向 = V 的列（右奇异向量）。
- 特征值 $\lambda_j = s_j^2 / N$ （ s_j 是奇异值）。
- 得分 = US 。

SVD 更数值稳定，实践中常用 SVD 实现 PCA。

4.3.5 降维方法族总览

降维要回答两个问题：**保留什么性质**（方差 / 距离 / 邻近关系 / 判别性）与**是否允许非线性**。

方法	保留目标	线性?	有监督?	输出
PCA	方差最大	线性	无	正交基
Kernel PCA	核空间方差	非线性	无	核系数
Sparse PCA	方差 + 稀疏	线性	无	稀疏载荷
Robust PCA	低秩 + 稀疏分离	线性	无	L, S
PPCA	生成概率模型	线性	无	W, σ^2
ICA	统计独立	线性	无	独立分量
因子分析	共享潜因子	线性	无	Λ, Ψ
LDA (Fisher)	类间 / 类内比	线性	有	判别方向
CCA	两组变量相关	线性	无	成对方向
NMF	平方误差 + 非负	线性	无	非负基
MDS	距离保留	线性 / 非线性	无	嵌入坐标
Isomap / LLE	邻域几何	非线性	无	嵌入坐标
t-SNE / UMAP	邻域概率	非线性	无	可视化嵌入
自编码器 / VAE	重构误差	非线性	无	网络参数

4.3.6 PCA 的变体

(1) 核 PCA (Kernel PCA)

在核空间做 PCA。先中心化核矩阵：

$$\tilde{K} = K - \mathbf{1}_N K - K \mathbf{1}_N + \mathbf{1}_N K \mathbf{1}_N, \quad \mathbf{1}_N = \frac{1}{N} \mathbf{1} \mathbf{1}^\top$$

其中：

- $K_{ij} = K(x_i, x_j)$: **Gram 矩阵** (核函数值)。
- $\mathbf{1}_N$: **中心化矩阵** (每行每列减均值的效果)。
- 含义：核空间的"均值"无法显式计算，故用上式把核矩阵**等价地中心化**。

再对 $\tilde{K}$ 做特征分解 $\tilde{K} \alpha_k = \lambda_k \alpha_k$ ，得到**投影**：

$$t_k(x) = \sum_{i=1}^N \alpha_i^{(k)} K(x_i, x)$$

其中 $\alpha^{(k)}$ 是第 k 个特征向量（需归一化为 $\|\alpha^{(k)}\| = 1/\sqrt{\lambda_k}$ ）； $t_k(x)$ 是新样本在核主成分 k 上的坐标。 - 含义：**不需要显式特征映射**，只靠核函数就能得到**非线性主成分**。 - 与核 K-means / 谱聚类关系：三者都是核方法在无监督场景的分支。

(2) 稀疏 PCA (Sparse PCA)

主成分通常是**所有原始特征的密度组合**，不可解释。稀疏 PCA 加约束：

$$\max_v \|Xv\|^2 \quad \text{s.t.} \quad \|v\|_2 \leq 1, \|v\|_0 \leq k$$

等价惩罚形式（弹性网）：

$$\max_v v^\top \Sigma v - \lambda_1 \|v\|_1 - \frac{\lambda_2}{2} \|v\|^2$$

其中：

- k ：主成分允许使用的**特征个数**（ L_0 约束，非凸）。
- $\|v\|_1$ ： L_1 松弛（凸），使载荷**稀疏化**。
- $\Sigma = \frac{1}{N} X^\top X$ ：样本协方差矩阵。
- 含义：每个主成分只依赖**少数原始变量**，可用于**特征选择与因子命名**。

(3) 鲁棒 PCA (Robust PCA / RPCA)

把观测矩阵分解为**低秩部分** + **稀疏部分**：

$$\min_{L,S} \|L\|_* + \lambda \|S\|_1 \quad \text{s.t.} \quad M = L + S$$

其中：

- $\|L\|_* = \sum_i \sigma_i(L)$ ：**核范数**（奇异值之和），是**秩的凸松弛**。
- $\|S\|_1 = \sum_{ij} |S_{ij}|$ ： L_1 范数，是**稀疏度的凸松弛**。
- $\lambda = 1/\sqrt{\max(m,n)}$ ：常用理论最优值。
- 含义： L = **背景 / 低维结构**， S = **离群点 / 前景 / 遮挡**——**背景建模与去遮挡**的经典工具。
- 求解：**IALM / ADMM**（交替方向乘子法）。

(4) 概率 PCA (PPCA)

PCA 的**生成模型**版本：

$$x = Wz + \mu + \epsilon, \quad z \sim \mathcal{N}(0, I), \quad \epsilon \sim \mathcal{N}(0, \sigma^2 I)$$

其中：

- $z \in \mathbb{R}^k$ ：**低维隐变量**（ $k < D$ ）。
- $W \in \mathbb{R}^{D \times k}$ ：**载荷矩阵**； μ ：均值。

- ϵ : 各向同性噪声。

由此得观测的边缘分布与协方差：

$$p(x) = \mathcal{N}(x \mid \mu, C), \quad C = WW^\top + \sigma^2 I$$

其中：

- 最大似然解与 PCA 直接相关： $W_{\text{ML}} = U_k(\Lambda_k - \sigma^2 I)^{1/2} R$ 。
- U_k : 前 k 个特征向量； Λ_k : 对应特征值对角阵； R : 任意正交旋转。
- $\sigma_{\text{ML}}^2 = \frac{1}{D-k} \sum_{j=k+1}^D \lambda_j$: 丢掉的方差均值。
- 含义：PPCA 给出了 PCA 的概率解释，因此能：
- 处理缺失值（EM 填补）；
- 用 BIC / 边际似然自动选 k ；
- 推广到 混合 PPCA 与非线性（就是后来的变分自编码器）。

(5) 增量与随机化 PCA

- 增量 PCA (IPCA)：把已有 SVD 与新数据块的 SVD 拼接后再奇异值分解，避免重跑全数据：

$$\tilde{X} = [U_k \Sigma_k \quad X_{\text{new}}] \Rightarrow \text{对 } \tilde{X} \text{ 再求 SVD}$$

适合流式 / 大数据（scikit-learn 的 `IncrementalPCA`）。

- 随机化 SVD：用随机投影把大矩阵降到低维再算：

$$Y = X\Omega \rightarrow Q = \text{qr}(Y) \rightarrow B = Q^\top X \rightarrow [U, \Sigma, V] = \text{svd}(B)$$

其中 $\Omega \in \mathbb{R}^{D \times (k+p)}$ 是随机高斯矩阵；准确度概率意义下极高，速度比全 SVD 快一个数量级。

- NIPALS：交替求得分向量与载荷向量的迭代法，可处理缺失值。
- lrn1z / 幂法：只求第一个主成分，目标函数用迭代法上升：

$$v \leftarrow \frac{X^\top(Xv)}{\|X^\top(Xv)\|}$$

(6) 2D-PCA

对图像矩阵不做向量化，而直接对行方向投影：

$$\max_u \text{tr} \left(u^\top \left[\frac{1}{N} \sum_{i=1}^N (A_i - \bar{A})(A_i - \bar{A})^\top \right] u \right), \quad u^\top u = I$$

其中：

- $A_i \in \mathbb{R}^{h \times w}$: 第 i 张图像矩阵； $\bar{A}$: 均值图像。
- $u \in \mathbb{R}^{h \times d}$: 投影方向矩阵（对行采样）。

- 含义：**不把图像拉成 hw 维向量**，避免高维协方差矩阵奇异与巨大内存；降维后特征仍是矩阵（保留二维结构）。

4.3.7 相关但不同的线性降维方法

(1) 独立成分分析 (ICA)

PCA 只要求成分**不相关**，ICA 要求**统计独立**——能分开混合信号：

$$x = As, \quad \hat{s} = Wx, \quad W \approx A^{-1}$$

其中：

- s ：**互独立**的源信号（如多个人说话的声音）。
- A ：未知**混合矩阵**； W ：待求解**混矩阵**。
- 估计准则：**非高斯性最大化**。常用**负熵**近似：

$$J(y) \approx \left[\mathbb{E}(G(y)) - \mathbb{E}(G(\nu)) \right]^2$$

其中 ν 是标准高斯变量， G 是非常数非线性函数（如 $G(u) = \frac{1}{a} \log \cosh(au)$ ）。 - **FastICA** 不动点迭代（需先中心化与白化）：

$$w \leftarrow \mathbb{E}\{x g(w^\top x)\} - \mathbb{E}\{g'(w^\top x)\}w, \quad w \leftarrow w / \|w\|$$

- 含义：**盲源分离**：鸡尾酒会问题、脑电 / 脑磁去伪迹、金融因子分离。
- 与 PCA 的对比：PCA 去相关、ICA 去独立；ICA 常以 PCA 白化作为**预处理**。

(2) 因子分析 (Factor Analysis, FA)

与 PPCA 几乎同形，但噪声协方差是**对角而非各向同性**：

$$x = \Lambda f + \epsilon, \quad f \sim \mathcal{N}(0, I), \quad \epsilon \sim \mathcal{N}(0, \Psi)$$

$$\Sigma = \Lambda \Lambda^\top + \Psi, \quad \Psi = \text{diag}(\psi_1, \dots, \psi_D)$$

其中：

- Λ ：**因子载荷**（每个变量对公因子的依赖）。
- Ψ ：**独特方差**（对角）， ψ_j 是变量 j 独有的噪声。
- 与 PPCA 的关键区别：FA 允许**每个变量噪声不同**，因此参数不可识别性更严重（需旋转约束）。
- 含义：社会科学、心理测量、金融因子模型的理论基础。

(3) 线性判别分析 (LDA / Fisher LDA)

PCA 无监督（最大方差），LDA **有监督**（最大类别可分性）：

$$\max_w \frac{w^\top S_B w}{w^\top S_W w}, \quad S_B = \sum_{c=1}^C n_c (\mu_c - \mu)(\mu_c - \mu)^\top, \quad S_W = \sum_{c=1}^C \sum_{i \in c} (x_i - \mu_c)(x_i - \mu_c)^\top$$

其中：

- S_B ：类间散度矩阵（希望大）； S_W ：类内散度矩阵（希望小）。
- 最优解是广义特征值问题 $S_B w = \lambda S_W w$ ，即 $w \propto S_W^{-1}(\mu_1 - \mu_2)$ （二类）。
- 最多降到 $C - 1$ 维（类数减一）。
- 含义：**降维是为了分类**，而 PCA 降维不关心标签；样本数少时 S_W 奇异，需先 PCA 降维或加正则（正则化 LDA）。

(4) 典型相关分析 (CCA)

找两组变量 X, Y 的**成对线性组合使相关最大**：

$$\max_{u,v} u^\top \Sigma_{xy} v \quad \text{s.t.} \quad u^\top \Sigma_{xx} u = 1, v^\top \Sigma_{yy} v = 1$$

其中：

- Σ_{xy} ： X 与 Y 的**交叉协方差**。
- u, v ：**典型权重**； $u^\top x$ 与 $v^\top y$ 称为一对**典型变量**。
- 解：广义特征值问题，相关系数的平方为相关的**特征值**。
- 含义：跨模态对齐（图-文、声音-图像）、多变量关联分析；**核 CCA / Deep CCA** 是自监督表征学习的重要工具。

(5) 非负矩阵分解 (NMF)

$$\min_{W, H \geq 0} \|X - WH\|_F^2$$

乘法更新规则（Lee & Seung）：

$$H \leftarrow H \odot \frac{W^\top X}{W^\top W H}, \quad W \leftarrow W \odot \frac{X H^\top}{W H H^\top}$$

其中：

- $W \in \mathbb{R}^{D \times k}$ ：**基矩阵**； $H \in \mathbb{R}^{k \times N}$ ：**系数矩阵**。
- $\odot$ ：**逐元素乘法**；除法也是逐元素。
- 非负约束：使分解结果**只有加法组合、不互相抵消**，因此天然可解释（**部件式表征**）。
- 含义：主题模型（PLSA 与 NMF 等价）、化学光谱分峰、图像部件分解。

4.3.8 PCA 求解算法对比

方法	原理	适用
协方差特征分解	$\Sigma = \frac{1}{N} X^T X$ 后 eig	小 D
SVD 直接分解	$X = U \Sigma V^T$	数值最稳定
幂迭代	反复 $X^T X v$	只要前几个主成分
NIPALS	交替回归	含缺失值
随机化 SVD	随机投影 + QR	大矩阵
增量 SVD	分块拼接	流式数据
PPCA 的 EM	迭代求期望	缺失值 + 自动选 k
ADMM / IALM	稀疏 + 低秩优化	RPCA

关键数值事实：直接对 X 做 SVD 优于先算 Σ 再特征分解，因为后者会把条件数平方 ($\kappa(\Sigma) = \kappa(X)^2$)，放大精度损失。

4.3.9 应用方向

(1) 图像 / 视觉

- **特征脸 (Eigenfaces)：**人脸图像 PCA 降维，前几个主成分是"脸的基本模式"。
- **图像压缩：**保留前 K 个主成分重构图像。
- **去噪：**丢弃小方差方向（多为噪声）。
- **描述子降维：**SIFT 128 维 $\rightarrow$ PCA 降到 20~64 维，加速匹配。
- **白化：**PCA 后各维除以 $\sqrt{\lambda_j}$ ，使各维等方差。

(2) 数据预处理与特征工程

- **降维与去相关：**高维表格数据的基础预处理。
- **降噪与压缩：**小方差方向中常含噪声。
- **特征去共线性：**回归 / 线性模型前处理。
- **白化：**使各维等方差，便于后续建模。

(3) 金融与量化

- **收益率因子提取：**债券 / 股票曲线的水平-斜度-曲度因子 (Level-Slope-Curvature) 。
- **风险因子正交化：**去相关后的风险暴露。

- **统计套利**：主成分残差信号。

(4) 生物、医学与化学

- **基因表达降维**：上万基因压到几十维再聚类。
- **光谱 / 质谱分析**：近红外、拉曼、质谱的降维与病变识别。
- **化学计量学**：多元校准与异常样本检测。

(5) 传感、信号与语音

- **振动信号监测**：设备状态特征提取。
- **脑电 / 心电降维**：伪迹去除与特征压缩。
- **语音特征压缩**：声学特征降维。

(6) 作为通用工具

- **探索性分析**：主成分散点图看数据结构。
- **低秩近似**：矩阵补全、推荐系统（矩阵分解的线性版本）。
- **异常检测**：重构误差大的样本为异常。

4.3.10 与深度学习的联系

- **PCA = 线性自编码器**：单层线性 AE 的最优解就是 PCA 子空间。
- **白化**是深度网络输入预处理的常用手段。
- **注意力/低秩分解**：PCA 的低秩思想用于网络压缩（SVD 分解权重）。
- **对比**：PCA 是线性无监督降维，自编码器是非线性版本。
- **VAE**：把 PPCA 的隐变量推向非线性（用网络参数化 $p(x|z)$ ），其 ELBO 在线性高斯下退化为 PPCA。
- **自监督中的 CCA / Deep CCA**：BYOL、SimSiam 的"避免坍塌"与 CCA 的改进目标同源。
- **LoRA / 低秩适配**：把大模型的权重增量约束为低秩，本质上是 **RPCA / 低秩近似**的应用。
- **鲁棒性与离群点**：RPCA 的"低秩 + 稀疏"分解思想被用于深度异常检测与去雨 / 去反射。

4.4 流形学习 (Manifold Learning)

4.4.1 核心假设

流形假设：高维数据实际上分布在一个**低维流形**上（局部像欧氏空间）。流形学习的目标是**恢复这个低维结构**，做**非线性降维**。

形式化：存在映射

$$\phi: \mathcal{M} \subset \mathbb{R}^d \rightarrow \mathbb{R}^D, \quad D \gg d$$

其中：

- $\mathcal{M}$ ：低维流形（内在维度 d ）。
- D ：观测空间维度。
- ϕ ：嵌入映射（把低维坐标映到高维观测）。
- 目标：找逆映射 ϕ^{-1} ，即从高维数据恢复低维坐标。

4.4.2 代表方法

(1) LLE (局部线性嵌入)

假设每个点可由其近邻**线性重构**，且重构权重在低维保持：

$$\min_W \sum_i \left\| x_i - \sum_{j \in \mathcal{N}(i)} W_{ij} x_j \right\|^2, \quad \sum_j W_{ij} = 1$$

其中：

- W_{ij} ：样本 j 对重构 i 的**权重**。
- $\mathcal{N}(i)$ ： i 的近邻集合。
- 约束 $\sum_j W_{ij} = 1$ ：权重归一化（平移不变）。

再固定 W ，求低维坐标 y_i ：

$$\min_Y \sum_i \left\| y_i - \sum_j W_{ij} y_j \right\|^2, \quad Y^\top Y = I$$

其中：

- $Y \in \mathbb{R}^{N \times d}$ ：低维嵌入坐标。
- $Y^\top Y = I$ ：约束防止退化解（尺度/旋转不定）。
- 解为矩阵 $(I - W)^\top (I - W)$ 的最小 d 个特征向量。

(2) Isomap

用**测地距离**（图上最短路径）替代欧氏距离，再做 MDS：

$$d_{\text{geo}}(i, j) = \min_{\text{path}} \sum \|x_a - x_b\|$$

其中 d_{geo} 是流形上的**测地距离**，通过近邻图的最短路径近似。

(3) t-SNE

把高维相似度转成概率，低维也转成概率，最小化两者 KL 散度：

$$KL(P||Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}$$

其中：

- p_{ij} ：高维空间中 i, j 的**相似度概率**（高斯核）。
- q_{ij} ：低维空间中的相似度概率（**t 分布核**，重尾，缓解拥挤）。
- KL：KL 散度，衡量两个分布的差异。
- 含义：让低维的邻接关系尽量匹配高维。

(4) **UMAP**：基于拓扑数据分析，比 t-SNE 更快且更好保留全局结构。

4.4.3 流形学习方法族总览

流形学习的差异在于：**保留什么局部量**（距离 / 夹角 / 重构权重 / 概率）与**如何拼接全局**。

方法	保留的局部量	全局拼接方式	是否凸
MDS	成对距离	直接全局优化	近似凸
Isomap	测地距离	再用 MDS	非凸
LLE	线性重构权重	固定 W 求特征向量	特征值问题
Hessian LLE	二阶 (Hessian) 几何	特征值问题	特征值问题
LTSA	局部切空间坐标	对齐切空间	特征值问题
拉普拉斯特征映射	图上的局部距离	广义特征值	特征值问题
扩散映射	马尔可夫扩散距离	谱分解	特征值问题
MVU	邻域距离不变 + 最大方差	半定规划	凸 (SDP)
Kernel PCA	核空间方差	特征值问题	特征值问题
t-SNE	邻域概率	KL 最小化	非凸
UMAP	模糊邻域隶属	交叉熵最小化	非凸

4.4.4 谱方法变体：MDS、拉普拉斯特征映射、扩散映射与 MVU

(1) 经典 MDS (Torgerson 尺度化)

给定距离矩阵 D ($D_{ij} = \|x_i - x_j\|$)，构造双中心化矩阵：

$$B = -\frac{1}{2} J D^{(2)} J, \quad J = I - \frac{1}{N} \mathbf{1} \mathbf{1}^\top$$

其中：

- $D^{(2)}$ ：逐元素平方的距离矩阵。
- J ：中心化矩阵（每行每列减去均值）。
- 含义：若 D 来自欧氏距离，则 B 恰好是中心化后的内积矩阵 $B = \tilde{X} \tilde{X}^\top$ 。
- 嵌入：对 B 做特征分解，取前 d 个正特征值： $Y = U_d \Lambda_d^{1/2}$ 。
- 度量 MDS (SMACOF)：若 D 不是欧氏距离（如主观相似度），直接最小化 Stress：

$$\text{Stress} = \sqrt{\frac{\sum_{i < j} (d_{ij} - \|y_i - y_j\|)^2}{\sum_{i < j} d_{ij}^2}}$$

SMACOF 用主化-最小化 (MM) 迭代，单调递减 Stress。 - 非度量 MDS (nMDS)：只要求距离的序关系一致（秩相关最大），适合人类感知实验（音色、味道相似度）。

(2) 拉普拉斯特征映射 (Laplacian Eigenmaps, Belkin & Niyogi)

在近邻图上让相连的点在低维坐标中尽量靠近：

$$\min_Y \sum_{i,j} W_{ij} \|y_i - y_j\|^2 = 2 \operatorname{tr}(Y^\top L Y) \quad \text{s.t.} \quad Y^\top D Y = I$$

其中：

- W_{ij} ：边权（高斯核或 0/1）。
- $D = \operatorname{diag}(d_i)$, $d_i = \sum_j W_{ij}$ ：度矩阵。
- $L = D - W$ ：拉普拉斯矩阵。
- 等式变换： $\sum_{i,j} W_{ij} \|y_i - y_j\|^2 = 2 \sum_i d_i \|y_i\|^2 - 2 \sum_{i,j} W_{ij} y_i^\top y_j = 2 \operatorname{tr}(Y^\top L Y)$ 。
- 约束 $Y^\top D Y = I$ ：消除尺度与退化解（归一等权）。
- 解：广义特征值问题 $Ly = \lambda Dy$ ，取除 0 外最小的 d 个特征向量。
- 归一化变体：用 $L_{\text{sym}} = I - D^{-1/2} W D^{-1/2}$ 或 $L_{\text{rw}} = I - D^{-1} W$ 。
- 含义：与谱聚类共用数学基础——只是谱聚类对特征向量跑了 K-means，拉普拉斯特征映射直接把它当坐标。

(3) 扩散映射 (Diffusion Maps)

把图上的**随机游走**当扩散过程，定义多尺度距离：

$$P = D^{-1}W, \quad D_t(i, j)^2 = \sum_{k=1}^N \lambda_k^{2t} (\psi_k(i) - \psi_k(j))^2$$

其中：

- P ：转移矩阵， P_{ij} 是从 i 一步走到 j 的概率。
- λ_k, ψ_k ： P 的特征值 / 左特征向量（排序后 $1 = \lambda_1 > \lambda_2 \geq \dots$ ）。
- t ：扩散时间（步数），控制观察的尺度—— t 小看局部， t 大看全局。
- 嵌入坐标： $\Psi_t(x) = (\lambda_1^t \psi_1(x), \lambda_2^t \psi_2(x), \dots)$ 。
- 含义：提供多尺度的流形描述，对噪声鲁棒（ t 大时噪声被衰减），还能用来估计内在维度。

(4) 最大方差展开 (MVU / SDE, Maximum Variance Unfolding)

思路：拉开不相邻的点，同时保持相邻点之间的距离：

$$\max_Y \sum_{i,j} \|y_i - y_j\|^2 \quad \text{s.t.} \quad \|y_i - y_j\|^2 = \|x_i - x_j\|^2 \quad \forall (i, j) \in \mathcal{E}$$

其中：

- $\mathcal{E}$ ：近邻图的边集（只约束相邻点）。
- 第二个约束保证局部几何不变；第一个目标拉大距离，把切空间"展开"。
- 约束可重写为半正定约束 $K \succeq 0$ ，故是一个 SDP（半定规划）问题：

$$\max_K \text{tr}(K) \quad \text{s.t.} \quad K \succeq 0, \sum_{ij} K_{ij} = 0, K_{ii} + K_{jj} - 2K_{ij} = d_{ij}^2 \quad \forall (i, j) \in \mathcal{E}$$

其中 K 是嵌入的内积（Gram）矩阵。 - 含义：唯一的凸流形学习目标，因此无局部最优问题——代价是 SDP 求解复杂度高，不适合大 N 。

4.4.5 局部几何变体：Hessian LLE、LTSA 与参数化可视化

(1) Hessian LLE (HLLE)

LLE 用局部线性（一阶）重构，当邻域有曲率时误差大。HLLE 用二阶（Hessian）估计：

$$\min_Y \sum_i \sum_{l=1}^{k(k+1)/2} (H_i^{(l)} Y)^2, \quad Y^\top Y = I, \quad Y^\top \mathbf{1} = 0$$

其中：

- $H_i^{(l)}$: 在第 i 个邻域上用**二次多项式拟合**得到的环境 Hessian 方向上的**行向量**。
- $k(k+1)/2$: k 维二次型的**独立二阶项个数** (含交叉项)。
- 零均值约束 $Y^\top \mathbf{1} = 0$: 把解限制在非平凡子空间。
- 含义: 对**有曲率的流形**比 LLE 更准确, 但对噪声敏感且要求**较大邻域** ($k > d$)。

(2) LTSA (Local Tangent Space Alignment)

不学重构权重, 而是对齐切空间坐标:

1. 对每个邻域做 PCA, 得到**局部切空间坐标** $\Theta_i \in \mathbb{R}^{k \times d}$;
2. 寻找全局坐标 Y , 使局部坐标能通过**仿射变换**从全局坐标得到:

$$\min_{Y, L_i} \sum_i \left\| \Theta_i - (\mathbf{1} t_i^\top + Y_i L_i) \right\|^2$$

其中:

- Θ_i : 第 i 个邻域的**切空间投影坐标** (PCA 得分)。
- L_i : 待求**局部仿射变换**; t_i : 平移。
- Y_i : 邻域在全局坐标中的子矩阵。
- 化简后同样变为**特征值问题** ($B\mathbf{1}$ 对应的零空间)。
- 含义: 与 LLE 同宗但更**数值稳定**, 且能直接给出**切空间对齐误差**作为诊断量。

(3) Kernel PCA 作为流形学习

当核为**高斯径向基**时, 核 PCA 就等价于拉普拉斯特征映射的近似:

$$W_{ij} \approx \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$$

含义: 两者共享"**局部高斯相似度 + 谱分解**"的框架; 区别是 Kernel PCA 基于**全局核矩阵** (也适用于新样本), 拉普拉斯特征映射基于**稀疏 KNN 图** (更局部、更快)。

(4) 可视化导向的变体 (t-SNE / UMAP 家族)

t-SNE 的概率与评估定义:

$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma_i^2)}, \quad p_{ij} = \frac{p_{j|i} + p_{i|j}}{2N}$$

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|y_k - y_l\|^2)^{-1}}$$

其中:

- σ_i : 点 i 的高斯带宽, 由**困惑度 (perplexity)** 确定:

$$\text{Perp}(P_i) = 2^{H(P_i)} = 2^{-\sum_j p_{j|i} \log_2 p_{j|i}}$$

典型值 5~50; 相当于 “有效邻居数” 。

- q_{ij} 用 t 分布 (自由度 1) : 重尾使**不同簇之间能有较大间隙**, 直接解决了低维高斯核的**拥挤问题 (crowding problem)** 。
- 梯度: $\frac{\partial \text{KL}}{\partial y_i} = 4 \sum_j (p_{ij} - q_{ij})(y_i - y_j)(1 + \|y_i - y_j\|^2)^{-1}$, 引力 (p) 与斥力 (q) 的差——**引力只在近邻起作用, 斥力作用到全局**。

UMAP 的两个关键公式:

$$v_{j|i} = \exp\left(-\frac{d(x_i, x_j) - \rho_i}{\sigma_i}\right), \quad \mu_{ij} = v_{j|i} + v_{i|j} - v_{j|i} v_{i|j}$$

$$w_{ij} = \left(1 + a \|y_i - y_j\|^{2b}\right)^{-1}$$

其中:

- ρ_i : 到第 i 个点**最近邻的距离** (保证局部连通性) 。
- σ_i : 使 $\sum_j v_{j|i} = \log_2 k$ 的带宽 (与 t-SNE 的困惑度思路一致) 。
- a, b : 由非线性最小二乘**拟合**出来的参数, 使低维核在"曲线"上匹配高维隶属度。
- 损失: **模糊交叉熵 (fuzzy cross-entropy)** , 比 KL 更类对称, 且**不需要全局归一化** (所以能**分批处理、支持新样本**) 。

变体	关键改动	解决的问题
Barnes-Hut t-SNE	用四叉树近似斥力	$O(N \log N)$ 加速
Flt-SNE (FFT)	插值 + 卷积算斥力	进一步加速
参数化 t-SNE	学 $x \mapsto y$ 的网络	能嵌入新样本
监督 UMAP	相似度加上标签项	保留类别结构
LargeVis	负采样近似	大数据
TriMap	三体约束	更好保留 全局结构
PaCMAP	近邻 / 中点 三类对	同时保留局部与全局
Localmap	只保留局部	局部结构极敏感场景

4.4.6 嵌入质量如何评估

流形学习的目标不唯一, 因此评测需要**行为指标**, 而非损失值。

(1) 邻域保持度 (Trustworthiness) 与连续性 (Continuity)

$$T(k) = 1 - \frac{2}{Nk(2N - 3k - 1)} \sum_{i=1}^N \sum_{j \in \mathcal{U}_k(i)} (r(i, j) - k)$$

其中：

- $\mathcal{U}_k(i)$: 在低维中是 i 的 k 近邻、但在高维中不是的点集（假邻居）。
- $r(i, j)$: 点 j 在高维空间中按距离排序的名次。
- $T(k) \in [0, 1]$: 越接近 1 越好，度量 “是否无中生有地拉来了陌生点”。
- 连续性 $C(k)$ 是对称定义（高维邻居是否在低维被丢失），度量 “是否丢掉了真邻居”。

(2) 全局指标

指标	衡量	说明
距离相关度	全局距离保真	高维与低维距离的相关系数
类内/类间分离度	分类可用性	有标签时直接用 kNN 准确率
可视化稳定性	可重复性	不同随机种子结果的一致性

(3) 内在维度估计

- **MLE 法** (Levina-Bickel)：用 KNN 距离的平均对数比估计 d ：

$$\hat{d}_k(x) = \left[\frac{1}{k-1} \sum_{j=1}^{k-1} \log \frac{T_k(x)}{T_j(x)} \right]^{-1}$$

其中 $T_j(x)$ 是 x 到第 j 个近邻的距离。

- **两近邻法 (TwoNN)**：用 “第一 / 第二近邻距离比” 的分布拟合 d 。
- 内在维度是**选邻域大小 k 的关键依据**（一般要求 $k > d$ ）。

4.4.7 应用方向

(1) 图像 / 视觉

- **可视化**：把 CNN 特征降到 2D 看类别可分性（t-SNE 最常用）。
- **人脸/姿态流形**：人脸图像随姿态、光照变化形成低维流形。
- **检索**：流形上的近邻检索。
- **降维预处理**：Isomap/LLE 用于手写数字、人脸识别。

(2) 数据探索与可视化 (最广泛)

- **高维数据可视化**: 单细胞、文本、表格数据的 2D 散点。
- **聚类结果展示**: 配合可视化解释分群。
- **深度特征分析**: 理解嵌入空间结构。

(3) 生物与医学

- **单细胞测序**: 细胞轨迹与分化路径 (UMAP/t-SNE 标配)。
- **发育 / 疾病进展轨迹**: 沿流形恢复连续变化。
- **分子构象空间**: 高维构象的低维流形。

(4) 语音、文本与推荐

- **声学特征可视化**: 音素 / 说话人分布。
- **文档主题可视化**: 语料结构探索。
- **用户 / 物品嵌入可视化**: 推荐结果解释。

(5) 物理与科学

- **动力系统降维**: 相空间的低维吸引子恢复。
- **材料 / 气候数据**: 高维观测的流形结构分析。

4.4.8 与深度学习的联系

- **流形假设是深度学习的理论基石之一**: 深度网络学的是"把流形展平"的映射。
 - **自编码器 / VAE 是参数化、可泛化的流形学习** (能处理新样本)。
 - **t-SNE/UMAP 用于分析深度特征空间**, 是理解网络的常用工具。
 - **对比学习**的目标就是让同类在嵌入流形上聚集。
 - **几何深度学习 (Geometric DL)**: 把流形假设推到图、网格、流形网络上 (GCN、PointNet、等变网络)。
 - **参数化嵌入**: 深度自编码器把"每跑一次都不同的 t-SNE 坐标"变成"可微、可泛化的编码器"。
 - **扩散模型 (Diffusion)**: 名字与扩散映射同源——都建立在"随机游走 / 热核"之上。
-

4.5 半监督学习 (Semi-supervised Learning)

4.5.1 问题设定

有少量有标签数据 $\{(x_i, y_i)\}_{i=1}^L$ 和大量无标签数据 $\{x_j\}_{j=L+1}^{L+U}$ ，利用无标签数据提升性能。核心假设：

- **平滑假设**：相近样本有相近标签。
- **聚类假设**：同一簇内样本同类。
- **流形假设**：数据在低维流形上，沿流形标签平滑。

4.5.2 主要方法

(1) 自训练 (Self-training)

1. 用有标签数据训练模型。
2. 预测无标签数据，取**高置信度**样本加入训练集。
3. 重复。

置信度阈值 τ ：只把 $\max_c P(c | x) \geq \tau$ 的样本加入。

(2) 协同训练 (Co-training)

用两个**不同视图**（特征子集）各训一个分类器，互相给对方标注高置信样本。

(3) 图半监督 (Label Propagation)

在相似度图上传播标签。目标函数：

$$E(f) = \sum_{i,j} W_{ij} \|f_i - f_j\|^2$$

其中：

- W_{ij} ：样本 i, j 的**相似度**（如高斯核）。
- f_i ：样本 i 的**预测分数**（软标签）。
- 含义：相似样本的预测应接近；有标签样本固定为真值。
- 解： $f = (I - \alpha S)^{-1} y$ ，其中 $S = D^{-1/2} W D^{-1/2}$ 是归一化相似度矩阵， α 是传播强度。

(4) **半监督 SVM (S3VM)**：让超平面穿过低密度区域。

(5) **一致性正则 (深度半监督)**：对同一输入加不同扰动，要求输出一致（ Π -model、Mean Teacher、FixMatch）。

4.5.3 半监督方法族总览

所有半监督方法都在做同一件事：把无标签数据携带的分布信息翻译成约束。

家族	无标签信息的用法	代表	是否凸
自训练 / 伪标签	自己标自己	Self-training、Pseudo-label	迭代非凸
协同训练	多视图互相标	Co-training、Tri-training	迭代非凸
生成式	对 $p(x \mid y)$ 建模	EM + GMM、半监督 NB	EM 非凸
判别式大间隔	低密度分割	S3VM / TSVM	非凸
图方法	标签在相似度图上传播	Label Propagation、GRF	凸 (闭式解)
熵最小化	让决策边界远离数据	Entropy Minimization	非凸
一致性正则	扰动下输出不变	Π -model、Mean Teacher、FixMatch	非凸
生成对抗	用 GAN 生成 / 判别	Semi-supervised GAN	非凸 (博弈)
半监督聚类	用约束引导聚类	COP-KMeans、Seeded K-means	非凸
对比 / 自监督	预训练表征	SimCLR、MAE + 微调	非凸

4.5.4 生成式与判别式变体

(1) 生成式：EM + 混合模型（最古典的半监督）

对每个簇（类）建一个分布，已知标签样本只在自己的分量里算责任度：

$$\theta^{(t+1)} = \arg \max_{\theta} \left\{ \underbrace{\sum_{i=1}^L \log p_{\theta}(x_i, y_i)}_{\text{监督部分}} + \underbrace{\sum_{j=L+1}^{L+U} \mathbb{E}_{q(z_j)} [\log p_{\theta}(x_j, z_j)]}_{\text{EM 的无标签部分}} \right\}$$

其中：

- $p_{\theta}(x, y) = P(y) p_{\theta}(x \mid y)$ ：生成模型（GMM 中 $p(x|y = k) = \mathcal{N}(x \mid \mu_k, \Sigma_k)$ ）。
- 无标签样本的隐变量 z_j 用后验（E 步）处理，与标准 EM 完全一致。
- 含义：只需把“有标签样本的责任度固定”，两条流水线（监督 / 无监督）就能合并。
- 前提：**生成假设必须正确**（如真是高斯），否则无标签数据反而降低性能（Cozman & Cohen 的著名反例）。

(2) 判别式大间隔：S3VM / TSVM

在半监督 SVM 中，无标签样本的标签也变成可优化变量：

$$\min_{w, b, \{\hat{y}_j\}, \xi} \frac{1}{2} \|w\|^2 + C_l \sum_{i=1}^L \xi_i + C_u \sum_{j=L+1}^{L+U} \xi_j$$

$$\text{s.t. } y_i(w^\top x_i + b) \geq 1 - \xi_i, \quad \hat{y}_j(w^\top x_j + b) \geq 1 - \xi_j, \quad \hat{y}_j \in \{-1, +1\}$$

其中：

- $\hat{y}_j$ ：无标签样本的待定标签（离散变量 $\rightarrow$ 问题非凸）。
- C_l, C_u ：有标签 / 无标签样本的惩罚系数。
- 含义：目标相当于寻找一个穿过低密度区域的分界面（聚类假设的体现）。
- 求解路线：
- **TSVM (Joachims)**：用 $\hat{y}_j$ 的连续松弛，交替优化 w, b 与标签分配，并在迭代中逐渐增大 C_u （从 0 到目标值），避免陷入差的局部极值。
- **CCCP (凹凸过程)**：把非凸损失写为凸减凸，再迭代求解凸子问题。
- **S4VM / 安全半监督**：同时优化多个 S3VM 解，保证不会比普通 SVM 差。
- **对偶观点**：无标签样本可能在优化过程中被赋予很小或极大的 α ，这与 SVM 的边界样本行为相呼应。
- 局限：当两个类不均衡或不分离时，S3VM 会把小类整个投入大类。

4.5.5 图半监督变体：从标签传播到随机场

所有图方法共享同一个“图拉普拉斯正则”框架：

$$\min_f \underbrace{\sum_{i,j} W_{ij} \|f_i - f_j\|^2}_{\text{平滑项：图拉普拉斯二次型}} + \underbrace{\sum_{i=1}^L \|f_i - y_i\|^2}_{\text{拟合项：匹配已知标签}}$$

上式的解具有闭式形式（设 $S = D^{-1/2} W D^{-1/2}$ ， F 为软标签矩阵）：

$$F^* = (I - \alpha S)^{-1} Y, \quad F^{(t+1)} = \alpha S F^{(t)} + (1 - \alpha) Y$$

其中：

- W_{ij} ：相似度（高斯核 / KNN 图）。
- D ：度矩阵； S ：归一化相似度。
- Y ：标签矩阵（有标签行是 one-hot，无标签行全 0）。
- $\alpha \in (0, 1)$ ：传播强度（ α 大则标签传得远）。
- 含义： $(I - \alpha S)^{-1} = I + \alpha S + \alpha^2 S^2 + \dots$ ——即沿图的所有路径无限次传播的无限级数；这解释了为什么迭代 $F \leftarrow \alpha S F + (1 - \alpha) Y$ 一定收敛。

变体	关键区别
Label Propagation (LP)	用未归一化 W ，硬固定已知标签
Label Spreading (LS)	用归一化 $D^{-1/2} W D^{-1/2}$ ，允许已知标签也被小幅调整
高斯随机场 (GRF)	把平滑项看作能量，无标签解是调和函数: $f_u = (D_{uu} - W_{uu})^{-1} W_{ul} f_l$
Mincut	用图割代价代替二次型，输出硬标签
谱图 transducer	先谱嵌入再在嵌入空间做 k NN 传播
局部与全局一致性	同时用有标签邻居与全图结构传播
流形正则化 (Manifold Regularization)	把图平滑项加到任意监督损失上 (如 SVM / 回归)

图方法的通用问题:

- 必须处理全部无标签样本 ($N \times N$ 矩阵求逆, $O(N^3)$) $\rightarrow$ 大 N 需稀疏近似。
- 对图结构极度敏感: k 与 σ 选择不当会大幅劣化。
- 只能处理已见样本 (transductive), 不能直接预测新样本。
- 类别非常不均衡时, 图会被大类主导 (需归一化 / 类别平衡约束)。

4.5.6 深度半监督: 一致性正则与伪标签家族

(1) 一致性正则的基本形式 (Π -model)

同一输入加两次不同扰动, 要求输出一致:

$$\mathcal{L} = \sum_{i=1}^L \mathcal{L}_{\text{sup}}(y_i, f_{\theta}(x_i)) + \lambda(t) \sum_{j=L+1}^{L+U} \|f_{\theta}(x_j + \varepsilon) - f_{\theta}(x_j + \varepsilon')\|^2$$

其中:

- $\varepsilon, \varepsilon'$: 两次独立的随机扰动 (Dropout、数据增强、噪声)。
- $\lambda(t)$: 随时间上升的权重 (常见阈值 $\lambda(t) = 0.1 \cdot e^{-5(1-t)^2}$) , 训练早期以监督为主, 后期逐渐重视一致性。
- 含义: 不做一致性时, 网络会对同一输入在不同 Dropout 下给出很不稳定的预测; 一致性损失直接抹平这种不稳定。

(2) 教师-学生架构: Mean Teacher

教师权重是学生权重的指数移动平均 (EMA) :

$$\theta'_t = \alpha \theta'_{t-1} + (1 - \alpha) \theta_t, \quad \mathcal{L}_{\text{cons}} = \|f_{\theta'}(x') - f_{\theta}(x)\|^2$$

其中：

- θ ：学生（用梯度更新）； θ' ：教师（只用 EMA）。
- α ：EMA 衰减（常见 0.999）——越慢越准，因为教师是多时刻的集成。
- x, x' ：学生对同一样本的不同增强版本。
- 含义：教师="参数的滑窗平均"（相当于权重空间的 Polyak 平均），比学生更稳，故用它作目标更可靠。
- 衍生：Noisy Student（教师标伪标签、学生加噪声训练）、Dual Student（两个学生互为教师）。

(3) 对抗扰动：VAT 与 UDA

- VAT (Virtual Adversarial Training)：不随机扰动，而是找模型最敏感的方向：

$$r_{\text{adv}} = \arg \max_{\|r\| \leq \epsilon} \text{KL}\left(p(y|x) \parallel p(y|x+r)\right), \quad \mathcal{L}_{\text{VAT}} = \text{KL}\left(p(y|x) \parallel p(y|x+r_{\text{adv}})\right)$$

其中 r_{adv} ：在 ϵ 球内最改变输出分布的扰动；可用幂迭代近似（ $r \leftarrow \nabla_r \text{KL}$ 再归一化）。 - UDA (Unsupervised Data Augmentation)：把随机扰动换成强数据增强（图像 RandAugment、文本回译），并用训练信号退火 (TSA) 调节 λ ；核心公式与 Π -model 相同，但“扰动”变为了有语义的增强。

(4) 伪标签家族：FixMatch、MixMatch 与 ReMixMatch

FixMatch 是现代半监督的基线，两条分支：

$$\mathcal{L}_u = \frac{1}{\mu B} \sum_{j=1}^{\mu B} 1\left[\max_c p_w(y=c|x_j) \geq \tau\right] \cdot \text{CE}\left(\hat{p}_w(y|x_j), p_s(y|\mathcal{A}(x_j))\right)$$

其中：

- p_w ：弱增强（翻转 / 平移）下的预测 → 用来生成伪标签 $\hat{p}_w = \arg \max_c p_w$ 。
- $\mathcal{A}(x_j)$ ：强增强（RandAugment + Cutout）后的输入。
- τ ：置信度阈值（如 0.95）；低于阈值的样本不产生损失。
- μ ：无标签批量相对于有标签批量的倍数。
- 含义：弱增强定阈值 + 硬伪标签 + 强增强训练——三个部件都不可少。

方法	伪标签怎么来	关键骰子
Π -model	自身两次扰动	一致损失
Temporal Ensembling	历史预测的 EMA	多?? 次集成
Mean Teacher	教师网络	EMA 权重
MixMatch	多个增强的平均 + 锐化	Sharpening + MixUp
ReMixMatch	分布对齐 + 旋转	弱增强的伪标签更可靠
FixMatch	弱增强硬标签 + 阈值	简单、强、易复现
FlexMatch	类别自适应阈值	解决类不平衡
FreeMatch	阈值自适应训练	免调阈值
Noisy Student	教师标伪标签 + 学生加噪	迭代自我训练

(5) 其他深度半监督路线

- **熵最小化 (Entropy Minimization)**：直接惩罚预测的不确定度：

$$\mathcal{L}_{\text{ent}} = - \sum_c p_{\theta}(y = c | x) \log p_{\theta}(y = c | x)$$

它是一致性正则的“极限形式”（无限小扰动下的一致性）。

- **半监督 GAN (SGAN)**：判别器输出 K 类 ($K - 1$ 真实类 + 1 生成类)，无标签真实样本只需判别“是真实类之一”，从而**同时利用无标签数据与生成数据**。
- **对比半监督**：先 SimCLR / MoCo 预训练，再线性探测或微调（见 4.5.8）。

4.5.7 半监督聚类与约束聚类

若不（或很少）有标签，可以用“约束”而非标签来引导聚类：

- **Must-link / Cannot-link 约束**：认为 i, j 必同簇 / 必不同簇。
- **COP-KMeans**：在标准 K-means 分配时**强制遵守约束**：

分配 x_i 到 $k \iff \forall x_j \in C_k$ ：不违反 cannot-link, $\forall (i, j) \in \text{must-link} : j \in C_k$

若某点无合法簇可选，算法宣告**失败**（需回退或松弛）。 - **Seeded / Constrained K-means**：用带标签样本初始化中心并固定它们的簇归属，其余样本正常迭代。 - **PCK-means (惩罚式)**：不强约束，而是加入惩罚项：

$$J = \sum_k \sum_{x_i \in C_k} \|x_i - \mu_k\|^2 + \sum_{(i,j) \in \mathcal{M}} w_{ij} 1[z_i \neq z_j] + \sum_{(i,j) \in \mathcal{C}} \bar{w}_{ij} 1[z_i = z_j]$$

其中 $\mathcal{M} / \mathcal{C}$ 分别是 must-link / cannot-link 约束集, w_{ij} 是违反约束的惩罚权重。

4.5.8 与自监督、主动学习的关系

范式	标签	核心思想
监督	全部有	直接拟合标签
半监督	少量 + 大量无	用无标签数据的 分布结构
自监督	零 + 大量无	用数据自身构造 代理任务
主动学习	少量 + 可选择	主动 挑选最有价值的样本 去标
弱监督	粗糙标签	用噪声 / 部分 / 不精确标签

三种性能提升来源的分解：

- 1. **代表性**：无标签数据帮助学更好的特征（自监督、生成模型）。
- 2. **边界位置**：无标签数据揭示决策边界应该在哪（S3VM、一致性正则）。
- 3. **数据增强正则**：一致性 / 扰动本身就是一种强正则。

主动学习与半监督互补：前者决定“**标什么**”，后者决定“**挖什么**”——工业上常先用主动学习选出 1% 样本标注，再用半监督把 99% 用上。

4.5.9 应用方向

(1) 图像 / 视觉

- **医学图像分割**：标注昂贵，用少量标注 + 大量未标注。
- **遥感分类**：标注成本高。
- **网页图像分类**：少量标注 + 海量未标注。
- **伪标签 (Pseudo-labeling)**：竞赛与工业界常用。

(2) 文本与语音

- **文本分类**：少量标注评论 + 海量无标注语料。
- **半监督词性标注 / 句法分析**：协同训练的历史起点。
- **语音识别**：少量转写 + 大量未转写语音。
- **说话人识别**：少量带标签声纹。

(3) 推荐、搜索与广告

- **冷启动推荐**：少量交互 + 大量无反馈行为。
- **CTR 预估**：无点击样本作为无标签数据。
- **搜索相关性**：少量人工标注 + 海量点击日志。

(4) 生物、医学与化学

- **药物活性预测**：少量实验验证 + 大量未验证化合物。
- **基因组 / 蛋白功能注释**：少量注释 + 海量序列。
- **疾病筛查**：标签难得，未标注病例很多。

(5) 工业与网络

- **故障诊断**：故障样本稀少，正常样本充足。
- **入侵检测 / 日志分类**：少量标注告警。
- **金融风控**：带标签的违约样本极少。

4.5.10 与深度学习的联系

- **半监督是深度学习的核心训练范式之一**：FixMatch、Mean Teacher、Noisy Student。
 - **自监督学习**（SimCLR、MAE、MoCo）可看作“无标签预训练 + 少量标签微调”，是半监督的极端形式。
 - **伪标签**是知识蒸馏与半监督的桥梁。
 - **EMA 教师**的思想已泛化到分割（Mean Teacher）、检测、语音，以及 BYOL / DINO 中作为“防坍塌”的核心机制。
 - **一致性正则 ↔ 数据增强对齐**：RandAugment / CutMix 等增强技术最初就是为了服务半监督。
 - **半监督的极限就是自监督**：MoCo v3 / DINO 证明无标签数据可以完全取代人工标签。
-

5. 其他版本中的扩展算法 (ICDM 2008 版差异项)

本节补齐 ICDM 2008 版名单中用户版本未列出的算法：**C4.5**、**CART**、**PageRank**、**AdaBoost**、**EM**、**Apriori**，以及入门教材版常列的**神经网络 / 深度学习**。这些算法在图像领域未必是主力，但在数据挖掘、推荐系统、集成学习、概率推断等领域地位极高，因此本节同时给出完整的应用方向。

5.1 C4.5

5.1.1 定位

C4.5 是 **ID3 的改进版** (Quinlan, 1993)，是决策树算法史上最著名的版本之一，也是 ICDM 2008 榜单的**第一名**。它解决了 ID3 的两个致命缺陷：

- ID3 只能处理**离散特征**，C4.5 可处理**连续特征**（二分阈值）。
- ID3 用信息增益会**偏向取值多的特征**，C4.5 改用**信息增益率**。

5.1.2 信息增益率

$$\text{GainRatio}(S, A) = \frac{\text{Gain}(S, A)}{\text{SplitInfo}(S, A)}$$

其中：

- S ：当前节点的样本集合。
- A ：候选划分特征。
- $\text{Gain}(S, A) = H(S) - \sum_v \frac{|S_v|}{|S|} H(S_v)$ ：**信息增益**，即用 A 划分后熵的下降量。
- $H(S) = - \sum_c p_c \log_2 p_c$ ： S 的**信息熵**， p_c 是类别 c 的占比。
- S_v ： S 中特征 A 取值为 v 的子集； $|S_v|/|S|$ 是子集权重。
- $\text{SplitInfo}(S, A) = - \sum_v \frac{|S_v|}{|S|} \log_2 \frac{|S_v|}{|S|}$ ：**分裂信息**，衡量 A 把数据切得多碎。
- 含义：分母惩罚“取值过多”的特征（如身份证号），使增益率不被这类特征主导。

5.1.3 连续特征处理

对连续特征 A ，把取值排序后取相邻中点作为候选阈值 t ：

$$t = \frac{a_i + a_{i+1}}{2}$$

其中：

- a_i, a_{i+1} ：排序后相邻的两个取值。
- t ：候选**二分阈值**，把 $A \leq t$ 与 $A > t$ 分成两支。
- 对所有候选 t 计算增益率，取最优者。

5.1.4 缺失值处理

- **划分时**：把缺失样本按权重比例分到各分支。
- **预测时**：把缺失样本同时送入所有分支，按权重加权投票。

5.1.5 剪枝：悲观剪枝

C4.5 用**悲观错误剪枝 (PEP)**：把训练集上的错误率加上一个惩罚项（基于二项分布的标准差），若剪枝后惩罚错误率不升则剪掉子树。

$$e_{\text{pes}} = e + z \sqrt{\frac{e(1-e)}{N}}$$

其中：

- e ：节点上的**训练错误率**。
- N ：该节点覆盖的样本数。
- z ：置信度对应的正态分位数（如 95% 对应 1.645）。
- e_{pes} ：**悲观错误率**，样本越少惩罚越大，避免小样本子树过拟合。

5.1.6 C4.5 家族的演进与对比

版本	年份	关键改动	解决的问题
ID3	1986	信息增益	仅离散、多叉、无剪枝
C4.5	1993	增益率、连续值、缺失值、PEP	通用化
C4.5rules	1993	从树提取规则集 + OCC 剪枝	规则可读、可手工编辑
C5.0	1997	提升 (Boosting)、更小树、样本权重	精度与速度
See5	商业	C5.0 的 Windows 版	工业应用
J48	Weka	C4.5 的 Java 重写	开源、可扩展
J48graft	Weka	允许向上移植分支	修正不可回溯的分裂

C5.0 相对于 C4.5 的核心改进：

- 支持样本权重（与 AdaBoost 配合时应为基学习器）。
- 误分类代价矩阵（漏判一个癌症比误判严重）。
- Boosting 模式：在内部自建多棵树提升（很多实现同时提供 boosting 与 bagging）。
- 更小的树：默认使用更激进的剪枝，精度往往更高。
- 不支持增量学习（C4.5 的早期版本曾支持，但效果一般）。

5.1.7 规则后处理与分裂准则变体

(1) C4.5rules：从树到规则

1. 对每个叶节点，把从根到叶的路径反向改写为一条规则：

$$\text{IF } (a_1 = v_1) \wedge (a_2 \leq v_2) \wedge \cdots \wedge (a_m \in S_m) \text{ THEN } c_k$$

1. 对每条规则逐条件删除（OCC：One Condition Cut），若删除后规则在验证集上的评估不下降则保留删除：

$$\text{删除条件 } a_i \iff \text{Acc}(\text{rule} \setminus a_i) \geq \text{Acc}(\text{rule})$$

1. 按规则质量排序（常用 Laplace 校正精度），分类时从上到下命中即停：

$$\text{LapAcc}(r) = \frac{n_c + 1}{n_{\text{cov}} + k}$$

其中：

- n_c ：该规则覆盖的样本中类别正确的个数。

- n_{cov} : 该规则覆盖的样本总数。
- k : 类别数（拉普拉斯校正，避免小覆盖规则得到 100% 的假像）。
- 含义：把“树”变成“规则集”后，各条规则可以**独立增删**（树做不到）；这是专家系统与合规判定场景喜欢 C4.5rules 的原因。

(2) 分裂准则之间的对比

准则	公式	缺点 / 特点
信息增益 (ID3)	$H(S) - \sum_v \frac{ S_v }{ S } H(S_v)$	偏好 多取值 特征
信息增益率 (C4.5)	$\text{Gain}(S, a) / \text{SplitInfo}(a)$	修正偏好；可能反向偏好少取值
基尼 (CART)	$1 - \sum_c p_c^2$	无对数、更快
卡方 (CHAID)	$\sum \frac{(O-E)^2}{E}$	统计显著性、多叉
G 统计量 (似然比)	$2 \sum O \ln(O/E)$	与卡方同族，适合对数线性模型
距离度量	$-\sum_v \frac{ S_v }{ S } \log \frac{ S_v }{ S }$	纯结构项

为什么 C4.5 要用增益率？

$$\text{SplitInfo}(S, a) = - \sum_{v \in \text{values}(a)} \frac{|S_v|}{|S|} \log_2 \frac{|S_v|}{|S|}$$

其中 SplitInfo 是“**按特征 a 划分本身带来的熵**”——取值越多这个值越大，作为分母恰好**抵消了信息增益的偏好**。C4.5 实际实现中还会先选出**增益高于平均水平**的特征，再在其中选增益率最大的，以避免增益率偏向“取值很少”的特征。

(3) 连续值离散化的两种策略

- **二分法 (C4.5)**：把连续值排序，只在**类别发生变化**的两个相邻值之间试切点：

$$\text{候选切点} = \left\{ \frac{a_i + a_{i+1}}{2} \mid y_{(i)} \neq y_{(i+1)} \right\}$$

这把 $O(N)$ 个候选降到“**类别边界数**”，大幅提速。

- **预离散化**：先分箱（等频 / 等宽 / 卡方分箱）再当离散特征用；在**风控评分卡**里，等频分箱 + WOE 是最常见做法。

5.1.8 应用方向

(1) 表格数据与风控医疗（核心场景）

- **信用评分**：银行用 C4.5 建可解释的违约预测树。
- **医疗诊断**：规则可读，医生能理解判断路径。
- **客户流失预测**：电信、银行经典应用。
- **遥感/生物分类**：特征混合（连续+离散）时优势明显。

(2) 规则抽取与知识发现

- **专家系统 / 知识库**：把决策树转换成 if-then 规则。
- **法规 / 合规判定**：可审计的判定路径。
- **保险定价**：费率因子规则提炼。

(3) 工业与能源

- **设备故障根因分析**：可读规则定位故障条件。
- **电力负荷 / 能耗分类**：多变量工况判别。
- **工艺参数优化**：特征阈值挖掘。

(4) 作为可解释代理模型

- **XAI 代理模型**：用 C4.5 近似黑盒模型的行为。
- **特征重要性排序**：按信息增益率筛选变量。

5.1.9 与深度学习的联系

- **可解释性对照**：C4.5 输出的是人能读的规则，深度网络是黑箱；可解释 AI (XAI) 常拿决策树做"代理模型"解释网络。
- **软决策树**：把硬分裂换成可微的软分裂，即可端到端训练 (Deep Neural Decision Trees) 。
- **规则提取 (Rule Extraction)**：从训练好的深度网络中抽取决策树 / 规则集，是 XAI 的重要分支（如 TREPAN、决策树蒸馏）；C4.5rules 的 OCC 剪枝就是蒸馏里"精简"的前身。
- **信息增益率 → 特征选择**：在深度模型中，互信息 / 增益类指标仍用于特征筛选与剪枝。

5.2 CART

5.2.1 定位

CART (Classification and Regression Trees, Breiman et al., 1984) 是**随机森林与 GBDT 的基学习器**，也是 ICDM 2008 榜单成员。与 C4.5 的关键区别：

维度	C4.5	CART
划分方式	多叉（按取值）	二叉（是/否）
不纯度	信息增益率	基尼不纯度
任务	仅分类	分类 + 回归
剪枝	悲观剪枝	代价复杂度剪枝
输出	规则集	二叉树

5.2.2 基尼不纯度

$$\text{Gini}(S) = 1 - \sum_{c=1}^C p_c^2 = \sum_{c \neq c'} p_c p_{c'}$$

其中：

- S ：节点样本集合。
- C ：类别数。
- p_c ： S 中类别 c 的占比。
- $\sum_c p_c^2$ ：随机抽两个样本同类的概率。
- $1 - \sum_c p_c^2$ ：随机抽两个样本异类的概率，即不纯度。
- 与熵对比：基尼无对数运算，计算更快，且曲线形状接近，实践中效果相当。

5.2.3 回归树的划分准则

回归任务用平方误差代替不纯度：

$$\text{SSE}(S) = \sum_{i \in S} (y_i - \bar{y}_S)^2, \quad \bar{y}_S = \frac{1}{|S|} \sum_{i \in S} y_i$$

其中：

- y_i ：样本 i 的连续目标值。
- $\bar{y}_S$ ：节点 S 内目标值的均值（叶子的预测值）。
- SSE：平方误差和，越小越纯。
- 划分时选使左右子节点 SSE 之和最小的特征与阈值。

5.2.4 代价复杂度剪枝 (CCP)

$$R_{\alpha}(T) = R(T) + \alpha|T|$$

其中：

- T ：一棵子树。
- $R(T)$ ：子树 T 在训练集上的**误差**（如误分类率或 SSE）。
- $|T|$ ：子树 T 的**叶子数**（复杂度）。
- $\alpha \geq 0$ ：**复杂度惩罚系数**，越大越倾向剪枝。
- $R_{\alpha}(T)$ ：**代价复杂度**，权衡"误差"与"复杂度"。
- 做法：从小到大取一系列 α ，得到嵌套的子树序列，再用交叉验证选最优。

5.2.5 CART 的工程变体：缺失值、多变量与代价敏感

(1) 缺失值处理：替代分裂 (Surrogate Splits)

设主分裂用特征 a 与阈值 t 。对每个候选替代特征 s ，定义它的**与主分裂一致性**：

$$\text{一致性}(s) = \frac{|\{i : s(x_i) \text{ 与 } a(x_i) \text{ 指向同一子节点}\}|}{N_{\text{non-missing}}}$$

选择一致性最高的若干个特征作为 $s_1, s_2, \dots$ (**替代分裂序列**)。含义：

- 预测时若 a 缺失，就用 s_1 判断； s_1 也缺失则用 s_2 ，以此类推；
- 训练时缺失样本被**按比例分派到两个子节点**（不是随便丢）；
- 两个附带诊断量：
- **替代分裂质量 (Adjusted Agreement)**：一个分裂在所有替代上的平均一致性；质量差说明该分裂不可靠，可用来**筛掉可疑分裂**。
- **变量重要性**：主分裂的 $\Delta i(S)$ 加上所有替代分裂的贡献，这就是 `rpart` 的变量重要性排名依据。
- 含义：**单树能原生处理缺失值**，而大部分神经网络必须插补缺失值才能训练，这是树模型在工业表格数据上的一大优势。

(2) 多变量分裂 (Oblique / Linear Combination Splits)

不再要求阈值沿单一坐标轴，而是允许**线性组合**：

$$\sum_{j=1}^D w_j x_j \leq t, \quad \Delta i(S) \text{ 最大化}$$

其中：

- w_j ：待学的**线性组合权重**（OC1 算法用随机的"扰动 + 局部搜索"求解）；

- t : 阈值。
- 含义：当真实决策边界是**斜的**（如 $x_1 + x_2 = c$ ）时，轴对齐树需要**很多次分裂**才能逼近，而斜树一次就够了——**同样精度下树深更小**。
- 代价：分裂搜索从 $O(D)$ 变成 " $O(D)$ 到 $O(D^2)$ + 局部优化"，训练慢很多。

(3) 代价敏感分裂 (Cost-Sensitive Splitting)

若不同类错误代价不同（漏判癌症 vs 误判健康），有两条路线：

- **只改叶子预测**（最简单）：叶子取**最小期望代价**的类：

$$\hat{c} = \arg \min_c \sum_{c'} p_{c'} C(c', c)$$

其中：- $p_{c'}$ ：叶子内类 c' 的**占比**；- $C(c', c)$ ：把真实类 c' 判为 c 的**代价**（ $C(c, c) = 0$ ）。- 含义：分裂阶段不变，只在叶子做阈值偏移——这就是"**调整决策阈值**"的树版本。

- **改分裂准则**：把不纯度换为**代价加权不纯度**：

$$\Delta i_C(S) = i_C(S) - \frac{n_L}{n} i_C(S_L) - \frac{n_R}{n} i_C(S_R)$$

其中 $i_C(S)$ 是把 $\sum_c p_c^2$ 换成 $\sum_{c,c'} p_c p_{c'} C(c', c)$ 得到的加权不纯度。

- **样本加权**：给少数类样本更大权重（`class_weight="balanced"`），等价于把 $C(c', c)$ 折进权重里，实现最简单、最常用。

(4) 树的大小与偏差-方差权衡

若叶子内有 n_ℓ 个样本、目标方差为 σ^2 ，则叶子预测（均值）的方差为：

$$\text{Var}(\hat{y}_\ell) = \frac{\sigma^2}{n_\ell}$$

其中：

- 树**越深** → 叶子 n_ℓ 越小 → **偏差降、方差升**（容易过拟合）；
- 树**越浅** → 叶子大 → **偏差升、方差降**（容易欠拟合）。
- 两个最常见的"硬阈值"超参数：
- `min_samples_split`：节点至少多少样本才能分裂；
- `min_samples_leaf`：叶子至少多少样本；
- `max_depth` / `min_impurity_decrease`：深度与增益阈值。
- 含义：单棵 CART 必须在两者之间取平衡；**Bagging 单独降方差、Boosting 单独降偏差**——这就是为什么它们都要先有一棵"强一些"的单树。

5.2.6 CART 在集成学习中的地位

CART 回归树是现代梯度提升家族的唯一基学习器，原因有三：

- 1. 能拟合任意（分段常量）函数——包括伪残差（可为正可为负）；
- 2. 分裂只依赖样本相对顺序——对特征单调变换不变（无需归一化）；
- 3. 自带特征选择与缺失值处理——工程上省心。

四大提升框架对 CART 的改造点对比（具体公式见 3.5.9）：

框架	对 CART 的改造	标志性贡献
GBDT	拟合负梯度（伪残差） + 学习率 ν	函数空间梯度下降
XGBoost	二阶泰勒展开 + 叶子权重 L2 + 每叶子代价 γ	可自定义损失、并行化
LightGBM	直方图分箱 + leaf-wise 生长 + GOSS / EFB	大数据、高维稀疏
CatBoost	对称（oblivious）树 + 有序提升	类别特征、低过拟合

CART 与随机森林的两个关键点（见 3.5.8）：

- 每棵树的基学习器就是 CART（但**不做剪枝**，让单树长到纯，由平均去降方差）；
- 分裂时只随机考察 m 个特征，正是为了**降低树间相关度** ρ 。

CART 与可微树的桥梁：

- 把"硬选择特征"换成"软选择（sigmoid / entmax）"；
- 把"叶权重"当成可学习参数；
- 则 XGBoost 的叶子最优权重公式 $w_j^* = -G_j / (H_j + \lambda)$ 就是可微树在二阶近似下的**自然梯度解**。

5.2.7 应用方向

(1) 表格数据与集成学习（核心场景）

- 随机森林 / GBDT / XGBoost / LightGBM 的基学习器——表格数据的事实标准。
- 金融风控：信用评分卡、反欺诈。
- 医疗：疾病风险预测、疗效分析。
- 工业：设备故障预测、销量预测（回归树）。
- 特征工程：用 CART 的特征重要性做特征筛选。

(2) 回归任务（CART 独有的优势）

- 房价 / 销量 / 需求量预测：非线性回归建模。

- **视差 / 深度 / 光流估计**：逐像素连续值回归。
- **能耗与负载预测**：时序回归特征。

(3) 图像 / 视觉

- **语义分割**：像素分类与回归。
- **关键点 / 姿态**：树集成做坐标回归（早期方法）。
- **随机森林与分类器森林**：特征匹配与快速分类。

(4) 生物、环境与科学

- **基因 / 蛋白功能预测**：高维特征的非线性判别。
- **生态与环境建模**：物种分布、地物分类。
- **材料性能预测**：小样本高维材料数据。

(5) 在线服务与排序

- **CTR / 转化预估**：GBDT + 逻辑回归的经典组合。
- **搜索排序 (LTR)**：LambdaMART 的核心。
- **推荐系统**：GBDT 做特征交叉与排序。

5.2.8 与深度学习的联系

- **表格数据上 GBDT 常胜过深度网络**，是深度学习的强劲对手。
- **深度森林 (gcForest)**：用 CART 森林堆叠成多层，模拟深度结构。
- **NODE / 可微树**：把 CART 的软分裂嵌入网络，实现端到端训练。
- **特征交叉建模**：CART 的分裂天然构造特征组合，与 DNN 的 "Embedding + MLP" 互补；搜广告排序中"把 GBDT 的叶索引当 one-hot 送给 LR/MLP"是经典做法。
- **模型压缩 / 蒸馏**：把深度网络蒸馏到浅树，可在端侧低功耗部署。

5.3 PageRank

5.3.1 定位

PageRank (Page & Brin, 1998) 是 **Google 搜索的奠基算法**，也是 ICDM 2008 榜单成员。它把网页看成图的节点，超链接看成有向边，用**迭代**方式计算每个节点的重要性。

5.3.2 核心公式

$$\text{PR}(u) = \frac{1-d}{N} + d \sum_{v \in B_u} \frac{\text{PR}(v)}{L(v)}$$

其中：

- $\text{PR}(u)$ ：节点 u 的**重要性得分**（PageRank 值）。
- N ：图中节点总数。
- $d \in (0, 1)$ ：**阻尼系数**（damping factor），通常取 0.85，表示用户继续点击链接的概率。
- $1 - d$ ：**随机跳转概率**，用户随机打开任意网页的概率。
- B_u ：**指向 u 的所有节点集合**（入链来源）。
- $L(v)$ ：节点 v 的**出链数量**。
- $\text{PR}(v)/L(v)$ ： v 把自己的重要性**均分**给它的每个出链。
- 含义：一个网页的重要性 = 随机跳转的基线 + 所有入链网页分来的重要性之和。

5.3.3 矩阵形式

$$\mathbf{r} = \frac{1-d}{N} \mathbf{1} + d M^\top \mathbf{r}$$

其中：

- $\mathbf{r} \in \mathbb{R}^N$ ：所有节点的 PageRank 向量。
- $\mathbf{1}$ ：全 1 向量。
- M ：**列随机转移矩阵**， $M_{uv} = 1/L(v)$ 表示从 v 跳到 u 的概率（ v 有链到 u 时）。
- $M^\top$ ：转置，使 $\mathbf{r}$ 按列更新。
- 含义：这是一个**不动点方程**，用幂迭代 $\mathbf{r}^{(t+1)} = \frac{1-d}{N} \mathbf{1} + d M^\top \mathbf{r}^{(t)}$ 求解。

5.3.4 收敛性

- 阻尼系数 $d < 1$ 保证转移矩阵**本原**，幂迭代必收敛到唯一平稳分布。
- 收敛速度由 d 决定， d 越大收敛越慢（通常迭代几十次即可）。
- 等价于求矩阵 $\frac{1-d}{N} \mathbf{1} \mathbf{1}^\top + d M^\top$ 的**主特征向量**。

5.3.5 PageRank 变体总览

变体	改动点	解决的问题
个性化 PR (PPR)	跳转向量换成 e_q	与查询 / 用户相关
主题敏感 PR	多个主题跳转向量	多主题排序
加权 PR	边权不相等	链接强度不同
反向 PR	在转置图上迭代	度量"外向重要性"
TrustRank	可信种子作跳转向量	抗垃圾链接
Anti-TrustRank	用垃圾页面种子	反向发现作弊页
RWR	从固定点重启动	图上的相似度度量
Manifold Ranking	与 RWR 同构	半监督排序
TextRank / LexRank	词 / 句为节点	文本摘要与关键词
HITS	同时求 hub / authority	查询相关的重要性
SimRank	拓扑相似度递归定义	结构相似的节点
Katz / 热核	幂级数 / 指数核	平滑的多跳影响力
Monte Carlo PR	随机游走采样	极大图近似计算
BlockRank / 增量 PR	分块 / 局部更新	工程加速

5.3.6 个性化与主题变体

(1) 个性化 PageRank (PPR)

把均匀跳转向量换成**集中在某个（组）节点上的向量**：

$$\text{PR}_q(u) = (1 - d) p_q(u) + d \sum_{v \in B_u} \frac{\text{PR}_q(v)}{L(v)}, \quad p_q(u) = \begin{cases} 1, & u = q \\ 0, & u \neq q \end{cases}$$

其中：

- p_q ：个性化（偏好）向量，也称**重启动分布**。
- q ：源节点（用户当前兴趣点、查询实体）。
- 含义：把"全网重要性"换成"**从 q 看上去的重要性**"，直接当图上的相似度用。
- 工程上一般不显式求逆，而用**截断随机游走**：

$$\text{PPR}_q \approx (1 - d) \sum_{t=0}^T d^t M^t e_q$$

——止于 T 步或残差小于阈值，这叫 **Forward Push / Bookmark-Coloring**；把每步的残差存下来（**残差向量**），就能得到 $O(1/\epsilon)$ 的近似算法。

(2) 主题敏感 PageRank (Topic-Sensitive PageRank)

为每个主题 t 准备一个跳转向量 p_t （该主题目录下的代表性页面），离线算好 K 个向量 $\{\text{PR}_t\}$ ；在线时根据查询 / 用户画像**线性混合**：

$$\text{PR}_{\text{user}}(u) = \sum_{t=1}^K \lambda_t \text{PR}_t(u), \quad \sum_t \lambda_t = 1, \quad \lambda_t \geq 0$$

其中 λ_t ：用户属于主题 t 的**兴趣权重**。含义：**离线算好、在线只需一次加权求和**——比在线跑 PPR 便宜得多。

(3) 加权 PageRank

边权不同时，转移概率为**归一化边权**：

$$\text{PR}(u) = \frac{1 - d}{N} + d \sum_{v \in B_u} w_{v \rightarrow u} \text{PR}(v), \quad \sum_u w_{v \rightarrow u} = 1$$

其中 $w_{v \rightarrow u}$ ：从 v 到 u 的**归一化"投票份额"**；适用于"同一页面上链接多则每个链接权重小"的情形。

(4) TrustRank / Anti-TrustRank (抗垃圾链接)

$$\text{TrustRank}(u) = (1 - d) p_{\text{trust}}(u) + d \sum_{v \in B_u} \frac{\text{TrustRank}(v)}{L(v)}$$

其中 p_{trust} ：**可信种子集**（如 .gov / .edu 或人工审核页）上的分布。含义：
- **信任从种子向外传播且逐层衰减**，垃圾页很难进入信任传播链；
- **Anti-TrustRank** 把跳转向量换成**已知垃圾页**，得到"垃圾度"，与 TrustRank 组合即可做**半监督的作弊页面发现**；
- 这是 Google **BadRank / TrustRank** 类反作弊算法的基础。

5.3.7 图上的其他随机游走与中心性方法

(1) 带重启的随机游走 (RWR) 与图相似度

$$r_q^{(t+1)} = \alpha W r_q^{(t)} + (1 - \alpha) e_q, \quad r_q^* = (1 - \alpha)(I - \alpha W)^{-1} e_q$$

其中：

- W ：**行归一化**的邻接矩阵（ $W = D^{-1}A$ ，不同文献略有差异）。

- $\alpha \in (0, 1)$: **重启概率** (越大则越局限于 q 的局部邻域)。
- e_q : 源节点上的**单位向量** (重启目标)。
- 含义: r_q^* 就是**节点 q 与其他节点的图相似度**, 它是**个性化 PageRank 的等价形式** (只是记号不同: $\alpha \leftrightarrow d$)。
- 应用: 图上的近邻检索、推荐、链路预测、**Manifold Ranking** (半监督排序)。
- 与 4.5.5 的标签传播完全同构:

$$F^* = (I - \alpha S)^{-1} Y \quad \Longleftrightarrow \quad r_q^* = (1 - \alpha)(I - \alpha W)^{-1} e_q$$

(2) HITS (Hubs and Authorities)

每个节点有两个分数, **互相增强**:

$$a = A^\top h, \quad h = A a, \quad \text{迭代后归一化}$$

其中:

- a : **Authority 分数** (被好 hub 指向的页面更重要) ;
- h : **Hub 分数** (指向多好 authority 的页面是好 hub) ;
- 收敛到 $A^\top A$ (authority) 与 $AA^\top$ (hub) 的**主特征向量**。

PageRank 与 HITS 的三大区别:

维度	PageRank	HITS
查询相关性	查询无关 (全局单一向量)	查询相关 (子图上重算)
输出	单一分数	两组分数 (hub / authority)
稳定性	抗垃圾链接 (受随机跳转约束)	易被"互指链接"作弊
计算	离线全局一次	在线对候选集迭代

(3) SimRank (结构相似度)

递归定义: "两个点的邻居相似, 则这两个点也相似" :

$$s(a, b) = \frac{C}{|I(a)| |I(b)|} \sum_{i \in I(a)} \sum_{j \in I(b)} s(i, j), \quad s(a, a) = 1$$

其中:

- $I(a)$: 指向 a 的**入邻居集合**;
- $C \in (0, 1)$: **衰减因子**;
- 含义: **不看链接指向谁、只看链接结构**, 因此能发现"两个品类的商品有相似买家"这类**结构等价性**;
- 与 PageRank 的关系: SimRank 本质上是"两个随机游走相遇的概率"。

(4) Katz 中心性与热核中心性

$$\text{Katz} : x = \sum_{k=1}^{\infty} \beta^k A^k \mathbf{1} = ((I - \beta A)^{-1} - I) \mathbf{1}, \quad \text{Heat} : x = e^{-\beta L} \mathbf{1}$$

其中：

- β ：衰减系数（需 $\beta < 1/\lambda_{\max}(A)$ 保证收敛）；
- A^k ： k 跳路径数，故 Katz 是“所有长度路径的加权计数”；
- $L = D - A$ ：拉普拉斯矩阵；热核把“扩散”换成连续时间。
- 含义：PageRank 是固定归一化 + 随机跳转的版本，Katz 是不归一化 + 无跳转的版本，两者都度量“多跳可达性”。

5.3.8 文本与其他图上的变体

(1) TextRank (关键词与摘要)

把文本建为词共现图或句子相似图，直接跑 PageRank 式迭代：

$$\text{WS}(V_i) = (1 - d) + d \sum_{V_j \in \text{In}(V_i)} \frac{w_{ji}}{\sum_{V_k \in \text{Out}(V_j)} w_{jk}} \text{WS}(V_j)$$

其中：

- V_i ：词或句子节点； w_{ji} ：共现次数或句子相似度。
- 输出：词的重要性（关键词抽取）或句子的重要性（抽取式摘要）。
- **LexRank**：句子图上的变体，用 TF-IDF 余弦相似度作边权；另有 **Positional Power Iteration**（句子重要性加上位置先验）。

(2) 推荐、知识图谱与二部图

- **二部图上的 PR**：用户-物品、查询-文档、作者-论文。
- **异质图上的 PR**：不同节点类型用不同阻尼（如“跨类型跳转”与“同类型跳转”分开），或者说“Drunkard 随机游走”。
- **知识图谱的实体排序**：PPR 作为链路预测与实体重要性的强基线。

5.3.9 大规模与动态图上的计算

(1) Monte Carlo PageRank (近似算法)

$$\hat{\text{PR}}(u) = \frac{1}{R} \sum_{r=1}^R 1[\text{第 } r \text{ 次随机游走落在 } u], \quad \text{误差} = O\left(\frac{1}{\sqrt{R}}\right)$$

其中：

- R ：从源头出发的**随机游走次数**。
- 每走一步以 d 的概率继续、以 $1 - d$ 的概率停止。
- 含义：**只需存每个游走当前的位置**，内存 $O(R)$ 而非 $O(N)$ ；适合只算**少数源节点**的 PPR。

(2) BlockRank 与增量更新

- **BlockRank**：按域名分块，先在块内算局部 PR，再用块间重要性加权作为初值，可使全局迭代**从更好的起点开始**，加速数倍。
- **增量 PageRank**：若有 δ 的图变化，则只需解**修正方程**：

$$\Delta PR = (I - dM^\top)^{-1}b, \quad b = \text{局部变化引起的跳转分布差}$$

其中 b 只在受影响节点上非零，用**局部迭代 / 近似求解**即可，避免全图重算。

(3) 工程实现要点

技巧	作用
稀疏矩阵 CSR / CSC + 向量乘	每轮 $O(E)$ 而非 $O(N^2)$
邻接表 + 阻尼因子提前解法	减内存
分块 + 多线程 / GPU	亿级边上的加速
悬挂节点（出度为 0）统一处理	保证随机矩阵
误差阈值或固定轮数停止	控制精度与耗时

其中**悬挂节点**的两种常见处理：

- 把它的质量**均匀分给所有节点**： PR_{dangling}/N ；
- 或**分给个性化向量** p_q （PPR 更常用）。

5.3.10 应用方向

(1) 图像 / 视觉

- **显著性检测**：把图像块建图，用 PageRank 找“最受关注”的区域。
- **图像检索重排序**：在相似度图上做流形排序（Manifold Ranking），本质是 PageRank 的变体。
- **超像素图**：超像素为节点、相似度为边，做图上的重要性传播。
- **点云/网格分析**：网格顶点的重要性排序。

(2) 搜索、推荐与文本

- **网页搜索排序**：Google 的原始排序信号。
- **关键词 / 实体重要性 (TextRank)**：自动摘要与关键词抽取。
- **推荐系统**：用户-物品二部图上的重要性传播。
- **问答与知识图谱**：实体重要性、链接预测排序。

(3) 社交与传播分析

- **意见领袖识别**：社交网络影响力排序 (KOL)。
- **谣言 / 舆情传播**：关键传播节点定位。
- **影响力最大化**：种子用户选取。

(4) 科学与工程网络

- **学术引用分析**：论文 / 期刊重要性 (Eigenfactor)。
- **生物网络**：蛋白质互作网络中的关键蛋白识别。
- **交通网络**：路网节点重要性、拥堵传播分析。
- **电力 / 通信网络**：关键节点与脆弱性评估。

5.3.11 与深度学习的联系

- **图神经网络 (GNN)**：GCN 的传播规则 $H^{(l+1)} = \sigma(\hat{A}H^{(l)}W^{(l)})$ 与 PageRank 的迭代传播同源，都是"邻居信息聚合"。
 - **注意力即传播**：自注意力可看作**带权、可学习的** PageRank 式传播。
 - **随机游走**：Node2Vec、DeepWalk 用随机游走学图嵌入，直接继承 PageRank 思想。
 - **PPR 与现代 GNN**：**APPNP**、**PPRGo** 直接把 PPR 传播写进网络层——用跳转连接受限的多层聚合。
 - **图卷积的极限**：当层数 $\rightarrow \infty$ 时 GCN 会退化为"同一个向量"，即**过平滑**；而 PageRank 用一个阻尼因子 d 恰好避开了这个问题——这就是为什么 PPR 能作为"**无限层 GNN**"的合理替代。
 - **Transformer 的随机游走解释**：多头注意力的单头可看作一个"学出来的随机游走矩阵"。
-

5.4 神经网络 / 深度学习 (Neural Networks / Deep Learning)

5.4.1 单神经元

$$a = \phi\left(\sum_{j=1}^D w_j x_j + b\right) = \phi(w^\top x + b)$$

其中:

- x_j : 输入第 j 维。
- w_j : 权重。
- b : 偏置。
- ϕ : 激活函数 (Sigmoid、ReLU、tanh) 。
- a : 神经元输出。

5.4.2 多层感知机 (MLP)

$$h^{(l)} = \phi\left(W^{(l)}h^{(l-1)} + b^{(l)}\right)$$

其中:

- $h^{(l)}$: 第 l 层激活。
- $W^{(l)}$: 第 l 层权重矩阵。
- $b^{(l)}$: 第 l 层偏置。
- $h^{(0)} = x$: 输入。

万能逼近定理: 足够宽的单隐层网络可逼近任意连续函数。

5.4.3 反向传播

链式法则:

$$\frac{\partial L}{\partial W^{(l)}} = \delta^{(l)}(h^{(l-1)})^\top, \quad \delta^{(l)} = \left((W^{(l+1)})^\top \delta^{(l+1)}\right) \odot \phi'\left(z^{(l)}\right)$$

其中:

- L : 损失。
- $\delta^{(l)}$: 第 l 层的**误差项** (损失对该层预激活的梯度) 。

- $z^{(l)} = W^{(l)}h^{(l-1)} + b^{(l)}$: 预激活。
- $\odot$: 逐元素乘。
- ϕ' : 激活函数导数。

5.4.4 网络架构家族总览

神经网络不是一个算法，而是一个可自由拼装的函数逼近器。差异全在四个零件上：层形状、激活函数、损失函数、优化器。

家族	核心结构	标志性能力
前馈 (MLP)	全连接层堆叠	通用函数逼近
CNN	卷积 + 池化	局部性、平移等变
RNN / LSTM / GRU	隐状态递归	序列、变长
Transformer	自注意力 + FFN	长距离依赖、可并行
GNN	图上的消息传递	不规整结构
自编码器 (AE / VAE)	编码器 + 解码器	表征学习、生成
GAN	生成器 + 判别器对抗	高质量生成
扩散模型	逐步去噪	当前生成 SOTA
神经算子 (FNO / DeepONet)	函数空间的映射	求解 PDE
状态空间模型 (SSM / Mamba)	线性递归 + 选择机制	长序列高效

5.4.5 激活函数族

激活函数决定了网络的表达力、梯度行为与训练稳定性。

激活	公式 $\phi(z)$	导数	特点
Sigmoid	$\frac{1}{1+e^{-z}}$	$\phi(1-\phi)$	饱和、梯度消失
Tanh	$\frac{e^z - e^{-z}}{e^z + e^{-z}}$	$1 - \phi^2$	零中心，仍饱和
ReLU	$\max(0, z)$	$1[z > 0]$	稀疏、不饱和 ；负区“死亡”
LeakyReLU	$\max(\alpha z, z)$	$1[z > 0] + \alpha 1[z \leq 0]$	修复死亡神经元
PReLU	$\max(\alpha z, z), \alpha$ 可学	同左	自适应负斜率
ELU	z 或 $\alpha(e^z - 1)$	1 或 $\phi + \alpha$	负区平滑、均值近零
GELU	$z \Phi(z)$	平滑近似 ReLU	Transformer 标配
Swish / SiLU	$z \sigma(\beta z)$	平滑、非单调	深度模型常用
Mish	$z \tanh(\text{softplus}(z))$	平滑、非单调	检测 / 分割
Softmax	$\frac{e^{z_c}}{\sum_k e^{z_k}}$	$\text{diag}(\phi) - \phi\phi^\top$	输出：多项分布

几个关键的理论事实：

- **非线性必要性**：若不用非线性激活，多层网络**严格等于**单层线性变换：

$$W_2(W_1x) = (W_2W_1)x$$

- **GELU 的常用近似**（工程实现）：

$$\text{GELU}(z) \approx 0.5z \left(1 + \tanh \left[\sqrt{2/\pi} (z + 0.044715z^3) \right] \right)$$

- **死亡 ReLU 问题**：若某神经元的输入长期为负，梯度为 0，权重永不更新——这是 LeakyReLU / PReLU / ELU 存在的理由。
- **饱和与梯度消失的联系**： $|\phi'| \leq 0.25$ (Sigmoid) $\rightarrow$ 多层链式相乘指数衰减，这就是 ResNet / BN / ReLU 需要的原因。
- **输出层的选择**：二分类 $\rightarrow$ Sigmoid；多分类 $\rightarrow$ Softmax；多标签 $\rightarrow$ 逐类 Sigmoid；回归 $\rightarrow$ 线性；计数 $\rightarrow$ Softplus / 泊松损失；比例 $\rightarrow$ Sigmoid + 归一化。

5.4.6 损失函数变体

任务	损失	公式
回归	MSE	$\frac{1}{N} \sum_i (y_i - \hat{y}_i)^2$
稳健回归	Huber	小误差用 MSE、大误差用 MAE: $\begin{cases} \frac{1}{2}r^2, & r \leq \delta \\ \delta(r - \frac{1}{2}\delta), & \text{否则} \end{cases}$
分类	交叉熵	$-\sum_c y_c \log \hat{p}_c$
多标签	二元交叉熵	$-\sum_c [y_c \log \hat{p}_c + (1 - y_c) \log(1 - \hat{p}_c)]$
类别不平衡	Focal Loss	$-\alpha (1 - p_t)^\gamma \log p_t$
度量学习	Triplet	$[\ f(a) - f(p)\ ^2 - \ f(a) - f(n)\ ^2 + m]_+$
对比学习	InfoNCE	$-\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_k \exp(\text{sim}(z_i, z_k)/\tau)}$
生成	KL / ELBO	$\mathbb{E} \log p_\theta(x z) - \text{KL}(q(z x) \ p(z))$
生成对抗	对抗损失	$\min_G \max_D \mathbb{E} \log D(x) + \mathbb{E} \log(1 - D(G(z)))$
去噪扩散	噪声预测	$\mathbb{E}_{x_0, \epsilon, t} \ \epsilon - \epsilon_\theta(x_t, t)\ ^2$

其中：

- p_t ：正确类的预测概率； $\gamma \geq 0$ ：聚焦参数（ $\gamma = 0$ 退化为交叉熵， γ 越大则易分样本被压得越低）； α ：类权重。
- a, p, n ：锚点 / 正样本 / 负样本； m ：间隔。
- z ：归一化后的嵌入； τ ：温度（越小则负样本越被惩罚）。
- $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon$ ：前向加噪的中间样本。
- 含义：换个损失函数就等于换个任务——网络结构可以完全不变。

5.4.7 优化器族

令 $g_t = \nabla_\theta L_t(\theta_{t-1})$ 为当前梯度， η 为学习率：

优化器	更新规则	关键思想
SGD	$\theta \leftarrow \theta - \eta g$	基线，泛化常最好
Momentum	$v \leftarrow \beta v + g, \theta \leftarrow \theta - \eta v$	动量、加速穿越平坦区
Nesterov	在 $\theta - \eta \beta v$ 处算梯度	前瞻修正
AdaGrad	$\theta \leftarrow \theta - \frac{\eta}{\sqrt{G+\epsilon}} g$	每参数自适应（ G 累加已见平方梯度和）
RMSProp	$E[g^2] \leftarrow \beta E[g^2] + (1 - \beta) g^2$	滑窗代替累加，修复 AdaGrad 过早衰减
Adam	$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$	一阶 + 二阶矩估计
AdamW	解耦权重衰减（L2 不进入 Adam 的矩）	现代默认选择

Adam 的完整更新（含偏差校正）：

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}, \quad \theta_t = \theta_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \epsilon}}$$

其中：

- m_t ：**一阶矩**（梯度的指数滑动均值，即动量）；
- v_t ：**二阶矩**（梯度平方的滑动均值，即自适应学习率）；
- $\beta_1 \approx 0.9$ 、 $\beta_2 \approx 0.999$ ：两个衰减率；
- $1 - \beta^t$ ：**偏差校正**——因为 $m_0 = v_0 = 0$ ，训练早期矩估计偏小，除以 $1 - \beta^t$ 才能无偏；
- ϵ ：数值稳定项。
- 含义：Adam = "带偏差校正的动量 + 自适应学习率"，对初始学习率不敏感，但泛化有时不如调好动量的 SGD——所以现代实践中常用 **Adam 训练 + 早停 / 余弦退火**。

学习率调度：

调度	公式
Step / MultiStep	到设为步数时乘 γ
余弦退火	$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_0 - \eta_{\min})(1 + \cos \frac{t\pi}{T})$
预热 (Warmup)	$\eta_t = \eta_0 \cdot t / T_w \ (t < T_w)$
OneCycle	先升后降
ReduceLROnPlateau	验证指标停滞时衰减

含义：**学习率是最重要的超参数**；“预热 + 余弦退火 + 权重衰减” 是 Transformer 类模型几乎固定的配方（为什么需要预热？因为 Adam 的二阶矩初期估计不可靠）。

5.4.8 正则化与归一化变体

(1) 正则化手段

方法	公式 / 做法	解决的问题
L2 (权重衰减)	$L + \frac{\lambda}{2} \ W\ ^2$	过拟合、权重爆炸
L1	$L + \lambda \ W\ _1$	稀疏、剪枝友好
Dropout	训练时 $h \leftarrow h \odot m/(1 - p)$, 推理不变	破坏共适应、集成效应
DropPath / Stochastic Depth	整层随机丢弃	深层网络 (如 ViT)
标签平滑	$y \leftarrow (1 - \epsilon)y + \epsilon/K$	防止过度自信
MixUp / CutMix	样本与标签插值	数据增强正则
早停	验证损失不再下降时停	最简单有效
数据增强	翻转 / 剪裁 / RandAugment	不变性先验

其中 **Dropout 的推理期望一致性**：

$$\mathbb{E}_m[h \odot m/(1 - p)] = h, \quad \text{方差} = h^2 \cdot \frac{p}{1 - p}$$

含义：除以 $(1 - p)$ 是为了让训练与推理的**期望输出一致** (inverted dropout) 。

(2) 归一化层族

$$\text{BN}(x) = \gamma \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} + \beta$$

其中：

- μ_B, σ_B^2 ：当前批量在通道维上的均值 / 方差。
- γ, β ：可学习的**缩放与平移**（保证归一化不损害表达力）。
- 训练时用批量统计，推理时用**滑动平均** (running mean / var) 。
- BN 的**内部协变量变移假单**现已被质疑，但事实证明其真正作用是 **使损失面更平滑、允许更大学习率**。

归一化	统计维度	适用场景
BatchNorm	(N, H, W) → 每通道	CNN、大 batch
LayerNorm	(C, H, W) → 每样本	RNN、Transformer
InstanceNorm	(H, W) → 每样本每通道	风格迁移
GroupNorm	把通道分组后 (组, H, W)	小 batch 下的 CNN
RMSNorm	只除以均方根，不减均值	LLaMA 类模型（更快）
WeightNorm	对权重向量归一	与 BN 等价的替代

含义：归一化位置的选择（Pre-Norm vs Post-Norm）直接影响深层网络的稳定性，现代 Transformer 几乎都用 **Pre-Norm + RMSNorm**。

(3) 初始化与残差连接

初始化	方差	适用激活
Xavier / Glorot	$\frac{2}{n_{in}+n_{out}}$	Sigmoid / Tanh
He / Kaiming	$\frac{2}{n_{in}}$	ReLU 家族
正交初始化	$W^T W = I$	RNN
LSUV / 数据驱动	逐层实测方差	无归一化层时

残差连接与恒等映射：

$$y = F(x) + x \implies \frac{\partial y}{\partial x} = \frac{\partial F}{\partial x} + I$$

含义：那个 $+I$ 保证了梯度在反向传播时**至少以恒等速率传递**，即使 $\partial F/\partial x$ 很小也不会消失。这就是能训到 100+ 层的根本原因。

(4) 其他正则/稳定手段

- 谱归一化 (Spectral Norm) : $W \leftarrow W/\sigma_{\max}(W)$ ，保证 Lipschitz 常数，GAN 判别器的标配。
- 梯度裁剪 (Gradient Clipping) : $g \leftarrow g \cdot \min(1, c/\|g\|)$ 。
- 随机深度 / 层间 Dropout、梯度累积、混合精度 (AMP) 。
- Bayesian 手段：MC Dropout、深度集成 (Deep Ensemble) 、SWA / EMA 权重平均。

5.4.9 架构变体

(1) 卷积网络的变体

标准二维卷积：

$$(f * g)[i, j] = \sum_m \sum_n f[m, n] g[i - m, j - n]$$

变体	做法	带来什么
空洞卷积 (Dilated)	卷积核间插 $r - 1$ 个空洞	感受野指数增长，不增参数
转置卷积	反向卷积	上采样 / 分割
深度可分离卷积	逐通道卷积 + 1×1 卷积	参数量降为 $\frac{1}{C_{out}} + \frac{1}{k^2}$
分组卷积	通道分组后各自卷积	减少计算 (ResNeXt)
可变形卷积	采样位置可学习偏移	几何形变适应
池化	max / avg / 自适应	降分辨率、平移不变
空间金字塔池化 (SPP)	多尺度池化后拼接	任意尺寸输入

(2) 循环网络及其门控变体

$$h_t = \phi(W_{hh} h_{t-1} + W_{xh} x_t + b)$$

LSTM 的四门公式：

$$\begin{aligned} f_t &= \sigma(W_f[h_{t-1}, x_t] + b_f), \quad i_t = \sigma(W_i[h_{t-1}, x_t] + b_i), \\ o_t &= \sigma(W_o[h_{t-1}, x_t] + b_o), \quad c_t = f_t \odot c_{t-1} + i_t \odot \tanh(W_c[h_{t-1}, x_t] + b_c), \\ h_t &= o_t \odot \tanh(c_t) \end{aligned}$$

其中：

- f_t ：遗忘门（丢弃多少旧记忆）；
- i_t ：输入门（写入多少新信息）；
- o_t ：输出门（向外暴露多少记忆）；
- c_t ：细胞状态（信息高速公路）； h_t ：隐状态。
- 含义：门控 = 可学的遗忘曲线，使梯度能沿 c_t 无衰减地传播。

GRU 的两个门 (LSTM 的简化)：

$$\begin{aligned} z_t &= \sigma(W_z[h_{t-1}, x_t]), \quad r_t = \sigma(W_r[h_{t-1}, x_t]), \\ h_t &= (1 - z_t) \odot h_{t-1} + z_t \odot \tanh(W[r_t \odot h_{t-1}, x_t]) \end{aligned}$$

其中 z_t ：更新门； r_t ：重置门。参数比 LSTM 少约 1/3，效果相当。

(3) 注意力变体

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

其中：

- Q, K, V ：查询 / 键 / 值矩阵（由输入线性变换得到）。
- d_k ：键的维度；除以 $\sqrt{d_k}$ 是防止点积随维度增大而**方差爆炸**，使 softmax 不进入饱和区。
- 含义：输出是值的加权平均，权重由查询与键的相似度决定。

多头注意力（MHA）：

$$\text{MHA} = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O, \quad \text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

变体	关键改动	解决的问题
自注意力（Self-Attn）	Q, K, V 同源	序列内部建模
交叉注意力（Cross-Attn）	Q 来自解码器, K, V 来自编码器	多模态 / 翻译
因果掩码（Causal Mask）	上三角置 $-\infty$	自回归生成
MQA / GQA	多个头共享 K, V	减少 KV Cache 显存
FlashAttention	分块 + 在线 softmax	内存 $O(N)$ 、大幅加速
稀疏 / 局部注意力	只算局部窗口	长序列
线性注意力	去掉 softmax 核化	$O(N)$ 复杂度

(4) 图神经网络

$$H^{(l+1)} = \sigma\left(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H^{(l)} W^{(l)}\right)$$

其中：

- $\tilde{A} = A + I$ ：加了自环的邻接矩阵（保证自己也参与聚合）；
- $\tilde{D}$ ： $\tilde{A}$ 的度矩阵；
- 含义：先归一化平均邻居表征，再线性变换，与 PageRank 的传播同构。
- 变体：GraphSAGE（采样邻居）、GAT（注意力权重）、MPNN（通用消息传递）、Graph Transformer。

(5) 生成模型三大路线

路线	目标	采样方式
VAE	最大化 ELBO	编码器 + 重参数化 + 解码器
GAN	对抗博弈	生成器一次前向
扩散 (DDPM)	拟合噪声	多步去噪

三者的关键公式（已在 5.4.6 列出）各自的**采样速度与质量**是不同的：

- **VAE**：快，但模糊（拟合均方误差的代价）。
- **GAN**：快、锐利，但训练难、模式坍塌。
- **扩散**：质量最高，但采样需几十到几千步（用 DDIM / 蒸馏可压缩到 1~4 步）。
- **融合路线**：Latent Diffusion（VAE 编码到隐空间再扩散）、Consistency Models（一步生成）。

(6) 长序列与高效现代架构

架构	关键思想
SSM / S4 / Mamba	线性递归 + 选择性参数, $O(N)$ 且带长记忆
Linear Attention / RWKV	去掉二次注意力
状态空间 + 块卷积	FFT 加速训练
MoE (混合专家)	稀疏激活, 参数大但计算少

5.4.10 应用方向

(1) 图像 / 视觉

- **图像分类 / 检测 / 分割**：CNN 是当前主流。
- **超分辨率、去噪、去模糊**：图像到图像的回归。
- **风格迁移与图像生成**：GAN、扩散模型。
- **人脸 / 生物特征识别**：度量学习。
- **医学影像分析**：病灶检测与分割。

(2) 文本与语音

- **机器翻译与文本生成**：Seq2Seq、Transformer、LLM。
- **文本分类与情感分析**：嵌入 + 分类头。
- **语音识别与合成**：CTC、TTS。
- **信息抽取 / 问答**：预训练 + 微调。

(3) 推荐、搜索与广告

- **CTR / CVR 预估**：深度推荐模型（DeepFM、DIN）。
- **向量召回**：双塔模型生成嵌入。
- **搜索相关性**：语义匹配模型。

(4) 生物、医学与化学

- **蛋白质结构预测**：AlphaFold。
- **分子性质与药物设计**：图神经网络、生成模型。
- **基因 / 单细胞分析**：序列与表达建模。
- **医疗诊断辅助**：多模态（影像 + 文本 + 检验）。

(5) 工业、金融与科学计算

- **预测性维护**：传感器时序异常检测。
- **金融风控**：时序与图神经网络反欺诈。
- **气象 / 物理仿真**：神经算子、代理模型。
- **自动驾驶**：感知-预测-规划端到端。

(6) 通用基础模型

- **大语言模型**：预训练 + 提示 + 微调。
- **多模态大模型**：图文对齐与理解。
- **科学基础模型**：跨领域通用表征。

5.4.11 与前面算法的关系

- 逻辑回归 = 无隐层网络。
- SVM = 单层 + Hinge 损失。
- PCA = 线性自编码器。
- K-means = 硬分配的自编码器。
- Softmax 回归 = 单层网络 + 交叉熵。
- LR / SVM / NB 的梯度、IRLS、SMO 都是现代优化器的前身（见 3.3.11 / 3.4.11）。
- 树的集成（Bagging / Boosting）与深度网络的集成（Dropout、Deep Ensemble）目标一致：降方差。
- 深度学习是这些经典算法的非线性、端到端、可扩展版本。

详细内容见仓库 `cnn-transformer-notes.md`。

5.5 AdaBoost

5.5.1 核心思想

自适应提升：串行训练多个**弱分类器**，每个关注前一个分错的样本，最后加权投票成强分类器。

5.5.2 算法

样本权重 $D_t(i)$ ：第 t 轮中样本 i 的权重，初始均匀 $1/N$ 。

弱分类器误差：

$$\epsilon_t = \sum_{i=1}^N D_t(i) 1[h_t(x_i) \neq y_i]$$

其中：

- h_t ：第 t 个弱分类器。
- ϵ_t ：**加权错误率**。
- $D_t(i)$ ：样本 i 在第 t 轮的权重。

分类器权重：

$$\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \epsilon_t}{\epsilon_t} \right)$$

其中：

- α_t ：第 t 个弱分类器的**话语权**。
- ϵ_t 越小 $\rightarrow \alpha_t$ 越大（越准的越有发言权）。
- $\epsilon_t = 0.5$ 时 $\alpha_t = 0$ （等于瞎猜，无贡献）。

权重更新：

$$D_{t+1}(i) = \frac{D_t(i) \exp(-\alpha_t y_i h_t(x_i))}{Z_t}$$

其中：

- $y_i \in \{-1, +1\}$ ：真实标签。
- $h_t(x_i) \in \{-1, +1\}$ ：预测。
- $y_i h_t(x_i) = +1$ 表示分对， -1 表示分错。

- 分错时指数项 > 1 ，权重**增大**；分对时权重**减小**。
- Z_t : 归一化因子，使 $\sum_i D_{t+1}(i) = 1$ 。

最终分类器：

$$H(x) = \text{sign}\left(\sum_{t=1}^T \alpha_t h_t(x)\right)$$

其中 T 是弱分类器个数。

5.5.3 AdaBoost 变体总览

AdaBoost 家族的所有变体都在回答同一个问题：“**弱学习器应该输出什么？输出的权重怎么算？**”

变体	弱学习器输出	权重 α_t	特点
Discrete AdaBoost	$\{-1, +1\}$	$\frac{1}{2} \ln \frac{1-\epsilon}{\epsilon}$	经典版
Real AdaBoost	实数（对数几率）	固定为 1	用置信度，收敛快
Gentle AdaBoost	实数（加权回归）	固定为 1	最稳健 ，不易过拟合
LogitBoost	实数（对数几率）	牛顿步长	等价于可加的 logistic 回归
BrownBoost	实数	随时间衰减	抗噪声样本
SAMME	类别标签	$\ln \frac{1-\epsilon}{\epsilon} + \ln(K - 1)$	多类（离散）
SAMME.R	类概率	固定为 1	多类（实数，更好）
AdaBoost.M1	类别标签	同二类	多类（需 $\epsilon < 1/2$ ）
AdaBoost.M2	类别 + 置信度	伪损失	处理不均衡多类
AdaBoost.R2	实数值	按中位数误差	回归
Cost-sensitive	类别标签	同二类	代价敏感（改初始权重）
级联（Cascade）	类别标签	同二类	实时检测（Viola-Jones）

5.5.4 统一视角：前向分步加法模型与指数损失

AdaBoost 不是“启发式加权投票”，而是在**函数空间最小化一个特定损失**的。

(1) 加法模型与前向分步

$$F_m(x) = F_{m-1}(x) + \alpha_m h_m(x), \quad H(x) = \text{sign}(F_T(x))$$

每轮只优化**新加的那一项**（而不是同时优化全部）：

$$(\alpha_m, h_m) = \arg \min_{\alpha, h} \sum_{i=1}^N L(y_i, F_{m-1}(x_i) + \alpha h(x_i))$$

(2) 指数损失与权重的自然导出

取 **指数损失**：

$$L(y, F(x)) = \exp(-y F(x))$$

则最优权重与样本权重都可以推出来：

$$\alpha_m^* = \frac{1}{2} \ln \frac{1 - \epsilon_m}{\epsilon_m}, \quad w_{m+1}(i) \propto \exp(-y_i F_m(x_i)) = w_m(i) \exp(-\alpha_m y_i h_m(x_i))$$

其中：

- $\epsilon_m = \sum_i w_m(i) 1[h_m(x_i) \neq y_i]$ ：当前弱学习器的**加权错误率**。
- 含义：**样本权重并不是人为规定的**，它就是**指数损失的当前损失值**——分错了的样本指数损失大，因而下一轮权重自动变大。
- **总体损失上界**：

$$\frac{1}{N} \sum_{i=1}^N 1[H(x_i) \neq y_i] \leq \prod_{m=1}^T Z_m = \prod_{m=1}^T 2\sqrt{\epsilon_m(1 - \epsilon_m)}$$

其中 Z_m 是第 m 轮的归一化因子。含义：**每轮只要 $\epsilon_m < 0.5$ ，错误率就指数下降**。

- **结论**：AdaBoost = **指数损失下的前向分步加法模型**；GBDT = **任意可微损失下的前向分步加法模型**（见 3.5.9）。

5.5.5 实数输出变体：Real / Gentle / LogitBoost

(1) Real AdaBoost（输出置信度，而非仅标签）

弱学习器输出一个**实数分数**（正比于对数几率）：

$$f_t(x) = \frac{1}{2} \ln \frac{P_w(y = 1 | x)}{P_w(y = -1 | x)}, \quad F_t = F_{t-1} + f_t$$

其中：

- P_w ：用**加权样本**训练出的概率估计。
- 含义：比 Discrete AdaBoost **多用了概率信息**，收敛更快；但输出可能是极端值（ $\pm\infty$ ）——这正是 Gentle 版要修的。
- 样本权重更新： $w_{t+1}(i) \propto w_t(i) \exp(-y_i f_t(x_i))$ 。

(2) Gentle AdaBoost (最稳健)

不做分类、直接做加权最小二乘回归，权重步长固定为 1：

$$f_t = \arg \min_f \sum_{i=1}^N w_t(i) \left(\tilde{y}_i - f(x_i) \right)^2, \quad \tilde{y}_i = y_i \in \{-1, +1\}$$

其中：

- $\tilde{y}_i$ ：把类别 $\{0, 1\}$ 编码为 $\{-1, +1\}$ 的**回归目标**。
- $F_t = F_{t-1} + f_t$ ，**无权重系数** α 。
- 含义：Real AdaBoost 的更新可能把权重推到极端（某些样本权重 $\rightarrow 0$ ）。Gentle 通过“**缓步走**”（固定步长 1）避开了这个问题，因此在**噪声标签与小样本**上表现最好。

(3) LogitBoost (与 logistic 回归等价)

换用**对数损失**，用牛顿法在加法模型中逐步拟合：

$$L(y, F) = \log \left(1 + \exp \left(- 2yF(x) \right) \right), \quad p(x) = \frac{1}{1 + \exp \left(- 2F(x) \right)}$$

每轮用**加权最小二乘**拟合工作响应：

$$z_i = \frac{y_i^* - p(x_i)}{p(x_i)(1 - p(x_i))}, \quad w_i = p(x_i)(1 - p(x_i)), \quad y_i^* = \frac{y_i + 1}{2} \in \{0, 1\}$$

其中：

- z_i ：**工作响应**（与 3.3.11 的 IRLS 完全同形）；
- w_i ：**伪权重**，恰好是伯努利方差。
- 含义：LogitBoost 就是**用加法模型逐步实现的逻辑回归**——它把“线性 LR”换成“基函数叠起来的 LR”，因此能处理非线性边界；当基函数是线性时，它退化为普通 LR。

(4) BrownBoost

引入一个**时间变量** t （随时间推迟样本的权重增加幅度），允许部分样本被“**放弃**”：含义：对**噪声标签**鲁棒——噪声样本不会无限地吸引后续弱学习器，代价是需要提前知道噪声水平。

5.5.6 多类与回归变体

(1) SAMME (Stagewise Additive Modeling with a Multiclass Exponential loss)

直接用**离散**的类别标签作弱学习器输出：

$$\alpha_m = \ln \frac{1 - \epsilon_m}{\epsilon_m} + \ln(K - 1), \quad H(x) = \arg \max_k \sum_{m=1}^M \alpha_m 1[h_m(x) = k]$$

其中：

- K ：类别数；多出的 $\ln(K - 1)$ 正是"随机猜测的错误率 $1 - 1/K$ "的修正项；
- 要求： $\epsilon_m < 1 - 1/K$ （弱学习器必须优于随机猜），否则 $\alpha_m \leq 0$ ；
- 含义：二类时 $\ln(K - 1) = 0$ ，退化为经典 AdaBoost；选举投票的用法是"每轮给一类投一票"。

(2) SAMME.R (用类别概率的实数版)

$$h_m^k(x) = (K - 1) \left(\log p_m^k(x) - \frac{1}{K} \sum_{j=1}^K \log p_m^j(x) \right), \quad H(x) = \arg \max_k \sum_{m=1}^M h_m^k(x)$$

其中：

- $p_m^k(x)$ ：第 m 个弱学习器给出的类 k 的概率估计；
- 第二项是**中心化**（避免各类共同漂移）；
- 系数 $(K - 1)$ ：使多个弱学习器可直接相加而不需权重（类似 Gentle 的思路）；
- 含义：**SAMME.R 通常比 SAMME 收敛更快、精度更高**，是 scikit-learn `AdaBoostClassifier` 的默认算法（`algorithm='SAMME.R'`）。

(3) 回归变体：AdaBoost.R2

每个样本的"错误"由**相对误差**定义：

$$\ell_i = \frac{|y_i - h_m(x_i)|}{D}, \quad D = \max_i |y_i - h_m(x_i)|$$

则加权平均误差与权重：

$$\bar{\ell}_m = \sum_i w_m(i) \ell_i, \quad \beta_m = \frac{\bar{\ell}_m}{1 - \bar{\ell}_m}, \quad w_{m+1}(i) \propto w_m(i) \beta_m^{1-\ell_i}$$

最终预测用**所有弱学习器的加权中位数**：

$$H(x) = \text{weighted median} \left\{ h_m(x), \text{weight } \log \frac{1}{\beta_m} \right\}$$

含义：

- 为什么用**中位数**而不是均值？因为平方损失的均值易受离群点影响，中位数更鲁棒（与 Gentle 选固定步长同理）。
- 错误率越高（ $\bar{\ell}_m$ 大）， β_m 越大、 $\log(1/\beta_m)$ 越小——不准确的回归器被自动降权。

(4) 多类回归与不平衡变体

- **AdaBoost.M1**: 直接多类, 但要求 $\epsilon_m < 1/2$, 约束太强, 已被 SAMME 取代。
- **AdaBoost.M2**: 用**伪损失** (pseudo-loss) 代替错误计数, 允许输出**类间置信度**, 适合不均衡与硬分类器。
- **代价敏感 AdaBoost**: 修改初始权重 $D_1(i) \propto C(y_i)$, 与 5.2.5 的树代价敏感同一个思路。

5.5.7 级联结构与与其他集成的对比

(1) 级联 AdaBoost (Viola-Jones 人脸检测)

把多个 AdaBoost 分类器**串起来**, 每级用较少的弱分类器, 只保留高召回:

$$\text{第 } \ell \text{ 级输出: } H_\ell(x) = \text{sign}\left(\sum_{t=1}^{T_\ell} \alpha_t h_t(x) - \theta_\ell\right)$$

其中:

- T_ℓ : 第 ℓ 级的**弱分类器个数** (逐级增大) ;
- θ_ℓ : **阈值偏移**, 用来调节该级的**召回 / 误报**。
- 训练目标: 固定第 ℓ 级的**目标误报率 f** 与**最小可接受召回率 d** , 逐个加弱分类器直到满足 (**AdaBoost 的预训练目标与普通集成不同**) 。
- 含义: **大部分背景窗口在第 1~2 级就被拒绝** (每级只需 $O(1)$ 个特征) , 整体评估代价降到常数级——这是**实时人脸检测能跑 15 FPS 的关键**。
- 同样的级联思想被 **Cascade R-CNN** (提高检测 IoU 阈值)、**Early-Exit Networks**、**级联排序模型** 继承。

(2) AdaBoost 与 GBDT / Bagging 的关系

维度	Bagging / RF	AdaBoost	GBDT / XGBoost
训练方式	并行	串行	串行
主要作用	降方差	降偏差	降偏差
损失	任意	指数损失	任意可微损失
样本权重	均等	重加权关键	不需要 (用梯度代替)
权重系数	均等	α_t (根据错误率)	学习率 ν (固定)
对噪声	鲁棒	敏感	比 AdaBoost 鲁棒

从 AdaBoost 到 GBDT 的关键一步: 把"重加权样本"换成"拟合负梯度"——机制不同, 但都是前向分步加法。

5.5.8 应用方向

(1) 图像 / 视觉

- **Viola-Jones 人脸检测**: AdaBoost + Haar 特征 + 级联, 实时人脸检测的里程碑。
- **目标检测**: 级联分类器逐级过滤背景。
- **特征选择**: AdaBoost 天然做特征选择 (只选有用的弱分类器)。

(2) 表格数据与风控

- **信用评分与风控**: 多弱分类器集成提升违约预测精度。
- **竞赛基线**: Kaggle 早期表格数据常用。
- **客户流失 / 营销响应**: 与决策树桩组合。

(3) 生物、医学与文本

- **生物信息学**: 基因表达数据分类、蛋白质功能预测。
- **医学诊断**: 多指标融合的辅助诊断。
- **文本分类与情感分析**: 弱学习器叠加提升。
- **实体识别 / 意图分类**: 早期 NLP 流水线。

(4) 信号、传感与工业

- **人体活动识别**: 传感器特征的弱分类器集成。
- **工业故障诊断**: 多指标融合报警。
- **目标跟踪**: 在线 Boosting 跟踪器。

5.5.9 与深度学习的联系

- **Boosting 思想**: 梯度提升 (GBDT) 是 AdaBoost 的推广。
 - **级联思想**: 被深度检测器 (Cascade R-CNN) 继承。
 - **与 Bagging 对比**: Bagging 并行降方差, Boosting 串行降偏差。
 - **自蒸馏与渐进学习**: FixMatch 的阈值筛选、知识蒸馏的"难例优先"与 AdaBoost 的"重加权难例"异曲同工。
 - **MoE 的门控**: 稀疏专家选择与 AdaBoost 的"选弱学习器"都是在每步只激活一小部分容量。
 - **损失函数视角**: AdaBoost 的指数损失对应不能直接用于深度网络 (因为它对错误标签指数惩罚), 故现代深度模型更常用交叉熵 / 焦点损失; 但**样本重加权 (IRM、Group DRO、难例挖掘)**的思路完全一致。
-

5.6 EM 算法 (Expectation-Maximization)

5.6.1 问题

含隐变量 Z 时，最大似然难解：

$$\log p(X | \theta) = \log \sum_Z p(X, Z | \theta)$$

其中：

- X ：观测数据。
- Z ：隐变量（如 GMM 的簇归属）。
- θ ：参数。
- 难点：对数内有求和，无法直接求导。

5.6.2 EM 两步

E 步：计算隐变量后验（责任度）：

$$Q(\theta | \theta^{(t)}) = \mathbb{E}_{Z|X, \theta^{(t)}} [\log p(X, Z | \theta)]$$

M 步：最大化：

$$\theta^{(t+1)} = \arg \max_{\theta} Q(\theta | \theta^{(t)})$$

其中：

- $\theta^{(t)}$ ：第 t 轮参数。
- Q ：期望对数似然（对隐变量求期望）。
- 含义：E 步"猜"隐变量，M 步"更新"参数，交替上升。

5.6.3 收敛性

EM 保证 $\log p(X | \theta^{(t+1)}) \geq \log p(X | \theta^{(t)})$ ，即**单调不减**，收敛到局部最优。

5.6.4 EM 为什么有效：ELBO 下界

(1) 下界分解

对任意分布 $q(Z)$ ，将边缘似然拆为两项：

$$\log p(X | \theta) = \underbrace{\mathcal{L}(q, \theta)}_{\text{ELBO, 下界}} + \underbrace{\text{KL}(q(Z) \| p(Z | X, \theta))}_{\geq 0}$$

其中 **ELBO** 为：

$$\mathcal{L}(q, \theta) = \sum_Z q(Z) \log \frac{p(X, Z | \theta)}{q(Z)} = \underbrace{\mathbb{E}_q[\log p(X, Z | \theta)]}_{\text{就是 E 步的 } Q} - \underbrace{\mathbb{H}[q]}_{\text{熵}}$$

其中：

- $q(Z)$ ：对隐变量后验的**任意近似分布**。
- KL 项 ≥ 0 （非负），所以 $\mathcal{L}(q, \theta) \leq \log p(X | \theta)$ ，即 ELBO 确实是**下界**（**Jensen 不等式**的直接结果）。
- 含义：**这就是为什么 E 步与 M 步能交替上升**：
- **E 步**：固定 θ ，令 $q(Z) = p(Z | X, \theta^{(t)}) \rightarrow$ **KL 项 = 0**，ELBO 恰好等于似然（下界最紧）；
- **M 步**：固定 q ，最大化 $\mathcal{L}(q, \theta)$ 关于 $\theta \rightarrow$ ELBO 上升，而 KL 项非负，所以似然必然上升得更多。
- 两项的“追求”是矛盾的：
- $\mathbb{E}_q[\log p(X, Z | \theta)]$ 希望 q 集中在**高后验**的地方（EM 的倾向）；
- $-\mathbb{H}[q]$ 希望 q 尽量**分散**（变分推断的倾向）。两者的平衡正是 **变分推断** 的核心。

(2) 为什么不能一步到位？

- 若 $p(Z | X, \theta)$ 能用解析式求出（GMM、HMM），这就是**精确 EM**；
- 若不能（如带长依赖的隐变量模型），就必须用**近似后验** $\rightarrow$ 变分 EM。

5.6.5 EM 变体总览

变体	改动点	解决的问题
标准 EM	E 步精确后验 + M 步精确最大化	基线
GEM (广义 EM)	M 步只需使 Q 不下降	解不出闭式解时
ECM	M 步拆成多次条件最大化	高维参数耦合
ECME	部分参数用 EM、部分直接优化	兼顾两者
PEM (惩罚 EM)	目标加正则	奇异性、稀疏
变分 EM (VBEM)	E 步用变分分布	无闭式后验
MCEM	E 步用 MCMC 采样	期望不可解
随机 EM / 在线 EM	每次只用部分数据	大数据流式
增量 EM	参数随新数据更新	在线学习
DAEM (确定性退火)	逐步将 Q 变为似然	逃出差局部解
分类 EM (CEM)	E 步直接取最大 (不软)	聚类的 MAP 估计

5.6.6 广义 EM、条件最大化与惩罚变体

(1) GEM: M 步不必求极小

只需新参数使 Q 不下降即可：

$$Q(\theta^{(t+1)} \mid \theta^{(t)}) \geq Q(\theta^{(t)} \mid \theta^{(t)})$$

其中：

- $Q(\theta \mid \theta^{(t)}) = \mathbb{E}_{Z \mid X, \theta^{(t)}} [\log p(X, Z \mid \theta)]$ 。
- 含义：单步不再"最优"，但**单调性证明不变**（而实际实现变简单）。
- 应用：当 M 步无闭式解时，只需跑**一步（或几步）梯度上升**即可。

(2) ECM (Expectation Conditional Maximization)

把参数分组 $\theta = (\theta_1, \dots, \theta_S)$ ，M 步拆为 S 次**条件最大化**：

$$\theta_s^{(t+1)} = \arg \max_{\theta_s} Q\left(\theta_s \mid \theta_1^{(t+1)}, \dots, \theta_{s-1}^{(t+1)}, \theta_{s+1}^{(t)}, \dots, \theta_S^{(t)}\right)$$

其中：

- θ_s : 第 s 组参数——**固定其他组，只优化一组**。
- 含义：当参数耦合（如高斯混合中的 (μ_k, Σ_k) ）时，一次同时最大化很难，但**逐个条件最大化有闭式解**且仍保持单调增。
- 对偶： $S = 1$ 时退化为普通 EM。

(3) ECME (把不必用 EM 的部分直接优化)

- 对导数难解的参数（如混合系数）用 EM 的**闭式更新**；
- 对导数好算的参数（如噪声方差）用**直接最大似然**（梯度 / 牛顿）；
- 含义：ECM 的参数拆分组，**ECME 则把“拆”与“直接优化”混用**——通常比 ECM 收敛更快。

(4) PEM (惩罚 EM)

目标函数加正则项（与 4.2.11 的 GMM 正则思路一致）：

$$\theta^{(t+1)} = \arg \max_{\theta} \left\{ Q(\theta | \theta^{(t)}) - \lambda \mathcal{R}(\theta) \right\}$$

其中 $\mathcal{R}(\theta)$ ：正则项（如 $\lambda \|\theta\|_1$ 促稀疏，或惩罚 Σ_k 趋于奇异）。含义：**单调性依然保持**，但能得到更稳定 / 稀疏的解。

5.6.7 变分、采样与随机变体

(1) 变分 EM (VBEM / Mean-Field EM)

E 步不求精确后验，而是求一个**最优近似分布**：

$$q^* = \arg \max_q \mathcal{L}(q, \theta^{(t)}) = \arg \min_q \text{KL} \left(q(Z) \parallel p(Z | X, \theta^{(t)}) \right)$$

若假设**均场分解**：

$$q(Z) = \prod_{i=1}^N q_i(z_i)$$

则最优单因子有闭式解：

$$\log q_i^*(z_i) = \mathbb{E}_{j \neq i} [\log p(X, Z | \theta)] + \text{const}$$

其中：

- $\mathbb{E}_{j \neq i}$ ：对**除 i 外所有隐变量**在 q 下求期望。
- 含义：**交替更新每个 q_i (CAVI 算法)**，复杂度与 MCMC 相当但无采样噪声；代价是均场假设**低估后验方差**。
- 同时，M 步还要对参数后验求矩（这就是 **VBEM** 的“VB”部分）。

(2) Monte Carlo EM (MCEM)

E 步的期望用**采样**近似：

$$\hat{Q}(\theta) = \frac{1}{M} \sum_{m=1}^M \log p(X, Z^{(m)} | \theta), \quad Z^{(m)} \sim p(Z | X, \theta^{(t)})$$

其中：

- M ：**采样次数**（通常从大到小递减）。
- 采样用 **Gibbs / MH / HMC**。
- 含义：理论上**不会陷入参数的局部极值**（隐变量被采样而非固定），但每次迭代昂贵，且需要监控 M 是否足够。

(3) 随机 EM 与在线 EM

$$Z_t \sim p(Z | x_t, \theta^{(t)}), \quad \theta^{(t+1)} = \arg \max_{\theta} \log p(x_t, Z_t | \theta)$$

其中：

- 每个时刻**只用一个样本**（或一个小批）。
- 含义：把"期望"换成"一次采样"，代价是**不再单调增**，但换来 $O(1)$ 的每步代价；这是**在线学习 / 大数据流式**场景的标准做法，也是 SGD 的 EM 版。

(4) 确定性退火 EM (DAEM)

把 E 步中的后验**降温**（温度 β 从小升到 1）：

$$q_{\beta}(z_i) \propto p(z_i | X, \theta)^{\beta}$$

其中：

- $\beta \rightarrow 0$ ：后验趋于均匀（软）； $\beta = 1$ ：真实后验。
- 含义：早期用退火平滑似然面，**避免早期陷入差的局部极值**；晚期回到标准 EM。

5.6.8 收敛速度与 MM 算法视角

(1) EM 的收敛速率

在不动点 θ^* 附近，EM 是**线性收敛**，速率由**缺失信息比**决定：

$$\rho = 1 - \frac{\mathcal{I}_{\text{obs}}(\theta^*)}{\mathcal{I}_{\text{com}}(\theta^*)}, \quad \|\theta^{(t+1)} - \theta^*\| \approx \rho \|\theta^{(t)} - \theta^*\|$$

其中：

- $\mathcal{I}_{\text{com}}$ ：**完全数据**的 Fisher 信息（若隐变量已知）；

- $\mathcal{I}_{\text{obs}}$: 观测数据的 Fisher 信息。
- $\rho \in [0, 1)$: 称为**信息比 / 缺失信息占比**, $\rho \rightarrow 1$ 表示隐变量携带大量信息 $\rightarrow$ **收敛极慢**。
- 含义: 这也解释了为什么 GMM 中**分量严重重叠**时 EM 慢得令人发指。
- 加速手段: **Aitken 加速**、**SOR (超松弛)**、**参数扩充**、**Quasi-Newton EM**。

(2) EM 是 MM 算法的特例

MM (Minorize-Maximization) : 若存在**代理函数** $g(\theta \mid \theta^{(t)})$ 满足

$$g(\theta \mid \theta^{(t)}) \leq f(\theta) \quad \forall \theta, \quad g(\theta^{(t)} \mid \theta^{(t)}) = f(\theta^{(t)}), \quad \theta^{(t+1)} = \arg \max_{\theta} g(\theta \mid \theta^{(t)})$$

其中:

- $f(\theta)$: 真实目标 (如观测对数似然) 。
- g : **下界 (minorizer)** , 在 $\theta^{(t)}$ 处与 f 相切、其余处不超过 f 。
- 含义: $f(\theta^{(t+1)}) \geq g(\theta^{(t+1)}) \geq g(\theta^{(t)}) = f(\theta^{(t)})$ ——单调性立刻得证。
- **EM 就是取** $g(\theta \mid \theta^{(t)}) = Q(\theta \mid \theta^{(t)}) - \mathbb{H}[q]$ **的 MM 算法**。
- 这一视角的好处: 只要能**构造下界**就能设计新算法—— **MM 已经被广泛用于 PCA、谱聚类、稳健回归、非负矩阵分解**。

(3) 与梯度 / 牛顿法的对比

方法	每步代价	收敛阶	需要
梯度上升	低	线性	一阶导
牛顿法	高	二次	二阶导
EM	中 (通常有闭式)	线性	后验期望
MM	低到中	线性	minorizer
拟牛顿 (L-BFGS)	中	超线性	数值二阶近似

EM 的优势在于**总能保持可行性与单调性** (例如协方差矩阵不会变成非正定) , 而梯度 / 牛顿法在带约束的似然面上容易跑飞。

5.6.9 应用方向

(1) 图像 / 视觉

- **GMM-EM 图像分割**: 对颜色/纹理建模, 做像素聚类。
- **背景建模**: GMM 对像素颜色随时间建模, 检测运动目标。

- **缺失像素/遮挡填补**：把缺失值当隐变量做 EM 推断。
- **图像配准 / 点集配准**：混合模型拟合点分布。

(2) 语音、文本与序列

- **隐马尔可夫模型 (HMM) 的 Baum-Welch**：语音识别的经典训练算法。
- **话题模型 (PLSA)**：文档-主题的隐变量刻画。
- **文本对齐 / 机器翻译 (IBM 模型)**：词对齐的隐变量推断。

(3) 统计与数据缺失

- **缺失数据填补**：统计调查、临床试验中的缺失值。
- **混合模型聚类**：客户分群、市场细分。
- **隐变量回归**：带潜在因子的建模。

(4) 生物、医学与金融

- **基因序列分析**：HMM 做序列建模。
- **疾病亚型发现**：混合建模的患者分型。
- **金融状态切换**：马尔可夫转换模型 (Markov Switching)。
- **生存分析**：带删失数据的最大似然。

(5) 工程与传感器

- **雷达 / 信号参数估计**：多分量信号拟合。
- **可靠性分析**：寿命分布的混合建模。
- **混合专家 (MoE)**：门控网络的参数估计。

5.6.10 与深度学习的联系

- **VAE 的变分推断**是 EM 的推广 (用神经网络参数化 q)。
 - **EM 是"硬/软分配"的统一框架**，K-means 与 GMM 都是特例。
 - **ELBO 就是 VAE 的损失函数**：VAE 的 $\mathcal{L} = \mathbb{E}_q[\log p(x|z)] - \text{KL}(q(z|x)||p(z))$ 正是上面那个 ELBO (只是把 GMM 换成了神经网络)。
 - **均场近似 $\rightarrow$ 摊销推断**：EM 的均场变分对每个样本单独优化，VAE 用一个编码器**一次性预测后验参数**，这就是"**摊销 (Amortized) 变分推断**"。
 - **EM 视角的对比学习**：SwAV / DINO 的聚类分配步就是 E 步，簇中心更新就是 M 步 (已见 3.1.12)。
 - **扩散模型的训练目标**可视为"**带已知隐变量的 EM**" (隐变量就是每一步的噪声)，因此不需要真正的 E 步。
 - **MoE 与路由**：稀疏门控的分配与 EM 的软分配是同一件事的两种写法。
-

5.7 Apriori

5.7.1 问题：关联规则挖掘

从交易数据中发现"买了 A 也会买 B"的规则 $A \Rightarrow B$ 。

5.7.2 关键指标

支持度：

$$\text{supp}(A \Rightarrow B) = \frac{|\{T : A \cup B \subseteq T\}|}{|T_{\text{all}}|}$$

其中：

- T ：一笔交易（项集）。
- $A \cup B \subseteq T$ ：同时包含 A 和 B 的交易。
- $|T_{\text{all}}|$ ：总交易数。
- 含义：规则覆盖的交易比例。

置信度：

$$\text{conf}(A \Rightarrow B) = \frac{\text{supp}(A \cup B)}{\text{supp}(A)}$$

其中 $\text{supp}(A)$ 是只含 A 的交易比例；含义：买了 A 的人中买 B 的比例。

提升度：

$$\text{lift}(A \Rightarrow B) = \frac{\text{conf}(A \Rightarrow B)}{\text{supp}(B)}$$

其中 $\text{supp}(B)$ 是 B 的基础频率； $\text{lift} > 1$ 表示正相关。

5.7.3 Apriori 原理

先验性质：频繁项集的所有子集也频繁（反之，非频繁项集的超集非频繁）。据此逐层生成候选并剪枝。

5.7.4 频繁模式挖掘算法族总览

关联规则挖掘是一个**算法族**，差异在于：**用什么数据结构、要不要生成候选、模式长什么样。**

算法 / 家族	数据结构	是否生成候选项集	特点
Apriori	水平（事务列表）	是	经典，扫描次数多
AprioriTid	水平 + TID-set	是	后期扫描不用原始库
AprioriHybrid	两者混合	是	自适应切换
FP-Growth	FP 树	否	只扫两遍库
Eclat	垂直 (TID-list)	否（用交运算）	求交集快
H-Mine / dEclat	内存版 / 差分集	否	节省内存
Partition / Sampling	分区抽样	是	减少扫描 / I/O
DIC	动态计数	是	减少扫描次数
闭项集 / 最大项集	压缩表示	衍生	大幅减数量
GSP / PrefixSpan / SPADE	序列扩展	是 / 否 / 否	序列模式
HUI-Miner / FHM	效用列表	否	高效用项集
gSpan / FSG	图同构	是	子图模式

5.7.5 Apriori 的工程改进

(1) AprioriTid / AprioriHybrid

AprioriTid 把每个候选项集对应的**交易 ID 集合 (TID-set)** 存下来：

$$\text{tid}(X) = \{T_i \mid X \subseteq T_i\}, \quad \text{supp}(X) = \frac{|\text{tid}(X)|}{N}$$

其中：

- $\text{tid}(X)$ ：包含项集 X 的**交易编号列表**。
- N ：总交易数。
- 含义：完全**不需要原始数据库**就能算支持度（只需维护这些 TID 列表）。
- 早期候选项集多时，TID 列表比原库还大 → 慢；
- 后期候选项集少时，TID 列表小 → 快。
- **AprioriHybrid**：前几轮用 Apriori，等 TID-set 变小后自动切换到 AprioriTid。

(2) Partition (分区) 与 Sampling (抽样)

- **Partition**：把库分成 n 个分区，每个分区用**降低后的阈值**找局部频繁项集：

$$\text{局部阈值} = \text{min_supp} \times \frac{|\text{分区}|}{N}$$

合并后就是全局频繁项集的**超集**，再用一遍全库扫描去假阳。好处：**只需两次全库扫描**（与数据量无关）。
 - **Sampling**：在随机样本上按**降低的阈值**找频繁项集，再全库验证：

$$\text{抽样阈值} = \text{min_supp} \times (1 - \varepsilon)$$

其中 ε 是允许的**抽样误差界**；参数选择需保证“真正的频繁项集以高概率落入样本频繁集”。
 - **DIC (Dynamic Itemset Counting)**：把项集按“已扫过的部分”**分级**，每隔 M 个交易就检查一次，发现某候选已达阈值则**提前开始它的超集计数**——把“全库扫描次数”从 max_len 降到约 $\log$ 量级。

(3) 性能对比直觉

场景	首选
事务长、密集（如购物篮）	FP-Growth
事务短、密集度中等	Apriori / Eclat
稀疏、长事务	Eclat / dEclat
超大库（I/O 受限）	Partition / Sampling
只需模式集合（不需提取规则）	闭项集 / 最大项集

5.7.6 FP-Growth 与 Eclat：不用生成候选

(1) FP-Growth（频繁模式树）

两步流程：

1. **建树**：先扫一遍库计数（1-项集频率），把每个事务中的项**按频率降序**重排；
2. 把事务按前缀共享路径插入 **FP 树**，并维护**头表与节点链**（每个项指向它在树中的所有出现）。

设项 a 的条件模式基（conditional pattern base）：所有包含 a 的前缀路径，带节点计数；据此构造**条件 FP 树**，递归挖掘。

复杂度与含义：

- 建树： $O(\sum_T |T| \log |T|)$ （排序 + 插入）。
- 挖掘：与**输出模式总数**成正比，与**数据库大小无关**。
- 含意：**只需扫库两次**（一次计数、一次建树），把 Apriori 的 $O(\text{max_len})$ 次 I/O 全消掉；代价是**内存要装得下 FP 树**。
- 挖掘目标通常为**最小支持度**上的**频繁项集**，再从中提取关联规则。

(2) Eclat (垂直数据格式)

把水平事务库转成 **TID-list 垂直格式**，并用**集合交**算支持度：

$$t(X \cup Y) = t(X) \cap t(Y), \quad \text{supp}(X \cup Y) = \frac{|t(X) \cap t(Y)|}{N}$$

其中：

- $t(X)$ ：包含 X 的**交易 ID 集合**。
- 含义：**支持度计数变成集合交的大小**，可用位向量 / bitmap 高度加速；与 **FP-Growth** 一样**不需生成候选项集**，但没有树构建开销。
- **dEclat**：只存“**差分集**”（两个相交前一者比后者多出的部分），大幅降低内存（对长事务尤为有效）。

5.7.7 项集的压缩表示与扩展模式

(1) 闭项集 (Closed Itemset) 与最大项集 (Maximal Itemset)

定义：

$$X \text{ 是闭的} \iff \neg \exists Y \supset X : \text{supp}(Y) = \text{supp}(X)$$

$$X \text{ 是最大的} \iff \neg \exists Y \supset X : \text{supp}(Y) \geq \text{min_supp}$$

其中：

- **闭项集**：**没有同样频繁的真超集**；它保留了**全部支持度信息**，因为任何项集的支持度等于包含它的最小闭项集的支持度。
- **最大项集**：**没有更长的频繁超集**；数量最少，但会丢失支持度信息（只能从最大项集推回支持度）。
- **两者的关系**：最大频繁项集 $\subset$ 闭频繁项集 $\subset$ 频繁项集。
- 典型算法：**Close**、**A-Close**、**CHARM**、**CLOSET**、**FP-Close**（闭项集）；**MaxMiner**、**DepthProject**（最大项集）。
- 含义：在**密集数据集**（如基因表达数据，频繁项集可能 10^{10} 个）上，压缩到闭 / 最大项集是从“不可算”到“可算”的关键。

$$\text{闭合度 closure}(X) = \bigcap \{T \in \mathcal{T} : X \subseteq T\}$$

其中 $\text{closure}(X)$ 是包含 X 的**所有交易的交集**——这就是从 X 能恢复信息的最小闭集。

(2) 负关联规则 (Negative Association Rules)

不仅发现 $A \Rightarrow B$ ，也发现 $A \Rightarrow \neg B$ ：

$$\text{supp}(A \cup \neg B) = \text{supp}(A) - \text{supp}(A \cap B), \quad \text{conf}(A \Rightarrow \neg B) = \frac{\text{supp}(A) - \text{supp}(A \cap B)}{\text{supp}(A)}$$

其中：

- $\neg B$ ：不含 B 。
- 含义：可用于发现"替代品"关系（买了 iPhone 就不买华为手机）与**排除式营销**；代价是候选规则数量翻倍，需额外剪枝。

(3) 多层与多维关联规则

- **多层关联**：项有概念层次（牛奶→乳制品→食品），可在不同抽象层挖掘。跨层规则如“**面包 → 乳制品**”（而不是面包 → 牛奶）。
- **多维关联**：除商品维度外，还有时间、地点、年龄等维度：

$$\text{年龄}(30-40) \wedge \text{收入}(\text{高}) \Rightarrow \text{买笔记本电脑}$$

与 **量化关联规则**（numeric association rules）一起，常用于**客户行为分析**。

5.7.8 兴趣度量（Interest Measures）

置信度的自信问题（置信度高但实际负相关）需用其他度量修正：

度量	公式	含义
Lift（提升度）	$\frac{\text{supp}(AB)}{\text{supp}(A)\text{supp}(B)}$	> 1 正相关、= 1 独立、< 1 负
Conviction	$\frac{1 - \text{supp}(B)}{1 - \text{conf}(A \rightarrow B)}$	规则 被违背的程度 （= 1 独立， ∞ 蕴含）
All-confidence	$\frac{\text{supp}(AB)}{\max(\text{supp}(A), \text{supp}(B))}$	满足 向下封闭 ，可用于剪枝
Cosine	$\frac{\text{supp}(AB)}{\sqrt{\text{supp}(A)\text{supp}(B)}}$	向量夹角
Jaccard	$\frac{\text{supp}(AB)}{\text{supp}(A) + \text{supp}(B) - \text{supp}(AB)}$	集合相似度
Kulczynski	$\frac{1}{2}(\text{conf}(A \rightarrow B) + \text{conf}(B \rightarrow A))$	平均置信度
Odds Ratio / ϕ 系数	$\phi = \frac{\text{supp}(AB) - \text{supp}(A)\text{supp}(B)}{\sqrt{\text{supp}(A)\text{supp}(B)(1 - \text{supp}(A))(1 - \text{supp}(B))}}$	统计相关强度
互信息 (MI)	$\sum_{a,b} p(a,b) \log \frac{p(a,b)}{p(a)p(b)}$	信息论相关

关键提醒：Lift 与 Reliance 等度量不满足向下封闭（一个项集的 Lift 高，其超集的 Lift 不一定高），因此不能像支持度那样剪枝，这就是**"非频繁项集挖掘"**与 **"H-confidence / all-confidence 剪枝"** 的由来。

5.7.9 序列模式与结构模式

(1) 序列模式挖掘 (Sequential Pattern Mining)

数据换成**序列数据库**（每个顾客的事件时间序列）：

$$\text{supp}_{\text{seq}}(S) = \frac{|\{\text{顾客} : S \text{ 是其子序列}\}|}{N}, \quad S = \langle s_1, s_2, \dots, s_k \rangle$$

其中：

- S ：待挖的**序列模式**（有序的事件集合）。
- 子序列：需保持**先后顺序**（不同于项集的无序）。
- 三大算法：

算法	思路	优势
GSP	Apriori 式逐层生成候选序列	简单、可剪枝
PrefixSpan	前缀投影数据库	不生成候选 、快
SPADE	垂直格式 + 格分解	适合磁盘 I/O
FreeSpan	投影数据库	早期方案

- 含义：购物篮→**浏览/购买路径**；运维→**告警序列**；生物→**基因/蛋白序列特征**。
- 扩展：**带间隔约束 (time gap)**、**带分类约束 (只关心某类事件)**、**序列规则 (sequential rules)**。

(2) 高效用项集挖掘 (HUI Mining)

支持度只数“出现次数”，**不区分商品价值**（一瓶牛奶与一台电脑等权）。效用 (utility) 把价值引入：

$$u(X) = \sum_{i \in X} u(i), \quad u(i) = \text{内部效用} \times \text{外部效用 (价格)}$$

$$\text{TWU}(X) = \sum_{T \supseteq X} \text{TU}(T), \quad \text{TU}(T) = \sum_{i \in T} u(i)$$

其中：

- $u(i)$ ：项 i 在某交易中的**总效用**（数量 × 单价）；
- $\text{TU}(T)$ ：**一笔交易的总效用**；
- $\text{TWU}(X)$ ：包含 X 的所有交易的 TU 之和。

- **关键上界性质**: $u(X) \leq \text{TWU}(X)$, 且 TWU 不满足向下封闭 (需用 **弱向下封闭**: TWU 低于阈值的项集的所有超集 TWU 也低)。
- 常用算法: **Two-Phase**、**UP-Growth**、**HUI-Miner** (效用列表)、**FHM**、**EFIM**。
- 含义: 零售利润分析、推广推荐 (“买了这个高毛利商品的人”) 的关键工具。

(3) 子图与结构模式

$$\text{supp}_{\text{graph}}(g) = \frac{\#\{\text{包含 } g \text{ 为子图的图}\}}{N}$$

- **Apriori 式**: FSG (频繁子图生成 + 候选裁剪) ;
- **模式增长式**: gSpan、FFSM、GASTON;
- 核心难点: **子图同构是 NP-hard** (用规范编码 canonical labeling 去重)。
- 含义: 化学分子 (官能团)、蛋白质互作网络、社交网络模式。

5.7.10 规则的提取与后处理

从频繁项集 L 中提取**强关联规则**: 对每个 $X \in L$ 与每个真子集 $A \subset X$:

$$A \Rightarrow X \setminus A \quad \text{若} \quad \text{conf}(A \Rightarrow X \setminus A) \geq \text{min_conf}$$

$$\text{conf}(A \Rightarrow X \setminus A) = \frac{\text{supp}(X)}{\text{supp}(A)}$$

其中:

- A : **前件**; $X \setminus A$: **后件**。
- 含义: **先算频繁项集、再生成规则** (两步分离) 是 Apriori 架构的核心思想, 把 “规则搜索” 从 $3^{|I|}$ 降到 “候选数 $\times$ 子集数”。
- 闭项集上的规则提取: 可用**造格 (Galois Lattice)** 结构, 用最小生成集表示全部规则。
- 可进一步排序: 按**支持度 / 置信度 / Lift / 卡方 / 信息增益**筛选与排序。

5.7.11 应用方向

(1) 图像 / 视觉

- **图像共现模式**: 发现常一起出现的视觉元素 (如“天空+草地”)。
- **场景理解**: 物体共现关系建模。
- **图像标注**: 标签关联规则。

(2) 零售、电商与推荐 (最经典)

- **购物篮分析**：超市发现"啤酒 + 尿布"式关联规则。
- **推荐系统**："看了 A 也看 B"的关联推荐。
- **交叉销售**：电商捆绑销售策略。
- **货架与品类布局**：商品关联度指导陈列。

(3) 医学与生物信息

- **医疗处方分析**：药物共现与不良反应挖掘。
- **食疗 / 并发症关联**：临床事件的频繁共现。
- **生物信息**：基因/蛋白共表达模式。
- **流行病学**：症状-疾病关联规则。

(4) 网络、安全与运维

- **网络安全**：入侵检测中的事件关联。
- **日志 / 告警分析**：频繁共现的故障模式。
- **点击流分析**：网页访问路径模式挖掘。
- **根因分析**：故障事件链路挖掘。

(5) 制造与质量

- **缺陷模式挖掘**：多缺陷共现规律。
- **工艺参数关联**：参数组合与质量结果的规则。

5.7.12 与深度学习的联系


- **共现统计**被用于**图神经网络**的边构建。
 - **注意力中的共现**：自注意力可看作学习特征间的"关联强度"。
 - **推荐系统的两条路线**：这条路线（基于共现/规则的**可解释推荐**）与深度序列模型（GRU4Rec、SASRec、BERT4Rec）形成对比。
 - **稀疏输入 + 共现先验**：在 Embedding 层嵌入"共现得分"可以缓解冷启动。
 - **大语言模型与知识图谱**：用频繁模式 / 关联规则从语料中**抽取事实**再注入模型，是 "符号 + 神经" 混合的一条路线（AMIE 等规则学习系统）。
 - **气候 / 交易级的模式挖掘**：把"频繁模式"当作**先验与可解释约束**加在深度模型上，已用于**可解释推荐**（Explainable RecSys）与**异常链路分析**。
-

6. 应用总览

算法	图像 / 视觉中的典型任务	其他领域中的典型任务	输入特征	备注
KNN	检索、匹配、分类基线	语义检索 / RAG 召回、协同过滤、异常检测	描述子、CNN 特征、向量嵌入	需加速结构
朴素贝叶斯	肤色检测、分割	垃圾邮件、文本分类、疾病诊断	颜色、像素、词频	生成式
逻辑回归	二分类、多标签	信用评分卡、CTR 预估、临床风险模型	任意特征	网络分类头
SVM	行人检测、分类	文本分类、基因 / 蛋白分类、高维小样本判别	HOG、SIFT、TF-IDF	核方法
ϵ -SVR / ν -SVR	深度 / 视差回归、超分辨	销量 / 能耗 / 股价回归、光谱定量	描述子、时序特征	回归
One-Class SVM / SVDD	缺陷检测、异常图像	异常检测、故障预警、新颖性检测	任意特征	单类
LS-SVM	—	在线 / 增量建模、快速拟合	任意特征	线性方程组
决策树/森林	分割、关键点、检测	风控、医疗、工业质控、地理分类	像素、Texton、表格特征	随机蕨
C4.5	像素分类、遥感	信用评分、医疗诊断、规则抽取	混合特征	可解释规则
CART	分割、回归（深度/视差）	表格数据、CTR/LTR、销量回归	像素、描述子、表格特征	随机森林基学习器
聚类	分割、词袋、超像素	客户分群、基因 / 单细胞、社区发现	颜色+位置、任意向量	无监督
K-means/GMM	颜色量化、背景建模	客户分群、GMM-HMM 语音、异常检测	颜色、声学 / 表格特征	GMM 背景建模
PCA	特征脸、压缩、降维	因子模型、光谱降维、白化预处理	图像、描述子、表格特征	线性
流形学习	可视化、检索	单细胞轨迹、高维数据可视化、动力系统降维	CNN 特征、任意向量	非线性

算法	图像 / 视觉中的典型任务	其他领域中的典型任务	输入特征	备注
半监督	医学分割、遥感	文本 / 语音标注、冷启动、故障诊断	图像、文本、语音	标注稀缺
AdaBoost	人脸检测	信用评分、生物信息、目标跟踪	Haar、表格特征	级联
EM	GMM 分割	HMM 语音、话题模型、缺失值填补	颜色、序列特征	隐变量
Apriori	场景共现	购物篮分析、推荐、处方与告警关联	标签、交易项集	关联规则
FP-Growth / Eclat	视觉元素共现	高频模式挖掘、路径分析	共现项集	无候选生成
PrefixSpan / GSP	视频事件序列	点击流 / 告警 / 基因序列	事件序列	序列模式
HUI-Miner	—	零售利润、推荐组合优选	项 + 价值	高效用
PageRank	显著性、检索重排序	搜索排序、社交影响力、学术引用、交通网络	图像块图、图结构	流形排序
PPR / RWR	检索重排序	图上相似度、反作弊、推荐	图结构	灵活起点
HITS / SimRank	—	社区发现、结构相似度	图结构	结构等价
DBSCAN / HDBSCAN	遥感分割、点云聚类	异常检测、地理 POI、客户分群	任意特征	任意形状
谱聚类	图像分割	社区发现、字符辨识	相似度图	图分割
Kernel / Sparse PCA	非线性降维	因子分析、光谱去混叠	核矩阵 / 高维特征	非线性 / 稀疏
t-SNE / UMAP	嵌入可视化	单细胞、文本嵌入可视化	高维嵌入	仅可视化
Mean Teacher / FixMatch	医学图像分割	文本 / 语音标注、工业质检	图像、文本	一致性正则
XGBoost / LightGBM	目标检测重排	竞赛 / 风控 / CTR 主力	表格特征	提升树
Isolation Forest	异常图像检测	工业故障、网络入侵	任意特征	无监督异常
CHARM / CLOSET	—	密集数据频繁模式	交易项集	闭项集压缩
变分 EM / MM	图像生成	主题模型、缺失数据	隐变量	下界优化

图像处理流水线中的位置：



7. 与深度学习的联系（重点）

7.1 经典算法是深度网络的"积木"

经典算法	深度对应	关系
逻辑回归	单层网络 / Softmax 头	完全相同
SVM	Hinge 损失 / 大间隔 softmax	损失函数沿用
PCA	线性自编码器	最优解等价
K-means	VQ-VAE 码本 / 硬分配 AE	量化思想
GMM	MoE 门控 / VAE 先验	软分配
EM	VAE 变分推断	推广
决策树	深度森林 / 注意力路由	结构类比
C4.5 / CART	软决策树 / NODE / gcForest	可微化
AdaBoost	梯度提升 / 级联检测	思想继承
KNN	度量学习 / 原型网络	嵌入空间近邻
流形学习	自编码器 / 对比学习	参数化版本
半监督	FixMatch / 自监督	训练范式
PageRank	GNN 消息传递 / 随机游走嵌入	邻居聚合

7.2 三代特征表示（与仓库其他文档呼应）

阶段	代表	人的参与	对应文档
手工设计	SIFT、HOG、LBP	高	feature-descriptors-notes.md
浅层学习	PCA、K-means、SVM、GMM	中	本文
深度表示学习	CNN、Transformer	低	cnn-transformer-notes.md

7.3 为什么深度学习"取代"了经典方法

- **特征学习**：经典方法依赖手工特征，深度网络**端到端学特征**。
- **非线性**：核方法靠固定核，深度靠**多层非线性**。
- **可扩展**：深度网络能吃海量数据，经典方法在高维大数据上受限。
- **统一**：分类、检测、分割统一到一个网络。

7.4 经典方法为何仍然重要

- **小数据**：样本少时，SVM、随机森林常优于深度网络。
- **可解释**：决策树、逻辑回归系数可解释。
- **轻量**：嵌入式/实时场景，KNN、PCA、AdaBoost 仍高效。
- **理论**：理解深度网络需要经典理论（偏差-方差、流形、核）。
- **基线**：任何深度模型都该与经典基线对比。

7.5 偏差-方差视角

$$\mathbb{E}[\text{误差}] = \underbrace{\text{偏差}^2}_{\text{欠拟合}} + \underbrace{\text{方差}}_{\text{过拟合}} + \underbrace{\text{噪声}}_{\text{不可约}}$$

其中：

- **偏差**：模型假设与真实规律的差距（模型太简单）。
 - **方差**：模型对训练集扰动的敏感度（模型太复杂）。
 - **噪声**：数据本身的随机性，无法消除。
 - **含义**：Bagging/随机森林**降方差**，Boosting**降偏差**，深度网络靠**层次**同时降两者。
-

8. 速查表

8.1 算法速查

算法	类型	关键公式	超参数	优点	缺点
KNN	监督/非参数	$d(x, x')$	k 、距离	简单、无训练	慢、维度灾难
朴素贝叶斯	监督/生成	$P(c) \prod_j P(x_j c)$	分布类型	快、小数据好	独立假设强
逻辑回归	监督/判别	$\sigma(w^\top x + b)$	λ, η	概率输出、可解释	线性
SVM	监督/判别	max 间隔 + 核	C, γ	高维有效、核灵活	大数据慢、调参
L2-SVC	监督/判别	平方松弛 + 对角加载	C, γ	强凸、解唯一	无稀疏截断
ν -SVC	监督/判别	用 ν 替代 C	ν, γ	参数有概率含义	需 $\nu \in (0, 1]$
LS-SVM	监督	等式约束 $\rightarrow$ 线性方程组	γ 、核	求解快、可增量	解不稀疏
ϵ -SVR	回归	ϵ -不敏感损失	C, ϵ, γ	鲁棒回归	需调 ϵ
ν -SVR	回归	ν 自动定 ϵ	ν, C, γ	免调 ϵ	需 $\nu \in (0, 1]$
One-Class SVM	单类/异常	原点侧最大间隔	ν, γ	只需正类样本	对 ν 敏感
SVDD	单类/异常	最小包围超球	C 、核宽	几何直观	与 OC-SVM 近等价
决策树	监督	不纯度下降	深度、叶子数	可解释、混合特征	易过拟合
C4.5	监督	信息增益率	置信度	连续+缺失值	多叉树、慢

算法	类型	关键公式	超参数	优点	缺点
CART	监督	基尼 / SSE	α	分类+回归、二叉树	贪心、不稳定
随机森林	监督/集成	Bagging + 特征随机	T, m	稳健、特征重要性	模型大
聚类	无监督	簇内距离和	K, ϵ	发现结构	需选参
K-means	无监督	$\sum \ x_i - \mu_k\ ^2$	K	快、简单	球形假设
GMM	无监督/生成	$\sum \pi_k \mathcal{N}$	K 、协方差型	软分配、灵活	局部最优
PCA	无监督/线性	$\Sigma u = \lambda u$	K	降维、去噪	仅线性
流形学习	无监督/非线性	保持邻域	近邻数、 d	非线性结构	慢、难泛化
半监督	半监督	一致性/传播	阈值	省标注	假设依赖
AdaBoost	集成	α_t 加权投票	T 、弱学习器	高精度	对噪声敏感
EM	通用	E 步 + M 步	初值	隐变量框架	局部最优
Apriori	关联规则	支持度/置信度	支持度阈值	可解释	组合爆炸
PageRank	图/排序	$\frac{1-d}{N} + d \sum \frac{PR(v)}{L(v)}$	d	无监督、全局	需建图、静态
PPR / RWR	图/相似度	$(1 - \alpha)(I - \alpha W)^{-1} e_q$	α	图上相似度	每次需重算
TrustRank	图/反作弊	可信种子作跳转向量	种子集	抗垃圾链接	种子难获取
TextRank	文本	词/句图上的 PR	d 、窗口	无需语料训练	图构建敏感
HITS	图/排序	$a = A^\top h, h = Aa$	迭代数	查询相关	易被互指作弊
SimRank	图/相似度	邻居递归相似	C	结构等价性	$O(N^2)$
BIRCH	聚类/层次	聚类特征 CF 树	阈值、分支	单遍扫描、流式	仅球形

算法	类型	关键公式	超参数	优点	缺点
CURE	聚类/层次	多代表点收缩	代表点数、 α	任意形状	需抽样
DBSCAN	聚类/密度	密度相连	ϵ 、MinPts	任意形状 + 噪声	密度不均难调
OPTICS / HDBSCAN	聚类/密度	可达距离 / 簇稳定性	MinPts	多密度、免调 ϵ	稍慢
谱聚类	聚类/图论	L 的前 K 特征向量	K 、 σ	任意形状	$O(N^3)$
模糊 C 均值	聚类/模糊	$\sum u_{ik}^m \ x_i - c_k\ ^2$	K 、 m	软隶属度	需预设 K
Affinity Propagation	聚类/消息传递	责任度 + 可用度	偏好值	自动定 K	$O(N^2)$ 内存
K-means++	聚类/初始化	$p(x) \propto D(x)^2$	—	解决初值敏感	—
Kernel K-means	聚类/核	仅用 Gram 矩阵	核、 K	非线性簇	$O(N^2)$ 内存
球形 K-means	聚类/方向	最大化余弦	K	文本聚类	仅方向有意义
VB-GMM / DPMM	聚类/非参贝叶斯	参数先验 + 因子分解	上界 K	自动定 K	计算贵
t 分布混合	聚类/鲁棒	重尾成分	ν	抗离群点	非凸且需调 ν
Kernel PCA	降维/核	$\tilde{K}\alpha = \lambda\alpha$	核、 k	非线性主成分	$O(N^2)$
Sparse PCA	降维/稀疏	方差 + L_1	k 、 λ	可解释	非凸
鲁棒 PCA (RPCA)	降维/分解	$\ L\ _* + \lambda\ S\ _1$	λ	背景+前景分离	迭代慢
PPCA	降维/生成	$x = Wz + \mu + \epsilon$	k	处理缺失 + 定 k	高斯假设
LDA (Fisher)	降维/有监督	$S_B w = \lambda S_W w$	维度	判别性强	$\leq C - 1$ 维

算法	类型	关键公式	超参数	优点	缺点
NMF	降维/非负	$\min \ X - WH\ _F^2$	k	部件式可解释	非凸
Isomap / LLE	流形	测地距离 / 重构权重	k, d	非线性结构	新样本难
拉普拉斯特征映射	流形/谱	$Ly = \lambda Dy$	k, σ	与谱聚类同源	仅训练样本
扩散映射	流形/多尺度	扩散距离	t	多尺度 + 抗噪	需选 t
t-SNE / UMAP	流形/可视化	KL / 模糊交叉熵	困惑度、 $n_neighbors$	二维可视化	仅可视化
S3VM / TSVM	半监督/大间隔	无标签标签也是变量	C_l, C_u	低密度分割	非凸、类不平衡
Label Propagation	半监督/图	$(I - \alpha S)^{-1}Y$	α, k	凸、闭式解	$O(N^3)$ 、不泛化
一致性正则	半监督/深度	扰动下输出一致	$\lambda(t)$	不依赖生成假设	需强增强
Mean Teacher	半监督/深度	EMA 权重	α, λ	教师更稳	训练慢
FixMatch	半监督/深度	弱标签 + 强增强	τ, μ	简单强效	阈值需调
Real / Gentle AdaBoost	集成/提升	实数输出、固定步长	T	Gentle 最稳健	仍需好基学习器
SAMME / SAMME.R	集成/多类	$\ln \frac{1-\epsilon}{\epsilon} + \ln(K-1)$	T	多类提升	需 $\epsilon < 1 - 1/K$
级联 AdaBoost	集成/检测	逐级减误报	每级 f, d	实时检测	训练流程复杂
GBDT / XGBoost	集成/提升	二阶泰勒 + 显式正则	ν 、深度、 λ	表格数据 SOTA	调参多、串行
LightGBM / CatBoost	集成/提升	直方图+leaf-wise / 有序提升	叶子数 等	快、类别特征好	实现复杂
Extra Trees	集成/并行	随机阈值	T, m	更快、方差低	偏差略高

算法	类型	关键公式	超参数	优点	缺点
Isolation Forest	集成/异常	路径长度 $s(x, n)$	T 、子采样	无监督异常检测	高维效果差
FP-Growth / Eclat	关联/频繁模式	FP 树 / TID 交	支持度阈值	无候选生成	内存 / I/O
PrefixSpan	序列模式	前缀投影	支持度阈值	不生成候选	长序列内存
HUI-Miner	高效用模式	效用列表 + TWU	效用阈值	引入价值	剪枝更复杂
ECM / 变分 EM	通用/隐变量	条件最大化 / 变分后验	分组、先验	解高维耦合	实现复杂
MM 算法	通用/下界	$g(\theta \mid \theta^{(t)})$	—	只要下界就能新算法	需设计下界

8.2 变体族速查（一页看懂）

记忆三条主线：换损失、换正则、换假设。

主线	典型改动	代表
换损失	Hinge → 平方松弛 / 等式约束 / ϵ -不敏感 / 单类	L2-SVC、LS-SVM、 ϵ -SVR、One-Class SVM
换正则	无 → L1 → L2 → Elastic Net → 惩罚 EM	Lasso LR、Sparse PCA、PEM
换假设	独立 → 单依赖 → 树 → 完整图	NB → TAN → AODE → BN
换输出结构	标量 → 概率 → 序 → 结构化	LR → Platt / 有序 LR → SVM-struct
换距离 / 核	欧氏 → 核 → 度量学习 → 图	Kernel K-means → LMNN/NCA → 谱聚类
换参考模型	均值 → medoid → 多个代表点 → 密度吸引子	K-means → PAM → CURE → Mean Shift
换求解器	闭式 → IRLS/牛顿 → SMO → 次梯度/ADMM	LR、SVM、SVD、RPCA
换数据表示	水平 → 垂直 → 树 → 闭 / 最大项集	Apriori → Eclat → FP-Growth → CHARM
换正则化位置	损失 → 权重 → 数据增强 → 一致性	L2 → Dropout → MixUp → FixMatch

三个统一视角：


1. 一切都在最小化“损失 + 正则”：

$$\min_{\theta} \underbrace{\sum_i L(y_i, f_{\theta}(x_i))}_{\text{拟合}} + \underbrace{\lambda \Omega(\theta)}_{\text{约束}}$$

其中：

2. L ：损失函数（Hinge / 交叉熵 / MSE / Focal / 对比 ...）。
3. $\Omega(\theta)$ ：正则项（ L_2 / L_1 / 树复杂度 / 核范数 / 图平滑 ...）。
4. λ ：权衡系数。SVM、逻辑回归、PCA、RPCA、XGBoost、神经网络全都是这个形式。
5. 一切都在做“下界 + 上升”：EM、MM、变分推断、ELBO、Boosting 的前向分步——共同结构都是“**找一个下界（或弱模型），再向上升**”。
6. 一切都在做“邻域 / 传播”：PageRank、标签传播、GNN、谱聚类、流形学习、KNN、DBSCAN——共同结构是“**定义邻域，再在邻域上聚合 / 传播**”。

8.3 选择指南



9. 结论

1. **"十大"没有唯一版本**：ICDM 2008 版偏数据挖掘（C4.5、K-Means、SVM、Apriori、EM、PageRank、AdaBoost、kNN、Naive Bayes、CART），入门教材版偏机器学习基础（含逻辑回归、PCA、流形、半监督）。本文两版通吃。
2. **所有算法都是"损失 + 正则 + 优化"的特例**，差别在 L 、 Ω 、 f_θ 的选择。
3. **图像领域**：KNN/SVM/随机森林用于分类检测，K-means/GMM 用于分割与词袋，PCA/流形用于降维与可视化，半监督用于标注稀缺场景。
4. **非图像领域同样重要**：C4.5/CART 是表格数据与风控医疗的主力，PageRank 是搜索与图排序的基石，Apriori 是推荐与购物篮分析的核心，EM 是含隐变量问题的通用框架。
5. **与深度学习一脉相承**：逻辑回归→网络分类头，PCA→自编码器，K-means→VQ-VAE，EM→变分推断，AdaBoost→梯度提升，KNN→度量学习，C4.5/CART→软决策树与深度森林，PageRank→GNN 消息传递。
6. **经典方法不会消失**：小数据、可解释、轻量、理论、基线——五个理由让它们长期有用。
7. **每个算法都有一个“变体族”**：本文为每个算法补齐了变体与公式。掌握了变体族，就掌握了“在什么条件下用哪一档精度 / 成本”的决策能力——这是从“会用一个算法”到“会用一族算法”的分界线。
8. **变体不是孤立的**：同一个数学结构在不同算法里反复出现——逻辑损失 ↔ 最大熵 ↔ Softmax；拉普拉斯特征向量 ↔ 谱聚类 ↔ 谱嵌入 ↔ GNN 传播； $(I - \alpha S)^{-1}$ ↔ 标签传播 ↔ 个性化 PageRank ↔ RWR；ELBO ↔ EM ↔ VAE；前向分步加法 ↔ AdaBoost ↔ GBDT ↔ XGBoost。看到这些桥，整本书就连成了一张网。

与仓库其他文档的关系： `feature-descriptors-notes.md`（手工描述子）→ **本文（浅层机器学习）** → `cnn-transformer-notes.md`（深度表示学习），三者构成“特征表示三代演进”的完整链条。